

TRACE-RPG: 인터랙티브게임세계의생성이벤트를위한 trace 연결기호커밋게이트

익명저자

Abstract—대규모언어모델은표현력있는퀘스트와 NPC 대화를생성할수있지만, 유창하거나스키마에맞는텍스트만으로제안이벤트의실행가능성, 권한적합성, 정식게임상태와의일관성이성립하지않는다. 본 논문은신뢰하지않는제안을상태변경으로부터격리하는기호커밋게이트 TRACE-RPG 을제안한다. 타입엄격 parser, 외부공급행동정책, 여섯개의결정론적상태대상대술어가모든허용전이를결정하며, 거부후보는제한수리로보낼수있고수락후보는변경직전에다시검증한다. 반례유도연산자 ρ 는직전후보와구조화 validation error 만읽고권위있는상태는결코읽지않는다. 키없는 SHA-256 콘텐츠연결, 상태의미 replay, 에피소드연속성검사, 할당완전 outcome 계수가해당무결성경계안에서 trace 를감사가가능하게만든다. 근거는세레인으로분리한다. 단일작성 world 의결정론적오프라인적합성과일릿, 단일모델라이브스크리닝확장, 런타임권한이없는 engineering-only closed-world KG/온톨로지링크제안시물레이션이다. 오프라인레인은인코딩된필드의 mechanism 적합성만확립한다. 라이브레인은 $K=1$ 에서의도적으로수리가가능하게만든 policy-blind regime 에한해 guided 5/5 대 blind 0/5 commit 을관찰했고다른 regime 은귀무였으므로 pilot-only 로남는다. 어느레인도모집단효능, 모델우월성, 플레이어경험, 감정, 런타임검색 · 메모리억, 상용엔진성능을확립하지않는다.

Index Terms—게임인공지능, 인터랙티브내러티브, 기호검증, 제약생성, 런타임강제, 재현성

I. 서론

인터랙티브생성은언어과제에그치지않는다. 후보이벤트가자연스러워도존재하지않는아이템을요구하거나, 화자가모르는사실을주장하거나, 금지된퀘스트정보를공개하거나, 허가되지않은효과를도입하거나, 퀘스트단계를후퇴시킬수있다. 실행가능한텍스트환경은그렇듯한발화와유효한전이의차이를명시한다 [1], [2]. 근거기반대화화개인화퀘스트시스템은퀘스트, 엔터티, 그래픽팩의가치를추가로보여주지만 [3], [4], 맥락자체가정식상태변경을승인하지않는다.

구조적생성제약은인접한문제를해결한다. 문법제약디코딩, 언어모델질의언어, 점진파서는생성구조를제한할수있다 [5], [6], [7]. 그러나구문상허용되는이벤트도현재세계에대해서는거짓일수있다. 검색과메모리는유용한근거를공급할수있지만 [8], [9], [10], 검색된내용역시상태전이의권한주체가아니다.

본 논문은이러한관심사를감사가가능한트랜잭션프로토콜로결합한구현인 TRACE-RPG 을제시한다. 현재기여는다음과같다.

- 1) **C1—계약**: state, policy, candidate, record, game bridge 에대한 버전형신뢰경계 *contract* 와, proposal/replay 경계에서 known field 의모호한타입및 candidate unknown key 를거부하는 type-strict parser;
- 2) **C2—controller**: 상태기준 predicate 6 개, bounded repair, unchanged fallback, defensive pre-commit revalidation 을갖춘 *validate-repair-commit controller*;
- 3) **C3—감사**: unkeyed SHA-256 content link, state-semantic replay, episode-continuity check 를묵은 감사 근거 *layer*;

익명심사를위해제출된원고입니다.

- 4) **C4—harness**: 동결 assignment key, 분류된 terminal failure, proposal trace 가존재할수없는 failure 까지보존하는 assignment-complete accounting 을갖춘 오프라인적합성 *harness*;
- 5) **C5—수리**: prior candidate 와 structured error 만읽는 *counterexample-guided operator* $\rho(a, E)$ 및 blind unchanged retry, state-reading oracle upper bound, 동결 repairability class 비교.

별도구조화 crosscheck 는 C1–C5 를선행주제, citation key, claim ID, 저장소근거, 실험레인, 추론상한에결합한다. 결정론적 parser, state-isolation, repair, fault-injection, manifest fixture 가이다섯구현기여의정확집계근거다. 근거지도는서로대체할수없는세레인으로구성된다. 첫째, 실증의중심은단일작성 world state 의결정론적적합성과일릿으로, 인코딩된 parser-validation-repair-replay-accounting 동작을측정하며모집단효능은측정하지않는다. 둘째, 셀당 5 회라이브스크리닝확장은하나의 hosted proposer 에서 repair transfer 를탐색하지만, 고정되지않은 revision, sampling 을제어하지못하는 seed label, 의도적으로구성한 state 때문에 pilot-only 가상한이다. 셋째, closed-world KG/온톨로지시물레이션은작성된 typed-link proposal 을평가할뿐런타임검색을구현하지않고어떤 C-RESULT-* claim 도지지하지않는다. 보존한 Godot 4.7.1 policy-mirror trace 와 render replay 는엔진로컬적합성근거만추가한다. 네 fixture 실행모두에서 headless frame sample 5 개중최대값은첫 sample 이었고범위는 98.760–116.667 ms 로 16.7 ms budget 을넘었다. 이 startup-sensitive trace 는안정적인 frame benchmark 가아니다. 참여자, 감정또는런타임검색실험, live Python-Godot 승인왕복, 대표성있는 end-to-end 게임플레이성능측정은없다.

II. 관련연구와연구공백

A. 인터랙티브내러티브와게임에이전트

KNUDGE 는퀘스트와엔터티명세에근거한분기형 NPC 대화를평가한다 [3]. 지식그래프보조퀘스트생성 [4], 메모리-성찰-계획에이전트 [11], 학습가능한역할연기 에이전트 [12] 는근거성과개연성있는행동의상호보완적측면을다룬다. 플레이어대상연구는 선호와지각된대화품질을평가한다 [13], [14]. Yin 등의 2026 년 온라인레코드는서지감사당시미래시점의권호배정되어있어제출시다시확인해야한다 [15]. 2025 년프리프린트는역할에따른안정성-즉흥성 trade-off 를보고하며 [16], 본 논문은이를최근동기로만사용한다. 이연구들은하드허용가능성을선택적자연스러움및플레이어경험구성개념과분리할필요성을뒷받침한다.

경험주도콘텐츠생성 [17] 과관찰자표식참여도 [18] 는미래적응트랙의동기가된다. 최근프리프린트는 vision-language model 의참여도추론한계를보고한다 [19]. 따라서감정은비권위적맥락으로유지되며현재구현근거에는포함되지않는다.

B. 환경과벤치마크

TextWorld 와 ScienceWorld 는 명시적인 인터랙티브 상태를 제공하며 [1], [2], MineDojo 는 개방형 지식 집약 embodied 과제를 추가한다 [20]. General Video Game AI 는 에이전트, 게임, 콘텐츠 트랙을 분리한다 [21]. AgentBench 는 이질적인 환경의 에이전트를 연구하고 [22], AgentBoard 는 과점 수준 진단을 추가하며 [23], SOTOPIA 는 사회적 상호 작용을 평가하고 [24], BALROG 는 장기 언어 및 시각 게임 추론을 평가한다 [25]. 자동화된 플레이 스타일에 에이전트는 상호 보완적인 시험 레이지만 인간 평가를 대체하지 않는다 [26]. 이 벤치마크는 미래 평가 설계에 정보를 주지만 트레이닝 승인 환경을 규정하지 않는다.

C. 제약, 신경-기호 검증, 검색

제약 디코더는 출력 구조를 개선한다 [5], [6], [7]. 반면 TRACE-RPG 은 구조를 독립적인 상태 대승인의 입력 조건으로 취급한다. 직접적인 게임 특화 비고 대승인 시스템은 서로 다른 경계를 보여준다. PANGeA 는 메모리, 검증, REST 서비스, Unity 통합을 결합하지만, 공개된 검증 절차는 LLM 이 설계자 규칙에 따라 콘텐츠를 판정하고 반복 수정하도록 한다 [27]. 현재 비아카이브 ICC3 2026 자료와 연계된 프리프린트 IVIE 는 기호 검증을 사용한 인터랙티브 픽션 세계를 점진적으로 생성한다 [28]. 같은 계보의 2026 년 시스템은 LLM 을 저장된 world-state transformation 선택으로 제한하고 플레이어 표현에 대한 탐색적 8 인 연구를 보고한다 [29]. 이 시스템은 구성 상 일관성을 유지하지만 트레이닝 데이터, 감사 연결 코드, 수리 연산자 근거는 제공하지 않는다. 어느 비고도 우월성을 뜻하지 않으며, 각 시스템의 유효성은 해당 시스템이 인코딩한 목표와 술어에 한정된다.

G-Retriever, HippoRAG, Mem0 는 관련 하위 그래프 검색과 장기 메모리를 다루고 [8], [9], [10], Generative Agents 와 Character-LLM 은 행동 메모리와 persona 를 다룬다 [11], [12]. TRACE-RPG 은 향후 이러한 맥락을 사용할 수 있지만 직접적인 커밋 권한은 부여하지 않는다. 검색과 시간적 메모리 효익은 여기에서 측정하지 않는다.

D. 감사 가능성과 재현성

과정 지표는 중간 실패를 보존할 동기를 제공하고 [23], 강건한 평가는 소수 확률적 실행의 과도한 해석을 경고한다 [30]. 재현성과 환경 보고 지침은 동결된 산출물과 명시적 측정 경계를 뒷받침한다 [31], [32]. 인간 및 LLM 평가는 구성 개념, 평가자, 편향 통제를 요구하며 [33], [34], [35], [36], 향후 비열등성과 참여자 분석에는 정당화된 margin 과 random-effects 구조가 필요하다 [37], [38].

제한된 novelty 는 개별 구성 요소의 발명이 아니라 구현된 결합이다. 행동 개입 (interposition) 자체는 오래된 기법이다. 내러티브 mediation 은 사용자나 에이전트의 행동을 실행 전 예가로 채차단하거나 계획을 수정해 수용하고 [39], 고전 계획법은 precondition 과 effect 로 작용 가능성을 정의하며 [40], 런타임 강제는 신뢰하지 않는 행위자를 monitor 로 감싸 허용된 전이만 통과시키고 [41], 작성형 논리 기반 인터랙티브 드라마는 본 저널의 전신에서 캐릭터가 할 수 있는 발화를 규율했으며 [42], 신념 인지 내러티브 계획법은 캐릭터가 가는 바를 추론한다 [43]. 이는 본 논문의 knowledge/disclosure 술어가 훨씬 더 철저하게 인코딩하는 관심사다. TRACE-RPG 은 interposition 을 발명했다고 주장하지 않는다. C1-C2 는 strict contract 와 validate-repair-commit controller 를 이 계보 위에 배치하고, C3-C4 는 checksum-linked terminal record, state-semantic replay, episode continuity, proposal trace 가 존재할 수 없는 사례까지 포함한 assignment-complete accounting 을 결합하며, C5 는 실행 전 typed validator error 만 소비하는 수리 연산자를 분리한다. 보고서 예 기능이 없다고 해서 모든 구현에 그 기능이 없다고 추론하지 않는다.

III. 문제 정의와 보장 경계

설명을 위해 시점 t 에서 validation 이 사용하는 controller 입력을 다음과 같이 분해한다.

$$c_t = (G_t, q_t), \quad (1)$$

여기서 G_t 는 typed snapshot field 를, q_t 는 해당 snapshot 과 함께 저장되는 외부 작성 action-policy, disclosure, quest-stage 제약 을 나타낸다. 종단 record history $h_{<t}$ 는 WorldState snapshot 과 별도로 유지된다. Validation predicate 는 이를 읽지 않으며 구현은 log 에서 상태를 재구성하지 않는다. 검색, 내러티브 점수, 모델 rationale, 메모리 요약, 미래의 감추 추정 은 비권위적 proposal context 이다.

신뢰하지 않는 proposer 가 후보 a_t 를 출력한다. 타입 엄격 parsing 은 알 수 없는 top-level field 의 거부를 포함한 공유 candidate-key contract 를 먼저 강제하고 선언 스키마를 확립한다. validator 는 다음을 반환한다.

$$V(c_t, a_t) = (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, v_{\text{disc}}, v_{\text{quest}}, E_t), \quad (2)$$

여기서 E_t 는 구조화 오류 집합이다. 상태 변경은 다음과 같다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_i v_i = 1, \\ c_t, & \text{그외.} \end{cases} \quad (3)$$

Controller 는 인코딩된 계약 아래 다음 구현 불변량을 주장한다. 파일럿은 이를 일반 정리로 제시하지 않고 deterministic valid, invalid, repair, fallback, replay, fault-injection fixture 로 해당 mechanism 을 시험한다. **I1 (소진 실패 불변성):** 예산 K 까지 반환된 어떤 후보도 검증을 통과하지 못하거나 proposal/controller 실행이 commit 전에 실패하면 반환 상태는 공급된 prior state 와 같다. **I2 (제한된 기록 시도):** 모든 proposal 과 repair callback 이 반환한다는 조건에서 repair budget $K \geq 0$ 은 최대 $K + 1$ 개의 candidate attempt 를 기록한다. 성공적인 commit 은 변경 전 전 수락 후보에 대한 방어적 validation 을 한번 추가한다. Runtime 은 callback deadline 을 강제하지 않으므로 I2 는 wall-clock 종로 보장이 아니다. **I3 (효과 권한):** 수락 후보는 ActionPolicy.allowed_effects 밖의 선언된 fact effect 를 CandidateAction.effects 에 포함하지 않으며, quest-stage target 도 해당 policy 예의 해명 시적으로 승인된다. **I4 (상태의 미적 리플레이):** 동결된 스키마와 결정론적 전이 아래 수락된 trace 는 명시된 terminal state 를 재구성한다.

이 주장된 불변량은 올바른 정책 작성, 선언된 후보 필드로의 완전하고 충실한 추출, 결정론적 소프트웨어 버전, callback 반환, 단일 프로세스 파일 소유권을 가정한다. 상태의 미적 리플레이는 기록된 구조화 후보와 전이를 재검증하지만, 중간 수리의 provenance, reasoning, prompt, 확률적 생성은 재현하거나 검증하지 않는다. 구조화 필드에서 누락된 자연어 함의는 보장 범위 밖이다.

IV. TRACE-RPG 아키텍처와 알고리즘

A. 신뢰 경계와 계약

그림 1 는 모델 또는 recorded adapter 를 canonical owner 밖에 둔다. Parser 는 알려진 필드의 모호한 숫자 또는 collection type 을 거부하고 공유 key contract 에 따라 알 수 없는 top-level candidate field 도 거부한다. action policy 는 candidate 와 별도로 공급되며 required precondition 과 allowed effect 를 정의한다. Game bridge 는 observation, proposal, validation, rejection, fallback, commit 을 전달할 수 있는 versioned event interface 이며, 정식 상태 변경은 유효한 commit 만 승인한다. 이는 interface 를 분리하지 만 상용 엔진으로의 portability 를 아직 입증하지 않는다. 표 1 은 인코딩된 거부 경계를 요약하며 미적 완결성 주장이다.




Fig. 1. 신뢰경계. 검색맥락과 생성후보는 알려진 필드의 타입 검사와 상태상대 validation 이 완료될 때까지 비권위적이다.

TABLE I
인코딩된 Validator 경계

술어	거부대상	실패시상태
Action policy	알수없는 action/type	변경없음
Precondition	누락/거짓 requirement	변경없음
Reachability	접근불가 object	변경없음
NPC knowledge	선언되지않은 known fact	변경없음
Disclosure	forbidden fact	변경없음
Quest	부적격/후퇴 stage	변경없음

B. Validate-Repair-Commit

그림 2은 제어기의 추가패키지없는 의사코드를 제시한다. “Record”는 in-memory trace 표현에 추가하는 것을 뜻하며, 영속쓰기는 종단일관성 검사 뒤에만 수행한다.

검증 오류는 구조화된 error code 로 repair callback 에 노출된다. repair 는 상태를 직접 변경하지 않으며, 예산 소진 시 변경없는 결정론적 fallback 을 반환한다. 그림 3은 종단 경로를 나타낸다. 파일럿은 구현된 두 callback 을 비교한다. 반례 유도 연산자는 직전 후보 a 와 validator 의 구조화 오류 집합 E 만을 소비하며 권위있는 상태는 결코 읽지 않는다.

$$\rho(a, E) = a \oplus \bigcup_{e \in E} \delta(e), \quad (4)$$

여기서 각 $\delta(e)$ 는 표 II 의 오류 class 별 결정론적 edit 이고 $\oplus$ 는 그 field edit 들을 적용한다. 각 edit 은 오류 entity 당 최대 하나의 candidate field 만 수정하므로 시도당 변경 field 수는 $|E|$ 로 유계이고, 같은 오류 집합으로 ρ 를 두 번 적용하면 고정점이며, 같은 field 에서 동시에 요구되고 거부되는 entity 는 수리불가로 선언되어 수정되지 않는다. 상태를 읽는 참조 callback 은 반대로 오류 집합을 폐기하고 정책이 규율하는 field(precondition, effect, 두 quest-stage field) 를 권위있는 상태에서 직접 재구성한다. 이 callback 은 선언 무결성 field(required object, used fact, disclosed fact) 를 의도적으로 수정하지 않는다. 의존성이나 disclosure 의 선언을 지우는 것은 후보를 수리하는 것이 아니라 위반을 게이트 뒤로 세팅하는 것이기 때문이다. 이는 상태 판독 가능 수리에 대한 oracle 상한이며, 그 결과를 배포 가능한 수리 방법의 근거로 읽어서는 안 된다.

C. 무결성, 의미적 리플레이, 계수

각 result row 는 키없는 SHA-256 무결성 체크섬을 가지며, proposal outcome 은 추가로 trace checksum 과 연결된다. 이 hash

```

1:  $a \leftarrow \text{Propose}(c); j \leftarrow 0$ 
2: repeat
3:    $(ok, E) \leftarrow V(c, a); \text{Record}(a, E)$ 
4:   if  $ok$  then
5:     assert  $V(c, a).ok$ ; return  $\text{Commit}(c, a)$ 
6:   if  $j = K$  then return  $\text{Fallback}(c)$ 
7:    $a \leftarrow \text{Repair}(c, a, E); j \leftarrow j + 1$ 
8: until terminal

```

Fig. 2. Validate-repair-commit 절차. 최대 $K + 1$ 개의 candidate attempt 를 기록하며, 성공경로는 상태 변경 전 방어적 validation 을 수행한다.

TABLE II
유도 연산자 ρ 의 오류 class 별 edit

Validator 오류 class	후보에 대한 edit $\delta(e)$
정책 precondition 누락	명명된 predicate 삽입
정책 effect 누락	명명된 effect 삽입
정책 effect 위반	명명된 effect 제거
불충족 precondition	명명된 predicate 제거
비인가 stage 변이	quest_stage_effect 초기화
알수없는 action type	no-op (등록된 대안 없음)
도달 불가 object; knowledge, disclosure, stage class	no-op (후보 속 edit 은 선택이거나 상태 지시 필요)

들은 우발적이거나 시험 대상 인 콘텐츠 변경을 탐지하지만 signature, message-authentication code, writer identity 가 아니며 콘텐츠와 checksum 을 모두 다 시 쓸 수 있는 행위자에 대한 보호도 아니다. 의미적 리플레이는 prior state 와 기록된 모든 candidate/validation pair 를 엄격히 parsing 하고, final 이 아닌 모든 attempt 가 invalid 임을 요구하며, terminal transition 을 재계산하고, 명시된 final state 와 비교함으로써 byte 무결성을 넘어선다. Episode replay 는 인접 JSONL record 사이의 상태 연속성도 요구한다. Replay 는 candidate $j + 1$ 을 만든 repair-generation 단계를 인증하거나 다 시 실행하지 않는다.

Terminal record class 는 commit, symbolic fallback, adapter failure, controller failure 이다. Controller-failure row 는 동결된 assignment denominator 에 남고 상태를 변경하지 않지만, candidate outcome 이 생성되지 않았다면 완성된 proposal trace 가 없어도 된다. 따라서 result completeness 가 모든 terminal row 의 trace 존재를 뜻하지 않는다. 실행 전 assignment key 는 (run, arm, scenario, seed, model, revision, $h_{\text{controller}}$, h_{input} , h_{prior}) 이다. 집계는 중복, 누락, 예기치 않은 key 를 거부하고 symbolic, adapter, controller failure 를 각각 보고한다.

V. 실험 레인과 근거 경계

A. EI 오프라인 적합성 설계

파일럿은 다음을 묻는다. (PQ1) 유효 후보는 commit 되고 명명된 invalid-policy 사례는 변경 없이 유지되는가? (PQ2) 동결된 모든 repairability class 의 작성 사례에서 rejection-only, 블라인드 동일 후보 retry, 반례 유도 연산자 ρ , 상태를 읽는 참조 callback 이 예상 결과를 만드는가? (PQ3) 동결된 checksum, state-semantic, linkage, continuity mutation 이 지정된 검사 연산에서 거부되고, 두 번째 파일 append 의 주입된 실패가 예상 pair-write rollback 검사를 작동시키는가? (PQ4) 엄격한 adapter 와 assignment manifest 가 할당 사례마다 정확히 하나의 분류된 terminal row 를 유지하거나 fail closed 하는가? (PQ5) proposal 및 replay parser 가 그 외에 는 완전하고 유효한 candidate 에 unknown top-level key 하나를 추가한 사례를 모두 거부하는가?




Fig. 3. Proposal, validation, 제한된 repair, fallback, commit, replay 상태. Controller failure 는 중단상태이며 완성된 proposal trace 가 없을 수 있다.

사례는 의도적으로 설계된 적합성 픽처이며 모델 또는 게임 모집단의 표본이 아니다. 네도메인은 validator/state isolation, repair-arm 비교, record/trace fault injection, adapter/accounting contract 이다. 모든 repair fixture 는 실행 전에 동결된 repairability class 를 선언한다. *guided-repairable*(구조화 오류 payload 만으로 ρ 에 충분한 정보가 담김), *oracle-only*(수리에 권위 있는 상태판독이 추가로 필요함), *irreparable*(구현된 어떤 arm 도 commit 할 수 없음) 이며, class 별 arm 당 기대 결과는 설계 픽처 계약의 일부다. 반복된 결정론적 seed 가 아니라 고유 사례가 기술적 denominator 를 구성한다. 모든 기대 값은 실행 전에 명시한다.

B. E1 측정치와 동결 산출물

측정치는 정확한 count 이다. expected/observed validator-class agreement, rejected 또는 controller-failure 사례의 state mutation, repair arm 과 repairability 별 commit 및 attempt 결과, 지정된 연산에서 거부된/사전 명세된 detectable fault, replayed/committed trace, rejected/injected manifest violation, 사전 명세한 unknown-key 음성 회귀에 대한 proposal/replay 거부 일치를 센다. 마지막 측정치는 결정론적 parser-contract parity 이며 실증적 safety outcome 이 아니다. Exception class 만으로 안정적인 detector layer 를 식별할 수 없으므로 detector 귀속 결과는 보고하지 않는다. 의도적으로 설계된 픽처에 p -value 나 모집단 confidence interval 을 부여하지 않는다. Adapter 사례가 지연 latency 및 token 상수는 입력 스키마가 JSON-Schema const 로 고정된 합성값이다. 이 값들은 계수 필드 전파만 확인하며 provider, runtime, device 에 대한 측정값이 아니다.

릴리스 패킷은 fixture 및 assignment manifest, schema, outcome/trace record 를 포함한 result JSON 산출물, 환경과 코드 revision, 생성 table, checksum 을 동결한다. 보고는 재현성과 측정 경계 지침을 따른다 [31], [32].

C. E2 라이브 RQ2 스크리닝

라이브 확장은 블라인드 동일 후보 retry 와 ρ 를 동일한 $K=1$ 에서 비교한다. 각 셀에서 seed 로 구분한 Codex CLI 호출 5 회가 gpt-5.6-sol 후보 하나씩을 만들고, 두 arm 은 같은 최초 후보를 받아 호출 내제안 차이를 제거한다. 조건은 policy 공개 여부와 자명 한 효과 0 경로의 존재를 바꾼다. 승격 패킷은 정정된 현재 셀과 폐기된 v1 진단을 함께 보존하고 모든 JSON/JSONL 영수증을 SHA-256 으

로 결합하며 근거를 screening-pilot-only 로 표시한다. Seed label 은 hosted sampler 를 제어하지 않고, hosted revision 은 고정되지 않았으며, token 회계는 없고, 구성 상태는 모집단 표본이 아니다. 따라서 p -value, confidence interval, 모델 순위 없이 정확한 기술 count 와 실패 class 만 보고한다.

D. E3 KG/온톨로지 링크 제약 시뮬레이션

SL-KG-ONTOLOGY-SIM-001 은 Graphify 문서 탐색 그래프 및 권한을 가진 typed WorldState 와 분리된 engineering-only closed-world 레인이다. 저장소로 OKF node 43 개와 reference edge 106 개를 내보내고, 검토된 typed edge 24 개를 overlay 하며, type/domain/range 무결성과 source 별 competency question 6 개를 검사하고, 권한이 없는 SQLite mirror 를 생성한다. 고정 전략 7 개는 작성형질의 6 개와 질의 당 후보 5 개를 평가했다. Retained S2-typed-lexical-loose 는 holdout 6/6 을 복원했고 ($P = R = F_1 = 1.000$, realistic MRR = 0.944, Brier = 0.131, Sem@3 = 1.000), degree baseline 은 하나도 복원하지 못했다. Machine-generated JSON, TSV, TeX, SVG 산출물 이전 체수식과 trial 을 보존한다. 이는 구성 결과이며 OWL/SHACL 적합성, 의미 완전성, runtime retrieval, 장기 모순 감소, 어떤 C-RESULT-* claim 의 근거도 아니다.

VI. 파일럿 결과

A. 구조 필드 게이트 적합성

파일럿 loader 는 구현된 validator code 를 정확히 한 번씩 고립시키는 fixture 집합과 유효 control 1 개만을 허용한다. 따라서 13/13 일치와 구현된 오류 코드 12 종의 관찰은 측정된 성공률이 아니라 하니스의 구성 불변량이다. 이 실행이 보여주는 것은 loader 가 강제하지 않는 부분, 즉 고립된 음성 fixture 12 개가 각각 다른 코드 가 아니라 작성된 기대 코드와 일치했고 비 commit 경로가 전체 정준 상태를 유지했다는 관찰이다. 이는 단일 world state 에서 저자가 설계한 구조 필드 oracle 에 대한 구현 적합성이며 독립의 미판정의 정확도가 아니다.

B. 설계 픽처에서의 수리 arm 비교

처음부터 유효하지 않은 설계 case 12 개는 guided-repairable 5 개, oracle-only 1 개, irreparable 6 개의 동결된 repairability class 로 분할된다. Rejection-only 와 블라인드 동일 후보 retry 는 각각 0/12 commit 이었다. 반례도 연산자 ρ 는 guided-repairable case 5/5 를 commit 했고, 설계상 oracle-only 0/1, irreparable 0/6 였다. 모든 ρ commit 은 candidate field 를 평균 1.0 개 수정했으며, 실패한 모든 arm 실행은 정준 상태를 변경 없이 유지했다. 상태를 읽는 참조 callback 은 guided-repairable 5/5 와 oracle-only 1/1 를 commit 했고 irreparable 은 0/6 였다. 이 정확한 count 는 세메커니즘을 설계 픽처 위에서 분리한다. 블라인드 retry 는 반례를 commit 으로 전환하지 못하고, ρ 는 오류 payload 에 충분한 정보가 담긴 case 만 전환하며, oracle 은 상태 지식 이 필요한 case 를 추가로 전환한다. 이는 동결 픽처에 대한 연산자 적합성이며, 어떤 live model 의 수리 품질도 아니다.

C. 무결성, 경계, 배정 회계

현재 명세가 검증 가능하다고 지정한 10 개 fault fixture 는 모두 지정된 검사 연산에서 거부됐다 (10/10). 이 파일럿은 안정적인 typed detector code 까지 대조하지 않으므로 detector layer 귀속을 입증하지 않는다. 별도로, 동일하게 기록된 유효 수리 앞의 무효 선행 후보를 다른 무효 후보로 치환하고 체크섬을 재계산한 알려진 provenance

OBSERVATION EVENT evt-000-observe	FALLBACK · NO MUTATION EVENT evt-002-fallback-secret	COMMIT · REPLAY-BOUND EVENT evt-005-commit-hint
(a) 도착관찰	(b) 상태불변거부	(c) 승인 commit

패널	캡처	이벤트	검증	상태관계
(a)	sl-rc-001-arrival	evt-000-observe	not applicable	snapshot = before
(b)	sl-rc-002-rejected-secret	evt-002-fallback-secret	invalid	world = before
(c)	sl-rc-003-authorized-hint	evt-005-commit-hint	valid	world $\neq$ before

Full-resolution artifact pointer: godot-4.7.1-20260813t115916z-sealed-lighthouse-render-v5/rendered-canonical-v1/; 파일명은 위 capture ID 에 .png 를붙인것이다.

Fig. 4. 작성형 Godot render replay 에서 status/event 를확대한 illustrative crop 과 manifest metadata. 이 trace-bound 대응은 live transport, 성능, usability, immersion, efficacy 근거가아니다.

TABLE III
수리 arm 별 reparability class 정확집계 (설계픽스처)

Arm	정보원	Commit / 사례			평균수정 ^e
		G-rep. ^f	O-only ^f	Irrep. ^f	필드수
Rejection-only (K=0)	없음	0/5	0/1	0/6	—
블라인드 retry	없음	0/5	0/1	0/6	—
반례유도 ρ	오류집합 E	5/5	0/1	0/6	1.0
상태판독 oracle	권위상태 + 정책	5/5	1/1	0/6	1.0

^eCommit된수리의변경 candidate field 평균개수 (최소성 proxy); 실패한 arm 실행은상태를변경하지않았다. ^fCommit/사례수. G-rep. = guided-repairable, O-only = oracle-only, Irrep. = irreparable(동결 reparability class).

TABLE IV
동결파일럿검사와중단결과 (행간직접비교불가)

검사또는중단군	정확결과	해석범위
게이트 fixture 일치	13/13	저자 oracle 일치
알려진경계허용	2/2	인코딩한계, safety pass 아님
닫힌 unknown-key 거부	1/1	proposal/replay parser parity
탐지가능무결성결함거부	10/10	지정된검사연산
알려진 provenance 경계허용	1/1	repair 생성출처미인증
Adapter 종단 class	1 commit; 1 fallback; 5 실패 / 배정 7	배정 7 건의분류완전성
Manifest guard 거부	3/3	주입결함 fail-closed

행마다분포와성공방향이다르므로비율처럼순위를비교하지않는다. 모든값은설계픽스처의정확한검사사실이다.

경계는예상대로재생을통과했다 (1/1 미검출). 따라서키없는체크섬을재계산할수있는작성자를방어하지않으며, 재생은 repair 생성연산의출처를인증하지않는다. 열린경계 sentinel 두건—자연어 disclosure 미추출과 required object 의후보 · 정책동시누락—은 2/2 가의도대로인코딩상허용됐고 safety pass 는 0 건이었다. 과거 unknown top-level field 허용경계는 Stage 8 이후닫힌무성회귀로재분류되었으며, 완전한 12-field candidate 에 unknown key 하나를추가한 fixture 를 proposal-replay parser 모두구체적으로거부했다 (1/1). 이는 parser rejection parity 이지의미안전성의증거가아니다. Adapter/accounting 7 개배정에서는 commit 1, 기호 fallback 1, adapter failure 5 있다. 합성 telemetry 필드는 2/7 배정에서채워져전파됐으며, 이는측정값이아니라회계필드전파확인이다. 배정 guard 3/3 가중복 · 누락을거부했다. 이수치는모두합성 offline fixture 의 raw count 다.

표 III와 IV은정확한설계픽스처 count 를보고한다. 수리표는

TABLE V
라이브스크리닝파일럿정확집계 (셀당제한 5 회, K=1)

기저 / 조건	최초유효 ρ	vs blind commit	Δ	최초오류
동결 / 공개	5/5	5/5 vs 5/5	+0	—
동결 / 비공개	5/5	5/5 vs 5/5	+0	—
동결 / 목표-비공개	0/5	0/5 vs 0/5	+0	QSR
Signal-v2 / 공개	5/5	5/5 vs 5/5	+0	—
Signal-v2 / 비공개	0/5	5/5 vs 0/5	+5	PEO+PEV+PPO

QSR = quest-stage regression, PEO = policy-effect omission, PEV = policy-effect violation, PPO = policy-precondition omission. Δ 는동일후보에서 ρ commit 수 minus blind commit 수다. 모든수치는 screening-pilot-only 이며추론통계가아니다. 폐기된 v1 진단은표에서제외한다.

동결된 reparability class 별로네 arm 을분리하며, 어느표도모집단또는 live-model 추정을지지하지않는다.

D. 라이브스크리닝파일럿 (pilot-only)

별도스크리닝파일럿은 Codex CLI 를통해 gpt-5.6-sol 을호출했다. 셀마다 seed 로구분한제한호출 5 회와수리예산 $K = 1$ 을사용했고, 각호출의최초후보하나를블라인드동일후보 retry 와 ρ 가공유했다. Hosted revision 은고정되지않았고 token 회계는제공되지않았으며 seed 는 hosted sampler 를제어하지않으므로이호출들은독립무작위표본이아니라준반복이다. 따라서추론통계나모델순위를보고하지않는다.

표 V에서유도우위는의도적으로 guided-repairable 오류가나오도록구성한 signal-repair-v2 의 policy-blind 셀에서만 나타났다. 최초후보 5/5 가모두무효였고 ρ 는 5/5, 블라인드는 0/5 를 commit 했다. 나머지현재셀 4 개는유도우위를보이지않았다. 세셀은최초후보가이미유효했고, 동결기저의 goal-directed 셀은수리불가 quest-stage regression 이었다. 현재셀의 모든 noncommit arm 결과 15/15 가 prior-state hash 를보존했다. 이결과해당 오류 regime 에서의 mechanism transfer 만지 지하며모집단효능, 모델승격, 표본효율일반화는지지하지않는다. 따라서 C-PILOT-007 과 C-PILOT-008 은 pilot-only 이고 C-RESULT-003 은 TODO-RESULT 로남는다. 폐기된 v1 진단에서는동반오류가최대 3 개에서수리불가 knowledge 오류 1 개로 줄었지만 commit 되지않아, 오류하나라도수리불가이면부분수리가합성되지않음을보여주었다.

그림 5는오프라인보고경계를명시한다. 동결 fixture 와지정검사연산이허용한 row 만오프라인생성표에들어간다. 라이브표는 SHA-256 으로결합한 screening promotion manifest 를통과하는별도경로를사용하며, 그 row 는동결오프라인 denominator 에 들어가지않는다.




Fig. 5. 동결된 fixture 에서 지정된 검사연산과 생성 table 로 이어지는 근거경계. 수치는 생성 산출물을 통해서만 반영한다.

ENG1. Godot 4.7.1 은 보존한 *Sealed Lighthouse* 정식 trace 를 non-headless 1280×720 SubViewport 에서 리플레이했다. Manifest 는 각 PNG 를 event/delivery index, validation, state hash 에 결합한다. 그림 4(b) 는 변경전 hash 를 보존하고, (c) 는 valid commit 뒤이를 변경한다. 모든 원본 panel 은 생성자산이 없는 primary-track render 이며, 아래 illustrative crop 은 작성된 status/event callout 만 확대한다.

선택 v5 packet 은 하나의 scripted fixture 의 render/state 대응 만 확립하며 live model 또는 Python transport, participant 또는 player input, adaptation intervention, narrative-quality result 를 추가하지 않는다.

VII. 논의

A. 확립 가능한 범위

설계 파일럿은 동결된 사례에 대해서만 mechanism behavior 를 확립할 수 있다. 인코딩된 검사 가 상태를 격리하는지, bounded repair 와 fallback 이 선언 경로를 따르는지, 명명된 corruption 이 지정된 검사 연산에서 거부되는지, assigned row 가 집계 를 위해 분류된 상태로 남는지를 평가한다. 거부를 안정적 인 typed detector code 에 귀속하지 않는다. 이는 authoring-time validation, continuous-integration regression, recorded-adapter test, engine 이전 replay inspection 에 유용하다.

오프라인 수리 비교의 정직한 해석은 guided-대-oracle 경계다. 상태를 읽는 callback 이상한으로 남는 이유는 권위 있는 상태를 참조 할 수 있어서 ρ 가 구성상 전환할 수 없는 oracle-only 사례를 전환 하기 때문이다. 반례 유도 연산자는 validator 의 구조화 반례만 소비 하 면서 guided-repairable class 에서 oracle 과 정확히 일치한다. 이 어라이브 스크리닝 확장은 이 mechanism 이 hosted proposal 로 전 이되는지를 탐색했다. 구성 상태가 모든 제안을 guided-repairable class 로 유도 했을 때만 ρ 와 blind retry 가 분리됐고, 최초 유효 및 guided-irreparable regime 은 귀무였다. 이 regime 의 존성, 고정 되지 않은 hosted revision, 준 반복 호출 때문에 일반 표본 효율 이나 모델 능력을 주장할 수 없다. Feedback 을 소비 하는 수리 루프에는 선 례가 있다. Self-Refine 은 같은 신뢰하지 않는 모델이 생성한 언어 를 feedback 으로 되먹이고 [44], Self-Debugging 은 신뢰되는 전체 프로그램 runtime 의 실행 결과를 소비한다 [45]. ρ 는 channel 과 권위에서 다르다. Feedback 은 실행 전에 결정론적 validator 가 계 산한 typed 오류 집합이고, 실패한 모든 live arm 은 상태를 격리 한 다.

B. 선행 연구와의 관계

TRACE-RPG 은 parsing 후 state-relative authorization 을 적용 하여 constrained decoder 를 보완한다 [5], [6], [7]. 검색 및 메모리 구성 요소에는 commit authority 를 부여하지 않는다는 점에서 구별된다 [8], [9], [10]. 실행 가능한 환경과 benchmark 를 대체 하지 않고 보완한다 [1], [2], [22], [25]. Process-linked trace 는 AgentBoard 가 강조한 측정 관심사를 구현하지만 [23], TRACE-RPG 이해당시 시스템이나 다른 시스템보다 우월하다는 근거는 아니 다.

확증 효능을 검증할 연구, 즉 독립적으로 label 된 semantic oracle 과 실제 blind-retry comparator 를 갖춘 사전 등 록 다중 모델 비교, 인 코딩된 validity 를 갖춘 retrieval 및 memory ablation, 정당화 된 검정력과 mixed-effects 분석을 갖춘 blinded matched-validity 인간 연구는 여전히 본 논문의 범위 밖이다. 스크리닝 파일럿은 어느 연 구도 대체하지 않는다 [22], [33], [30], [38].

VIII. 타당성 위험, 윤리, 산출물 범위

근거에는 명시적 경계 9 개가 있다. **L1:** encoded predicate 는 structured field 에서 빠진 의미를 발견하지 못한다. **L2:** authored world 하나와 constructed live-state variant 하나로 cross-world, cross-policy, 규모 일반화를 말할 수 없다. **L3:** state-reading callback 은 oracle 이며 offline class 와 regime-dependent screening 은 일반 repair 품질이나 sample efficiency 를 확립 하지 않는다. **L4:** hosted proposer 하나는 revision 고정, token 회계, sampling 을 제어하는 seed 가 없고 live Python-Godot authorization round trip 도 없다. **L5:** participant 와 affect data 가 없다. **L6:** unkeyed hash 는 integrity 만 제공 하며 writer authentication 이나 adversarial tamper resistance 는 제공 하지 않는다. **L7:** record consistency 는 single writer 를 가정 하며 concurrent-writer safety 는 미검증이다. **L8:** engine evidence 는 startup-dominated sample 이 16.7 ms 를 넘는 Godot fixture 하 나이며 portability 나 real-time 결과가 아니다. **L9:** 선택된 fixture 와 screening cell 은 population, safety-rate, model-ranking 추 론을 지지하지 않는다. Internal validity 는 독립 policy expectation 및 fixture leakage 부재에, reproducibility 는 고정 software 와 artifact 에 의존한다.

파일럿은 participant 또는 personal telemetry 를 처리하지 않는다. 향후 human 및 affect 연구에는 해당 review, informed consent, compensation disclosure, minimization, retention/deletion rule, opt-out 이 필요하다. LLM judge 를 사용하더라도 automated 및 crowd judgement 모두 calibration 과 bias control 이 필요하므로 보조 수단으로 유지한다 [33], [34], [35], [36].

IX. 결론

TRACE-RPG 은 작성된 candidate-event payload 를 encoded 기호 commit gate 를 통해 canonical mutation 으로부터 격리 하고, linked record 와 state-semantic replay 로 terminal outcome 을 감사가 가능하게 만든다. 결정론적 오프라인 파일럿은 동결된 작성 fixture 에서 mechanism 적합성을 확립한다. 별도 라이 브 스크리닝 파일럿은 구성한 수리 가능 regime 에서만 guided 5/5 대 blind 0/5 분리를 관찰하고 다른 regime 에서는 귀무였 으므로 pilot-only 로 남는다. Cross-model superiority, player-experience benefit, retrieval 또는 memory effectiveness, affect efficacy, commercial-engine performance 는 명시적인 확증 확장 으로 남는다.

AI 사용고지

Large language model 은 prose, code 와 test drafting, command orchestration, evidence review, 결과해석, simulated peer review, citation-identity check 를보조했고, hosted model 은별도표기된 live-screening candidate 도생성했다. 모든보고 count 는 deterministic runner 또는 hash-bound receipt 에서오며 offline, live-screening, engine evidence 는분리된다. 저자는 claim 을 source artifact 에대조했고내용에대한책임을진다.

데이터및코드가용성

Repository 에 는 implementation, build source, 분 리 된 offline/live-screening packet 과 contribution-evidence-matrix.csv, reference-topic-crosswalk.csv, experiment-evidence-matrix.csv 가 있다. Offline manifest 는 artifact 38 개, input 22 개, provenance row 121 개 (executed 85 개, aggregate 36 개) 를, live promotion manifest 는 JSON/JSONL receipt 14 개와 superseded v1 diagnostic 을결합한다. Portable offline invocation 에는 absolute clone path 가없고 clean-Git input binding 은 tag trace-rpg-guided-repair-inputs-20260821-v1 에서다시성립한다. Anonymized reviewer archive 나 DOI deposit 은 주장하지않는다.

References

- [1] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, “TextWorld: A learning environment for text-based games,” in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.
- [2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, “ScienceWorld: Is your agent smarter than a 5th grader?” in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.
- [3] N. Weir, R. Thomas, R. d’Amore, K. Hill, B. Van Durme, and H. Jhamtani, “Ontologically faithful generation of non-player character dialogues,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.
- [4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, “Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach,” in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.
- [5] S. Geng, M. Josifoski, M. Peyrard, and R. West, “Grammar-constrained decoding for structured NLP tasks without finetuning,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10932–10952.
- [6] L. Beurer-Kellner, M. Fischer, and M. Vechev, “Prompting is programming: A query language for large language models,” *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.
- [7] T. Scholak, N. Schucher, and D. Bahdanau, “PICARD: Parsing incrementally for constrained auto-regressive decoding from language models,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.
- [8] X. He, Y. Tian, Y. Sun *et al.*, “G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907.
- [9] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, “HippoRAG: Neurobiologically inspired long-term memory for large language models,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569.
- [10] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, “Mem0: Building production-ready AI agents with scalable long-term memory,” in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, peer-reviewed ECAI 2025 record; page range was not exposed by the accessible Crossref or publisher metadata at audit time.
- [11] J. S. Park, J. C. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, “Generative agents: Interactive simulacra of human behavior,” in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.
- [12] Y. Shao, L. Li, J. Dai, and X. Qiu, “Character-LLM: A trainable agent for role-playing,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187.
- [13] N. Akoury, Q. Yang, and M. Iyyer, “A framework for exploring player perceptions of LLM-generated dialogue in commercial video games,” in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.
- [14] M. Hochreiter, S. Kriglstein, and G. Wallner, “Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues,” in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.
- [15] M. Yin, H. Zu, W. Gu *et al.*, “How contextualized generative AI shapes player experience in games,” *Entertainment Computing*, vol. 58, p. 101194, 2026, online record with a future issue assignment at the 2026-08-12 audit; issue metadata must be rechecked at submission.
- [16] V. Figueiredo and D. Elumeze, “Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogues,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [17] G. N. Yannakakis and J. Togelius, “Experience-driven procedural content generation,” *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.
- [18] D. Melhart, D. Gravina, and G. N. Yannakakis, “Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch,” in *International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.
- [19] Z. Wang, Q. Guo, R. Singh, and X. Hu, “Do vision language models understand human engagement in games?” 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [20] L. Fan, G. Wang, Y. Jiang *et al.*, “MineDojo: Building open-ended embodied agents with internet-scale knowledge,” in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362.
- [21] D. Pérez-Liébana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, “General video game AI: A multitask framework for evaluating agents, games, and content generation algorithms,” *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.
- [22] X. Liu, H. Yu, H. Zhang *et al.*, “AgentBench: Evaluating LLMs as agents,” in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046, peer-reviewed official proceedings record; no publisher DOI assigned.
- [23] C. Ma, J. Zhang, Z. Zhu *et al.*, “AgentBoard: An analytical evaluation board of multi-turn LLM agents,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362.
- [24] X. Zhou, H. Zhu, L. Mathur *et al.*, “SOTOPIA: Interactive evaluation for social intelligence in language agents,” in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019, peer-reviewed official proceedings record; no publisher DOI assigned.
- [25] D. Paglieri, B. Cupial, S. Coward *et al.*, “BALROG: Benchmarking agentic LLM and VLM reasoning on games,” in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702, peer-reviewed official proceedings record; no publisher DOI assigned.
- [26] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, “Automated play-testing through RL-based human-like play-styles generation,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.
- [27] S. Buongiorno, L. Klinkert, Z. Zhuang, T. Chawla, and C. Clark, “PANGeA: Procedural artificial narrative using generative AI for turn-based, role-playing video games,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 20, no. 1, pp. 156–166, 2024.
- [28] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, “TVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds,” 2026, preprint; accepted/forthcoming at ICCV 2026, whose available pre-proceedings were explicitly non-archival and unpublished at retrieval time.
- [29] S. Góngora, L. Chiruzzo, G. Méndez, and P. Gervás, “World-state transformations for neuro-symbolic interactive storytelling,” 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-21.
- [30] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320, peer-reviewed official proceedings record; no publisher DOI assigned.
- [31] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, “Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program,” *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021, peer-reviewed official journal article; no publisher DOI assigned.
- [32] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, “Towards the systematic reporting of the energy and carbon footprints of machine learning,” *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020, peer-reviewed official journal article; no publisher DOI assigned.
- [33] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Krahmer, “Best practices for the human evaluation of automatically generated text,” in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.
- [34] M. Karpinska, N. Akoury, and M. Iyyer, “The perils of using Mechanical Turk to evaluate open-ended text generation,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.
- [35] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623.
- [36] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, “Humans or LLMs as the judge? a study on judgement bias,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.
- [37] D. Lakens, A. M. Scheel, and P. M. Isager, “Equivalence testing for psychological research: A tutorial,” *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.

- [38] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, “Random effects structure for confirmatory hypothesis testing: Keep it maximal,” *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.
- [39] M. O. Riedl, C. J. Saretto, and R. M. Young, “Managing interaction between users and agents in a multi-agent storytelling environment,” in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.
- [40] R. E. Fikes and N. J. Nilsson, “STRIPS: A new approach to the application of theorem proving to problem solving,” *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.
- [41] F. B. Schneider, “Enforceable security policies,” *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.
- [42] R. Evans and E. Short, “Versu—a simulationist storytelling system,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.
- [43] S. G. Ware and C. Siler, “Sabre: A narrative planner supporting intention and deep theory of mind,” in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.
- [44] A. Madaan, N. Tandon, P. Gupta *et al.*, “Self-Refine: Iterative refinement with self-feedback,” 2023, preprint; commonly indexed as NeurIPS 2023 but proceedings identity not re-verified as of 2026-08-21.
- [45] X. Chen, M. Lin, N. Schärli, and D. Zhou, “Teaching large language models to self-debug,” 2023, preprint; no archival venue or publisher DOI verified as of 2026-08-21.