TRACE-RPG: 대화형 게임 세계를 위한 감사 가능한 신경-기호 커밋 게이트

익명 저자

TABLE I
기여, 선행 주제, 근거 레인, 추론 상한 (구조화 매트릭스에서 생성)

ID	기여	선행 주제 (참고 문헌 수)	레인	추론 상한
C1	신뢰경계 contract	T1, T2, T3 (17)	E1, ENG1	인코딩 필드 계약 적합성
C2	validate–repair–commit controller	T1, T8 (14)	E1, ENG1	동결 사례의 메커니즘 동작
C3	감사 연결 근거 계층	T4, T7, T8 (6)	E1, ENG1	명명 fixture 의 무결성 · 재생
C4	assignment-complete harness	T1, T4, T6, T7 (20)	E1	설계 사례 정확 집계
C5	반례 유도 연산자 ρ	T1, T8, T9 (8)	E1, E2	동결 class + 단일 regime screen

T1 = 근거 게임 세계; T2 = 검색 · 메모리 에이전트; T3 = 구조 생성; T4 = 환경 · 벤치마크; T5 = 플레이어 경험; T6 = 인간 ·LLM 평가; T7 = 통계 · 재현성; T8 = 계획 · 런타임 개입; T9 = 피드백 수리. 레인은 표 V에 정의한다. 모든 행은 구현 · 작성 fixture 검증 상태이며 어떤 효능 claim 도 지지하지 않는다.

***Abstract*—유창한 게임 대화만으로 실행 가능하고 승인된 상태 전이는 성립하지 않는다. TRACE-RPG 은 생성 이벤트를 신뢰하지 않는 제안으로 취급한다. Strict parsing, 외부 policy, 여섯 계열의 일곱 술어, bounded repair, pre-commit revalidation 이 변경을 gate 한다. Typed-error 수리 ρ 는 후보/오류만 읽고 authoritative state 는 읽지 않는다. Unkeyed SHA-256 연결, semantic replay, complete accounting 은 결과를 감사한다. 근거는 단일 world 의 offline conformance, 단일 모델 live screening, 비권위적 closed-world graph simulation, 참여자 없는 Godot engineering 으로 분리한다. Offline 은 mechanism 근거뿐이다. $K{=}1$ 에서 guided/blind commit 5/5 대 0/5 는 constructed repairable policy-blind regime 에서만 관측됐다. Population efficacy, model superiority, player experience, commercial-engine performance 는 어느 레인도 확립하지 않는다.**

***Index Terms*—게임 인공지능, 인터랙티브 내러티브, 기호 검증, 제약 생성, 재현성**

I. 서론

생성 이벤트는 없는 아이템 요구, 모르는 사실 주장, 금지 공개, 비인가 효과, 단계 후퇴를 일으킬 수 있다. 그럴듯한 대화는 실행 가능한 전이가 아니며 [1], [2], quest/entity grounding 도 권한은 아니다 [3], [4]. **비신뢰 제안의 상태 변경은 TRACE-RPG 의 외부 결정론적 gate 만 허가한다** (그림 1).

기여: **C1—계약:** 버전형 parsing; **C2—controller:** 검사 ·bounded repair·unchanged fallback· 재검증; **C3—감사:** replay/continuity; **C4—harness:** proposal trace 없는 완전 계수; **C5—수리:** typed $\rho(a, E)$ 대 blind retry/state-reading oracle. 표 I–V는 C1–C3 을 E1/ENG1, C4 를 E1, C5 를 E1/E2 에 결속한다. Descriptive NPC-ENG1/NPC-SCR1 은 C6/C-RESULT 나 core Python–hard-policy/normal-play 근거가 아니다.

익명 심사를 위해 작성한 원고입니다.

II. 관련 연구와 연구 공백

Quest/entity 대화 KNUDGE [3], graph quest [4], memory–reflection–planning [5], 학습형 role [6] 는 grounding/개연성을 다룬다. Player/dialogue 연구 [7], [8], [9] 와 role-sensitive stability–improvisation(2025 preprint) [10] 는 admissibility 와 experience 의 분리를 동기화한다.

참여도/생성 연구는 future affect work 를 동기화하지만 [11], [12], [13], 여기서 affect 는 비권위적이며 미구현이다.

TextWorld/ScienceWorld 는 state [1], [2], MineDojo 는 embodied task [14], GVGAI 는 agent/game/content track [15] 을 제공한다. AgentBench, AgentBoard, SOTOPIA, BALROG 는 이질적 · 과정 · 사회적 · 장기 환경을 평가하며 [16], [17], [18], [19], 자동 playtesting 은 인간 평가를 보완한다 [20]. NCP-Bench 는 narrative commitment/fact consistency 이지 본 연구/player outcome 이 아니다 [21]. 검토 범위에서 authorization·typed repair·replay·accounting 의 결합은 없었으나 최초성 주장은 아니다.

구조 제약 [22], [23], [24] 은 상태 상대 승인과 다르다. LLM-Modulo 는 외부 sound critic [25], SayCan 은 skill affordance [26], AgentSpec 은 trigger–predicate rule 을 다룬다 [27]. Setting the DC 의 tool precondition 검사 [28] 와 달리 본 연구는 proposal 을 독립 policy 에 대조한다. STORY2GAME 은 precondition/effect 를 생성하고 [29], PANGeA 는 LLM rule judgement/refinement [30], IVIE 는 incremental world 의 symbolic validation [31], 후속 연구는 authored transformation 제약을 사용한다 [32]. 이는 transaction/audit/repair 질문의 답이나 encoded predicate 밖 우월성 근거가 아니다. JSONSchemaBench 의 structural compliance/coverage/quality 도 semantic authorization 을 확립하지 않는다 [33].

G-Retriever, HippoRAG, Mem0 는 subgraph retrieval· 장기 메모리를 다룬다 [34], [35], [36]. 이런 context 에 commit authority 를 주지 않으며 효익은 미측정이다.

과정 지표, sparse-run caution, reproducibility, environmental reporting 은 frozen artifact/실패 보존을 뒷받침한다 [17], [37], [38], [39]. Human/LLM 평가는 construct/rater/bias control, justified margin, random effects 가 필요하다 [40], [41], [42], [43], [44], [45]. 경험 재사용 [46] 과 달리 admitted transition 만 replay 한다. Leakage 검사는 분모를 보호하지 효능을 입증하지 않는다 [47].

C1–C5 는 기존 enforcement [27], game-state management [28], [29], feedback repair [48], replay [46], action interposition [49], precondition/effect [50], transition enforcement [51], abort [52], social logic [53], belief-aware planning [54] 의 결합이며 발명 주장이 아니다. 보고 누락은 구현 부재가 아니다.

III. 문제 정의와 보장 경계

입력 $c_t = (G_t, q_t)$ 는 typed snapshot G_t 와 외부 저작 action-policy/disclosure/quest-stage 제약 q_t 를 저장한다. Predicate 는

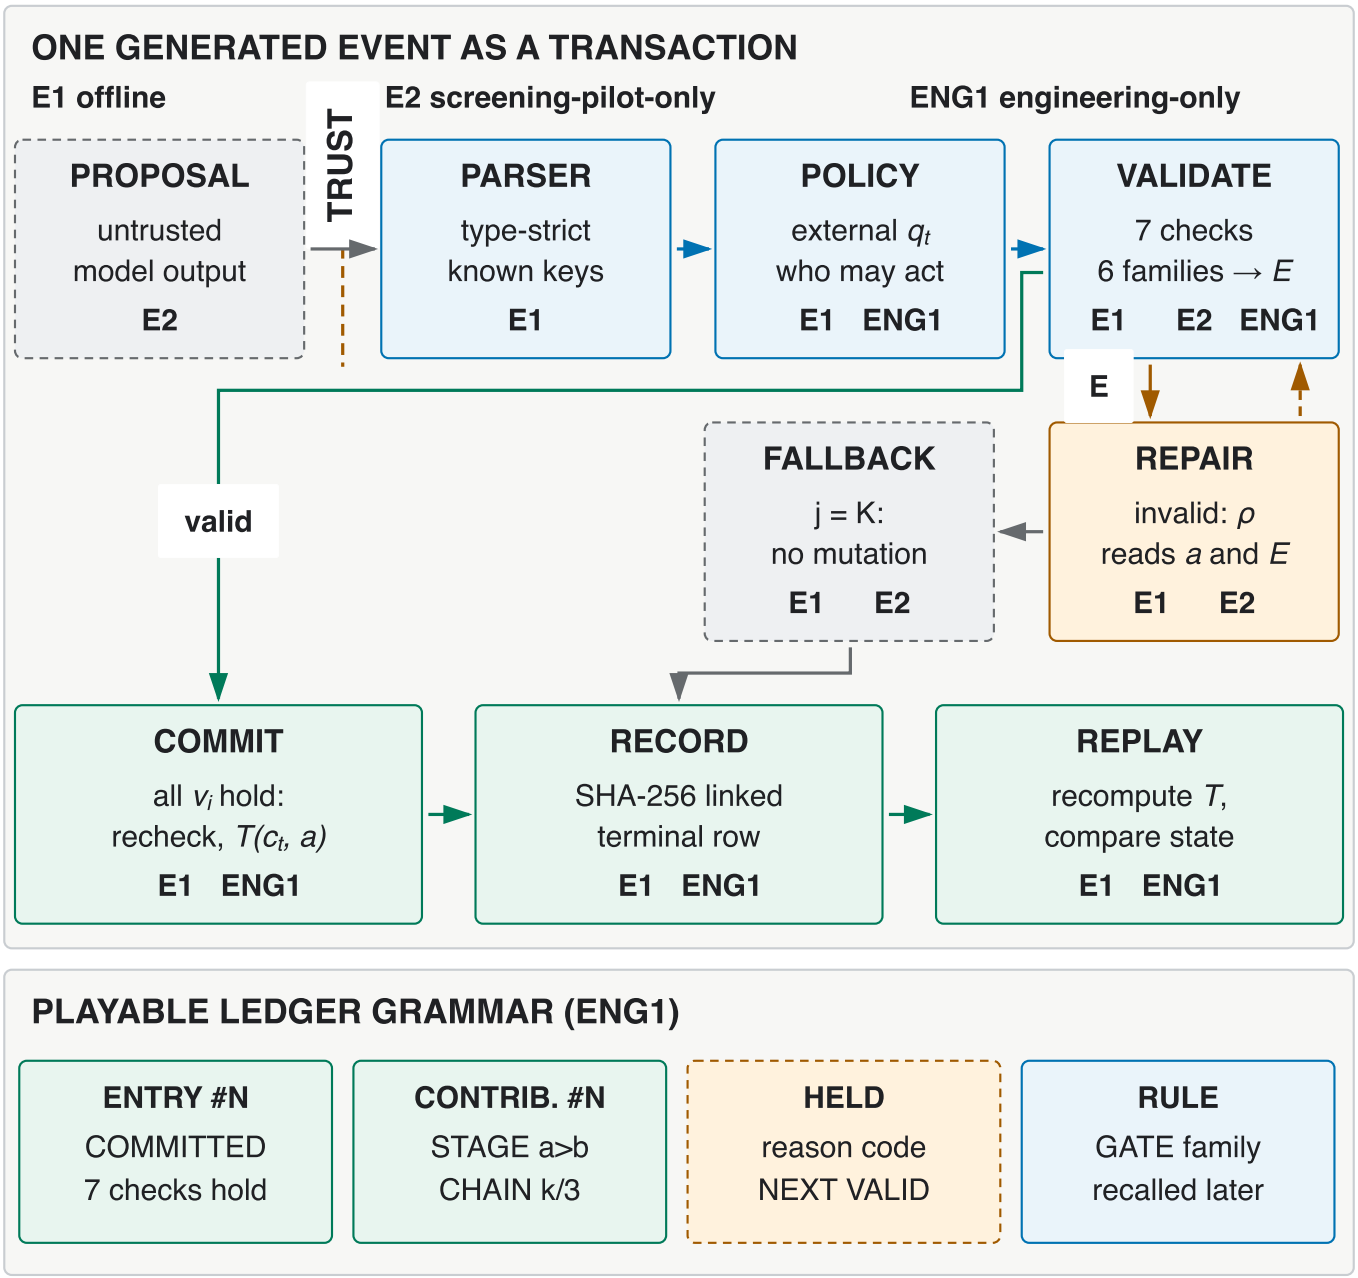


Fig. 1. 외부 policy 와 c_t 가 제안을 gate 하며 typed 오류는 bounded ρ(점선) 나 unchanged fallback 으로 이어진다. 통과 후보는 재검사 ·commit·record·replay 된다. Core tag 는 E1/E2/legacy ENG1 이며 additive NPC `npc-goal-recovery/1.1.0` 은 Godot-authoritative intent/planning 이지 core Python–hard-policy round trip 이 아니다. 아래 strip 은 committed-snapshot ledger 문법이다.

terminal history $h_{<t}$ 를 읽거나 log 로 `WorldState` 를 복원하지 않는다. 수락 전이는 G_t 만 바꾸며 policy rotation 은 제외한다. Retrieval, score, rationale, memory, future affect 는 비권위적이다.

엄격 parsing 은 unknown top-level field 를 거부하며 비신뢰 후보 a_t 의 공유 key/schema 계약을 강제한다. Validator 는

$$V(c_t, a_t) = (\boldsymbol{v}, E_t),$$
$$\boldsymbol{v} = (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, v_{\text{disc}}, v_{\text{elig}}, v_{\text{stage}}) \in \{0,1\}^7, \tag{1}$$

여기서 E_t 는 구조화 오류 집합이다. 상태 변경은 다음과 같다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_{i=1}^{7}(v_i = 1), \\ c_t, & \text{그 외.} \end{cases} \tag{2}$$

Fixture 는 정리가 아닌 구현 불변량을 시험한다. **I1:** validation 소진/commit 전 proposal·controller 실패는 불변이다. **I2:** 반환 callback 과 $K \geq 0$ 아래 최대 $K+1$ attempt 에 pre-commit 재검증을 더하며 deadline 없는 wall-clock 종료 보장은 아니다. **I3:** 수락 `CandidateAction.effects` 는 승인 quest-stage target 을 포함해 `ActionPolicy.allowed_effects` 안이다. **I4:** frozen schema/deterministic transition 은 종단 상태를 복원한다.

TABLE II
여덟 온톨로지 역할과 구체적 source 관계

역할	Source field 또는 관계 예시
World	`initial_state.world.object_locations`: `signal_lens→lamp_store`.
Actor	`initial_state.npcs.captain_mira`; `scope.eligible_actor_ids` 의 유일 원소.
Knowledge	Actor 의 `knowledge`→canonical Fact ID; 지식은 허가가 아니다.
Fact	`initial_state.facts`: `dock_saved`, `lighthouse_dark`; `keeper_betrayal` 은 ID 이며 비밀 payload 가 아니다.
Policy	`disclosure_policy`: `keeper_betrayal` 금지; `tide_marks_hint` 는 최소 quest stage 2 필요.
Quest	`initial_state.quest`: stage 0, flag `dock_saved`; 공개는 stage 를 보존한다.
Action	`reveal_hint(actor_id,fact_id)` 는 Fact/disclosed ID 를 추가하며 조석 단서만 relationship memory 를 추가한다. 최초 공개는 revision $+1$; 재표시는 불변이다.
Trace	`prior_state_hash`, `next_state_hash`, `rule_ids`, `template_id`, `case_id` 가 packet/version 을 근거에 결속하며 누락은 PASS 가 아니다.

가정: 올바른 policy, 충실한 추출, deterministic version, 반환 callback, 단일 프로세스 파일 소유. Replay 는 구조화 전이만 검사하며 repair provenance/prompt/확률 생성/미선언 자연어 함의는 검사하지 않는다.

IV. TRACE-RPG 아키텍처와 알고리즘

A. 신뢰 경계와 계약

모델/recorded adapter 는 canonical owner 밖이다 (그림 1). Parser 는 모호한 숫자 ·collection type 과 unknown top-level field 를 거부하며 독립 policy 는 required precondition/allowed effect 를 정의한다. Versioned bridge 는 observation/proposal/validation/rejection/fallback/commit 을 전달하고 유효 commit 만 변경을 승인한다. 근거는 unknown-key rejection parity 뿐이며 전체 proposal-default/replay-parser 동등성 · 상용 엔진 portability 는 아니다. 식 (1) 의 일곱 개의 결정론적 검사 (Python) 는 Godot 의 여섯 상태 상대 계열 (eligibility/stage 통합) 로 표시되며 NPC-DISC-1 의 DISC rule 7 개와 별개다 (표 III).

1) 여덟 역할 구조와 *source binding:* 읽기 전용 `game-track/web/dashboard/ontology-map.json` 은 8 개 역할 (표 II) 을 선언/frozen expectation 에 결속하며 live state 나 권한을 추론하지 않는다.

B. 고정 목표 *NPC* 통합

`npc-goal-recovery/1.1.0` 아래 Codex 는 intent 제안, Python 은 public claim/plan 검사, Godot 만 상태 쓰기를 맡는다. 항구 복구/승인 조석 단서 목표는 model-editable 이 아니다. 쓰기 binding 은 session, epoch, request, scenario, NPC, goal, version, policy/config hash, revision/state hash, deadline/budget, issued action 이다. Service 는 loopback `127.0.0.1:8768`; browser origin 은 `localhost`, `127.0.0.1:8877` 이다.

1) NPC-DISC-1 공개 계약과 권위 경계*:* 선언 유도형 NPC-DISC-1 `reveal_hint` 계약의 60 개 사례는 과거 `verified-run-006` 분모를 재실행 · 확장하지 않는다. 생성 결과/표 X–XII가 strata·binding· 입력-검사 매핑을 명시하며 Godot 만 service binding 재검사/상태 변경을 맡는다.

TABLE III
인코딩된 Validator 경계

술어	거부 대상	실패 시 상태
Action policy	알 수 없는 action/type	변경 없음
Precondition	누락/거짓 requirement	변경 없음
Reachability	접근 불가 object	변경 없음
NPC knowledge	선언되지 않은 known fact	변경 없음
Disclosure	forbidden fact	변경 없음
Quest eligibility	부적격 quest action	변경 없음
Quest stage	후퇴 또는 비인가 stage	변경 없음

TABLE IV
유도 연산자 ρ 의 오류 class 별 edit

Validator 오류 class	후보에 대한 edit $\delta(e)$
정책 precondition 누락	명명된 predicate 삽입
정책 effect 누락	명명된 effect 삽입
정책 effect 위반	명명된 effect 제거
불충족 precondition	명명된 predicate 제거
비인가 stage 변이	`quest_stage_effect` 초기화
알 수 없는 action type	no-op (등록된 대안 없음)
도달 불가 object; knowledge, disclosure, stage class	no-op (후보 국소 edit 은 세탁이거나 상태 지식 필요)

C. *Validate–Repair–Commit*

그림 3의 무의존성 의사코드에서 Record 는 in-memory append, 영속 쓰기는 종단 일관성 검사 뒤다. (ok, E) 는 V 와 집계 $\text{ok} := \bigwedge_{i=1}^{7}(v_i = 1)$ 의 축약이며 $V(c, a)$.ok 는 재검증이다.

Repair 는 상태를 바꾸지 않으며 소진 시 unchanged fallback 을 반환한다. Typed-error 연산자 (`counterexample_guided_repair`) 는 후보 a 와 오류 E(유일한 상태 유래 입력) 만 읽고 authoritative `WorldState` 는 읽지 않는다.

$$\rho(a, E) = a \oplus \bigcup_{e \in E} \delta(e), \tag{3}$$

표 IV의 $\oplus$ 는 결정론적 $\delta(e)$ 를 적용한다: 오류 entity 당 한 field, 시도당 최대 $|E|$ 이며 요구 · 거부 충돌은 불변이다. 고정점은 동일 E 조건이지 수렴이 아니다. 비배포 state-reading oracle 은 오류 대신 상태에서 precondition/effect/두 quest-stage field 를 복원하고 required object/used fact/disclosed fact 삭제로 위반을 세탁하지 않는다.

D. 무결성*,* 의미적 리플레이*,* 계수

키 없는 SHA-256 checksum/trace 연결은 우발적 · 시험 대상 변경만 탐지하며 writer identity 나 content/checksum 동시 재작성을 보장하지 않는다. Replay 는 prior state/candidate/validation 을 엄격 parsing 하고 invalid nonfinal attempt, 종단 상태 재계산 · 일치, 인접 JSONL continuity 를 요구하며 repair 는 재실행하지 않는다. Request→decision→result 와 첫 issued-action/exactly-one-receipt binding 은 duplicate-action-ID 발행 금지나 authentication 이 아니다.

종단 class 는 commit, symbolic fallback, adapter failure, controller failure 이며 마지막은 completed trace 없이 상태/assignment 를 보존한다. 실행 전 key 는 run, arm, scenario,

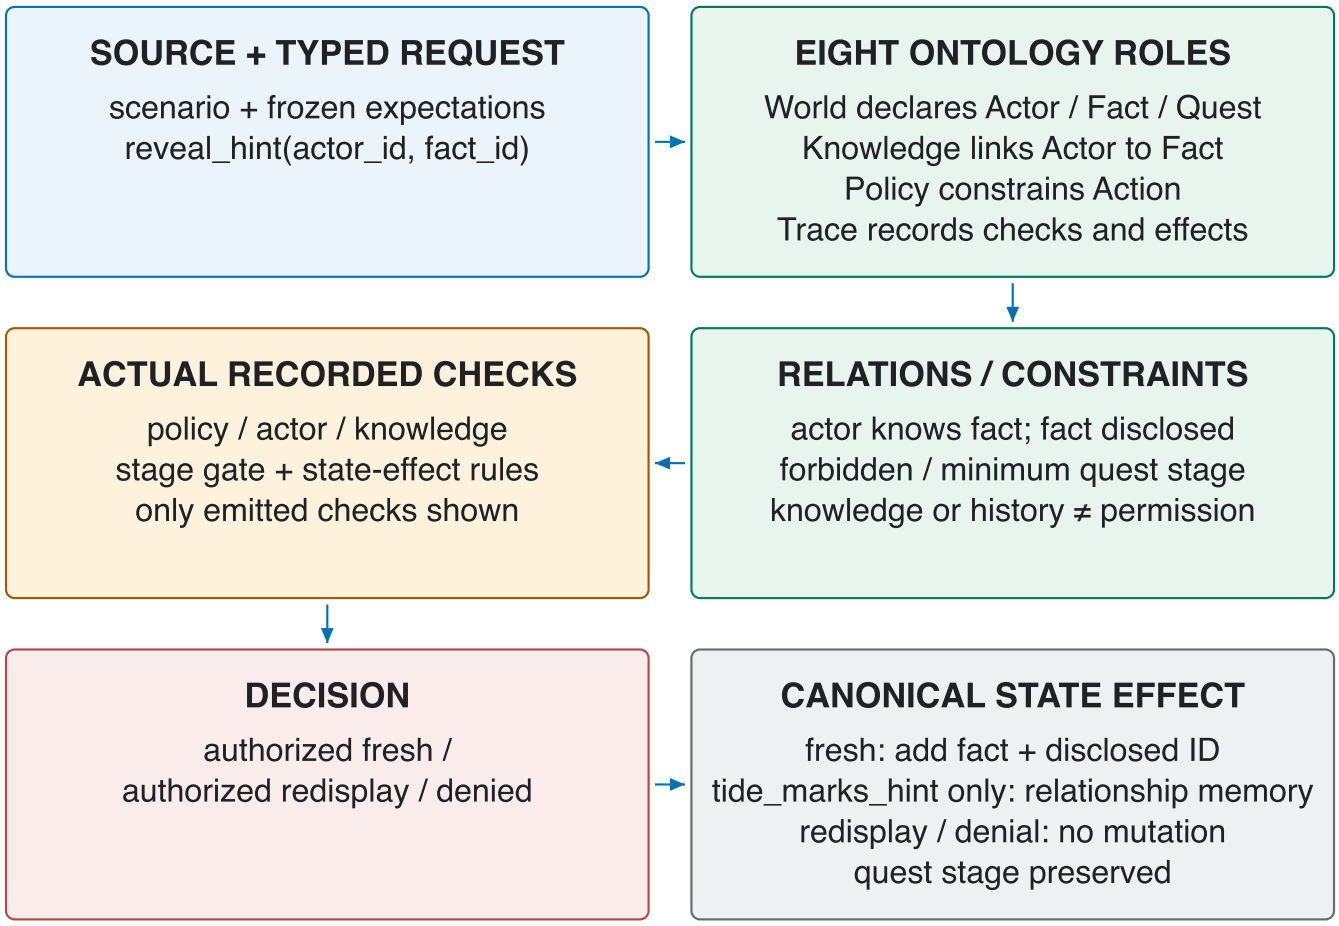


Fig. 2. 여덟 역할 온톨로지 구조 (표 II): World, Actor, Knowledge, Fact, Policy, Quest, Action, Trace 가 선언 source field 를 authored check 와 관측 결정에 연결한다. 승인된 전이만 canonical state 를 바꾸며, 도식은 live capture 나 hidden-state 근거가 아니다.

$a \leftarrow \text{Propose}(c)$; $j \leftarrow 0$
repeat
  $(\text{ok}, E) \leftarrow V(c, a)$; $\text{Record}(a, E)$
  if ok **then**
    assert $V(c, a).\text{ok}$; **return** $\text{Commit}(c, a)$
  if $j = K$ **then return** $\text{Fallback}(c)$
  $a \leftarrow \text{Repair}(c, a, E)$; $j \leftarrow j + 1$
until terminal

Fig. 3. Validate–repair–commit 절차. 최대 $K + 1$ 개의 candidate attempt 를 기록하며, 성공 경로는 상태 변경 전 방어적 validation 을 수행한다.

seed, model, revision, configuration/input/prior-state hash 를 결속한다. 집계는 중복/누락/예기치 않은 key 를 거부하고 실패를 분리한다.

V. 실험 레인과 근거 경계

표 V는 각 레인의 설계 · 단위 · 비교 · 추론 상한을 고정한다.

A. *E1* 오프라인 적합성 설계

E1 은 (PQ1) commit/invalid-policy 불변, (PQ2) frozen repair-class 결과, (PQ3) checksum/semantic/linkage/continuity fault 와 second-append rollback, (PQ4) assignment 계수/fail-closed adapter·manifest 거부, (PQ5) proposal/replay unknown-key 거부를 시험한다.

비모집단 의도 fixture 는 gate 13 개 (valid 1/음성 12) 와 repair 12 개를 분리한다. Frozen class 는 *guided-repairable*(오류 충분), *oracle-only*(상태 필요), *irreparable*(commit 불가) 이며 결과가 모든 arm 을 열거한다.

Count 는 detector 귀속/모집단 통계가 아니며 latency/token 상수는 회계만 시험한다. Frozen packet 은 fixture/assignment/schema/result/code 를 결속한다 [38], [39].

B. *E2* 라이브 *RQ2* 스크리닝

E2 는 셀당 seed-indexed hosted `gpt-5.6-sol` 후보 5 개를 $K{=}1$ 의 blind 동일 후보 retry/ρ 에 공유하며 policy 공개/효과

TABLE V
실험 레인 요약: 설계, 단위, 비교, 추론 상한 (실험 매트릭스에서 생성)

레인	설계	단위 / 예산	비교	상한
E1	오프라인 적합성: 작성 · 동결 fixture, 단일 world	gate 13; arm 당 repair 12; fault 10; adapter 7; guard 3	reject / blind / ρ / oracle	메커니즘 적합성
E2	RQ2 screening-pilot-only: hosted proposer 1 개, matched candidate	5 cell $\times$ 5 call; $K{=}1$	regime 별 ρ / blind	screening-pilot-only 전이 screen
E3	KG/온톨로지 시뮬레이션: closed-world typed-link holdout	node 43; 참조 edge 106; typed 24; score 210	degree baseline / 고정 전략 6 종	구성 결과만
ENG1	Engineering-only Godot/Web: 엔진 로컬 policy mirror, 참여자 없음	fixture 4; check 52; smoke 8; archetype 5	작성 fixture 경로	엔진 로컬 engineering-only 적합성

E1–E3 와 ENG1 은 서로 대체할 수 없으며 분모가 다르다. E2 는 screening-pilot-only 이고 ENG1 은 engineering-only 다. 어떤 레인도 모집단 효능, 모델 순위, 플레이어 경험, 런타임 검색 효익, 상용 엔진 성능을 확립하지 않는다.

0 경로를 바꾼다. 현재 셀/폐기 v1 진단/SHA-256 receipt 를 보존한다. 비제어 seed, revision 미고정, token 부재, 구성 state 는 count/실패 class 만 허용하며 모집단 통계/모델 순위는 아니다.

C. *NPC-ENG1* 고정 목표 *engineering* 레인

Stable v5 의 engineering 16 assignment/recipe 12 개 는 bootstrap, identity/hash, intent/plan/role/result, 음성/stale/duplicate/deadline, replay 를 시험한다. Status/count/latency/재현은 `research/academic-pipeline/npc-goal-recovery/verified-run-006/` 과 runner/validator 를 쓴다. Verified-run-002/003/004 는 immutable history, preflight 는 NPC-SCR1 밖이다.

D. *NPC-SCR1* 기술적 스크리닝

NPC-SCR1 $12 \times 2 \times 3$ P/R/O row(72; arm 당 24) 에 NPC-ENG1 을 더하면 88 assignment/28 definition($R/P/O = 40/24/24$) 이며 ENG1/E1 과 별개다. 실패 strata 를 모두 보존하고 recovery-eligible/unreachable 을 분리한다. 생성 결과가 P/R/O, 미상 metadata, 실패/stale-ACK/epoch-local replay 를 명시한다. O 의 same-family 일치는 미검증이며 auxiliary-source 100%, independent gold 는 없다. ENG-X01/SCR-X01, D02/QA-001, C-RESULT, Frozen8/Frozen16, v1–v4, `native012` 는 provenance 이지 C6 근거가 아니다.

E. *E3 KG/*온톨로지 링크 제안 시뮬레이션

E3 는 authoritative `WorldState` 와 분리된 engineering-only closed-world 시뮬레이션이다. Graph node 43 개/reference edge 106 개/검토 typed edge 24 개는 type/domain/range 검사와 competency question 6 개를 통과했다. Graph-edge-withheld authored target 6 개는 고정 전략 7 개의 채점과 retained strategy 선택 · 요약에 모두 쓰여 untouched/external test 가 아니다. Typed-lexical S2 는 6/6 을 복원했다 ($P = R = F_1 = 1.000$, realistic-tie MRR $= 0.944$, Brier $= 0.131$, Sem@3 $= 1.000$); degree baseline 은 0 개다. 구성 결과이지 OWL/SHACL 적합성, 의미 완전성, runtime retrieval, 효능 근거가 아니다.

VI. 파일럿 결과

A. 구조 필드 게이트 적합성

파일럿 loader 는 구현된 validator code 를 정확히 한 번씩 고립시키는 fixture 집합과 유효 control 1 개만을 허용한다. 따라서 13/13 일치와 구현된 오류 코드 12 종의 관찰은 측정된 성공률이 아니라 하니스의 구성 불변량이다. 이 실행이 보여주는 것은 loader 가 강제하지 않는 부분, 즉 고립된 음성 fixture 12 개가 각각 다른 코드가 아니라 작성된 기대 코드와 일치했고 비commit 경로가 전체 정준 상태를 유지했다는 관찰이다. 이는 단일 world state 에서 저자가 설계한 구조 필드 oracle 에 대한 구현 적합성이며 독립 의미 판정의 정확도가 아니다.

B. 설계 픽스처에서의 수리 *arm* 비교

처음부터 유효하지 않은 설계 case 12 개는 guided-repairable 5 개, oracle-only 1 개, irreparable 6 개의 동결된 repairability class 로 분할된다. Rejection-only 와 블라인드 동일 후보 retry 는 각각 0/12 commit 이었다. validator-error-guided 연산자 ρ 는 guided-repairable case 5/5 를 commit 했고, 설계상 oracle-only 0/1, irreparable 0/6 였다. 모든 ρ commit 은 candidate field 를 평균 1.0 개 수정했으며, ρ 는 직전 candidate 와 typed validator error E 만 읽고 error 가 state-derived input 의 유일한 경로이며, 실패한 모든 arm 실행은 정준 상태를 변경 없이 유지했다. 상태를 읽는 참조 callback 은 guided-repairable 5/5 와 oracle-only 1/1 를 commit 했고 irreparable 은 0/6 였다. 이 정확한 count 는 세 메커니즘을 설계 픽스처 위에서 분리한다. 블라인드 retry 는 validator error 를 commit 으로 전환하지 못하고, ρ 는 오류 payload 에 충분한 정보가 담긴 case 만 전환하며, oracle 은 상태 지식이 필요한 case 를 추가로 전환한다. commit 된 guided case 5 건이 처음 받은 validator code 는 각각 `POLICY_PRECONDITION_OMISSION+UNSATISFIED_PRECONDITION`, `POLICY_EFFECT_OMISSION`, `POLICY_EFFECT_VIOLATION`, `UNSATISFIED_PRECONDITION`, `POLICY_QUEST_STAGE_EFFECT_VIOLATION` 이며, 각 case 는 표 IV의 해당 edit $\delta(e)$ 만으로 유효해졌다. 이는 동결 픽스처에 대한 연산자 적합성이며, 어떤 live model 의 수리 품질도 아니다.

C. 무결성, 경계, 배정 회계

현재 명세가 검출 가능하다고 지정한 10 개 fault fixture 는 모두 지정된 검사 연산에서 거부됐다 (10/10). 이 파일럿은 안정적인 typed detector code 까지 대조하지 않으므로 detector layer 귀속을 입증하지 않는다. 별도로, 동일하게 기록된 유효 수리 앞의 무효 선행 후보를 다른 무효 후보로 치환하고 체크섬을 재계산한 알려진 provenance 경계는 예상대로 재생을 통과했다 (1/1 미검출). 따라서 키 없는 체크섬을 재계산할 수 있는 작성자를 방어하지 않으며, 재생은 repair 생성 연산의 출처를 인증하지 않는다. 열린 경계 sentinel 두 건—자연어 disclosure 미추출과 required object 의 후보 · 정책 동시 누락—은 2/2 가 의도대로 인코딩상 허용됐고 safety pass 는 0 건이었다. 과거 unknown top-level field 허용 경계는 이후 닫힌 음성 회귀로 재분류되었으며, 완전한 12-field candidate 에 unknown key 하나를 추가한 fixture 를 proposal·replay parser 모두 구체적으로 거부했다 (1/1). 이는 parser rejection parity 이지 의미 안전성의 증거가 아니다. Adapter/accounting 7 개 배정에서는 commit 1, 기호 fallback 1, adapter failure 5 였다. 합성 telemetry 필드는 2/7 배정에서 채워져 전파됐으며, 이는 측정값이 아니라 회

TABLE VI
E1 오프라인 적합성: 수리 가능성 class 별 정확 count (설계 fixture)

Arm	정보원	Commit / 사례			평균 수정 [e]
		G-rep.[f]	O-only[f]	Irrep.[f]	필드 수
Rejection-only ($K=0$)	없음	0/5	0/1	0/6	—
블라인드 retry	없음	0/5	0/1	0/6	—
Validator-error-guided ρ	오류 집합 E	5/5	0/1	0/6	1.0
상태 판독 oracle	권위 상태 + 정책	5/5	1/1	0/6	1.0

[e]Commit 된 수리의 변경 candidate field 평균 개수 (최소성 proxy); 실패한 arm 실행은 상태를 변경하지 않았다. E1 은 처음부터 invalid 한 12 개 설계 case 를 사용하며 rejection-only/blind 는 0/12, 0/12, validator-error-guided ρ 는 5/12, state-reading oracle 은 6/12 commit 이다. [f]Commit/사례 수. G-rep. = guided-repairable, O-only = oracle-only, Irrep. = irreparable(동결 repairability class); 모집단 효능이나 live-model 품질을 뜻하지 않는다.

TABLE VII
E1 오프라인 적합성: 동결 파일럿 검사와 종단 결과 (행 간 직접 비교 불가)

검사 또는 종단군	정확 결과	해석 범위
게이트 fixture 일치	13/13	저자 oracle 일치
알려진 경계 허용	2/2	인코딩 한계, safety pass 아님
닫힌 unknown-key 거부	1/1	proposal/replay parser parity
탐지 가능 무결성 결함 거부	10/10	지정된 검사 연산
알려진 provenance 경계 허용	1/1	repair 생성 출처 미인증
Adapter 종단 class	1 commit; 1 fallback; 5 실패 / 배정 7	배정 7 건의 분류 완전성
Manifest guard 거부	3/3	주입 결함 fail-closed

행마다 분모와 성공 방향이 다르므로 비율처럼 순위를 비교하지 않는다. 모든 값은 설계 픽스처의 정확한 감사 사실이다.

TABLE VIII
E2 screening-pilot-only: 라이브 스크리닝 정확 집계 (5 개 cell, 셀당 제안 5 회, $K=1$)

기저 / 조건	최초 유효	ρ vs blind commit	Δ	최초 오류
동결 / 공개	5/5	5/5 vs 5/5	+0	—
동결 / 비공개	5/5	5/5 vs 5/5	+0	—
동결 / 목표-비공개	0/5	0/5 vs 0/5	+0	QSR
Signal-v2 / 공개	5/5	5/5 vs 5/5	+0	—
Signal-v2 / 비공개	0/5	**5/5 vs 0/5**	**+5**	PEO+PEV+PPO

QSR = quest-stage regression, PEO = policy-effect omission, PEV = policy-effect violation, PPO = policy-precondition omission. Δ 는 동일 후보 (matched candidate) 에서 ρ commit 수 minus blind commit 수다. 5 개 cell × cell 당 5 회 호출이며, 3 개 cell 은 최초 5/5 유효, goal-blind cell 은 QSR 5/5 로 양 arm 0/5, 0/5 commit 인 null regime 이다. Signal-v2 blind 는 ρ 5/5 대 blind 0/5 로 분리되었다. 모든 수치는 screening-pilot-only 이며 추론 통계 · 모델 순위가 아니다.

계 필드 전파 확인이다. 배정 guard 3/3 가 중복 · 누락을 거부했다. 이 수치는 모두 합성 offline fixture 의 raw count 다.

D. 라이브 스크리닝 파일럿 *(pilot-only)*

표 VIII의 pilot-only 집계에서 Signal-v2/policy-blind 셀은 최초 후보 5/5 가 모두 무효였고 ρ 가 5/5, 블라인드가 0/5 를 commit 했다. 나머지 현재 4 개 셀은 null 관측이며 noncommit arm 의 15/15 결과가 prior-state hash 를 보존했다. 폐기된 v1 진단에서는 동반 오류가 최대 3 개에서 수리 불가 knowledge 오류 1 개로 줄었지만 commit 되지 않았다.

TABLE IX
NPC-SCR1 고정 사례 실행 계수. NPC-ENG1 의 16 개 사례와 분리하며 모든 실패를 분모에 보존한다.

Arm	배정	완료/실패	목표 도달	회복 E/U
P	24	20/4	4	24/0
R	24	20/4	4	24/0
O	24	20/4	4	24/0

E: 회복 평가 가능, U: 도달 불가; NA: 미측정. 목표 관측 계수는 회복률이 아니다. Replay 적합성은 실패 행을 완료로 바꾸지 않는다. O 의 독립 원본은 0 개다.

E. 고정 목표 *NPC* 운영 *(NPC-ENG1/NPC-SCR1)*

Mira 의 고정 목표는 항구 신호 복구 후 허가된 조석 단서를 제공하는 것이다. Python 은 typed intent 와 공개 관측으로 bounded BFS 계획을 계산한다. 획득 · 설치는 플레이어가, 허가된 `reveal_hint` 는 NPC 가 수행한다. Godot 은 session/epoch/request/goal/policy/revision/hash 를 동기 검사한 뒤 기존 writer 를 await 없이 호출한다. 결과와 새 관측이 다음 계획을 결정하므로 단일 후보의 validator-error repair 와 구별된다.

NPC-ENG1 은 실제 엔진 snapshot 에서 시작한 R arm 의 결정론적 engineering 사례 16 개 (assigned_failure=2, completed=14) 다. NPC-SCR1 은 P/R/O 각 24 개, 전체 72 개 배정과 실패를 모두 보존한다 (assigned_failure=12, completed=60). P 는 인증된 Codex CLI 실행 시도 24 회, 반환 decision 24 개, 배정 실패 4 개를 기록했다. 이는 원격 과금 호출 횟수가 아니다. 요청 모델: 알 수 없음 (null); decision 에 기록된 모델 식별자: 알 수 없음 (null). 후자는 설정된 selector 이며 provider revision 이 아니다. provider revision 은 사용할 수 없고 null 식별자는 미상으로 남긴다. 전역 설정은 모델 식별 근거가 아니다. R 은 작성된 규칙을 사용한다. O 는 `same_model_family_auxiliary` 로 선언된 protocol auxiliary 일 뿐이며 실제 모델 계열 일치는 unverified(검증되지 않음) 이다. 독립 원본은 0 개이고 O 는 oracle 이나 semantic gold 가 아니다. 표 IX은 bounded protocol-conformance 고정 사례의 기술적 계수이지 회복 효능 · 우월성 · 일반화 추정이 아니다. efficacy 는 pending 이며 토큰 · 비용은 미측정이다. 읽기 전용 CLI 와 격리 작업 디렉터리를 사용했지만 tool-free 추론이나 적대적 기밀성은 검증하지 않았다. 이 생성물은 2026-10-17 의 보관 source bytes (revision fa9fb8a) 에 대해 immutable verified-run-006 을 재검증한 역사적 packet 산출물이다. 현재 checkout 의 NPC runtime 이나 현재 release authority 를 인증하지 않는다. 검증된 사전 작성 stale-control ACK 거부는 arm 별 P=4, R=4, O=4 건 (SCR-T01 (stale_revision), SCR-T02 (stale_policy)) 이며, 12 개 인스턴스 모두 대응하는 음성 대조 gate 가 모두 통과했다. 따라서 이 행들은 assigned failure 로 분모에 남기되 method-performance 결과로 해석하지 않으며, 기타 assigned failure 0 개는 미분류로 남긴다. 재현 검증은 내보낸 epoch 내부에 한정한다 (`intent_lineage_scope=epoch_local_only`). epoch 간 의도 연속성은 입증하지 않는다 (`cross_epoch_intent_continuity_proven=false`). 불투명한 연속 지점을 허용하는 예외는 양의 epoch snapshot 에서 인접한 선두 observation 요청 ·decision 쌍에만 적용한다. epoch 0 의 고아 관측, 그 밖의 의도 확정 전 관측 요청, 후속 의도 불일치는 계속 거절한다.

F. 동결된 *reveal_hint* 계약과 공개 증거

이 산출물은 동결 기대값 패킷 `sl-npc-disclosure-expectations-v1` (v1.0.0) 과 네 개의 실제 결과 파일만 소비한다. 패킷 SHA-256 은 `9920aa834910a3ee35ed4446de4fdba42bb67dda71b07a93bccfc7a0b2e09028` 이며 sidecar 와 직접 대조했다. 정상 분모는 선언식 `1 eligible actor x 4 declared fact IDs x 3 declared stage values x 2 knowledge values x 2 prior-disclosed values` 의 48 개이고, 경계 4 개와 잘못된 입력 8 개는 정상 분모에서 제외한다. 각 trace 행의 기대 객체는 gate 출력이 아니라 packet 의 case ID 에서 다시 대조했다.

내용 우선 설명은 typed input(연산 · 행위자 ·fact·stage·knowledge·prior-disclosed) 에서 시작해 ontology entities/relations, authored rules, 실제 check 결과, allowed/denied 결정, canonical state effect 순으로 읽는다. 허용된 최초 표시는 요청 fact 만 (조석 단서이면 선언된 relationship-memory 도) 추가하고 stage 를 보존하며 revision 을 한 번 올린다. 거부와 기공개 재표시는 canonical state 를 바꾸지 않는다. 이 패널/그림은 설명용이며 hidden fact 나 자연어 함의를 복원하거나 live capture 를 주장하지 않는다.

온톨로지 선언은 `sl-npc-disclosure-expectations-v1:runtime-disclosure` / v1.0.0 이며 provenance 는 `frozen_expectation_packet` 이다. 범위는 네 canonical fact ID(dock_saved, keeper_betrayal, lighthouse_dark, tide_marks_hint) 와 행위자 `captain_mira` 뿐이다. 규칙 ID 는 DISC-001, DISC-002, DISC-003, DISC-004, DISC-005, DISC-006, DISC-007 이고 승인 template 은 `mira-safe-deflection-v1` 및 `sl-rc-003-authorized-hint` 뿐이다.

Python evaluator 는 같은 사례 · 기대 객체를 세 격리 arm 에 materialize 하고 semantic outcome, check trace, error, 상태 전후 SHA-256, template ID, replay equality 를 기록한다. Godot 은 별도 실행 경계에서 기존 `reveal_hint` writer 와 canonical mutation 을 소유하며 이 producer 는 이를 재구성하지 않는다. Python–Godot 연결은 operation `reveal_hint`, scenario `sealed-lighthouse-v1`, actor `captain_mira`, source hash 로 추적한다. 실행 시점 관측 hash 는 현재 source 와 일치한다. 동결 패킷 baseline 과 다른 source 는 3 개 (game-track/godot/scripts/game3d/game_3d.gd, game-track/godot/scripts/sealed_lighthouse_machine.gd, llm-wiki/wiki/reports/2026-10-22-ontology-signals-interview.md) 이며, 패킷 hash 는 수정하지 않고 이 차이를 공개한다.

표 XI는 같은 60 개 사례의 세 arm 을 정상/경계/잘못된 입력 분모로 분리해 보고한다. unchecked 위반은 의도된 격리 관측이며 general-rule 과 ontology-gate 의 frozen expectation mismatch 는 각각 0 개이다. 그림 4는 기대 일치 · 재생 사례 계수 (E/R), check-record PASS/FAIL 계수 (C), 기록된 check 가 없는 사례 수 (NR) 를 구별한다. NR 은 skipped, pass, out-of-scope 를 뜻하지 않는다. 표 XII는 두 rule-change fixture 와 네 paired case 를 shipped scenario 를 바꾸지 않는 disposable clone 에 매핑한다.

주장은 bounded engineering conformance 에 한정된다. human gold, access-separated holdout, efficacy, superiority, generalization, player benefit, model latent state 또는 cost 를 주장하지 않는다. 정확한 입력 경로 ·hash· 재생성 명령은 `paper/latex/generated/disclosure_producer_manifest.json` 에 결속된다.

TABLE X
동결된 reveal_hint 계약의 구조 · 내용 · 규칙 ID 와 실제 결과 provenance.

Field / 항목	Value / 값
Operation / 연산	reveal_hint
Scenario / 시나리오	sealed-lighthouse-v1
Normal denominator / 정상 분모	48
Boundary / 경계	4
Malformed / 잘못된 입력	8
Canonical facts / 정형 사실	dock_saved, keeper_betrayal, lighthouse_dark, tide_marks_hint
Eligible actor / 적격 행위자	captain_mira
Ontology / 온톨로지	sl-npc-disclosure-expectations-v1:runtime-disclosure
Rule IDs / 규칙 ID	DISC-001, DISC-002, DISC-003, DISC-004, DISC-005, DISC-006, DISC-007
Templates / 템플릿	mira-safe-deflection-v1; sl-rc-003-authorized-hint

기대값은 gate 출력에서 유도하지 않았고, 표의 분모는 동결 선언에서 읽었다.

Live disclosure sequence/`t_ms`, public-safe request/state hash, categorical check 는 engine timeline 이며 provider receipt time/latency 나 fixed-case 표가 아니다. Missing/out-of-scope cell 은 PASS/SKIPPED 가 아니다.

ENG1. (Legacy; no live transport.) Godot 4.7.1 은 authored disclosure 거부/commit 을 prior/offline terminal hash 로 replay 한다. 1280×720 capture 는 presentation-only 이지 근거가 아니다. Committed fact 는 board/hint/coach/chain prompt 를 채우며 dashboard 는 checks/holds/unreached/out-of-scope 를 구분한다. Core 52/52 와 extension 4 개는 engine-local conformance 이지 live model/Python transport, participant, narrative, usability, efficacy 근거가 아니다.

G. 단일 과제 *Codex* 개발 관측

별도 동결된 `ontology-map-20261023-01` 계약은 읽기 전용 bilingual dashboard 과제 하나 (n=1, independent repeats 0) 이며 추가 NPC trial 이나 공개 fixture 60 개 중 하나가 아니다. Native CLI 호출 6 회 (initial + resume 5 회, 그중 read-only/no-edit 1 회) 는 한 case 다. Native `turn_context.model` 은 `gpt-6.1-sol` 선택을 보고하지만 provider-returned identity, immutable revision, cost 는 `null` 이다. 과거 hosted `gpt-5.6-sol` 과 원래 NPC 분모는 재표기하지 않는다. 누적 reported token total 은 합산하지 않는다.

여섯째 호출은 mobile table 에 상속된 최소 너비 660 px 를 해당 범위에서 수정했다. 독립 pre-fix geometry 검사는 RED(2 실패/35 통과), 최종 map/signal/Web 검사는 내부 cell/paragraph geometry 를 포함해 62/62 통과했으며 실제 Godot Web build 도 통과했다. 연속 실제 입력 browser QA attempt 10 은 PASS 다. Attempt 01–09 는 보존했다 (01–08 setup/route 실패; 09 는 이전 gate 를 통과했으나 clipping 잔존). 최종 $(\mathrm{seq}, t_{\mathrm{ms}})$ 쌍은 stage 0 거부 $(68, 19468)$(hash 동일), 최초 공개 $(239, 58234)$(상이), 승인된 재표시 $(249, 59793)$(동일) 다. 같은 session 에서 $1440{\times}900$ 과 $390{\times}900$, 8 개 role(7 Python predicate/6 Godot display family/7 rule), keyboard Enter, inspection 무변경, 동결 comparison 불변, navigation 이전부터 console/page/network error 와 warning 모두 0 을 확인했다. 상태는 **동결 과제하 수락**이지 효능 근거가 아니다. Privacy/source-binding 실패와 동일 thread 수리는 과정 관측이며 검사는 n 을 늘리지 않는다. Jev 는 `proposal_only`,

TABLE XI
세 disclosure arm 의 raw trace 관측 계수; 정상/경계/잘못된 입력 분모를 분리한다.

Arm	n (N/B/M)	Allow/Deny	Semantic mismatch	State/Display fail	Replay fail	Unique unsafe
unchecked_isolated	48/4/8	60/0	60	0/0	0	51
general_rule	48/4/8	16/44	0	0/0	0	0
ontology_gate	48/4/8	16/44	0	0/0	0	0

N/B/M = normal/boundary/malformed. 의미 불일치는 전체 기대 결과와의 차이이고, 고유 위험 사례는 무허가 허용 또는 재표시 상태 변경의 합집합이다. 허용된 최초 공개의 표현 불일치만으로 위험 사례에 포함하지 않는다. 무검사군은 격리된 관측이며 효능 · 우월성 · 일반화 결과가 아니다.

TABLE XII
규칙 변경 fixture 의 paired-case traceability 와 수정 범위; shipped scenario 는 변경하지 않는다.

Fixture	Mutation	Paired cases	Changed paths	Missed cases	Match
RC-001-stage-gate-2-to-1	disclosure_policy.stage_gates[0].minimum_stage 2→1	N-043, N-044	disclosure_policy.stage_gates[0].minimum_stage	none	PASS
RC-002-forbid-tide-marks-hint	disclosure_policy.permanently_forbidden ['keeper_betrayal']→['keeper_betrayal', 'tide_marks_hint']	N-047, N-048	disclosure_policy.permanently_forbidden[1]	none	PASS

두 fixture 는 general_rule 과 ontology_gate 에 같은 변경을 적용한다. missed case 가 없고 mutation_scope_preserved 가 true 인 경우만 PASS 이다.

`evidence_supports=no`, $p(\text{yes}) = .27$(`jev-1.14.0`, 미검증) 로 advisory 이지 승인 ·gold 가 아니다. 개발 baseline comparator 가 없으며 생산성 · 우월성 · 재미 · 인간 효능 주장은 뒷받침하지 않는다. 보고: `research/development-cases/ontology-map-20261023-01/result.json`; 동결 명세: 인접 `contract.json`.

VII. 논의

Semantic repair [48], [55], [56], [57] 와 달리 ρ 는 deterministic pre-execution 오류를 쓰며 oracle-only 는 state-reading 만 처리한다. Frozen-case `general_rule`/`ontology_gate` 일치와 rule-change edit-scope 진단은 capability 나 ontology 우월성이 아니다.

미실행 계획은 사전등록 다중 모델/oracle/blind-retry 비교, matched-validity retrieval/memory ablation, 검정력 ·mixed-effects 를 갖춘 blinded matched-validity 인간 연구이며 screening 은 이를 대체하지 않는다 [40], [37], [45].

VIII. 타당성 위협, 윤리, 산출물 범위

경계는 아홉 가지다. **L1:** structured field 밖 의미 · 행동 일관성과 서사 품질은 미측정이다 [58]; **L2:** world/live-state 하나로 cross-world/cross-policy/scale 일반화는 안 된다; **L3:** state-reading 은 oracle 이며 class/regime 은 repair 품질/sample efficiency 를 입증하지 않는다; **L4:** hosted proposer 의 revision/seed 는 미고정 ·token 회계가 없고 E2 는 Python–Godot authorization round trip 이 없다; **L5:** 참여자, 정서, 이해, 행위 주체성, 즐거움, 몰입, 효익 근거가 없다; **L6:** unkeyed hash 는 integrity 이지 authentication/tamper resistance 가 아니다; **L7:** single-writer 외 concurrent-writer safety 는 미검증이다; **L8:** startup-dominated Godot fixture 의 16.7 ms 초과 sample 은 portability/performance 결과가 아니다; **L9:** 선택 fixture/cell 은 population/safety-rate/model-ranking 추론을 지지하지 않는다. Internal validity 는 독립 policy expectation/leakage 부재, 재현성은 frozen software/artifact 에 의존한다. NPC asynchronous deadline, duplicate/stale/late-drop, cumulative budget, synchronous binding 은 latency/quality 가 아닌 protocol invariant 다. IV절은 local-only cancellation/provider-completion 과 unit/controller-only `Core.cancel` 경계를 고정하며 human/cross-world/independent-gold/oracle/recovery efficacy 근거를 만들지 않는다. 현재 pilot 은 participant/personal telemetry 를 처리하지 않으며, planned human/affect work 에는 review, consent, compensation disclosure, minimization, retention/deletion, opt-out, calibrated/bias-controlled auxiliary LLM judge 가 필요하다 [40], [41], [42], [43]. NPC-DISC-1 은 frozen ID/template/state 축만 다루며 free-form/implicit·hidden-payload· 모든 UI 채널의 leakage-free 를 증명하지 않는다. 일치나 count 는 ontology 우월성 · 완전성 · 필수성, latent-state 추론, cost equality, semantic gold, accuracy ceiling 이 아니다. 선언 유도 기대값은 human gold/holdout 이 아니며 Jev 는 label/commit 권한이 없다.

IX. 결론

TRACE-RPG 은 mutation gate/replay 감사를 제공한다. 5/5 대 0/5 수리 차이는 constructed-regime conformance 뿐이다. NPC-DISC-1 은 유한 strata/세 arm `reveal_hint` 와 불변 재표시 근거를 추가한다. V절은 additive NPC/historical `native012`/legacy ENG1 을 분리한다.

AI 사용 고지

LLM 은 prose/code/test/citation check, hosted model 은 표기 screening candidate 를 보조했다. Count 는 deterministic runner/hash-bound receipt 다. Curated AI 생성 UI art(초상 · 인장 · 텍스처 ·board·icon·guide) 와 desk mesh 는 파일별 provenance 를 가지며 rendered snapshot 값/hash/ledger 는 presentation-only 다. 저자가 source 를 대조하고 책임진다. 별도 additive NPC 입력/표는 모든 assignment 와 project/protocol/schema hash 를 보존하며 미상 token/cost/model-revision 은 unknown 이다.

데이터 및 코드 가용성

Implementation/build source, frozen packet, Godot slice, deterministic evaluation, `research/academic-pipeline/` 의 기계 검증 기여 · 참조 주제 · 실험 매트릭스 (표 I, V) 를 포함한다. `paper/latex/generated/disclosure_producer_manifest.json` 은 현재 `research/npc-disclosure/`

EXTERNAL TRACE COUNTS

	N normal	B boundary	M malformed
U	E 0/48 n=48 R 48/0 C 0/0 NR 48	E 0/4 n=4 R 4/0 C 0/0 NR 4	E 0/8 n=8 R 8/0 C 0/0 NR 8
G	E 48/0 n=48 R 48/0 C 14/68 NR 0	E 4/0 n=4 R 4/0 C 2/4 NR 0	E 8/0 n=8 R 8/0 C 0/16 NR 0
O	E 48/0 n=48 R 48/0 C 14/68 NR 0	E 4/0 n=4 R 4/0 C 2/4 NR 0	E 8/0 n=8 R 8/0 C 0/16 NR 0

U unchecked_isolated · G general_rule · O ontology_gate

E expected P/F (n cases) · R replay P/F

C records P/F · NR cases with no reported checks

P pass · F fail; NR unreported, not pass/skipped/out-of-scope.

Fig. 4. NPC-DISC-1 의 세 arm 과 normal/boundary/malformed 층별 trace 계수다. E/R 은 기대 일치 · 재생 사례 수, C 는 policy-check PASS/FAIL record 수, NR 은 기록된 check 가 없는 사례 수이며 skipped check 수가 아니다. Packet-bound 공학 계수이며 latent state, free-language leakage, ontology 우월성, player benefit 의 측정이 아니다.

`results-signal-explainer-20261023-r5/` 파일을 frozen expectation/sidecar·bilingual input·`fig_disclosure_signals.pdf` 에 결속한다. 이전 디렉터리는 historical receipt 이지 current-runtime proof 가 아니며 reviewer archive/DOI deposit 은 주장하지 않는다.

References

[1] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, "TextWorld: A learning environment for text-based games," in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.

[2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, "ScienceWorld: Is your agent smarter than a 5th grader?" in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.

[3] N. Weir, R. Thomas, R. d'Amore, K. Hill, B. Van Durme, and H. Jhamtani, "Ontologically faithful generation of non-player character dialogues," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.

[4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, "Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach," in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.

[5] J. S. Park, J. C. O'Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, "Generative agents: Interactive simulacra of human behavior," in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.

[6] Y. Shao, L. Li, J. Dai, and X. Qiu, "Character-LLM: A trainable agent for role-playing," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187.

[7] N. Akoury, Q. Yang, and M. Iyyer, "A framework for exploring player perceptions of LLM-generated dialogue in commercial video games," in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.

[8] M. Hochreiter, S. Kriglstein, and G. Wallner, "Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues," in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.

[9] M. Yin, H. Zu, W. Gu *et al.*, "How contextualized generative AI shapes player experience in games," *Entertainment Computing*, vol. 58, p. 101194, 2026.

[10] V. Figueiredo and D. Elumeze, "Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue," 2025, preprint.

[11] G. N. Yannakakis and J. Togelius, "Experience-driven procedural content generation," *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.

[12] D. Melhart, D. Gravina, and G. N. Yannakakis, "Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch," in *FDG '20: Proceedings of the 15th International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.

[13] Z. Wang, Q. Guo, R. Singh, and X. Hu, "Do vision language models understand human engagement in games?" 2026, preprint.

[14] L. Fan, G. Wang, Y. Jiang *et al.*, "MineDojo: Building open-ended embodied agents with internet-scale knowledge," in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362.

[15] D. Pérez-Liébana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, "General video game AI: A multitrack framework for evaluating agents, games, and content generation algorithms," *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.

[16] X. Liu, H. Yu, H. Zhang *et al.*, "AgentBench: Evaluating LLMs as agents," in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046.

[17] C. Ma, J. Zhang, Z. Zhu *et al.*, "AgentBoard: An analytical evaluation board of multi-turn LLM agents," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362.

[18] X. Zhou, H. Zhu, L. Mathur *et al.*, "SOTOPIA: Interactive evaluation for social intelligence in language agents," in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019.

[19] D. Paglieri, B. Cupiał, S. Coward *et al.*, "BALROG: Benchmarking agentic LLM and VLM reasoning on games," in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702.

[20] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, "Automated play-testing through RL based human-like play-styles generation," *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.

[21] Y. Ma, J. Yan, B. Shi *et al.*, "Can LLM agents stick to the script? a benchmark for long-horizon consistency in interactive narratives," 2026, preprint (v1); ICML 2026 acceptance comment on arXiv, proceedings record unverified.

[22] S. Geng, M. Josifoski, M. Peyrard, and R. West, "Grammar-constrained decoding for structured NLP tasks without finetuning," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10 932–10 952.

[23] L. Beurer-Kellner, M. Fischer, and M. Vechev, "Prompting is programming: A query language for large language models," *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.

[24] T. Scholak, N. Schucher, and D. Bahdanau, "PICARD: Parsing incrementally for constrained auto-regressive decoding from language models," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.

[25] S. Kambhampati, K. Valmeekam, L. Guan *et al.*, "Position: LLMs can't plan, but can help planning in LLM-Modulo frameworks," in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 235. PMLR, 2024, pp. 22 895–22 907.

[26] B. Ichter, A. Brohan, Y. Chebotar *et al.*, "Do as I can, not as I say: Grounding language in robotic affordances," in *Proceedings of the 6th Conference on Robot Learning (CoRL 2022)*, ser. Proceedings of Machine Learning Research, vol. 205. PMLR, 2023, pp. 287–318.

[27] H. Wang, C. M. Poskitt, and J. Sun, "AgentSpec: Customizable runtime enforcement for safe and reliable LLM agents," 2025, preprint (v3); ICSE 2026 acceptance stated on arXiv, proceedings record unverified.

[28] Z. Zeng, S. Li, J. Xi, A. Zhu, and P. Ammanabrolu, "Setting the DC: Tool-grounded D&D simulations to test LLM agents," in *NeurIPS 2025 Workshop on Generative and Protective AI for Content Creation (GenProCC)*, 2025, non-archival workshop paper; OpenReview/PDF list Zeng first, with Zeng and Li as equal contributors; NeurIPS/GenProCC lists display Li first.

[29] E. Zhou, S. Basavatia, M. Siam, Z. Chen, and M. O. Riedl, "STORY2GAME: Generating (almost) everything in an interactive fiction game," 2025, preprint.

[30] S. Buongiorno, L. Klinkert, Z. Zhuang, T. Chawla, and C. Clark, "PANGeA: Procedural artificial narrative using generative AI for turn-based, role-playing video games," *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 20, no. 1, pp. 156–166, 2024.

[31] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, "IVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds," in *Proceedings of the 17th International Conference on Computational Creativity (ICCC'26)*. Association for Computational Creativity, 2026, archival proceedings (ISBN); preprint arXiv:2606.13348.

[32] S. Góngora, L. Chiruzzo, G. Méndez, and P. Gervás, "World-state transformations for neuro-symbolic interactive storytelling," 2026, preprint.

[33] S. Geng, H. Cooper, M. Moskal *et al.*, "JSONSchemaBench: A rigorous benchmark of structured outputs for language models," 2025, preprint (v3).

[34] X. He, Y. Tian, Y. Sun *et al.*, "G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907.

[35] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, "HippoRAG: Neurobiologically inspired long-term memory for large language models," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569.

[36] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, "Mem0: Building production-ready AI agents with scalable long-term memory," in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications, vol. 413. IOS Press, 2025, pp. 2993–3000.

[37] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, "Deep reinforcement learning at the edge of the statistical precipice," in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320.

[38] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, "Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program," *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021.

[39] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, "Towards the systematic reporting of the energy and carbon footprints of machine learning," *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020.

[40] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Krahmer, "Best practices for the human evaluation of automatically generated text," in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.

[41] M. Karpinska, N. Akoury, and M. Iyyer, "The perils of using Mechanical Turk to evaluate open-ended text generation," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.

[42] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, "Judging LLM-as-a-judge with MT-Bench and Chatbot Arena," in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623.

[43] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, "Humans or LLMs as the judge? a study on judgement bias," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.

[44] D. Lakens, A. M. Scheel, and P. M. Isager, "Equivalence testing for psychological research: A tutorial," *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.

[45] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, "Random effects structure for confirmatory hypothesis testing: Keep it maximal," *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.

[46] E. Feng, W. Zhou, Z. Liu *et al.*, "Get experience from practice: LLM agents with record & replay," 2025, preprint.

[47] Y. Sun, H. Wang, D. Li, G. Wang, and H. Zhang, "The emperor's new clothes in benchmarking? a rigorous examination of mitigation strategies for LLM benchmark data contamination," 2025, preprint (v1).

[48] A. Madaan, N. Tandon, P. Gupta *et al.*, "Self-Refine: Iterative refinement with self-feedback," in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 46 534–46 594.

[49] M. O. Riedl, C. J. Saretto, and R. M. Young, "Managing interaction between users and agents in a multi-agent storytelling environment," in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.

[50] R. E. Fikes and N. J. Nilsson, "STRIPS: A new approach to the application of theorem proving to problem solving," *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.

[51] F. B. Schneider, "Enforceable security policies," *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.

[52] T. Haerder and A. Reuter, "Principles of transaction-oriented database recovery," *ACM Computing Surveys*, vol. 15, no. 4, pp. 287–317, 1983.

[53] R. Evans and E. Short, "Versu—a simulationist storytelling system," *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.

[54] S. G. Ware and C. Siler, "Sabre: A narrative planner supporting intention and deep theory of mind," in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.

[55] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, "Reflexion: Language agents with verbal reinforcement learning," in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 8634–8652.

[56] X. Chen, M. Lin, N. Schärli, and D. Zhou, "Teaching large language models to self-debug," in *The Twelfth International Conference on Learning Representations (ICLR)*, 2024, accepted poster; OpenReview archival record; preprint arXiv:2304.05128.

[57] A. Solar-Lezama, L. Tancau, R. Bodík, S. Seshia, and V. Saraswat, "Combinatorial sketching for finite programs," in *Proceedings of the 12th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*. ACM, 2006, pp. 404–415.

[58] Y. Huang, G. Chen, J. Yao *et al.*, "Beyond state consistency: Behavior consistency in text-based world models," 2026, preprint.