TRACE-RPG: 출처 결속 온톨로지 근거와 대화형 게임의 단일 Codex 통합 사례

익명 저자

***Abstract*—TRACE-RPG 은 생성 게임 이벤트에 외부 권한 검사, typed-error repair, unchanged fallback, 재검증, replay, complete accounting 을 결합한다. 읽기 전용 한 · 영 ontology view 는 source 선언과 공개 관측만 연결한다. Codex dashboard 한 사례 (n=1, independent repeats 0) 는 `gpt-6.1-sol` 선택, geometry 수리, 실패 보존, 검사 62 개, Godot Web build, 실제 입력 거절 · 공개 · 재표시를 기록한다. 이 단일 개발 사례의 seed 는 미상이다. 고정 게임 native pilot 은 8 assigned/7 observed/5 system-goal successes; 첫 행은 pre-response harness JSON serialization 기술 실패로 재실행하지 않았고 `gpt-6.1-sol`/ontology 두 행은 response timeout 이다. Receipts 는 host invocation 23, repair 0, unsafe/commit 0/16, semantic-link replay 7 valid, fresh-engine VALID/INVALID/NOT_RUN/NOT_OBSERVED=6/0/1/1 을 보였다. Provider identity/revision/cost/request count 와 inference latency 는 미상이며 source 수정 confound 가 있다. 이는 bounded 관측이지 A/C 확인적 평가가 아니며 ontology 일반 일관성 · 우월 · 비열등성, frontier 등급, 다중 벤더 일반화 · 인간 편익을 추론하지 않는다. Traceability·whole-game·repeated-cross-model 연구는 제안이다. Native pilot 의 seed 는 20261024 다. 별도의 합성 v5 개발 수집에서는 배정 20/20 개에 응답을 받았고, 8/20 개가 strict gate 를 통과했으며 7/20 개가 지정 목표에 도달했고 10/20 개가 schema parsing 에 실패했다. 모든 배정을 포함한 기술적 계수이며 피드백의 인과 효과나 모델 우월성을 입증하지 않는다.**

***Index Terms*—게임 인공지능, 인터랙티브 내러티브, 기호 검증, 제약 생성, 재현성**

I. 서론

생성 이벤트는 없는 아이템, 미지 사실, 금지 공개, 비인가 효과, 단계 후퇴를 낳을 수 있다. 개연성과 quest/entity grounding 은 실행 전이 ·mutation 권한이 아니며 [1], [2], [3], [4]. 상태 변경은 TRACE-RPG 의 외부 결정론적 gate 만 허가한다 (그림 1).

본 연구의 기여는 범위가 명시된 proposal-to-commit 통합과 근거 계수 설계다. 수리 정보는 후보를 바꿀 수 있지만 동일한 외부 저작 제약에 대한 재검증만 상태 변경을 허가하며, 관측된 검사와 replay 의 증거 한계는 서로 구분한다. C1–C5 는 이 계약과 근거를 정리하며 구성 알고리즘의 발명이나 입증된 모델 우위를 주장하지 않는다.

Table I은 **C1—계약**, **C2—검증/수정**, **C3—감사 연결**, **C4—배정 계수**, **C5—수정 안내**의 증거 · 추론 한계를 묶는다.

II. 관련 연구와 연구 공백

Grounding/개연성은 quest/entity·graph quest·memory–reflection–planning· 학습형 role 을 다루고, player/dialogue·role 은 admissibility/experience 를 분리한다 [3], [4], [5], [6], [7], [8], [9], [10]; engagement affect 는 미래 · 비구현 · 비권위다 [11], [12], [13]. 여기서 다루는 설계 질문은 출처 결속 proposal-to-commit 경로 안에서 상태 변경 권한, 수리 정보, replay 근거를 어떻게 구분할 것인가이며, 선행 연구에 이 구성 요소가 없다는 주장은 아니다.

TABLE I
기여, 선행 주제, 근거 레인, 추론 상한 (구조화 매트릭스에서 생성)

ID	기여	선행 주제 (참고 문헌 수)	레인	추론 상한
C1	신뢰경계 contract	T1, T2, T3 (17)	E1, ENG1	인코딩 필드 계약 적합성
C2	validate–repair–commit controller	T1, T8 (14)	E1, ENG1	동결 사례의 메커니즘 동작
C3	감사 연결 근거 계층	T4, T7, T8 (6)	E1, ENG1	명명 fixture 의 무결성 · 재생
C4	assignment-complete harness	T1, T4, T6, T7 (20)	E1	설계 사례 정확 집계
C5	반례 유도 연산자 ρ	T1, T8, T9 (8)	E1	동결 offline repairability class

T1 = 근거 게임 세계; T2 = 검색 · 메모리 에이전트; T3 = 구조 생성; T4 = 환경 · 벤치마크; T5 = 플레이어 경험; T6 = 인간 ·LLM 평가; T7 = 통계 · 재현성; T8 = 계획 · 런타임 개입; T9 = 피드백 수리. 레인은 표 V에 정의한다. 모든 행은 구현 · 작성 fixture 검증 상태이며 어떤 효능 claim 도 지지하지 않는다.

TextWorld/ScienceWorld, MineDojo, GVGAI, AgentBench, AgentBoard, SOTOPIA, BALROG 와 자동 playtesting 은 state·embodied·agent/game-content· 과정 · 사회 · 장기 환경을 보완한다 [1], [2], [14], [15], [16], [17], [18], [19], [20]; NCP-Bench 는 narrative commitment/fact consistency 이지 player outcome 이 아니다 [21]. 구조 제약 ·critic·affordance·trigger rule·precondition/effect·rule refinement·incremental validation·authored transformation·JSONSchemaBench [22], [23], [24], [25], [26], [27], [28], [29], [30], [31], [32], [33] 는 우월성을 확립하지 않으며 G-Retriever/HippoRAG/Mem0 [34], [35], [36] 도 commit authority 가 없다.

재현성 · 평가는 frozen artifact· 실패 보존 ·construct/rater/bias control·justified margin/random effects 를 요구한다 [37], [38], [39], [40], [41], [42], [43], [44], [45]. Replay 와 leakage 검사는 배정 분모의 무결성을 뒷받침할 뿐 효능을 입증하지 않으며, replay 검사는 invalid nonfinal attempt 도 포함한다 [46], [47]. C1–C5 는 enforcement·game-state management·feedback repair·replay·action interposition·precondition/effect·abort·social logic·belief-aware planning 을 결합하지만 발명/최초성 주장은 아니다 [27], [28], [29], [48], [46], [49], [50], [51], [52], [53], [54].

III. 문제 정의와 보장 경계

입력 $c_t = (G_t, q_t)$ 는 typed game snapshot G_t 와 외부 저작 action-policy/disclosure/quest-stage 제약 q_t 를 구분한다. Python 은 둘을 `WorldState` 에 함께 담는다. locations, reachable locations, object locations, inventory, facts, NPC knowledge, quest stage 가 인코딩된 상태를 기술하고 action policies 와 forbidden disclosures 가 이를 제약한다.

익명 심사를 위해 작성한 원고입니다.

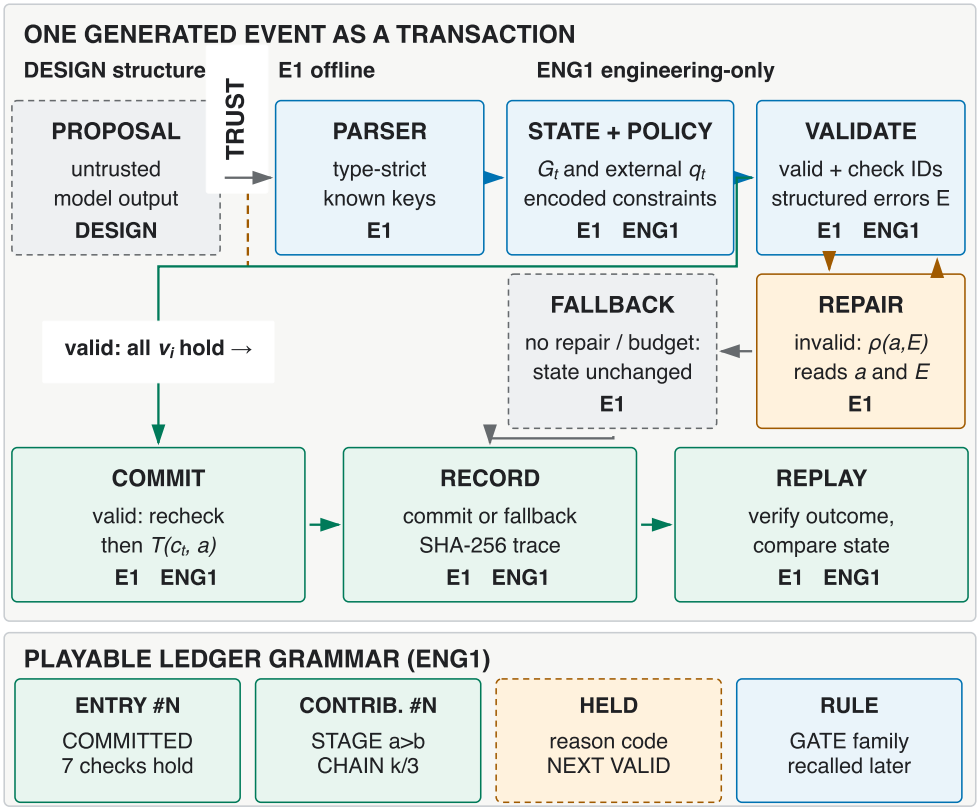


Fig. 1. 외부 policy 와 c_t 가 제안을 gate 하며 typed 오류는 bounded ρ(점선) 나 unchanged fallback 으로 이어진다. 통과 후보는 재검사 ·commit·record·replay 된다. 과거 코호트와 legacy ENG1 은 보존된 historical 자료이며 활성 모델 근거가 아니다. 아래 strip 은 committed-snapshot ledger 문법이다.

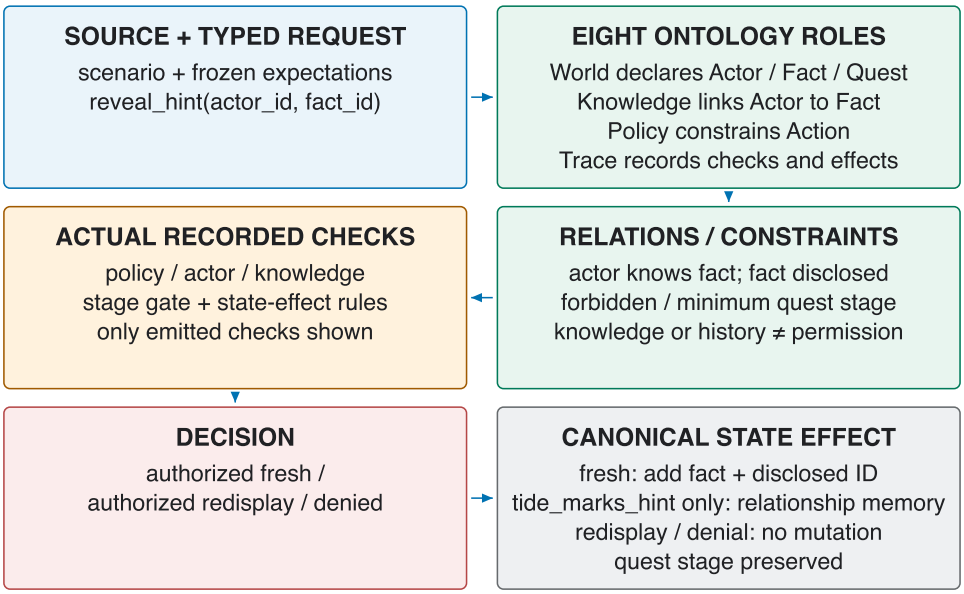


Fig. 2. 여덟 역할 온톨로지 구조 (표 III): World, Actor, Knowledge, Fact, Policy, Quest, Action, Trace 가 선언 source field 를 authored check 와 관측 결정에 연결한다. 승인된 전이만 canonical state 를 바꾸며, 도식은 live capture 나 hidden-state 근거가 아니다.

`ActionPolicy` 는 required preconditions, allowed/required effects, 허용된 quest-stage target 을 정의한다. 이 분리는 개념적이며 Python 이 두 독립 객체를 저장한다는 뜻이 아니다. Predicate 는 terminal history $h_{<t}$ 나 log 에서 `WorldState` 를 복원하지 않으며 수락 전이는 G_t 만 바꾸고 policy rotation 은 제외한다. Retrieval·score·rationale·memory·future affect 는 비권위적이다.

비신뢰 제안 a_t 를 엄격 parsing 한 후 다음은 validator 반환의 문자 그대로의 Python 타입이 아닌 개념적 표현이다.

$$\begin{aligned} V(c_t, a_t) &= (\boldsymbol{v}, E_t), \\ \boldsymbol{v} &= (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, \\ &\quad v_{\text{disc}}, v_{\text{elig}}, v_{\text{stage}}) \in \{0,1\}^7, \end{aligned} \tag{1}$$

여기서 E_t 는 구조화 오류이고 일곱 비트는 차례로 policy, precondition, reachability, NPC knowledge, forbidden disclosure, stage eligibility, stage monotonicity 를 뜻한다. Python 은 일곱 Boolean 결과가 아니라 `ValidationResult(valid, errors, checks_run)`, 즉 단일 validity flag, code/entity/reason/repair hint 를 가진 오류, 일곱 검사 ID 를 반환한다. 검사 ID 는 실행을 뜻할 뿐 별도의 검사별 결과 관측을 뜻하지 않는다. trace 나 필드가 없으면 통과도 실패도 아닌 미관측이다. 다음 식은 원래 제안의 전체 transaction 이 아니라 단일 현재 후보에 대한 gate 다. 여기서 a_t 는 수리로 바뀔 수 있는 현재 후보이며 $\boldsymbol{v}$ 는 변경되지 않은 c_t 에 대한 해당 후보의 검사 결과다. 거부된 시도는 c_t 를 그대로 두고 제어는 bounded repair 또는 fallback 으로 이어지며, 동일 policy 에 대한 재검증 통과만 상태 변경을 허가한다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_{i=1}^{7} (v_i = 1), \\ c_t, & \text{그 외.} \end{cases} \tag{2}$$

실제 경로는 제안 → 결정론적 검증 → 관측 가능한 validity·검사 ID· 구조화 오류 → 선택적 bounded repair → 동일 상태에 대한 재검증 → commit 또는 상태 불변 fallback 이다. 유효 후보도 적용 직전에 다시 검사하며 repair 가 없거나 예산이 소진되면 상태는 불변이다. 아래 guided repair operator 는 제안과 오류만 사용하지만 일반 Python repair callback 에는 `WorldState` 가 전달되므로 이 입력 제한을 모든 callback 의 성질로 일반화하지 않는다. 통제 비교에서는 결정론적 상세 수정과 모델 기반 상세 수정에 동일 제안과 상세 오류를 제공하고 같은 모델의 일반 오류 조건에는 일반 시그널을 제공한다. 이 설계 자체는 비교 결과를 뜻하지 않는다.

Fixture 는 다음 불변량을 시험하며 증명은 아니다. **I1:** validation 소진/commit 전 proposal·controller 실패 불변; **I2:** callback 과 $K \geq 0$ 에서 최대 $K+1$ attempt 와 pre-commit 재검증 (무 deadline wall-clock 보장 없음); **I3:** 수락 `CandidateAction.effects` 는 승인 quest-stage target 을 포함해 `ActionPolicy.allowed_effects` 안임; **I4:** 기록된 초기 스냅샷, 완전하고 순서가 보존된 전이 기록, 동결된 schema 및 결정론적 transition version 이 주어지면 replay 로 기록된 종단 구조화 상태를 복원할 수 있다. 이는 조건부 상태 복원이지 인증, 의미적 정확성 또는 모델 생성 과정의 재현이 아니다.

가정은 올바른 policy· 충실한 추출 ·deterministic version· 반환 callback· 단일 프로세스 파일 소유다. Replay 는 구조화 전이만 검사하며 repair provenance/prompt/확률 생성/미선언 자연어 함의는 검사하지 않는다.

TABLE II
인코딩된 Validator 경계

술어	거부 대상	실패 시 상태
Action policy	알 수 없는 action/type; policy-required preconditions/effects 누락; 비허용 effects 또는 비인가 quest-stage effects	변경 없음
Precondition	누락/거짓 requirement	변경 없음
Reachability	접근 불가 object	변경 없음
NPC knowledge	선언되지 않은 known fact	변경 없음
Disclosure	forbidden fact	변경 없음
Quest stage (`quest_stage`)	required stage 가 current stage 보다 높음	변경 없음
Quest-stage monotonicity (`quest_stage_monotonicity`)	regressive stage	변경 없음

IV. TRACE-RPG 아키텍처와 알고리즘

A. 신뢰 경계와 계약

모델/adapter 는 제안만 하며 parser 는 모호한 type/unknown key 를 거부하고 policy 가 precondition/effect 를 정의한다. Versioned bridge 는 observation/proposal/validation/rejection/fallback/commit 을 전달하며 unknown-key parity 는 전체 parser 동등성 · 상용 portability 가 아니다. Python 일곱 개의 결정론적 검사 ID 는 `action_policy`, `precondition`, `object_reachability`, `npc_knowledge`, `forbidden_disclosure`, `quest_stage`, `quest_stage_monotonicity`; Godot 여섯 상태 상대 계열/DISC 일곱 rule 은 비동형이고 `QUEST STAGE` display family 하나가 두 Python quest check 를 포괄한다.

1) 여덟 역할 구조와 *source binding:* 읽기 전용 `game-track/web/dashboard/ontology-map.json` 은 선언/frozen expectation 만 결속하고 live state/권한은 추론하지 않는다. 표의 I 는 `initial_state` 다. Ontology view, repair information, mutation authority 는 분리된다. 표 III의 `reveal_hint(actor_id,fact_id)` 에서 view 는 `tide_marks_hint`/stage-2 policy 를 보이고 guided operator 는 a_t, E_t 만 읽어 predicate 를 삽입할 뿐 `WorldState` 를 읽지 않는다. 일곱 검사 통과만 T 에 도달해 Godot 이 commit 하며 최초 공개 revision $+1$, 재표시는 불변이다.

B. 고정 목표 *NPC* 통합

`npc-goal-recovery/1.1.0` 에서 Codex 는 intent 제안, Python 은 public claim/plan 검사, Godot 만 상태 쓰기를 맡는다. 항구 복구/승인 조석 단서 목표는 model-editable 이 아니다. Write binding 은 session, epoch, request, scenario, NPC, goal, version, policy/config hash, revision/state hash, deadline/budget, issued action 이다. Service 는 loopback `127.0.0.1:8768`, browser origin 은 `localhost`/`127.0.0.1:8877` 이다.

1) NPC-DISC-1 공개 계약과 권위 경계*:* 선언 유도형 NPC-DISC-1 `reveal_hint` 의 60 개 사례는 과거 `verified-run-006` 분모를 재실행 · 확장하지 않는다. 생성 결과/표 X–XII는 strata·binding· 입력-검사 매핑을 명시하고 Godot 만 service binding 재검사/상태 변경을 맡긴다.

TABLE III
여덟 온톨로지 역할과 구체적 source 관계

역할	Source field 또는 관계 예시
World	I.`world.object_locations`: `signal_lens`→`lamp_store`.
Actor	I.`npcs.captain_mira`; `scope.eligible_actor_ids` 의 유일 원소.
Knowledge	Actor 의 `knowledge`→canonical Fact ID; 지식은 허가가 아니다.
Fact	I.`facts`: `dock_saved`, `lighthouse_dark`; `keeper_betrayal` 은 ID 이지 비밀 payload 가 아니다.
Policy	`disclosure_policy`: `keeper_betrayal` 금지; `tide_marks_hint` 는 최소 quest stage 2 필요.
Quest	I.`quest`: stage 0, flag `dock_saved`; 공개는 stage 불변.
Action	`reveal_hint(actor_id,fact_id)` 는 Fact/disclosed ID 를 추가하며 조석 단서만 relationship memory 를 추가한다. 최초 공개는 revision $+1$; 재표시는 불변이다.
Trace	`prior_state_hash`, `next_state_hash`, `rule_ids`, `template_id`, `case_id` 가 packet/version 을 근거에 결속하며 누락은 PASS 가 아니다.

1: $a \leftarrow \text{Propose}(c)$; $j \leftarrow 0$
2: **repeat**
3: $(\text{ok}, E) \leftarrow V(c, a)$; Record$(a, E)$
4: **if** ok **then**
5: **assert** $V(c, a)$.ok; **return** Commit(c, a)
6: **if** $j = K$ **then return** Fallback(c)
7: $a \leftarrow \text{Repair}(c, a, E)$; $j \leftarrow j + 1$
8: **until terminal**

Fig. 3. Validate–repair–commit 절차. 최대 $K + 1$ 개의 candidate attempt 를 기록하며, 성공 경로는 상태 변경 전 방어적 validation 을 수행한다.

C. Validate–Repair–Commit

그림 3의 무의존성 의사코드에서 Record 는 in-memory append, 영속 쓰기는 종단 일관성 검사 뒤다. (ok, E) 는 V 와 ok $:= \bigwedge_{i=1}^{7}(v_i = 1)$ 의 축약이며 $V(c, a)$.ok 는 재검증이다.

Repair 는 상태를 바꾸지 않으며 소진 시 unchanged fallback 을 반환한다. Typed-error 연산자 (`counterexample_guided_repair`) 는 후보 a 와 오류 E(유일한 상태 유래 입력) 만 읽고 authoritative `WorldState` 는 읽지 않는다.

$$\rho(a, E) = a \oplus \bigcup_{e \in E} \delta(e), \tag{3}$$

표 IV의 $\oplus$ 는 결정론적 $\delta(e)$ 를 적용한다: 오류 entity 당 한 field, 시도당 최대 $|E|$, 요구 · 거부 충돌 불변. 고정점은 동일 E 조건이지 수렴이 아니다. 비배포 state-reading oracle 은 오류 대신 상태에서 precondition/effect/두 quest-stage field 를 복원하고 required object/used fact/disclosed fact 삭제로 위반을 세탁하지 않는다.

D. 무결성, 의미적 리플레이, 계수

키 없는 SHA-256 link 는 writer identity/공동 재작성을 막지 않는다. Replay 는 prior state/candidate/validation parsing, invalid nonfinal attempt, 종단 상태 재계산 · 일치, JSONL continuity 를 요구하며 repair 는 재실행하지 않는다. Request⟶decision⟶result 와 first-issued-action/exactly-one-receipt 는 duplicate ID/authentication 을 막지 않는다. Terminal 은 commit/symbolic fallback/adapter failure/controller failure 이며 마지막은 state/assignment 를 보존한다. Pre-execution key 는 run, arm, scenario, seed, model, revision, configuration/input/prior-state hash 를 결속하고 집계는 duplicate/missing/unexpected key 를 거부 · 분리한다.

TABLE IV
유도 연산자 ρ 의 오류 class 별 edit

Validator 오류 class	후보에 대한 edit $\delta(e)$
정책 precondition 누락	명명된 predicate 삽입
정책 effect 누락	명명된 effect 삽입
정책 effect 위반	명명된 effect 제거
불충족 precondition	명명된 predicate 제거
비인가 stage 변이	`quest_stage_effect` 초기화
알 수 없는 action type	no-op (등록된 대안 없음)
도달 불가 object; knowledge, disclosure, stage class	no-op (후보 국소 edit 은 세탁이거나 상태 지식 필요)

TABLE V
실험 레인 요약: 설계, 단위, 비교, 추론 상한 (실험 매트릭스에서 생성)

레인	설계	단위 / 예산	비교	상한
E1	오프라인 적합성: 작성 · 동결 fixture, 단일 world	gate 13; arm 당 repair 12; fault 10; adapter 7; guard 3	reject / blind / ρ / oracle	메커니즘 적합성
E3	KG/온톨로지 시뮬레이션: closed-world typed-link holdout	node 43; 참조 edge 106; typed 24; score 210	degree baseline / 고정 전략 6 종	구성 결과만
ENG1	Engineering-only Godot/Web: 엔진 로컬 policy mirror, 참여자 없음	fixture 4; check 52; smoke 8; archetype 5	작성 fixture 경로	엔진 로컬 engineering-only 적합성

E1, E3, ENG1 은 서로 대체할 수 없으며 분모가 다르다. 역사적 E2 receipt 는 활성 생성에서 제외된다. 어떤 활성 레인도 모집단 효능, 모델 순위, 플레이어 경험, 런타임 검색 효익, 상용 엔진 성능을 확립하지 않는다.

V. 실험 레인과 근거 경계

근거는 세 수준으로 pooling 하지 않는다: Level 1 authored finite-case mechanism/conformance(E1 gate·repairability fixture), Level 2 authored closed-world construction simulation(E3 graph-edge-withheld target 6 개), Level 3 historical NPC conformance(ENG1/NPC-ENG1/NPC-SCR1) 와 단일 bounded assisted development observation(DEV-CASE). 각 수준은 실패/stale control 을 보존하며 다른 질문에 답해 model/efficacy 추정치가 아니다.

A. *E1* 오프라인 적합성 설계

PQ1–PQ5 는 불변성, frozen-class repair, checksum/semantic/linkage/continuity fault, second-append rollback, fail-closed assignment/adapter/manifest 계수, proposal/replay unknown-key 거부를 시험한다.

Gate fixture 는 13 개 (valid 1/negative 12), repair fixture 는 12 개다. 결과는 모든 arm 을 *guided-repairable*(오류 충분), *oracle-only*(상태 필요), *irreparable*(commit 불가) 로 구분하며 latency/token 은 accounting 이지 population/detector 성능이 아니다. Packet 은 fixture/assignment/schema/result/code 를 결속한다 [38], [39].

TABLE VI
동결된 타입 링크 holdout 에서의 시뮬레이션 전용 제안 전략 평가

전략	정밀도	재현율	MRR	Brier	Sem@3
S0 degree baseline	0.000	0.000	0.282	0.315	0.556
S2 typed-lexical	1.000	1.000	0.944	0.131	1.000

B. 보존된 *live-screening* 자료

보존 live-screening 은 immutable provenance/hash 일 뿐 활성 표 · 계수 · 주장에서 제외하고 `gpt-6.1-sol` 에 이전하지 않는다.

C. ***NPC-ENG1*** 고정 목표 *engineering* 레인

Stable v5 는 engineering assignment 16 개와 screening recipe 12 개 ($12 \times 2 \times 3 = 72$; $R/P/O = 40/24/24$) 로 bootstrap 해 identity/hash, intent/plan/role/result, negative/stale/duplicate/deadline/replay 를 시험한다. P 는 authenticated Codex OAuth without fallback, O 는 100% auxiliary-source(not independent gold) 다. Status/count/latency/reproduction 은 `research/academic-pipeline/npc-goal-recovery/verified-run-006/` 에 있고 verified-run-002/003/004 는 historical 이다. ENG-X01/SCR-X01, D02/QA-001, C-RESULT, Frozen8/Frozen16, v1–v4, `native012` 는 C6 근거가 아닌 provenance 다.

D. ***NPC-SCR1*** 기술적 스크리닝

NPC-SCR1 $12 \times 2 \times 3$ P/R/O row(72; arm 당 24) 에 ENG1 을 더하면 88 assignment/28 definition($R/P/O = 40/24/24$) 이며 ENG1/E1 과 별개다. 실패 strata, recovery-eligible/unreachable, P/R/O· 미상 metadata· 실패/stale-ACK/epoch-local replay 를 보존한다. O 의 same-family 일치는 미검증, auxiliary-source 100%, independent gold 없음. ENG-X01/SCR-X01, D02/QA-001, C-RESULT, Frozen8/Frozen16, v1–v4, `native012` 는 provenance 이지 C6 근거가 아니다.

E. ***E3*** *KG/*온톨로지 링크 제안 시뮬레이션

E3 는 engineering-only, non-authoritative authored closed-world 시뮬레이션이다. Graph-edge-withheld authored target 6 개는 고정 strategy 7 개의 채점 · 선택 · 요약에 쓰이며 untouched/external test 가 아니다. **범위.** 이 표는 설계된 closed-world 링크 복원 결과이며 런타임 KG 검색, 의미 완전성, 장기 모순 감소 또는 어떤 효능 주장의 근거도 아니다. 결정론적 방법론 그래프는 graph node 43 개, reference edge 106 개, curated typed edge 24 개를 포함하며 온톨로지 검사를 모두 통과한다. 생성 표는 구성 결과이며 OWL/SHACL 적합성, runtime retrieval, 의미 완전성 · 효능을 확립하지 않는다.

VI. 파일럿 결과

A. 구조 필드 게이트 적합성

loader 는 valid control 1 개와 구현 validator code 별 1 개 고립 fixture 만 허용한다. 따라서 13/13 일치와 12 개 implemented code 관찰은 하니스 구성 불변량이지 성공률이 아니다. 음성 fixture 12 개는 작성된 기대 code 와 일치해 다른 code 가 아니었고 비 commit 경로는 정준 상태를 보존했다. 이는 단일 world state 의 structured-field oracle conformance 이며 독립 semantic-label 정확도가 아니다.

TABLE VII
E1 오프라인 적합성: 수리 가능성 class 별 정확 count (설계 fixture)

Arm	정보원	Commit / 사례			평균 수정 [e]
		G-rep.[f]	O-only[f]	Irrep.[f]	필드 수
Rejection-only (K=0)	없음	0/5	0/1	0/6	—
블라인드 retry	없음	0/5	0/1	0/6	—
Validator-error-guided ρ	오류 집합 E	5/5	0/1	0/6	1.0
상태 판독 oracle	권위 상태 + 정책	5/5	1/1	0/6	1.0

[e]Commit 된 수리의 변경 candidate field 평균 개수 (최소성 proxy); 실패한 arm 실행은 상태를 변경하지 않았다. E1 은 처음부터 invalid 한 12 개 설계 case 를 사용하며 rejection-only/blind 는 0/12, 0/12, validator-error-guided ρ 는 5/12, state-reading oracle 은 6/12 commit 이다. [f]Commit/사례 수. G-rep. = guided-repairable, O-only = oracle-only, Irrep. = irreparable(동결 repairability class); 모집단 효능이나 live-model 품질을 뜻하지 않는다.

B. 설계 픽스처에서의 수리 *arm* 비교

12 개 initially invalid case 의 frozen class 는 guided-repairable 5 개, oracle-only 1 개, irreparable 6 개다. Rejection-only 와 blind unchanged-candidate retry 는 각각 0/12 commit. validator-error-guided ρ 는 같은 class 순서로 5/5, 0/1, 0/6 를 commit 하고 평균 1.0 개 field 를 수정했다. 직전 candidate 와 typed validator error E 만 읽는 ρ 에서 error 가 유일한 state-derived input 이며 실패 arm 은 정준 상태를 보존한다. State-reading reference callback 은 같은 순서로 5/5, 1/1, 0/6 를 commit 했다. Blind 는 error 를 commit 으로 못 바꾸고, ρ 는 payload-sufficient 만, oracle 은 state-knowledge case 까지 바꾼다. commit 된 guided case 5 건이 처음 받은 validator code 는 각각 `POLICY_PRECONDITION_OMISSION+UNSATISFIED_PRECONDITION`, `POLICY_EFFECT_OMISSION`, `POLICY_EFFECT_VIOLATION`, `UNSATISFIED_PRECONDITION`, `POLICY_QUEST_STAGE_EFFECT_VIOLATION` 이며, 각 case 는 표 IV의 해당 edit $\delta(e)$ 만으로 유효해졌다. Frozen-fixture conformance 이지 live-model repair quality 가 아니다.

C. 무결성, 경계, 배정 회계

Prespecified detectable fault 10 개는 designated check 에서 모두 거부됐다 (10/10); stable typed detector-code 비교가 없어 detector attribution 은 없다. Provenance boundary fixture 는 같은 recorded valid repair 앞의 invalid precursor 를 바꾸고 checksum 을 재계산해 replay 를 통과했다 (1/1 미검출): replay 는 repair generation 을 인증하지 않고 unkeyed checksum 재계산 작성자를 막지 못한다. 두 open sentinel—unextracted narrative disclosure 와 required object 의 candidate·policy 동시 누락—은 encoded layer 에서 허용됐다 (2/2); safety pass 0 건. Former unknown-top-level acceptance 는 closed regression 이 되어 proposal·replay parser 가 unknown key 하나의 완전한 12-field candidate 를 거부했다 (1/1); parser rejection parity 이지 semantic safety 가 아니다. 7 개 assignment: commit 1, symbolic fallback 1, adapter failure 5; synthetic telemetry 는 2/7 에서 populated·propagated 됐다 (schema-pinned accounting, not measurement). injected 중복 · 누락 assignment guard 3/3 는 fail closed 했고, 모두 synthetic offline fixture raw count 다.

TABLE VIII
E1 오프라인 적합성: 동결 파일럿 검사와 종단 결과 (행 간 직접 비교 불가)

검사 또는 종단군	정확 결과	해석 범위
게이트 fixture 일치	13/13	저자 oracle 일치
알려진 경계 허용	2/2	인코딩 한계, safety pass 아님
닫힌 unknown-key 거부	1/1	proposal/replay parser parity
탐지 가능 무결성 결함 거부	10/10	지정된 검사 연산
알려진 provenance 경계 허용	1/1	repair 생성 출처 미인증
Adapter 종단 class	1 commit; 1 fallback; 5 실패 / 배정 7	배정 7 건의 분류 완전성
Manifest guard 거부	3/3	주입 결함 fail-closed

행마다 분모와 성공 방향이 다르므로 비율처럼 순위를 비교하지 않는다. 모든 값은 설계 픽스처의 정확한 감사 사실이다.

D. 고정 목표 *NPC* 운영 *(NPC-ENG1/NPC-SCR1)*

Mira 의 고정 목표는 항구 신호 복구 후 허가된 조석 단서를 제공하는 것이다. Python 은 typed intent/공개 관측으로 bounded BFS 계획을 계산하고, 획득 · 설치는 플레이어가, NPC 는 허가된 `reveal_hint` 만 수행한다. Godot 은 session/epoch/request/goal/policy/revision/hash 를 동기 검사한 뒤 기존 writer 를 await 없이 호출하며, 결과 · 새 관측으로 다음 계획을 정한다 (단일 후보 validator-error repair 와 다름).

NPC-ENG1 은 실제 엔진 snapshot 에서 시작한 결정론적 R-arm engineering 사례 16 개 (assigned_failure=2, completed=14) 이며, NPC-SCR1 은 P/R/O 각 24 개씩 총 72 개 배정 · 실패를 보존한다 (assigned_failure=12, completed=60). P 는 인증된 Codex CLI 실행 24 회, 반환 decision 24 개, assigned failure 4 개를 기록하며 원격 과금 호출 수는 아니다. 요청 모델: 알 수 없음 (null); decision 에 기록된 모델 식별자: 알 수 없음 (null). 후자는 설정된 selector 이지 provider revision 이 아니다; provider revision 은 사용할 수 없고 null 식별자는 미상으로 남긴다. 전역 설정은 모델 식별 근거가 아니다. R 은 작성된 규칙을 사용한다. O 는 `same_model_family_auxiliary` 로 선언된 protocol auxiliary 일 뿐이다. 실제 모델 계열 일치는 unverified(검증되지 않음). 독립 원본은 0 개이며 O 는 oracle 이나 semantic gold 가 아니다. 표 IX은 bounded protocol-conformance 고정 사례의 기술적 계수이지 회복 효능 · 우월성 · 일반화 추정이 아니다; efficacy 는 pending, 토큰 · 비용은 미측정이다. 읽기 전용 CLI 와 격리 작업 디렉터리를 사용했지만 tool-free 추론과 적대적 기밀성은 검증하지 않았다. 2026-10-17 의 보관 source bytes (revision fa9fb8a) 로 immutable verified-run-006 을 재검증한 역사적 packet 결과이며, 현재 checkout NPC runtime 이나 current release authority 를 인증하지 않는다. 검증된 사전 작성 stale-control ACK 거부는 arm 별 P=4, R=4, O=4 건 (SCR-T01 (stale_revision), SCR-T02 (stale_policy)) 이며, 12 개 인스턴스 모두 대응하는 음성 대조 gate 가 모두 통과했다. 이 행들은 분모의 assigned failure 로 남되 method-performance 결과로 해석하지 않으며, 기타 assigned failure 0 개는 미분류로 남긴다. 재현 검증은 내보낸 epoch 내부에 한정되며 (`intent_lineage_scope=epoch_local_only`), epoch 간 의도 연속성을 입증하지 않는다 (`cross_epoch_intent_continuity_proven=false`). 불투명한 연속 지점 예외는 양의 epoch snapshot 의 인접한 선두 observation 요청 ·decision 쌍에만 적용하며, epoch 0 의 고아 관측, 그 밖의 의도 확정 전 관측 요청, 후속 의도 불일치는 계속 거절한다.

TABLE IX
NPC-SCR1 고정 사례 실행 계수. NPC-ENG1 의 16 개 사례와 분리하며 모든 실패를 분모에 보존한다.

Arm	배정	완료/실패	목표 도달	회복 E/U
P	24	20/4	4	24/0
R	24	20/4	4	24/0
O	24	20/4	4	24/0

E: 회복 평가 가능, U: 도달 불가; NA: 미측정. 목표 관측 계수는 회복률이 아니다. Replay 적합성은 실패 행을 완료로 바꾸지 않는다. O 의 독립 원본은 0 개다.

E. 동결된 *`reveal_hint`* 계약과 공개 증거

이 산출물은 동결 기대값 패킷 `sl-npc-disclosure-expectations-v1` (v1.0.0) 과 네 개 실제 결과 파일만 읽는다. 패킷 SHA-256 `9920aa834910a3ee35ed4446de4fdba42bb67dda71b07a93bccfc7a0b2e09028` 는 sidecar 와 대조했다. 선언식 `1 eligible actor x 4 declared fact IDs x 3 declared stage values x 2 knowledge values x 2 prior-disclosed values` 의 정상 분모는 48 개이며, 경계 4 개와 잘못된 입력 8 개는 제외한다. Trace 기대값은 gate 출력이 아닌 packet case ID 로 대조한다.

내용 우선 설명은 typed input(연산 · 행위자 ·fact·stage·knowledge·prior-disclosed) 을 ontology entities/relations 와 authored rules 에 통과시켜 check, allowed/denied 결정, canonical state effect 를 기록한다. 허용된 최초 표시는 요청 fact 만 (조석 단서의 선언된 relationship-memory 항목도) 추가하고 stage 를 보존하며 revision 을 한 번 증가시킨다. 거부 · 기공개 재표시는 canonical state 를 보존한다. 설명용일 뿐 hidden fact· 자연어 함의 ·live capture 를 주장하지 않는다.

온톨로지 선언은 `sl-npc-disclosure-expectations-v1:runtime-disclosure` / v1.0.0, provenance 는 `frozen_expectation_packet` 이다. 범위는 네 canonical fact ID(dock_saved, keeper_betrayal, lighthouse_dark, tide_marks_hint) 와 행위자 `captain_mira` 뿐이다. 규칙 ID: DISC-001, DISC-002, DISC-003, DISC-004, DISC-005, DISC-006, DISC-007; 승인 template 은 `mira-safe-deflection-v1` 및 `sl-rc-003-authorized-hint` 뿐이다.

Python evaluator 는 같은 사례 · 기대 객체를 세 격리 arm 에 materialize 하고 semantic outcome, check trace, error, 전후 state SHA-256, template ID, replay equality 를 기록한다. Godot 은 별도 game-execution 경계에서 기존 `reveal_hint` writer 와 canonical mutation 을 소유하며, 이 producer 는 state 를 재구성하거나 대체하지 않는다. 연결은 operation `reveal_hint`, scenario `sealed-lighthouse-v1`, actor `captain_mira`, bound source hash 로 추적한다. 실행 시점 관측 hash 는 현재 source 와 일치한다. 동결 패킷 baseline 과 다른 source 는 3 개 (game-track/godot/scripts/game3d/game_3d.gd, game-track/godot/scripts/sealed_lighthouse_machine.gd, llm-wiki/wiki/reports/2026-10-22-ontology-signals-interview.md) 이며, 패킷 hash 는 수정하지 않고 이 차이를 공개한다.

표 XI는 같은 60 개 사례의 세 arm 을 정상/경계/잘못된 입력 분모로 보고하며, unchecked 위반은 의도된 격리 관측이다. 검증된 general-rule 과 ontology-gate arm 은 저작된 사

TABLE X
동결된 reveal_hint 계약의 구조 · 내용 · 규칙 ID 와 실제 결과 provenance.

Field / 항목	Value / 값
Operation / 연산	reveal_hint
Scenario / 시나리오	sealed-lighthouse-v1
Normal denominator / 정상 분모	48
Boundary / 경계	4
Malformed / 잘못된 입력	8
Canonical facts / 정형 사실	dock_saved, keeper_betrayal, lighthouse_dark, tide_marks_hint
Eligible actor / 적격 행위자	captain_mira
Ontology / 온톨로지	sl-npc-disclosure-expectations-v1:runtime-disclosure
Rule IDs / 규칙 ID	DISC-001, DISC-002, DISC-003, DISC-004, DISC-005, DISC-006, DISC-007
Templates / 템플릿	mira-safe-deflection-v1; sl-rc-003-authorized-hint

기대값은 gate 출력에서 유도하지 않았고, 표의 분모는 동결 선언에서 읽었다.

례 전체에서 결과가 동일하다 (60/60). rule-change fixture 집합에는 두 arm 을 가르는 discriminating case 가 없으며, 2 개 fixture 의 4 개 paired case 가 모두 일치한다. 이는 공유 동결 규칙 아래 authorization-conformance limit 이며 일반적 ontology equivalence 또는 ontology superiority 의 증거가 아니다. 그림 4는 E/R(기대 일치 · 재생 사례), C(check-record PASS/FAIL), NR(보고된 check 가 없는 사례) 를 구별한다. NR 은 skipped/pass/out-of-scope 가 아니다. 표 XII는 rule-change fixture 와 paired case 를 disposable clone 에 매핑하며 shipped scenario 는 바꾸지 않는다.

주장은 bounded engineering conformance 에 한정된다. human gold, access-separated holdout, efficacy, superiority, generalization, player benefit, model latent state, cost 는 주장하지 않는다. 정확한 입력 경로 ·hash· 재생성 명령은 `paper/latex/generated/disclosure_producer_manifest.json` 에 결속된다.

Disclosure `t_ms`/hash/check 는 engine timeline 이다. Missing ≠ out-of-scope.

ENG1. Godot 4.7.1 은 authored rejection/commit 을 prior/offline hash 로 replay 한다 (no live transport). Capture 는 presentation-only 로 board/hint/coach/chain prompt 와 dashboard checks 를 보인다. Core 52/52 와 extension 4 개는 engine-local conformance 이지 transport, participant, narrative, usability, efficacy 근거가 아니다.

F. 단일 과제 *Codex* 개발 관측

동결 `ontology-map-20261023-01` 은 읽기 전용 한 · 영 dashboard 한 과제 (n=1, independent repeats 0) 이지 NPC trial/cohort 가 아니다. Native CLI 6 회 (initial + resume 5; read-only/no-edit 1) 는 한 사례다. `turn_context.model=gpt-6.1-sol` 은 runtime 선택이지 provider attestation 이 아니며 provider identity/revision/seed/cost 는 `null`, model-only latency 는 미상이다. Wall-clock 5942.665 s 와 CLI 263.32 s 는 inference latency/future endpoint 가 아니다.

여섯째 호출은 inherited mobile table 최소 너비 660 px 를 수리했다. Independent geometry RED(2 실패/35 통과) 후 cell/paragraph 포함 map/signal/Web 62/62 와 Godot Web build 가 통과했다. 실제 입력 browser attempt 10 통과; 01–08 setup/route 실패, 09 이전 gate 통과/clipping 보존. 최종 $(\text{seq}, t_{\text{ms}})$: stage-0 거부 $(68, 19468)$(hash 동일), 최초 공개 $(239, 58234)$(상이), 승인 재표시 $(249, 59793)$(동일). 1440×900/390×900, Enter, inspection/frozen-comparison 불변과 pre-navigation console/page/network 오류 ·warning 0 을 관측했다. Dated QA10 PASS 와 additive overall **NOT_PASS** 는 별개 (구성 gate 7 개 통과; pointer-lock/yaw-guard 및 pointer-lock page error 4 개 잔존). Full-game creation/Python–Godot authorization round trip/모델 결과가 아닌 제한된 통합이며 privacy/source-binding 실패와 동일 thread 수리는 추가

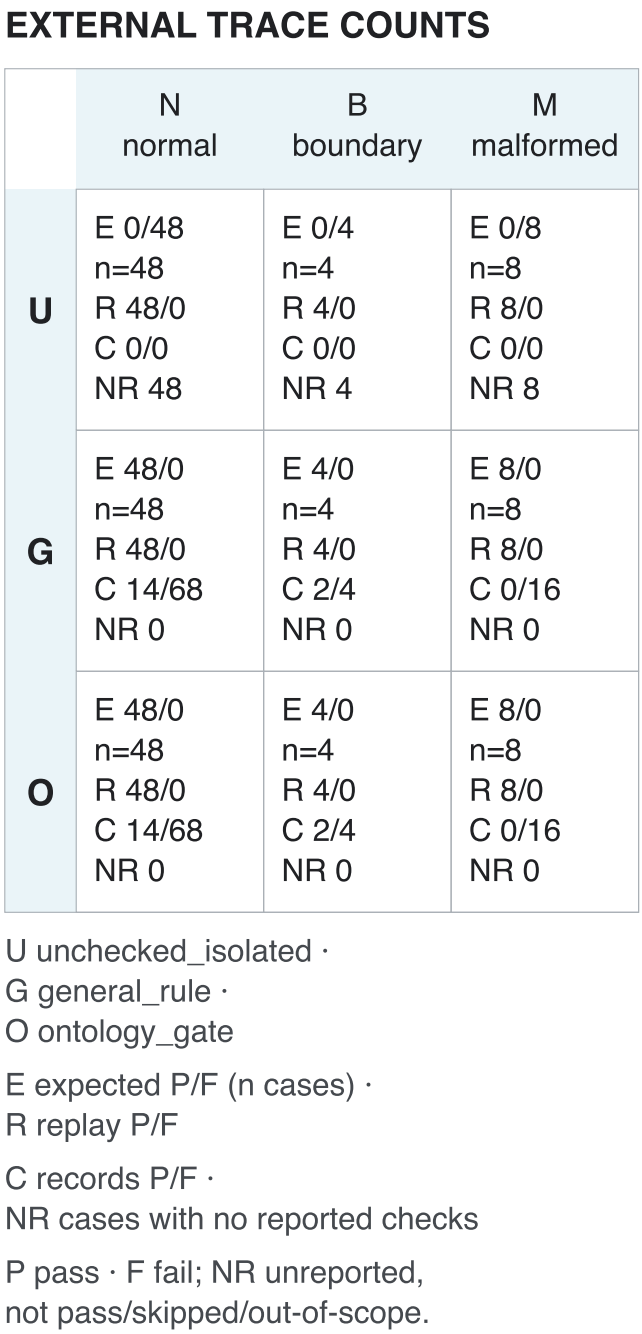


Fig. 4. NPC-DISC-1 arm/stratum 별 계수. E/R: 기대 일치/재생, C: policy-check PASS/FAIL, NR: check 기록 없음 (skipped 아님). Packet-bound 공학 계수이지 latent state, free-language leakage, 온톨로지 우월성, player benefit 측정이 아니다.

TABLE XI
세 disclosure arm 의 raw trace 관측 계수; 정상/경계/잘못된 입력 분모를 분리한다.

Arm	n (N/B/M)	Allow/Deny	Semantic mismatch	State/Display fail	Replay fail	Unique unsafe
unchecked_isolated	48/4/8	60/0	60	0/0	0	51
general_rule	48/4/8	16/44	0	0/0	0	0
ontology_gate	48/4/8	16/44	0	0/0	0	0

N/B/M = normal/boundary/malformed. 의미 불일치는 전체 기대 결과와의 차이이고, 고유 위험 사례는 무허가 허용 또는 재표시 상태 변경의 합집합이다. 허용된 최초 공개의 표현 불일치만으로 위험 사례에 포함하지 않는다. 무검사군은 격리된 관측이며 효능 · 우월성 · 일반화 결과가 아니다.

TABLE XII
규칙 변경 fixture 의 paired-case traceability 와 수정 범위; shipped scenario 는 변경하지 않는다.

Fixture	Mutation	Paired cases	Changed paths	Missed cases	Match
RC-001-stage-gate-2-to-1	disclosure_policy.stage_gates[0].minimum_stage 2→1	N-043, N-044	disclosure_policy.stage_gates[0].minimum_stage	none	PASS
RC-002-forbid-tide-marks-hint	disclosure_policy.permanently_forbidden ['keeper_betrayal']→['keeper_betrayal', 'tide_marks_hint']	N-047, N-048	disclosure_policy.permanently_forbidden[1]	none	PASS

두 fixture 는 general_rule 과 ontology_gate 에 같은 변경을 적용한다. missed case 가 없고 mutation_scope_preserved 가 true 인 경우만 PASS 이다.

n 이 아니다. Jev 는 label/approval 권한 없는 `proposal_only` 다. 보고서/계약: `research/development-cases/ontology-map-20261023-01/result.json`, `contract.json`.

G. 고정 게임 *native runtime* 비교

이 공개 결과는 하나의 authored quest(`sealed-lighthouse-v1`) 에 대해 seed 20261024, selector 당 representation 별 반복 2 회의 8 개 배정 행을 보존한다. 시스템 endpoint 성공은 5/8 이고, 관측된 native 실행은 7 개이다. 실제 receipt 에서 집계한 host 호출은 23 회이며, 관측된 repair 합은 0 이다. committed transition 은 16, 그중 unsafe 는 0 이며, semantic replay valid/invalid/NR 은 7/0/1 이다. fresh-engine reexecution 처분은 VALID=6; INVALID=0; NOT_RUN=1; NOT_OBSERVED=1 이다. elapsed 관측은 n=7; 48.19/41.09 초 (평균/중앙값), preparation 관측은 n=7; 6.67/6.30 초이다. 보고되지 않은 값은 0 이 아니라 NR 이다.

첫 행은 harness JSON serialization 기술 실패로 유지되어 GPT-6.1 능력에 귀속하지 않는다. GPT-6.1 ontology 에서 response-timeout 행 2 개 이상을 frozen 60 초 경계 안의 실패로 보존한다. 모델은 typed-intent proposal 만 담당하고 deterministic Python planner/checker 와 Godot commit 이 권한을 유지한다. 따라서 이 표는 한 quest 의 기술적 관측이며 efficacy, superiority, noninferiority, 일반 ontology 일관성 또는 player benefit 을 주장하지 않는다. semantic record-link replay 만으로 fresh-engine reexecution 을 주장하지 않는다. provider identity/revision/cost 와 provider request 수는 공개 관측 경계를 넘어 NR 이다.

H. 별도의 신호 탐색 사례

탐색 영수증 (`research/signal-exploratory-20261110T023502Z-cbf0c3b7/receipt.json`) 은 앞의 결과 및 사전 지정 파일럿과 별개인 합성 `missing_effect` 사례 1 건을 기록한다. 공통 제안은 필수 효과 `signal_restored` 를 누락했다. 결정적 대조는 한 번의 수리 후 commit 되었고, commit 된 상태에 해당 사실이 포함되어야 한다는 독립 지정 목표에 도달했다.

두 모델 조건은 각각 한 번의 시도가 기록되었으며 서로 다른 정보량의 신호를 받았다. 상세 신호는 오류, 누락된 효과와 수리 힌트를 명시한 반면 일반 신호는 `Action rejected.` 만 전달했다. 상세 조건의 응답은 효과를 추가하여 재검증 후 commit 과 목표 도달로 이어졌고, 일반 조건의 응답은 빈 효과를 유지하여 재검증에 실패하고 목표에 도달하지 못한 채 fallback 되었다. 이 대비는 단일 사례의 기술적 관측이며 정보량을 맞춘 비교, 인과 또는 통계 근거, 연구 전체 결과, 질문 A 나 C 의 답이 아니다. 요청 모델은 `gpt-6-luna` 였으나 실제 응답 모델의 신원, 비용, 제공자 요청 횟수와 재시도 횟수는 미상이다. 입력의 공개 여부 검증은 완료되지 않았다. 영수증에는 전체 프롬프트와 실행 코드 버전이 담겨 있지 않아 이 실행을 정확히 재현할 근거가 부족하다.

I. 별도의 합성 개발 파일럿

요청 selector `gpt-5.6-luna` 와 `gpt-5.6-terra` 각각에 대해 별도의 합성 개발 파일럿은 10 개 배정을 계획했다. 첫 상세 `missing_precondition` 배정은 `protocol_error` 로 `FAILED` 기록되었고 나머지 9 개는 pending 이며 유효한 모델 응답은 0 개였다. 첫 실패 후 수집을 중단했다. 오류 원문은 민감한 데이터를 포함할 수 있어 보존하지 않았고 원인은 미상이다. 요청 송신 또는 제공자 응답 수신 여부, 실제 제공자 모델 신원과 비용은 확인되지 않았다. 이 허구의 개발 사례들은 holdout 이나 인간 평가가 아니며 앞의 단일 사례 및 다른 연구와 별개다. 완료된 성능 비교, 확증 결과, 모델 자체의 실패 또는 미지원, 통계적 효과를 입증하지 않는다. 근거: `research/codex_feedback_pilot/codex-feedback-pilot-v2-evidence-20261110-luna/results.json`, `research/codex_feedback_pilot/codex-feedback-pilot-v2-evidence-20261110-terra/results.json`.

별도의 diagnostic cohort 는 selector 당 10 개 배정을 계획했다. Terra 는 첫 상세 `missing_precondition` 배정을 `protocol_error` 로 `FAILED` 기록했고 9 개는 pending 으로 남았다. Luna 의 첫 상세 배정은 사례 기록에 `IN_PROGRESS` 로 남아 있고 다른 9 개 행은 pending 이며, 집계 status 는 10 개 모두를 pending 으로 센다. 운영자는 프로세스가 없다고 보고했다. 송신 여부와 종료 원인은 미상이며 미완료 행을 성공으로 해석하지 않는다. 이 diagnostic 기록은 앞선 시도와 합산

TABLE XIII
고정 게임 native runtime 비교 (n=2/셀). 기술 실패와 timeout 을 포함한 원래 8 개 배정 행을 분모에 보존한다.

요청 selector	표현	목표/배정	관측 실행	Host 호출	Unsafe/Commit	Elapsed 중앙값 (n)	Fresh engine
gpt-6.1-sol	general_rule	1/2	1	4	0/3	45.91 (1)	1/0/0/1
gpt-6.1-sol	ontology	0/2	2	3	0/1	72.35 (2)	1/0/1/0
gpt-5.6-sol	general_rule	2/2	2	8	0/6	40.24 (2)	2/0/0/0
gpt-5.6-sol	ontology	2/2	2	8	0/6	33.11 (2)	2/0/0/0

Fresh engine 은 VALID/INVALID/NOT_RUN/NOT_OBSERVED 순서의 건수이다. NR 은 미보고이지 0 이 아니다. 전체 계수와 semantic replay 의 구분은 본문에 보고한다.

하지 않으며 모델 성능이나 미지원을 입증하지 않는다. 근거: `research/codex_feedback_pilot/codex-feedback-pilot-v2-diagnostic-20261110-terra/results.json`, `research/codex_feedback_pilot/codex-feedback-pilot-v2-diagnostic-20261110-luna/results.json`.

과거 파일 계수. 완료/실패/pending 배정 행 수는 최초 파일럿 $0/7/3$, 초기 selector/native 파일 4 개 $0/0/40$, 초기 v2 쌍 $0/0/20$, startup diagnostic $0/2/18$, v3 쌍 $0/0/20$, v4 Luna $10/0/0$(상세 목표 $4/5$, 일반 목표 $4/5$), Terra $0/1/9$ 이다. 위의 v2 evidence/diagnostic 계수는 Luna 의 `IN_PROGRESS` 스냅샷을 포함해 그대로 유지한다. 이 묶음은 파일 계수용이지 합산된 독립 표본이나 제공자 요청 수가 아니며 pending 행은 요청이나 모델 실패를 입증하지 않고 v4 와 v5 도 별개로 둔다. 실제 응답 모델 신원, 비용, 제공자 요청 횟수는 미상이다. 안전한 투영 `research/codex_feedback_pilot/public-history-20261111/cohort-inventory.json` 은 코호트별 계수와 로컬 원본 digest 를 보존할 뿐 원본 공개나 독립 실행 재현성을 제공하지 않는다.

J. 새로운 *v5 paired-selector* 개발 수집

이번 새로운 v5 수집은 이전의 모든 미완료 및 diagnostic cohort 와 별개다. 각 요청 selector 는 합성 개발 fixture 5 개를 상세 및 일반 신호 조건으로 받았다 (selector 당 배정 10 개). 명목상 고정 직렬 순서는 Luna 다음 Terra 였다. 배정 20 개 모두 응답을 수신했으며 pending 은 없지만 응답 수신은 과제 성공이 아니다. 표 XIV는 strict validator gate 통과, 독립 지정 목표 달성, schema 실패를 구분하며 각 cell 의 분모는 배정된 5 개 전체다.

동결된 수집 amendment 에 따라 schema 가 유효하지 않은 응답은 실패 배정이자 목표 실패로 남지만 adapter 완료가 입증되면 다음 배정의 수집을 계속한다. 실제 transport 또는 safety 실패는 여전히 수집을 중단한다. Gate 통과는 목표 달성과 다르며 Luna 상세 조건에서 통과한 사례 1 개는 목표에 도달하지 못했다. 다섯 fixture 는 `missing_precondition`, `missing_effect`, `unauthorized_objective`, `forbidden_disclosure`, `unsatisfied_dependency` 이다. `unauthorized_objective` 에서는 동결된 `signal` policy 가 어떤 효과도 허용하지 않지만 공통 목표는 `signal_restored` 를 요구한다. Luna 의 상세 피드백 응답은 금지된 효과를 제거하여 승인되었으나 해당 목표에는 도달하지 못했다. 이 policy·목표 충돌 사례를 포함한 다섯 배정을 각 분모에 그대로 유지한다. 소규모 합성 개발 집합은 holdout, 인간 평가 또는 인과 연구가 아니며 상세/일반 신호의 정보량도 다르다. 실제 응답 모델의 신원/revision, 제공자 요청 횟수와 비용은 미상이다. 이 관측은 selector 우월성, 온톨로지 효능 또는 A/C 확증을 입증하지 않는다.

공개 결과 투영은 `research/codex_feedback_pilot/public-v5/` 아래 `paired-model-comparison-20261110-v5-gpt-5.6-luna/` 와 `paired-model-comparison-20261110-v5-gpt-5.6-terra/` 디렉터리에 둔다. 각 `results.json` 은 모든 사례 결과, prompt hash, 실행 파일 hash/version 을 유지하되 로컬 실행 경로를 생략하고 원본 파일 digest 와 생략 필드를 명시한다. 동결 원본 결과와 승인 자료는 로컬에 변경 없이 보존한다. 한 단계 위의 공통 불변 `paired-model-comparison-20261110-v5-source.zip` 은 실행된 소스 7 개를 보존하는 출처 스냅샷이지 독립 실행 배포본은 아니다. 이 v5 수집에서는 성공적으로 파싱된 `response_text` 는 보존하지만 자격 증명이나 민감한 서버 데이터가 포함될 수 있어 CLI stdout/stderr 원문은 보존하지 않았으며 바이트 수, digest, 이벤트 요약은 남아 있다. 실패 배정 열 건은 null evaluation 과 함께 `CandidateParseError/evaluation_error` 로 기록되어 있으므로 보존된 산출물만으로 내용 수준의 원인을 확정할 수 없다. 이 실패들은 모든 배정 분모에 그대로 포함하며 수신이나 실패만으로 제공자 신원이나 모델 자체의 무능력을 입증하지 않는다.

그림 5은 게이트 검사 결과를 감정 추정이나 허가가 아닌 명시적 신호로 드러낸다. 상세 조건은 실패 검사와 수리 힌트를, 일반 조건은 거부만 전달한다. 두 응답에는 같은 strict parser, identity 검사와 7 개 predicate 를 적용한다. 이 v5 수집기는 일반적인 유한 수리 루프와 달리 추가 수리 호출이 0 회다. 그림 6는 모든 배정을 응답 수신, 파싱, gate 통과, 독립 목표 달성으로 추적하며 schema 실패와 gate 는 통과했으나 목표를 놓친 commit 도 표시한다.

K. 사전 지정된 두 트랙 파일럿

요청 패널은 Codex `gpt-5.6-sol`, Codex `gpt-6.1-sol`, Antigravity `gemini-3.8-flash-medium` 이다. 이들은 요청 selector 이지 실제 응답 모델의 신원 증명이 아니다. 제공자 간 medium 은 명목 설정이며 같은 연산량을 뜻하지 않는다. Runtime 은 3 개 target, 동일 정보의 2 개 표현, 10 회 fresh reset 을 교차한다 (60 개 단위, episode 당 180 s). 제한된 개발은 3 개 target, 최소 입력/공개 저장소 탐색, 같은 2 개 표현, 5 개 과제, 2 회 fresh run 을 교차한다 (120 개 단위, assignment 당 900 s). 예산 내 독립 검증 성공이 primary endpoint 이고 hard safety 는 별도 gate 다. 수집 전 protocol 에 seed, 순서, reset ID, repair 및 dispatch 한도를 보존했다.

전향 파일럿 상태: 모델 비교가 아님. 고정된 연구 `prospective-pilot-20261103` 는 요청된 세 target 에 걸쳐 180 개 단위 (런타임 60 개, 개발 120 개) 를 계획한다. 180 개 차단, 0 개 배정, 0 개 시도, 0 개 실행이며 native 프로세스 시작은 0 회이다. 상태 `NOT_RUN/BLOCKED`; 과학적 결론 `NOT_MET`.

TABLE XIV
별도의 v5 합성 개발 수집. 모든 분모는 schema 실패를 포함한 배정 5 개 전체이며 응답 수신은 과제 성공을 뜻하지 않는다.

요청 selector	신호	응답 수신	Strict gate 통과	목표 달성	Schema 실패
gpt-5.6-luna	상세	5/5	4/5	3/5	1/5
gpt-5.6-luna	일반	5/5	3/5	3/5	0/5
gpt-5.6-terra	상세	5/5	0/5	0/5	5/5
gpt-5.6-terra	일반	5/5	1/5	1/5	4/5

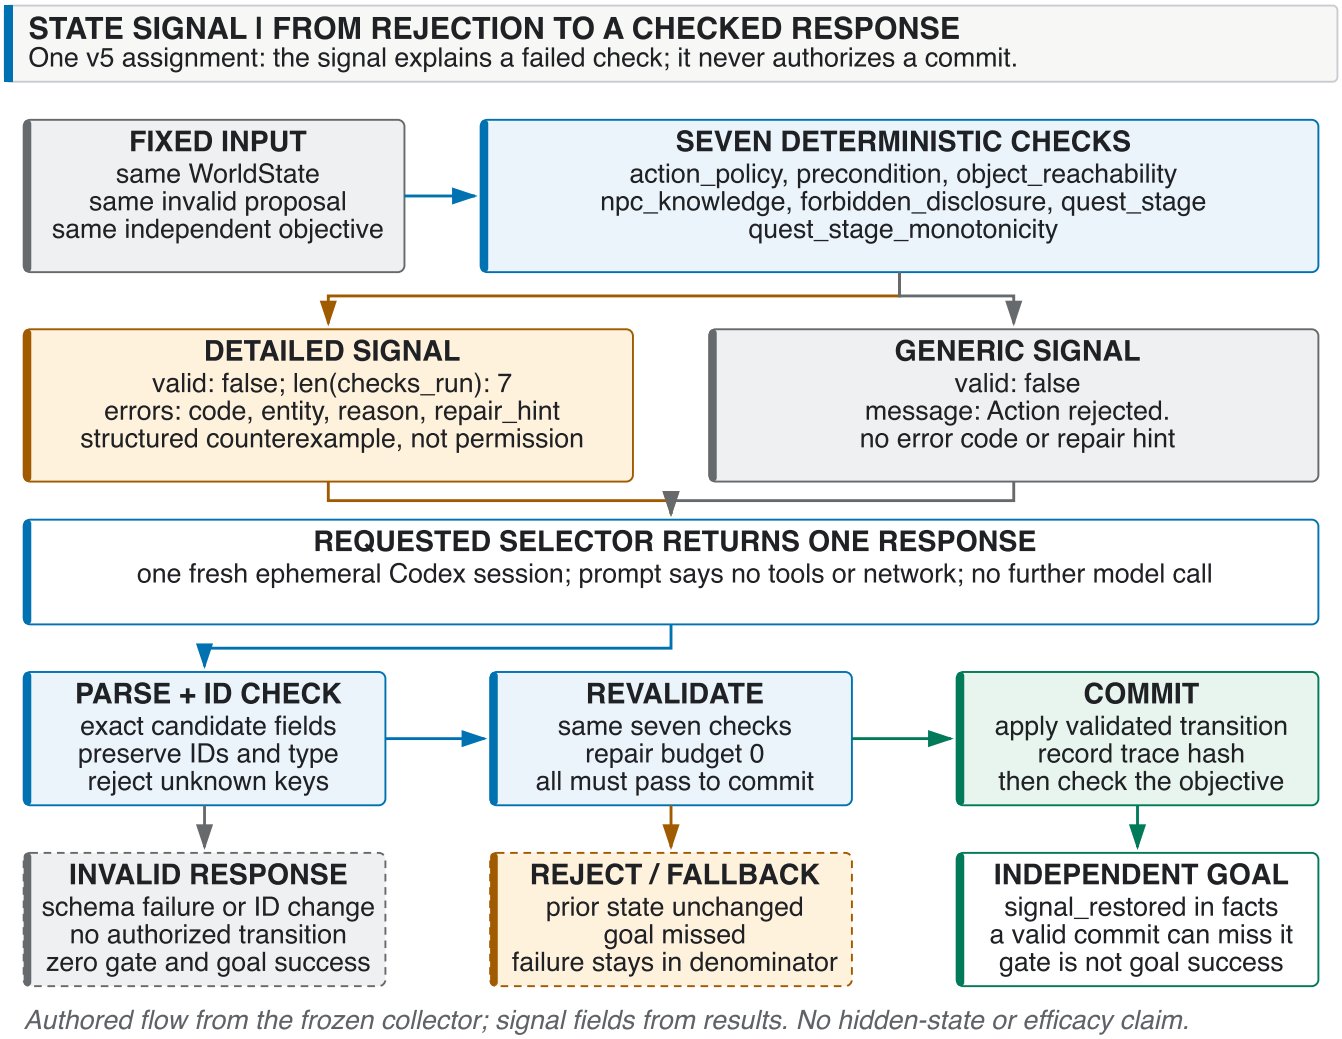


Fig. 5. 소스에서 유도한 v5 상태 시그널 경로. 구조화된 (ok, E) 검사 결과는 수리를 안내하지만 상태 변경은 재검증만 승인한다. 일반 신호는 오류 상세를 생략한다. 목표는 gate 통과와 별도로 검사하며 이 그림은 저작된 메커니즘 도해이지 효능 근거가 아니다.

성공률: null. 관측 비용: null (알려진 부분합 null; 비용을 알 수 없는 배정 단위 0 개). 효과 추정: null. null 은 측정이 없다는 뜻이며 0 이 아니다.

차단된 선결 조건 (단위별 집계): BLOCKED_ACTIVATION_ABSENT (180), BLOCKED_IDENTITY_FORMAT_UNOBSERVED (180), BLOCKED_ISOLATION_UNPROVEN (180), BLOCKED_LIVE_PATH_NOT_IMPLEMENTED (180), BLOCKED_NO_CREDIT_ENFORCEMENT (180), BLOCKED_PUBLIC_DERIVED_UNAPPROVED (180), BLOCKED_SCHEMA_ACCEPTANCE_UNOBSERVED (180), BLOCKED_TARGET_UNVERIFIED (60), BLOCKED_TASK_FREEZE_INCOMPLETE (180).

이전 8 행 5/8 파일럿, 중단된 신원 확장, Ollama 레인, 결정적 fixture, n=1 결과는 별도 레인이다. 여기서 합산하거나 다시 보고하지 않는다.

차단된 수집 snapshot 이후 독립 offline 검사는 5 개 과제 각각에서 정답 변형 2 개를 통과시키고 결함 원본과 그럴듯한 오답을 거부했다. 과제/코퍼스 누출 검사는 9303 개 파일에서 통과했다. 이는 모델 실행이 아닌 fixture control 이며 차단된 단위를 소급 승인하지 않는다. 포함한 공개 test 와 cross-language semantic mirror 를 고지하며 endpoint 는 완전한 게임 제작

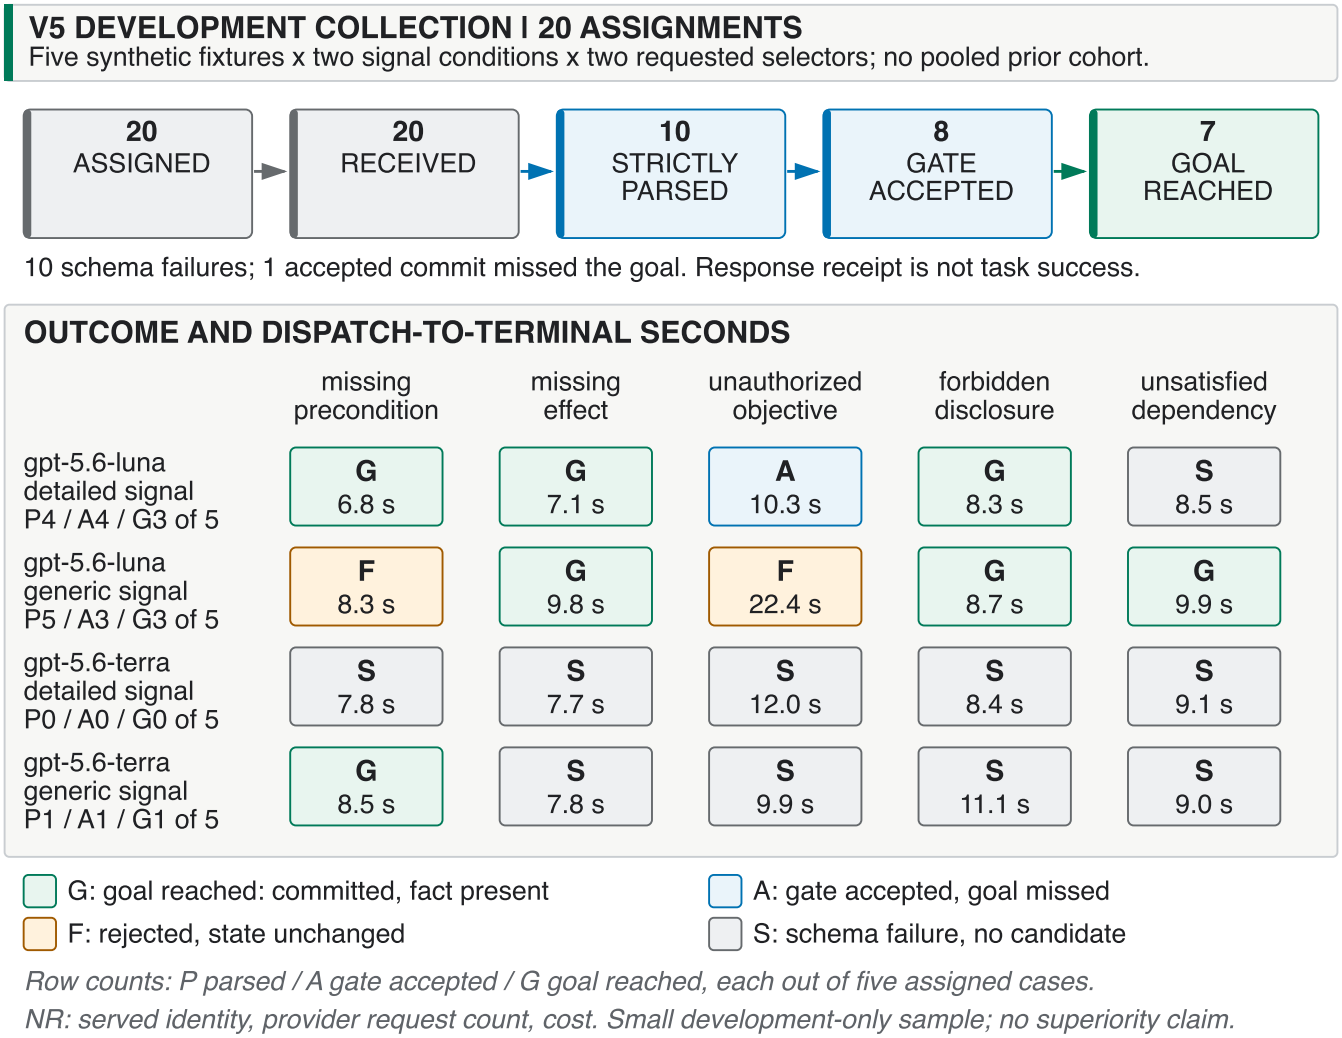


Fig. 6. 표 XIV와 같은 영수증에서 유도한 동결 v5 수집 흐름 및 배정 20 개 전체의 결과. Schema 실패 10 개도 분모에 남으며 통과 후보 8 개 중 목표 달성은 7 개다. 초 단위 값은 실패 응답을 포함한 dispatch-to-terminal 시간이지 모델 전용 지연이 아니다. 요청 selector 와 정보량이 다른 신호는 모델 우월성이나 온톨로지 효능을 입증하지 않는다.

이나 정상 target 원본 검색이 아닌 bounded repair 다. 이후의 task freeze 는 응답 결속 신원, credit 사용 방지, 격리, 새 activation 을 입증하지 않는다. 최신 agent 가 관련 skill, source, reference 를 모두 탐색한다는 가설은 미검증이며 탐색 허용은 실제 전수 탐색의 관측이 아니다. 현재 source 의 screenshot 은 presentation/state correspondence 만 입증한다.

VII. 논의

본 연구의 guided semantic repair 연산자 ρ [48], [55], [56], [57] 는 deterministic pre-execution 오류를 사용하고, oracle-only arm 은 상태를 읽는다. Frozen-case rule 일치/edit-scope 진단은 capability 나 ontology 우월성 증거가 아니다.

이 번 native runtime pilot 은 한 authored quest 에 서 요 청 된 `gpt-6.1-sol/gpt-5.6-sol`, `medium`, `general_rule/ontology` 를 condition 당 2 회 요청한 bounded observation 이다. 모델은 typed intent 만 생성하고 deterministic planner/checker 와 Godot 이 권위를 유지한다; source 수정 confound 와 provider identity/revision/request count/cost 미상이 남는다. 구현 교란: 첫 행은 controller-v3 에서 모델 응답 전에 직렬화 오류로 실패했다. 이후 행 2–8 은 모델에 보이는 입력을 바꾸지 않고 JSON 경계 한 줄을 수정한 controller-v4 를 사용했으므로 selector/representation 차 이 를 모 델 에 귀 속 할 수 없 다. 질 문 A(model/stack consistency) 와 C(fresh-reference noninferiority) 는 미 실 행 이 다. A 는 고 정 source/policy/replay 의 substituted model/stack budget-bounded goal completion, C 는 sealed assignment 의 candidate/fresh reference 비 교 다. Goal completion 은 safety/replay 와 다른 endpoint 이며, 둘 다 exact identity/revision 및 별도 safety/replay accounting 이 필요하다. 현재 pilot 은 답하지 않는다. 미래 제작 endpoint 는 matched request/evidence 부터 동결 mandatory check 를 모두 통과한 첫 receipt 까지의 time-to-first-all-predeclared-validation-pass 이며 unfinished/timeout/fail/stage-not-reached 에는 성공 시간이 없다.

부록 B의 별도 신원 검증 확장은 실제 응답 모델의 증거 누락으로 중단됐으며 신원이 검증된 새 비교 결과는 얻지 못했다.

VIII. 타당성 위협, 윤리, 산출물 범위

위협과 경계. State consistency 는 behavior/narrative coherence 를 입증하지 않는다 [58]. Predicate/role/Godot/DISC 집합은 latent-state vector 가 아니고 declaration expectation 은 human gold/holdout 이 아니다. Historical/활성 lane 은 분모가 달라 합산하지 않는다. Provider identity/revision/request count/cost 는 미상이고 source 수정 confound 가 있다. 참가자 · 정서 · 이해 ·agency· 즐거움 · 몰입 · 편익 ·population·safety-rate·model-ranking· 상용 성능을 추론하지 않는다. Unkeyed hash 는 authentication 이 아니며 replay equality 는 semantic correctness 가 아니다. 미래 human/affect 연구에는 review, consent, 보상 고지, 최소수집 · 보존 · 삭제, opt-out, calibrated judge 가 필요하다 [40], [41], [42], [43].

IX. 결론

TRACE-RPG 은 bounded C1–C5 authorization/repair/replay/accounting 과 출처 결속 한 · 영 observer 를 결합한다. 단일 Codex 사례는 실패 ·acceptance 경계를 보존하며 모델 성능 근거가 아니다. Native pilot 은 8 assigned/7 executed/5 system-goal successes 인 bounded observation 이며 A/C 확인적 평가 ·ontology/model 우월성 근거가 아니다. Time-to-first-all-predeclared-validation-pass·traceability·whole-game·repeated-cross-model 평가는 미래이고 historical cohort 는 합산하지 않는다.

AI 사용 고지

LLM 은 prose/code/test/citation check 를 보조하고 hosted model candidate 를 표기했다. Curated AI UI art/desk mesh 는 file provenance, rendered snapshot/hash/ledger 는 presentation-only 다. 저자가 source 를 대조하고 책임진다. NPC 입력/표는 assignment/project/protocol/schema hash 와 unknown token/cost/model-revision 을 보존한다.

데이터 및 코드 가용성

Implementation/build source, frozen packet, Godot slice, deterministic evaluation, 기계 검증 기여 · 참조 주제 · 실험 매트릭스: `research/academic-pipeline/`. Proposed rubric/codebook/source manifest: `research/traceability-scoring-20261023/`; prospective whole-game/repeated-cross-model plan: `research/development-comparison-20261023/`. Frozen disclosure expectation/sidecar/한영 input: `paper/latex/generated/disclosure_producer_manifest.json`. Standalone artifacts: `paper/latex/figures/fig_signal_comparison.pdf`, `paper/latex/figures/fig_npc_screening.pdf`; signal diagram/three-arm table 은 별도 역할이다. 이전 디렉터리는 historical receipt 이지 current-runtime proof 가 아니며 reviewer archive/DOI deposit 은 주장하지 않는다. Public runtime comparison JSON, traces, and integrity audit: `research/runtime-model-swap-20261024/codex-live-20261026/public-results-v1/`. 제안 · 미측정 Table XIV 는 `paper/latex/en/` 및 `paper/latex/ko/` 의 `traceability-supplement.pdf` 와 같은 이름의 `.tex` source 에 보존한다.

기존 8 개와 합산하지 않는 별도 신원 admission 자료: `research/runtime-model-swap-20261024/codex-identity-20261026/public-results-v1/`.

References

[1] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, "TextWorld: A learning environment for text-based games," in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.

[2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, "ScienceWorld: Is your agent smarter than a 5th grader?" in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.

[3] N. Weir, R. Thomas, R. d'Amore, K. Hill, B. Van Durme, and H. Jhamtani, "Ontologically faithful generation of non-player character dialogues," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.

[4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, "Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach," in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.

[5] J. S. Park, J. C. O'Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, "Generative agents: Interactive simulacra of human behavior," in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.

[6] Y. Shao, L. Li, J. Dai, and X. Qiu, "Character-LLM: A trainable agent for role-playing," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187.

[7] N. Akoury, Q. Yang, and M. Iyyer, "A framework for exploring player perceptions of LLM-generated dialogue in commercial video games," in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.

[8] M. Hochreiter, S. Krigl stein, and G. Wallner, "Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues," in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.

[9] M. Yin, H. Zu, W. Gu *et al.*, "How contextualized generative AI shapes player experience in games," *Entertainment Computing*, vol. 58, p. 101194, 2026.

[10] V. Figueiredo and D. Elumeze, "Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue," 2025, preprint.

[11] G. N. Yannakakis and J. Togelius, "Experience-driven procedural content generation," *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.

[12] D. Melhart, D. Gravina, and G. N. Yannakakis, "Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch," in *FDG '20: Proceedings of the 15th International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.

[13] Z. Wang, Q. Guo, R. Singh, and X. Hu, "Do vision language models understand human engagement in games?" 2026, preprint.

[14] L. Fan, G. Wang, Y. Jiang *et al.*, "MineDojo: Building open-ended embodied agents with internet-scale knowledge," in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362.

[15] D. Pérez-Liébana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, "General video game AI: A multitrack framework for evaluating agents, games, and content generation algorithms," *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.

[16] X. Liu, H. Yu, H. Zhang *et al.*, "AgentBench: Evaluating LLMs as agents," in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046.

[17] C. Ma, J. Zhang, Z. Zhu *et al.*, "AgentBoard: An analytical evaluation board of multi-turn LLM agents," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362.

[18] X. Zhou, H. Zhu, L. Mathur *et al.*, "SOTOPIA: Interactive evaluation for social intelligence in language agents," in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019.

[19] D. Paglieri, B. Cupiał, S. Coward *et al.*, "BALROG: Benchmarking agentic LLM and VLM reasoning on games," in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702.

[20] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, "Automated play-testing through RL based human-like play-styles generation," *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.

[21] Y. Ma, J. Yan, B. Shi *et al.*, "Can LLM agents stick to the script? a benchmark for long-horizon consistency in interactive narratives," 2026, preprint (v1); ICML 2026 acceptance comment on arXiv, proceedings record unverified.

[22] S. Geng, M. Josifoski, M. Peyrard, and R. West, "Grammar-constrained decoding for structured NLP tasks without finetuning," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10 932–10 952.

[23] L. Beurer-Kellner, M. Fischer, and M. Vechev, "Prompting is programming: A query language for large language models," *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.

[24] T. Scholak, N. Schucher, and D. Bahdanau, "PICARD: Parsing incrementally for constrained auto-regressive decoding from language models," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.

[25] S. Kambhampati, K. Valmeekam, L. Guan *et al.*, "Position: LLMs can't plan, but can help planning in LLM-Modulo frameworks," in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 235. PMLR, 2024, pp. 22 895–22 907.

[26] B. Ichter, A. Brohan, Y. Chebotar *et al.*, "Do as I can, not as I say: Grounding language in robotic affordances," in *Proceedings of the 6th Conference on Robot Learning (CoRL 2022)*, ser. Proceedings of Machine Learning Research, vol. 205. PMLR, 2023, pp. 287–318.

[27] H. Wang, C. M. Poskitt, and J. Sun, "AgentSpec: Customizable runtime enforcement for safe and reliable LLM agents," 2025, preprint (v3); ICSE 2026 acceptance stated on arXiv, proceedings record unverified.

[28] Z. Zeng, S. Li, J. Xi, A. Zhu, and P. Ammanabrolu, "Setting the DC: Tool-grounded D&D simulations to test LLM agents," in *NeurIPS 2025 Workshop on Generative and Protective AI for Content Creation (GenProCC)*, 2025, non-archival workshop paper; OpenReview/PDF list Zeng first, with Zeng and Li as equal contributors; NeurIPS/GenProCC lists display Li first.

[29] E. Zhou, S. Basavatia, M. Siam, Z. Chen, and M. O. Riedl, "STORY2GAME: Generating (almost) everything in an interactive fiction game," 2025, preprint.

[30] S. Buongiorno, L. Klinkert, Z. Zhuang, T. Chawla, and C. Clark, "PANGeA: Procedural artificial narrative using generative AI for turn-based, role-playing video games," *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 20, no. 1, pp. 156–166, 2024.

[31] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, "IVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds," in *Proceedings of the 17th International Conference on Computational Creativity (ICCC'26)*. Association for Computational Creativity, 2026, archival proceedings (ISBN); preprint arXiv:2606.13348.

[32] S. Góngora, L. Chiruzzo, G. Méndez, and P. Gervás, "World-state transformations for neuro-symbolic interactive storytelling," 2026, preprint.

[33] S. Geng, H. Cooper, M. Moskal *et al.*, "JSONSchemaBench: A rigorous benchmark of structured outputs for language models," 2025, preprint (v3).

[34] X. He, Y. Tian, Y. Sun *et al.*, "G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907.

[35] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, "HippoRAG: Neurobiologically inspired long-term memory for large language models," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569.

[36] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, "Mem0: Building production-ready AI agents with scalable long-term memory," in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications, vol. 413. IOS Press, 2025, pp. 2993–3000.

[37] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, "Deep reinforcement learning at the edge of the statistical precipice," in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320.

[38] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, "Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program," *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021.

[39] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, "Towards the systematic reporting of the energy and carbon footprints of machine learning," *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020.

[40] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Krahmer, "Best practices for the human evaluation of automatically generated text," in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.

[41] M. Karpinska, N. Akoury, and M. Iyyer, "The perils of using Mechanical Turk to evaluate open-ended text generation," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.

[42] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, "Judging LLM-as-a-judge with MT-Bench and Chatbot Arena," in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623.

[43] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, "Humans or LLMs as the judge? a study on judgement bias," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.

[44] D. Lakens, A. M. Scheel, and P. M. Isager, "Equivalence testing for psychological research: A tutorial," *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.

[45] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, "Random effects structure for confirmatory hypothesis testing: Keep it maximal," *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.

[46] E. Feng, W. Zhou, Z. Liu *et al.*, "Get experience from practice: LLM agents with record & replay," 2025, preprint.

[47] Y. Sun, H. Wang, D. Li, G. Wang, and H. Zhang, "The emperor's new clothes in benchmarking? a rigorous examination of mitigation strategies for LLM benchmark data contamination," 2025, preprint (v1).

[48] A. Madaan, N. Tandon, P. Gupta *et al.*, "Self-Refine: Iterative refinement with self-feedback," in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 46 534–46 594.

[49] M. O. Riedl, C. J. Saretto, and R. M. Young, "Managing interaction between users and agents in a multi-agent storytelling environment," in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.

[50] R. E. Fikes and N. J. Nilsson, "STRIPS: A new approach to the application of theorem proving to problem solving," *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.

[51] F. B. Schneider, "Enforceable security policies," *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.

[52] T. Haerder and A. Reuter, "Principles of transaction-oriented database recovery," *ACM Computing Surveys*, vol. 15, no. 4, pp. 287–317, 1983.

[53] R. Evans and E. Short, "Versu—a simulationist storytelling system," *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.

[54] S. G. Ware and C. Siler, "Sabre: A narrative planner supporting intention and deep theory of mind," in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.

[55] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, "Reflexion: Language agents with verbal reinforcement learning," in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 8634–8652.

[56] X. Chen, M. Lin, N. Schärli, and D. Zhou, "Teaching large language models to self-debug," in *The Twelfth International Conference on Learning Representations (ICLR)*, 2024, accepted poster; OpenReview archival record; preprint arXiv:2304.05128.

[57] A. Solar-Lezama, L. Tancau, R. Bodík, S. Seshia, and V. Saraswat, "Combinatorial sketching for finite programs," in *Proceedings of the 12th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*. ACM, 2006, pp. 404–415.

[58] Y. Huang, G. Chen, J. Yao *et al.*, "Beyond state consistency: Behavior consistency in text-based world models," 2026, preprint.

Appendix A
런타임 증거 부록

FIXED-GAME NATIVE RUNTIME COMPARISON I 8 ASSIGNED ROWS

One authored quest; n=2 per selector/representation cell; NR = not reported, not zero. Labels remain explicit; color is supplementary.

Row	Requested selector	Representation / repeat	Status	Goal	Host calls	Elapsed (s)	Safety R record-link / E engine
1	gpt-6.1-sol	general_rule / r1	HARNESS	NR	0	NR	NOT_OBSERVED R NR / E NOT_OBSERVED
2	gpt-6.1-sol	general_rule / r2	SUCCESS	YES	4	45.91	PASS R YES / E VALID
3	gpt-6.1-sol	ontology / r1	TIMEOUT	NO	2	84.66	PASS R YES / E VALID
4	gpt-6.1-sol	ontology / r2	TIMEOUT	NR	1	60.04	NO_COMMIT_OBSERVED R YES / E NOT_RUN
5	gpt-5.6-sol	general_rule / r1	SUCCESS	YES	4	41.09	PASS R YES / E VALID
6	gpt-5.6-sol	general_rule / r2	SUCCESS	YES	4	39.39	PASS R YES / E VALID
7	gpt-5.6-sol	ontology / r1	SUCCESS	YES	4	36.68	PASS R YES / E VALID
8	gpt-5.6-sol	ontology / r2	SUCCESS	YES	4	29.55	PASS R YES / E VALID

Endpoint outcomes, receipt-derived host calls, and dispatch-to-terminal elapsed time.

Typed-intent proposal; deterministic planner/checker and Godot commit retain authority.

No efficacy/superiority/noninferiority/player-benefit claim; provider metadata and request counts remain NR.

Fig. 7. 공개 trace 에서 도출한 native runtime 비교 이미지. 할당된 system endpoint 의 관측 결과, 기술적 실패와 timeout, 미상 항목을 요약하며 게임플레이 스크린샷이 아니다.

Appendix B
신원 검증 확장

신원 admission 중단: not a model comparison. 별도 확장은 20 개 계획, 1 개 배정, 1 회 native 프로세스 실행, 0 개 신원 검증, 19 개 미실행이다. 첫 요청 `gpt-6-luna/general_rule` 의 CLI turn 은 끝났지만 provider 모델 신원 증거가 없어 응답을 수용하지 않고 나머지 실행을 중단했다.

요청 selector 와 catalog 노출은 실제 응답 신원이 아니다. `openai-model` 의 부재 또는 유효 문자열로 전달되지 않은 경우를 현재 증거로 구분하지 못한다. 이는 관측된 모델 불일치나 모델 능력 실패가 아니다. `gpt-6-terra` 는 고정 catalog 에 없어서 배정하거나 다른 모델로 대체하지 않았다.

감사 구분: `record hash valid=true`; `engineering record accepted=false`. 원래 중단 label `episode_record_integrity_invalid` 는 보존한다. 해시 재계산은 일치하지만 compound 검증 함수가 engineering/safety PASS 도 요구하므로 이 label 을 바이트 손상으로 해석하지 않는다. 커밋은 0 개, safety 는 `NO_COMMIT_OBSERVED`, 새 엔진 재생은 `NOT_RUN` 이며 안전 통과가 아니다.

차단된 repair 요청 2 회는 native 재실행이 아니다. 원래 8 개 pilot 은 바이트 불변으로 별도 보존하며 새 분모와 합산하지 않는다. Provider 신원/revision/유효 effort/요청 수/비용/실제 credit 및 현금 청구는 `unknown` 이다. 계정 일치와 자동 충전 OFF 를 전후 관측했고 설정 변경이나 구매는 하지 않았지만 0 원 또는 credit 무사용의 증명은 아니다. 검증된 새 모델 비교, 온톨로지 효과, 확인적 A/C 근거는 없다.

Preparation 7.144 s; episode elapsed 4.257 s; native process 4.207 s; orchestration 11.566 s. 실패 시도의 서로 다른 시간 경계이며 순수 추론 지연이나 성공 시간이 아니다.

TABLE XV
신원 검증 중단 확장의 10 개 셀. 계획과 실제 배정 · 신원 검증 · 미실행을 분리하며 모델 성능 표가 아니다.

요청 selector	표현	계획	배정	신원 검증	미실행
`gpt-6-luna`	`general_rule`	2	1	0	1
`gpt-6-luna`	`ontology`	2	0	0	2
`gpt-6-sol`	`general_rule`	2	0	0	2
`gpt-6-sol`	`ontology`	2	0	0	2
`gpt-5.6-luna`	`general_rule`	2	0	0	2
`gpt-5.6-luna`	`ontology`	2	0	0	2
`gpt-5.6-sol`	`general_rule`	2	0	0	2
`gpt-5.6-sol`	`ontology`	2	0	0	2
`gpt-5.6-terra`	`general_rule`	2	0	0	2
`gpt-5.6-terra`	`ontology`	2	0	0	2
합계	—	20	1	0	19

Appendix C
로컬 Ollama feasibility note

이 부록은 결과나 비교 연구가 아닌 제한된 기술 feasibility 관측을 기록한다. 고정 게임의 단일 episode 배정 4 개를 모두 실행했으며 (4/4), 네 행 모두 게임 goal 에 도달하지 못했다 (0/4). Pilot 행은 plan-only receipt 가 기록되기 전에 실행되었고 나머지 세 plan-only receipt 는 실행 전에 기록되었으므로, 네 행은 frozen 또는 prospective cohort 가 아니다. 네 행은 모두 분모에 남기고 response-qualified eligibility 와 성공을 분리해 보고한다. timeout 이 아닌 21 개 응답에서는 requested model 과 response model 이름이 일치했다. 두 timeout receipt 에는 response-model observation 이 없으며, 특히 qwen2.5:0.5b `general_rule` run 에는 response-model observation 이 없다. 이 receipt 들은 identity 근거로 취급하지 않는다. Ollama 버전은 0.30.10 이며 model manifest/blob digest 는 실행 전후 일치했다. Provider identity, revision, cost, hardware, load 및 재현 가능한 timing 은 없다. 설정된 loopback endpoint 를 넘어서는 network 관측 주장은 하지 않는다.

두 representation 은 동일한 public facts 의 serialization 이며 독립적인 의미 조건이 아니다. Language model 은 public utterance 의 intent 만 분류했고 symbolic planner 가 action 을 선택했다. 따라서 이 episode 들은 ontology effect, model-size effect, ranking, planning ability, efficacy, usability 또는 player benefit 을 시험하지 않는다. 실패 taxonomy 는 기술적 서술일 뿐이다: host-call-budget exhaustion 1 회, cold-load deadline 아래 response-timeout 2 회, 그리고 malformed-response receipt 4 개를 보존한 repair-source error 1 회다. Raw malformed response 는 저장되지 않아 원인을 진단할 수 없다.

1–3 행은 state-changing commit 이 없고 initial state hash 를 유지했으며, 4 행은 state-changing commit 1 회가 fresh Godot process 에서 valid replay 되었다. Replay 에는 model call 이 0 회였다. Record, receipt 및 request hash 는 검증되었지만 adapter 와 runner source bytes 는 record 에 contemporaneously hash-bound 되지 않았다. 따라서 이 artifact 는 완전 재현 가능한 기록이 아니다. 외부 공개 전 absolute local path 를 정제해야 한다.

Local-only source packet 은 `_workspace/current/qa/releases/` 아래에 있다. Continuation directory 는 `2026-10-28-runtime-ollama-continuation-20261028/` 이다. Pilot directory 는 `2026-10-28-runtime-ollama-qwen15-general-rule-20261028/` 이며 `episode.json`, `pilot-verification.json`, post-hoc `plan-only-output.json` 을 포함한다.

TABLE XVI
로컬 Ollama 고정 게임 feasibility 관측. 각 행은 하나의 배정 episode 이며 receipt 수는 verified/failed/timeout 순이다. Eligibility 는 모든 receipt 가 response-qualified 였다는 뜻이지 goal 달성을 뜻하지 않는다.

Model	Form	배정/실행	Receipt	실패 코드	Eligible	상태/Replay	Engineering status
qwen2.5:1.5b	`general_rule` (pilot)	1/1	12/0/0	BUDGET	yes	no-change / valid	NOT_PASS
qwen2.5:1.5b	`ontology`	1/1	4/0/1	TIMEOUT	no	no-change / valid	NOT_PASS
qwen2.5:0.5b	`general_rule`	1/1	0/0/1	TIMEOUT	no	no-change / NOT_RUN	NOT_PASS
qwen2.5:0.5b	`ontology`	1/1	1/4/0	REPAIR	no	1 change / valid	PASS

실패 코드: BUDGET = `host_call_budget_exhausted`, TIMEOUT = `response_timeout`, REPAIR = `repair_source_error`. 네 행의 배정/실행은 $4/4$, goal 도달은 $0/4$, response-qualified eligibility 는 $1/4$ 이다. 유일한 engineering PASS 는 유효하게 replay 된 상태 변화 1 회를 뜻하며 task 성공이 아니다. 30 초 response deadline 은 `keep_alive=0` cold model loading 을 포함한다.