

TRACE-RPG: 인터랙티브게임세계의생성이벤트를위한 trace 연결기호커밋게이트

익명저자

Abstract—대규모언어모델은표현력있는퀘스트와 NPC 대화를 생성할수있지만, 유창하거나스키마에맞는텍스트만으로제안이벤트의실행가능성, 권한적합성, 정식게임상태와의일관성이성립하지않는다. 본논문은신뢰하지않는제안을상태변경으로부터격리하는기호커밋게이트 TRACE-RPG 을제안한다. 타입엄격 parser 는공유 candidate-key contract 를강제하여알려진필드의모호한 type 과알수없는 top-level candidate field 를거부하고, 외부공급행동정책과결정론적상태대술어가 controller 가허용하는모든전이를결정한다. 거부된후보는제한된 repair callback 에노출되고, 성공후보는변경직전에방어적으로재검증된다. 중단실험레코드는키없는 SHA-256 콘텐츠체크섬과연결되고, 상태의미재생은기록된전이를재계산하며, 에피소드연속성검사는단결된이력을거부한다. 평가는단일작성 world state 에대한의도적설계결정론적오프라인픽처에서수행하며, 보고수치중무엇이관찰값이고무엇이하니스의구성불변량인지명시한다. 반례유도수리연산자 ρ 는직전후보와 validator 의구조화오류집합만을소비하고권위있는상태는결코읽지않으며, 동결된 repairability class 위에서블라인드동일후보 retry 및상태를읽는참조 callback 과결정론적설계픽처비교로대조된다. 상태를읽는 callback 은배포가능수리방법이아니라 oracle 상한으로남고, adapter telemetry 값은측정값이아니라합성픽처상수다. 따라서근거는하나의 world 에서선언된구조화필드에대한구현적합성만을확립하며, 실시간모델동작, 플레이어경험, 감정, 검색, 메모리, 상용엔진성능에대해서는아무것도확립하지않는다.

Index Terms—게임인공지능, 인터랙티브내러티브, 기호검증, 제약생성, 런타임강제, 재현성

I. 서론

인터랙티브생성은언어과제에그치지않는다. 후보이벤트가자연스러워도존재하지않는아이템요구하거나, 화자가모르는사실을주장하거나, 금지된퀘스트정보를공개하거나, 허가되지않은효과를도입하거나, 퀘스트단계를후퇴시킬수있다. 실행가능한텍스트환경은그렇듯한발화와유효한전이의차이를명시한다 [1], [2]. 근거기반대화화개인화퀘스트시스템은퀘스트, 엔터티, 그래픽맥락의가치를추가로보여주지만 [3], [4], 맥락자체가정식상태변경을승인하지않는다.

구조적생성제약은인접한문제를해결한다. 문법제약디코딩, 언어모델질의언어, 점진파서는생성구조를제한할수있다 [5], [6], [7]. 그러나구문상허용되는이벤트도현재세계에대해서는거짓일수있다. 검색과메모리는유용한근거를공급할수있지만 [8], [9], [10], 검색된내용역시상태전이의권한주체가아니다.

본논문은이러한관심사를감사가능한트랜잭션프로토콜로결합한구현인 TRACE-RPG 을제시한다. 현재기여는다음과같다.

- 1) 버전화된신뢰경계계약 — 정식상태, 외부공급행동정책, 후보이벤트, 실험레코드, 게임브리지계약을타입엄격 parser 가강제하며, 모호한기지필드타입과알수없는 top-level candidate key 를거부한다. 증거: 사전지정된 unknown-key 부정사례에대한 proposal/replay 거부동등성을포함한결정론적 parser 계약픽처;

- 2) *validate-repair-commit controller* — 여섯개의상태상대술어가허용되는모든전이를결정하고, 유계 repair 예산, 변경없는결정론적 fallback, 커밋직전방어적재검증을갖춘다. 증거: 단일저작세계에대한정확수치의 validator/상태격리및 repair 제어흐름픽처;
- 3) 감사증거계층 — 중단레코드를키없는 SHA-256 콘텐츠체크섬에결속하고, 기록된전이를재계산하는상태의미재생과에피소드연속성검증을수행한다. 증거: 명명된모든손상이지정된검사연산에의해거부되는사전지정결함주입픽처;
- 4) 오프라인적합성 *harness* — 타입엄격기지필드 adapter 경계, 동결된할당기, 구분되는중단실패클래스, proposal trace 없는 controller-failure row 까지보존하는할당완전계수를갖춘다. 증거: manifest 위반픽처와재계산가능한해시를포함한동결릴리스패킷; 그리고
- 5) 반례유도수리연산자와픽처배터리 — $\rho(a, E)$ 는구조화오류집합과직전후보만을소비하며권위있는상태는결코읽지않고, guided-repairable/guided-irreparable 클래스로분할된확장결정론적픽처집합에서블라인드 unchanged-retry arm 및상태를읽는 oracle 상한과비교된다. 증거: 동결 manifest 하의 arm 별정확커밋/폴백수치.

실증의중심은단일작성 world state 에대한결정론적설계픽처적합성파일럿이며, 보존한 Godot 4.7.1 작성형 policy-mirror trace 와 render replay 가제한된엔진로컬근거를추가한다. 해당픽처의 headless 실행은엔진로컬타이밍을기록하며, 본논문이를있는그대로보고한다. 각실행은고정 seed 의 scripted fixture 하나이며, 요청당수치는모델이나네트워크추론이아니라로컬픽처처리를측정한다. 네 fixture 실행모두에서 5개 headless frame sample 중첫 sample 이가장쌔고그범위는 98.760–116.667 ms 였으므로 16.7 ms frame budget 을충족하지못했다. 이 startup-sensitive trace 는안정적인 frame benchmark 가아니다. 실시간모델호출, 참여자, 감정또는검색 실험, live Python-Godot 승인왕복, 대표성있는 end-to-end 게임플레이성능측정은없다. 해당연구는본논문의범위밖이다.

II. 관련연구와연구공백

A. 인터랙티브내러티브와게임에이전트

KNUDGE 는퀘스트와엔터티명세에근거한분기형 NPC 대화를평가한다 [3]. 지식그래프보조퀘스트생성 [4], 메모리-성찰-계획에이전트 [11], 학습가능한역할연기에이전트 [12] 는근거성과개연성있는행동의상호보완적측면을다룬다. 플레이어대상연구는선택화지각된대화품질을평가한다 [13], [14]. Yin 등의 2026 년온라인레코드는서지감사당시미래시점의권호가배정되어있어제출시다시확인해야한다 [15]. 2025 년프리프린트는 역할에따른안정성-즉흥성 trade-off 를보고하며 [16], 본논문은이를최근동기로만사용한다. 이연구들은하드허용가능성을선택

적자연스러움및플레이어경험구성개념과분리할필요성을뒷받침한다.

경험주도콘텐츠생성 [17] 과관찰자표식참여도 [18] 는미래적응트랙의동기가된다. 최근프리프린트는 vision-language model 의참여도추론한게를보고한다 [19]. 따라서감정은비권위적맥락으로유지되며현재구현근거에는포함되지않는다.

B. 환경과벤치마크

TextWorld 와 ScienceWorld 는명시적인인터랙티브상태를제공하며 [1], [2], MineDojo 는개방형지식집약 embodied 과제를추가한다 [20]. General Video Game AI 는에이전트, 게임, 콘텐츠트랙을분리한다 [21]. AgentBench 는이질적인환경의에이전트를연구하고 [22], AgentBoard 는과정수준진단을추가하며 [23], SOTOPIA 는사회적상호작용을평가하고 [24], BALROG 는장기언어및시각게임추론을평가한다 [25]. 자동화된플레이스타일에이전트는상호보완적인시험선레이지만인간평가를대체하지않는다 [26]. 이벤치마크는미래평가설계에정보를주지만트랜잭션승인경계를규정하지는않는다.

C. 제약, 신경-기호검증, 검색

제약디코더는출력구조를개선했다 [5], [6], [7]. 반면 TRACE-RPG 은구조를독립적인상태대상승인의입력조건으로취급한다. 직접적인게임특화비교대상두시스템은서로다른경계를보여준다. PANGeA 는메모리, 검증, REST 서비스, Unity 통합을결합하지만, 공개된검증절차는 LLM 이설계자규칙에따라콘텐츠를판정하고반복수정하도록한다 [27]. 현재비아카이벌 ICCG 2026 자료와연계된프리프린트 IVIE 는기호검증을사용해인터랙티브픽션세계를점진적으로생성한다 [28]. 같은게보의 2026 년시스템은 LLM 을저작된 world-state transformation 선택으로제한하고플레이어표현에대한탐색적 8 인연구를보고한다 [29]. 이시스템은구성상일관성을유지하지만트랜잭션게이트, 감사연결레코드, 수리연산자근거는제공하지않는다. 어느비교도우월성을뜻하지않으며, 각시스템의유효성은해당시스템이인코딩한목표와술어에한정된다.

G-Retriever, HippoRAG, Mem0 는관련하위그래프검색과장기메모리를다루고 [8], [9], [10], Generative Agents 와 Character-LLM 은행동메모리와 persona 를다룬다 [11], [12]. TRACE-RPG 은향후이러한맥락을사용할수있지만직접적인커밋권한은부여하지않는다. 검색과시간적메모리효익은여기에서측정하지않는다.

D. 감사가능성과재현성

과정지표는중간실패를보존할동기를제공하고 [23], 강건한평가는소수확률적실행의과도한해석을경고한다 [30]. 재현성과환경보고지침은동결된산출물과명시적측정경계를뒷받침한다 [31], [32]. 인간및 LLM 평가는구성개념, 평가자, 편향통제를요구하며 [33], [34], [35], [36], 향후비열등성과참여자분석에는정당화된 margin 과 random-effects 구조가필요하다 [37], [38].

제한된 novelty 는개별구성요소의발명이아니라구현된결합이다. 행동개입 (interposition) 자체는오래된기법이다. 내러티브 mediation 은사용자나에이전트의행동을실행전제가로채차단하거나계획을수정해수용하고 [39], 고전계획법은 precondition 과 effect 로적용가능성을정의하며 [40], 런타임강제는신뢰하지않는행위자를 monitor 로감싸허용된전지만통과시키고 [41], 작성형논리기반인터랙티브드라마는본저널의전신에서캐릭터가할수있는발화를규율했으며 [42], 신념인지

내러티브계획법은캐릭터가아는바를추론한다 [43]. 이는본논문의 knowledge/disclosure 술어가훨씬거칠게인코딩하는관심사다. TRACE-RPG 은 interposition 을발명했다고주장하지않는다. 더좁은기여는신뢰하지않는생성 proposer 아래에서그게이트에결합된근거계층이다. 즉콘텐츠체크섬과연결된종단레코드, 기록된전이의상태의미재생, 에피소드연속성검증, 그리고 proposal trace 가존재할수없는사례까지보존하는할당완전실패계수다. 보고서에기능이없다고해서모든구현에그기능이없다고추론하지않는다.

III. 문제정의와보장경계

설명을위해시점 t 에서 validation 이사용하는 controller 입력을다음과같이분해한다.

$$c_t = (G_t, q_t), \quad (1)$$

여기서 G_t 는 typed snapshot field 를, q_t 는해당 snapshot 과함께저장되는외부작성 action-policy, disclosure, quest-stage 제약을나타낸다. 종단 record history $h_{<t}$ 는 WorldState snapshot 과별도로유지된다. Validation predicate 는이를읽지않으며구현은 log 에서상태를재구성하지않는다. 검색, 내러티브점수, 모델 rationale, 메모리요약, 미래의감정추정은비권위적 proposal context 이다.

신뢰하지않는 proposer 가후보 a_t 를출력한다. 타입엄격 parsing 은알수없는 top-level field 의거부를포함한공유 candidate-key contract 를먼저강제하고선언스키마를확립한다. validator 는다음을반환한다.

$$V(c_t, a_t) = (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, v_{\text{disc}}, v_{\text{quest}}, E_t), \quad (2)$$

여기서 E_t 는구조화오류집합이다. 상태변경은다음과같다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_i v_i = 1, \\ c_t, & \text{그외.} \end{cases} \quad (3)$$

Controller 는인코딩된계약아래다음구현불변량을주장한다. 파일럿은이를일반정리로제시하지않고 deterministic valid, invalid, repair, fallback, replay, fault-injection fixture 로해당 mechanism 을시험한다. **I1 (소진실패불변성):** 예산 K 까지만환되어면후보도검증을통과하지못하거나 proposal/controller 실행이 commit 전에실패하면반환상태는공급된 prior state 와같다. **I2 (제한된기록시도):** 모든 proposal 과 repair callback 이반환한다는조건에서 repair budget $K \geq 0$ 은최대 $K + 1$ 개의 candidate attempt 를기록한다. 성공적인 commit 은변경직전수락후보에대한방어적 validation 을한번추가한다. Runtime 은 callback deadline 을강제하지않으므로 I2 는 wall-clock 종료보장이아니다. **I3 (효과권한):** 수락후보는 ActionPolicy.allowed_effects 밖의선언된 fact effect 를 CandidateAction.effects 에포함하지않으며, quest-stage target 도해당 policy 에의해명시적으로승인된다. **I4 (상태의미적리플레이):** 동결된스키마와결정론적전이어래수락된 trace 는명시된 terminal state 를재구성한다.

이주장된불변량은올바른정책작성, 선언된후보필드로의완전하고충실한추출, 결정론적소프트웨어버전, callback 반환, 단일프로세스파일소유권을가정한다. 상태의미적리플레이는기록된구조화후보와전이를재검증하지만, 중간수리의 provenance, reasoning, prompt, 확률적생성은재현하거나검증하지 않는다. 구조화필드에서누락된자연어함의는보장범위밖이다.




Fig. 1. 신뢰경계. 검색매락과 생성후보는 알려진 필드의 타입입검사와 상태상대 validation 이 완료될 때까지 비권위적이다.

TABLE I
인코딩된 VALIDATOR 경계

술어	거부대상	실패시상태
Action policy	알수없는 action/type	변경없음
Precondition	누락/거짓 requirement	변경없음
Reachability	접근불가 object	변경없음
NPC knowledge	선언되지않은 known fact	변경없음
Disclosure	forbidden fact	변경없음
Quest	부적격/후퇴 stage	변경없음

IV. TRACE-RPG 아키텍처와 알고리즘

A. 신뢰경계와 계약

그림 1는 모델 또는 recorded adapter 를 canonical owner 밖에 둔다. Parser 는 알려진 필드의 모호한 숫자 또는 collection type 을 거부하고 공유 key contract 에 따라 알수없는 top-level candidate field 도 거부한다. action policy 는 candidate 와 별도로 공급되며 required precondition 과 allowed effect 를 정의한다. Game bridge 는 observation, proposal, validation, rejection, fallback, commit 을 전달할 수 있는 versioned event interface 이며, 정식 상태 변경은 유효한 commit 만 승인한다. 이는 interface 를 분리하지만 상용 엔진으로의 portability 를 아직 입증하지 않는다. 표 I는 인코딩된 거부 경계를 요약하며 의미적 완결성 주장이 아니다.

B. Validate-Repair-Commit

그림 2는 제어기의 추가 패키지 없는 의사 코드를 제시한다. “Record” 는 in-memory trace 표현에 추가하는 것을 뜻하며, 연속쓰기는 종단일관성 검사 뒤에 만 수행한다.

검증 오류는 구조화된 error code 로 repair callback 에 노출된다. repair 는 상태를 직접 변경하지 않으며, 예산 소진 시 변경 없는 결정론적 fallback 을 반환한다. 그림 3는 종단 경로를 나타낸다. 파일럿은 구현된 두 callback 을 비교한다. 반례 유도 연산자는 직전 후보 a 와 validator 의 구조화 오류 집합 E 만 소비하며 권위 있는 상태는 결코 읽지 않는다.

$$\rho(a, E) = a \oplus \bigcup_{e \in E} \delta(e), \quad (4)$$

여기서 각 $\delta(e)$ 는 표 II의 오류 class 별 결정론적 edit 이고 $\oplus$ 는 그 field edit 들을 적용한다. 각 edit 은 오류 entity 당 최대 하나의 candidate field 만 수정하므로 시도당 변경 field 수는 $|E|$ 로 유계이고, 같은 오류 집합으로 ρ 를 두 번 적용하면 고정점이며, 같은 field 에서 동시에 요구되고 거부되는 entity 는 수리불가로 선언되어 수정되지 않는다. 상태를 읽는 참조 callback 은 반대로 오류 집합을 폐기하고 정책이 규율하는 field(precondition,

```

1:  $a \leftarrow \text{PROPOSE}(c); j \leftarrow 0$ 
2: repeat
3:    $(ok, E) \leftarrow V(c, a); \text{RECORD}(a, E)$ 
4:   if  $ok$  then
5:     assert  $V(c, a).ok$ ; return  $\text{COMMIT}(c, a)$ 
6:   if  $j = K$  then return  $\text{FALLBACK}(c)$ 
7:    $a \leftarrow \text{REPAIR}(c, a, E); j \leftarrow j + 1$ 
8: until terminal

```

Fig. 2. Validate-repair-commit 절차. 최대 $K + 1$ 개의 candidate attempt 를 기록하며, 성공 경로는 상태 변경 전 방어적 validation 을 수행한다.

TABLE II
유도 연산자 ρ 의 오류 CLASS 별 EDIT

Validator 오류 class	후보에 대한 edit $\delta(e)$
정책 precondition 누락	명명된 predicate 삽입
정책 effect 누락	명명된 effect 삽입
정책 effect 위반	명명된 effect 제거
불충족 precondition	명명된 predicate 제거
비인가 stage 변이	quest_stage_effect 초기화
알수없는 action type	no-op (등록된 대안 없음)
도달 불가 object; knowledge, disclosure, stage class	no-op (후보 국소 edit 은 세탁이거나 상태 지식 필요)

effect, 두 quest-stage field) 를 권위 있는 상태에서 직접 재구성한다. 이 callback 은 선언 무결성 field(required object, used fact, disclosed fact) 를 의도적으로 수정하지 않는다. 의존성이나 disclosure 의 선언을 지우는 것은 후보를 수리하는 것이 아니라 위반을 게이트 뒤로 세탁하는 것이기 때문이다. 이는 상태 판독 가능 수리에 대한 oracle 상한이며, 그 결과를 배포 가능한 수리 방법의 근거로 읽어서는 안 된다.

C. 무결성, 의미적 리플레이, 계수

각 result row 는 키 없는 SHA-256 무결성 체크섬을 가지며, proposal outcome 은 추가로 trace checksum 과 연결된다. 이 hash 들은 우발적이거나 시험 대상 인 콘텐츠 변경을 탐지하지만 signature, message-authentication code, writer identity 가 아니며 콘텐츠와 checksum 을 모두 다시 쓸 수 있는 행위자에 대한 보호도 아니다. 의미적 리플레이는 prior state 와 기록된 모든 candidate/validation pair 를 엄격히 parsing 하고, final 이 아닌 모든 attempt 가 invalid 임을 요구하며, terminal transition 을 재계산하고, 명시된 final state 와 비교함으로써 byte 무결성을 넘어서는다. Episode replay 는 인접 JSONL record 사이 의 상태 연속성도 요구한다. Replay 는 candidate $j + 1$ 을 만든 repair-generation 단계를 인증하거나 사실 행하지 않는다.

Terminal record class 는 commit, symbolic fallback, adapter failure, controller failure 이다. Controller-failure row 는 동결된 assignment denominator 에 남고 상태를 변경하지 않지만, candidate outcome 이 생성되지 않았다면 완성된 proposal trace 가 없어도 된다. 따라서 result completeness 가 모든 terminal row 의 trace 존재를 뜻하지 않는다. 실행 전 assignment key 는 (run, arm, scenario, seed, model, revision, $h_{\text{controller}}$, h_{input} , h_{prior}) 이다. 집계는 중복, 누락, 예기치 않은 key 를 거부하고 symbolic, adapter, controller failure 를 각각 보고한다.

V. 결정론적 오프라인 파일럿 방법

A. 질문과 설계 픽처

파일럿은 다음을 묻는다. (PQ1) 유효 후보는 commit 되고 명명된 invalid-policy 사례는 변경 없이 유지되는가? (PQ2) 동




Fig. 3. Proposal, validation, 제한된 repair, fallback, commit, replay 상태. Controller failure 는 중단상태이며 완성된 proposal trace 가 없을 수 있다.

결된 모든 repairability class 의 작성 사례에서 rejection-only, 블라인드 동일 후보 retry, 반례 유도 연산자 ρ , 상태를 읽는 참조 callback 이에 상결과를 만드는가? (PQ3) 동결된 checksum, state-semantic, linkage, continuity mutation 이 지정된 검사 연산에서 거부되고, 두 번째 파일 append 의 주입된 실패가 예상 pair-write rollback 검사를 작동시키는가? (PQ4) 엄격한 adapter 와 assignment manifest 가 할당 사례마다 정확히 하나의 분류된 terminal row 를 유지하거나 fail closed 하는가? (PQ5) proposal 및 replay parser 가 그 외에는 완전하고 유효한 candidate 에 unknown top-level key 하나를 추가한 사례를 모두 거부하는가?

사례는 의도적으로 설계된 적합성 픽스처이며 모델 또는 게임 모 집단의 표본이 아니다. 네도메인은 validator/state isolation, repair-arm 비교, record/trace fault injection, adapter/accounting contract 이다. 모든 repair fixture 는 실행 전에 동결된 repairability class 를 선언한다. *guided-repairable*(구조화 오류 payload 만으로 ρ 에 충분한 정보가 담김), *oracle-only*(수리에 권위 있는 상태 판독이 추가로 필요함), *irreparable*(구현되면 arm 도 commit 할 수 없음)이며, class 별 arm 당 기대 결과는 설계 픽스처 계약의 일부다. 반복된 결정론적 seed 가 아니라 고유 사례가 기술적 denominator 를 구성한다. 모든 기대 값은 실행 전에 명시한다.

B. 측정치와 재현성

측정치는 정확한 count 이다. expected/observed validator-class agreement, rejected 또는 controller-failure 사례의 state mutation, repair arm 과 repairability 별 commit 및 attempt 결과, 지정된 연산에서 거부된/사전 명세된 detectable fault, replayed/committed trace, rejected/injected manifest violation, 사전 명세한 unknown-key 음성 회귀에 대한 proposal/replay 거부 일치를 센다. 마지막 측정치는 결정론적 parser-contract parity 이며 실증적 safety outcome 이 아니다. Exception class 만으로 안정적인 detector layer 를 식별할 수 없으므로 detector 귀속 결과는 보고하지 않는다. 의도적으로 설계된 픽스처에 p -value 나 모 집단 confidence interval 을 부여하지 않는다. Adapter 사례가 지닌 latency 및 token 상수는 입력 스키마가 JSON-Schema const 로 고정된 적합성 값이다. 이 값 들은 계수 필드 전파만 확인하며 provider, runtime, device 에 대한 측정치이다.

릴리스 패킷은 fixture 및 assignment manifest, schema, outcome/trace record 를 포함한 result JSON 산출물, 환경과

코드 revision, 생성 table, checksum 을 동결한다. 보고는 재현 성과 측정 경계 지침을 따른다 [31], [32].

VI. 파일럿 결과

A. 구조 필드 게이트 적합성

파일럿 loader 는 구현된 validator code 를 정확히 한번씩 고립시키는 fixture 집합과 유효 control 1 개만을 허용한다. 따라서 13/13 일치와 구현된 오류 코드 12 종의 관찰은 측정된 성공률이다. 하니스의 구성 불변량이다. 이 실행이 보여주는 것은 loader 가 강제하지 않는 부분, 즉 고립된 음성 fixture 12 개가 각각 다른 코드 가 아니라 작성된 기대 코드와 일치했고 비 commit 경로가 전체 정준 상태를 유지했다는 관찰이다. 이는 단일 world state 에서 저자가 설계한 구조 필드 oracle 에 대한 구현 적합성이며 독립의 미판정의 정확도가 아니다.

B. 설계 픽스처에서의 수리 arm 비교

처음부터 유효하지 않은 설계 case 12 개는 guided-repairable 5 개, oracle-only 1 개, irreparable 6 개의 동결된 repairability class 로 분류된다. Rejection-only 와 블라인드 동일 후보 retry 는 각각 0/12 commit 이었다. 반례 유도 연산자 ρ 는 guided-repairable case 5/5 를 commit 했고, 설계상 oracle-only 0/1, irreparable 0/6 였다. 모든 ρ commit 은 candidate field 를 평균 1.0 개 수정했으며, 실패한 모든 arm 실행은 정준 상태를 변경 없이 유지했다. 상태를 읽는 참조 callback 은 guided-repairable 5/5 와 oracle-only 1/1 를 commit 했고 irreparable 은 0/6 였다. 이 정확한 count 는 세메커니즘을 설계 픽스처 위에서 분리한다. 블라인드 retry 는 반례를 commit 으로 전환하지 못하고, ρ 는 오류 payload 에 충분한 정보가 담긴 case 만 전환하며, oracle 은 상태 지식이 필요한 case 를 추가로 전환한다. 이는 동결 픽스처에 대한 연산자 적합성이며, 어떤 live model 의 수리 품질도 아니다.

C. 무결성, 경계, 배정 회계

현재 명세가 검출 가능하다고 지정한 10 개 fault fixture 는 모두 지정된 검사 연산에서 거부됐다 (10/10). 이 파일럿은 안정적인 typed detector code 까지 대조하지 않으므로 detector layer 귀속을 입증하지 않는다. 별도로, 동일하게 기록된 유효 수리 앞의 무효 선행 후보를 다른 무효 후보로 치환하고 체크섬을 재계산한 알려진 provenance 경계는 예상대로 재생을 통과했다 (1/1 미검출). 따라서 키 없는 체크섬을 재계산할 수 있는 작성자를 방어하지 않으며, 재생은 repair 생성 연산의 출처를 인증하지 않는다. 열린 경계 sentinel 두 건—자연어 disclosure 미추출과 required object 의 후보 · 정책 동시 누락—은 2/2 가 의도대로 인코딩 상 허용됐고 safety pass 는 0 건이었다. 과거 unknown top-level field 허용 경계는 Stage 8 이후 닫힌 음성 회귀로 재분류되었으며, 완전한 12-field candidate 에 unknown key 하나를 추가한 fixture 를 proposal · replay parser 모두 구체적으로 거부했다 (1/1). 이는 parser rejection parity 이지의 미안전성의 증거가 아니다. Adapter/accounting 7 개 배정에서는 commit 1, 기호 fallback 1, adapter failure 5 였다. 합성 telemetry 필드는 2/7 배정에서 채워져 전파됐으며, 이는 측정 값이 아니라 회계 필드 전파 확인이다. 배정 guard 3/3 가 중복 · 누락을 거부했다. 이 수치는 모두 합성 offline fixture 의 raw count 다.

표 III와 IV는 정확한 설계 픽스처 count 를 보고한다. 수리표는 동결된 repairability class 별로 네 arm 을 분리하며, 어느 표도 모 집단 또는 live-model 추정을 지지하지 않는다.




Fig. 4. 작성형 Godot render replay 에서 status/event 를확대한 illustrative crop 과 manifest metadata. 이 trace-bound 대응은 live transport, 성능, usability, immersion, efficacy 근거가아니다.

TABLE III
수리 ARM $\times$ REPAIRABILITY CLASS 정확집계 (설계픽처)

Arm	정보원	G-rep. ^f	O-only ^f	Irrep. ^f	수정 ^e
Rejection-only ($K=0$)	없음	0/5	0/1	0/6	—
블라인드 retry	없음	0/5	0/1	0/6	—
반례유도 ρ	오류집합 E	5/5	0/1	0/6	1.0
상태판독 oracle	권위상태 + 정책	5/5	1/1	0/6	1.0

TABLE IV
동결파일럿원시집계

검사	분자	분모
게이트 fixture 일치 ^c	13	13
알려진경계허용 ^a	2	2
단한 unknown-key 경계거부 ^d	1	1
탐지가능무결성결함거부	10	10
알려진무결성경계 replay 허용 ^b	1	1
Adapter 커밋	1	7
기호 fallback	1	7
Adapter 실패	5	7
Manifest guard 거부	3	3

^a 경계허용은의미추출과정적완결성한계를문서화하며 safety pass 가아니다.
^b Replay 는 repair 생성을인증하거나다시실행하지않는다. ^c Loader 가이일치를강제하므로측정값이아니라구성불변량이다. ^d Stage 8 이후의 parser 거부 parity 이며의미안전성증거가아니다. ^e commit 된수리의변경 candidate field 평균개수 (최소성 proxy); 실패한 arm 실행은상태를변경하지않았다. ^f commit/사례수. G-rep. = guided-repairable, O-only = oracle-only, Irrep. = irreparable(동결된 repairability class).

그림 5는보고경계를명시한다. 동결 fixture 와지정검사연산이허용한 row 만생성결과표에들어간다.

Godot 4.7.1 은보존한 *Sealed Lighthouse* 정식 trace 를 non-headless 1280 $\times$ 720 SubViewport 에서리플레이했다. Manifest 는각 PNG 를 event/delivery index, validation, state hash 에결합한다. 그림 4(b) 는변경전 hash 를보존하고, (c) 는 valid commit 뒤이를변경한다. 모든원본 panel 은생성자산이없는 primary-track render 이며, 아래 illustrative crop 은작성된 status/event callout 만확대한다.

선택 v5 packet 은하나의 scripted fixture 의 render/state 대응만확립하며 live model 또는 Python transport, participant 또는 player input, adaptation intervention, narrative-quality result 를추가하지않는다.




Fig. 5. 동결된 fixture 에서지정된검사연산과생성 table 로이어지는근거경계. 수치는생성산출물을통해서만반영한다.

VII. 논의

A. 확립가능한범위

설계파일럿은동결된사례에대해서만 mechanism behavior 를확립할수있다. 인코딩된검사가상태를격리하는지, bounded repair 와 fallback 이선언경로를따르는지, 명명된 corruption 이지정된검사연산에서거부되는지, assigned row 가집계를위해 분류된상태로남는지를평가한다. 거부를안정적인 typed detector code 에귀속하지는않는다. 이는 authoring-time validation, continuous-integration regression, recorded-adapter test, engine 이전 replay inspection 에유용하다.

수리비교의정직한해석은 guided-대-oracle 경계다. 상태를 읽는 callback 이상한으로남는이유는권위있는상태를참조할수 있어서 ρ 가구성상전환할수없는 oracle-only 사례를전환하기 때문이다. 반례유도연산자는 validator 의구조화반례—배포된 어떤 proposer 라도신뢰경계에서받게될것과동일한정보—만을소비하면서 guided-repairable class 에서 oracle 과정확히 일치한다. 발견은성공물이아니라이분리다. 즉이설계픽처에서어떤수리가오류 payload 만으로도달가능하고어떤수리가 구조적으로상태접근을요구하는지를위치시킨다. 동일한오류 payload 로 prompt 된 live model 이 ρ row 에근접하는지는 본논문의열린실증질문이다. Feedback 을소비하는수리루프에는선례가있다. Self-Refine 은같은신뢰하지않는모델이생성한 언어를 feedback 으로되먹이고 [44], Self-Debugging 은신뢰되는전체프로그램 runtime 의실행결과를소비한다 [45]. ρ 는 channel 과증거 class 모두에서다르다. 그 feedback 은어떤실행보다도먼저결정론적 validator 가계산한 typed 오류집합이며, live-model 능력이아니라설계픽처위의연산자로측정된다.

B. 선행연구와의관계

TRACE-RPG 은 parsing 후 state-relative authorization 을적용하여 constrained decoder 를보완한다 [5], [6], [7]. 검색및메모리구성요소에는 commit authority 를부여하지않는다는점에서구별된다 [8], [9], [10]. 실행가능한환경과 benchmark 를대체하지않고보완한다 [1], [2], [22], [25]. Process-linked trace 는 AgentBoard 가강조한측정관심사를구현하지만 [23], TRACE-RPG 이해당시스템이나다른시스템보다우월하다는근거는아니다.

효능을검정할연구, 즉독립적으로 label 된 semantic oracle 과실제 blind-retry comparator 를갖춘사전등록다중모델비교, 인코딩된 validity 를맞춘 retrieval 및 memory ablation, 정당화된검정력과 mixed-effects 분석을갖춘 blinded matched-validity 인간연구는본논문의범위밖이며부분적으로도보고하지않는다 [22], [33], [30], [38].

VIII. 타당성위협, 윤리, 산출물범위

구현근거는아홉개의명시적한계로유계된다. **L1 (인코딩된 의미의경계):** 검증은선언된필드와술어가표현하는것만거부한다. 구조화필드에서누락된자연어함의는검사없이통과하며, 인코딩된검사는저자가인코딩하지않은의미를발견할수없다. **L2 (단일세계):** 모든수치는하나의저작된세계상태와정책에조건화되어있다. 세계간, 정책간, 규모확장일반화는구성상검증되지않았다. **L3 (수리증거경계):** 상태를읽는참조 callback 은 oracle 상한으로남는다. 반례유도수리연산자 $\rho(a, E)$ 의증거는 guided-repairable/guided-irreparable 클래스에대한결정론적픽스처수치뿐이며, 어느결과도 live model 의수리품질을측정하지않는다. **L4 (라이브전송없음):** proposer 와 adapter 는기록되었거나합성이다. 라이브모델호출도, 라이브엔진승인 왕복도없으며, adapter telemetry 는스키마로고정된상수이지 측정아니다. **L5 (인간데이터없음):** 참가자나정서측정이없다. 커밋의식의플레이어체감가독성은설계가설이지평가된결과가아니다. **L6 (무결성이지인증이아님):** 키없는 SHA-256 체크섬은우발적 · 시험된손상만탐지한다. 작성자신원이나적대적변조저항성은제공하지않는다. **L7 (단일프로세스기록자):** 기록일 관성은단일프로세스의파일소유를가정한다. 동시기록자안전성은구현되지도검증되지도않았다. **L8 (엔진이식성미입증):** 버전화된브리지는인터페이스를분리할뿐이며, 엔진증거는시작구간 이 지배하는프레임샘플이 16.7 ms 예산을초과하는단일스크립트 Godot 픽스처가전부다. 상용엔진이식이나실시간결과는없다. **L9 (설계된픽스처, 모집단추론없음):** 픽스처는목적적으로저작된적합성프로브다. 정확수치는구현적합성만뒷받침하며모집단 · 안전율추론을담지않는다. Internal validity 는추가로 독립적으로작성된 policy expectation 과 fixture leakage 부재에, reproducibility 는고정된 software 및 artifact version 에의존한다.

파일럿은 participant 또는 personal telemetry 를처리하지않는다. 향후 human 및 affect 연구에는해당 review, informed consent, compensation disclosure, minimization, retention/deletion rule, opt-out 이필요하다. LLM judge 를사용하더라도 automated 및 crowd judgement 모두 calibration 과 bias control 이필요하므로보조수단으로유지한다 [33], [34], [35], [36].

IX. 결론

TRACE-RPG 은작성된 candidate-event payload 를 encoded 기호 commit gate 를통해 canonical mutation 으로

부터격리하고, linked record 와 state-semantic replay 로 terminal outcome 을감사가능하게만든다. 결정론적오프라인파일럿은단일작성 world state 의동결된 fixture domain 에서구현 mechanism 에대한근거이지 cross-model superiority, player-experience benefit, retrieval 또는 memory effectiveness, affect efficacy, commercial-engine performance 의근거가아니다. 이질문들은명시적인확증확장으로남는다.

AI 사용고지

본원과준비과정에서대규모언어모델은산문, 코드, 시험초안 작성, 명령실행조율, 근거감사와결과해석, 이번개정을이끈심사패널시뮬레이션, 서지메타데이터 API 에대한인용동일성검사를보조했다. 보고수치의출처로서결정론적실행을대체하지않았다. 파일럿 count 는작성 fixture 에서프로젝트 runner 가산출하여기계생성조각을통해원고에들어가고, Godot timing 과 render 서술은보존된 engine-evidence packet 에서전사한다. 이번개정의구현및결과주장은 source 와 artifact 에대조했고, 모든인용동일성은최소하나의독립색인에서확인했다. 내용에대한책임은전적으로저자에게있다.

데이터및코드가용성

Repository 에는구현, 파일럿번들, fixture 및 assignment manifest, 생성결과조각, build source 가포함된다. 현재 파일럿 SHA-256 manifest 는산출물 38 개와선언입력 22 개를포함하고 bound provenance row 121 개 (실행 fixture row 85 개와 aggregate row 36 개) 를결합하며, 모든산출물과입력 hash 는동결 packet 에서재계산된다. Manifest 의실행명령은이식가능한 uv run python 이며 절대사용자경로나 clone 경로를포함하지않는다. Clean-Git 입력결합 (tag 된입력 commit 에서의 dirty=false, 과거 trace-rpg-stage10-inputs-20260814-v1 tag 에서종결) 은이번릴리스에서 trace-rpg-guided-repair-inputs-20260821-v1 tag 로재확인된다. 이는릴리스 gate 이지중간 working tree 의속성이아니다. 이것이익명심사 archive 또는 DOI 기반저장소가이미존재한다는뜻은아니며본원고는어느것도주장하지않는다.

REFERENCES

- [1] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, “TextWorld: A learning environment for text-based games,” in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.
- [2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, “ScienceWorld: Is your agent smarter than a 5th grader?” in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.
- [3] N. Weir, R. Thomas, R. d’Amore, K. Hill, B. Van Durme, and H. Jhamtani, “Ontologically faithful generation of non-player character dialogues,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.
- [4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, “Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach,” in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.
- [5] S. Geng, M. Josifoski, M. Peyrard, and R. West, “Grammar-constrained decoding for structured NLP tasks without finetuning,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10 932–10 952.
- [6] L. Beurer-Kellner, M. Fischer, and M. Vechev, “Prompting is programming: A query language for large language models,” *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.

- [7] T. Scholak, N. Schucher, and D. Bahdanau, "PICARD: Parsing incrementally for constrained auto-regressive decoding from language models," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.
- [8] X. He, Y. Tian, Y. Sun *et al.*, "G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907.
- [9] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, "HippoRAG: Neurobiologically inspired long-term memory for large language models," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569.
- [10] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, "Mem0: Building production-ready AI agents with scalable long-term memory," in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, peer-reviewed ECAI 2025 record; page range was not exposed by the accessible Crossref or publisher metadata at audit time.
- [11] J. S. Park, J. C. O'Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, "Generative agents: Interactive simulacra of human behavior," in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.
- [12] Y. Shao, L. Li, J. Dai, and X. Qiu, "Character-LLM: A trainable agent for role-playing," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187.
- [13] N. Akoury, Q. Yang, and M. Iyyer, "A framework for exploring player perceptions of LLM-generated dialogue in commercial video games," in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.
- [14] M. Hochreiter, S. Kriglstein, and G. Wallner, "Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues," in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.
- [15] M. Yin, H. Zu, W. Gu *et al.*, "How contextualized generative AI shapes player experience in games," *Entertainment Computing*, vol. 58, p. 101194, 2026, online record with a future issue assignment at the 2026-08-12 audit; issue metadata must be rechecked at submission.
- [16] V. Figueiredo and D. Elumeze, "Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue," 2025, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [17] G. N. Yannakakis and J. Togelius, "Experience-driven procedural content generation," *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.
- [18] D. Melhart, D. Gravina, and G. N. Yannakakis, "Moment-to-moment engagement prediction through the eyes of the observer: PUB streaming on Twitch," in *International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.
- [19] Z. Wang, Q. Guo, R. Singh, and X. Hu, "Do vision language models understand human engagement in games?" 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [20] L. Fan, G. Wang, Y. Jiang *et al.*, "MineDojo: Building open-ended embodied agents with internet-scale knowledge," in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362.
- [21] D. Pérez-Liebana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, "General video game AI: A multitask framework for evaluating agents, games, and content generation algorithms," *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.
- [22] X. Liu, H. Yu, H. Zhang *et al.*, "AgentBench: Evaluating LLMs as agents," in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046, peer-reviewed official proceedings record; no publisher DOI assigned.
- [23] C. Ma, J. Zhang, Z. Zhu *et al.*, "AgentBoard: An analytical evaluation board of multi-turn LLM agents," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362.
- [24] X. Zhou, H. Zhu, L. Mathur *et al.*, "SOTOPIA: Interactive evaluation for social intelligence in language agents," in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019, peer-reviewed official proceedings record; no publisher DOI assigned.
- [25] D. Paglieri, B. Cupial, S. Coward *et al.*, "BALROG: Benchmarking agentic LLM and VLM reasoning on games," in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702, peer-reviewed official proceedings record; no publisher DOI assigned.
- [26] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, "Automated play-testing through RL-based human-like play-styles generation," *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.
- [27] S. Buongiorno, L. Klinkert, Z. Zhuang, T. Chawla, and C. Clark, "PANGeA: Procedural artificial narrative using generative AI for turn-based, role-playing video games," *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 20, no. 1, pp. 156–166, 2024.
- [28] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, "IVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds," 2026, preprint; accepted/forthcoming at ICCV 2026, whose available pre-proceedings were explicitly non-archival and unpublished at retrieval time.
- [29] S. Góngora, L. Chiruzzo, G. Méndez, and P. Gervás, "World-state transformations for neuro-symbolic interactive storytelling," 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-21.
- [30] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, "Deep reinforcement learning at the edge of the statistical precipice," in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320, peer-reviewed official proceedings record; no publisher DOI assigned.
- [31] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, "Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program," *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021, peer-reviewed official journal article; no publisher DOI assigned.
- [32] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, "Towards the systematic reporting of the energy and carbon footprints of machine learning," *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020, peer-reviewed official journal article; no publisher DOI assigned.
- [33] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Kraemer, "Best practices for the human evaluation of automatically generated text," in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.
- [34] M. Karpinska, N. Akoury, and M. Iyyer, "The perils of using Mechanical Turk to evaluate open-ended text generation," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.
- [35] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, "Judging LLM-as-a-judge with MT-Bench and Chatbot Arena," in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623.
- [36] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, "Humans or LLMs as the judge? a study on judgement bias," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.
- [37] D. Lakens, A. M. Scheel, and P. M. Isager, "Equivalence testing for psychological research: A tutorial," *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.
- [38] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, "Random effects structure for confirmatory hypothesis testing: Keep it maximal," *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.
- [39] M. O. Riedel, C. J. Saretto, and R. M. Young, "Managing interaction between users and agents in a multi-agent storytelling environment," in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.
- [40] R. E. Fikes and N. J. Nilsson, "STRIPS: A new approach to the application of theorem proving to problem solving," *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.
- [41] F. B. Schneider, "Enforceable security policies," *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.
- [42] R. Evans and E. Short, "Versu—a simulationist storytelling system," *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.
- [43] S. G. Ware and C. Siler, "Sabre: A narrative planner supporting intention and deep theory of mind," in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.
- [44] A. Madaan, N. Tandon, P. Gupta *et al.*, "Self-Refine: Iterative refinement with self-feedback," 2023, preprint; commonly indexed as NeurIPS 2023 but proceedings identity not re-verified as of 2026-08-21.
- [45] X. Chen, M. Lin, N. Schärli, and D. Zhou, "Teaching large language models to self-debug," 2023, preprint; no archival venue or publisher DOI verified as of 2026-08-21.