

TRACE-RPG: 인터랙티브게임세계의생성이벤트를위한 trace 연결기호커밋게이트

익명저자

Abstract—대규모언어모델은표현력있는퀘스트와대화를생성할수있지만, 유창하거나스키마에맞는텍스트만으로제한이벤트의실행가능성, 권한적합성, 정식게임상태와의일관성이성립하지는않는다. 본논문은생성된모든이벤트를신뢰하지않는트랜잭션제안으로취급하는기호커밋게이트 TRACE-RPG 을제안한다. 타입엄격 parser, 외부공급행동정책, 여섯상태상대계열로유인일곱개의결정론적검사가각하용전이를결정하며, 실패후보는최대 $K + 1$ 개의기록된시도안에서제한수리로보낼수있고통과후보는변경직전에도다시검증한다. 반례유도연산자 ρ 는직전후보와그 typed validation error 만읽고권위있는상태는결코읽지않는다. 키없는 SHA-256 콘텐츠연결, 상태의미 replay, 할당완전계수가모든 terminal outcome 을감사가능하게만든다. 근거는세레인으로분리한다. 단일작성 world 의결정론적오프라인적합성파일럿, 단일모델라이브스크리닝확장, 런타임권한이없는 closed-world 지식그래프링크제안시뮬레이션이다. 오프라인레인은 mechanism 적합성만확립한다. 라이브레인은 $K=1$ 에서의도적으로수리가가능하게만든 policy-blind regime 에한해 guided 5/5 대 blind 0/5 commit 을관찰했으므로 pilot-only 로남는다. 어느레인도모집단효능, 모델우월성, 플레이어경험, 상용엔진성능을확립하지않는다.

Index Terms—게임인공지능, 인터랙티브내러티브, 기호검증, 제약 생성, 런타임강제, 재현성

I. 서론

인터랙티브생성은언어과제에그치지않는다. 후보이벤트가자연스러워도존재하지않는아이템요구하거나, 화자가모르는사실을주장하거나, 금지된퀘스트정보를공개하거나, 허가되지않은효과를도입하거나, 퀘스트단계를후퇴시킬수있다. 실행가능한텍스트환경은그렇듯한발화와유효한전이의차이를명시한다 [1], [2]. 근거기반대화화개인화퀘스트시스템은퀘스트, 엔터티, 그래픽맥락의가치를추가로보여주지만 [3], [4], 맥락자체가정식상태변경을승인하지는않는다. TRACE-RPG 은생성된게임이벤트를신뢰하지않는트랜잭션제안으로취급하며, 정식상태변경을외부의결정론적 commit gate 를통해서만허용한다. 그림 1는그러한트랜잭션하나를왼쪽에서오른쪽으로읽는다.

구조적생성제약은인접한문제를해결한다. 문법제약디코딩, 언어모델질의언어, 점진파서는생성구조를제한할수있다 [5], [6], [7]. 그러나구문상허용되는이벤트도현재세계에대해서는거짓일수있다. 검색과메모리는유용한근거를공급할수있지만 [8], [9], [10], 검색된내용역시상태전이의권한주체가아니다.

본논문은이러한관심사를감사가능한트랜잭션프로토콜로결합한구현인 TRACE-RPG 을제시한다. 현재기여는다음과같다.

- 1) **C1—계약**: 버전형신뢰경계 contract 와, proposal/replay 경계에서 unknown key 와모호한타입을거부하는 type-strict parser (IV절; E1);
- 2) **C2—controller**: 여섯상태상대계열에걸친검사 7개, bounded repair, unchanged fallback, pre-commit revalidation 을갖춘 validate-repair-commit controller (IV-B절; E1, ENG1);
- 3) **C3—감사**: SHA-256 연결 record, state-semantic replay, episode-continuity check (IV-C절; E1, ENG1);

익명심사를위해제출된원고입니다.

TABLE I
기여, 선행주제, 근거레인, 추론상한 (구조화매트릭스에서생성)

ID	기여	선행주제 (참고문헌수)	레인	추론상한
C1	신뢰경계 contract	T1, T2, T3 (15)	E1, ENG1	인코딩필드계약적합성
C2	validate-repair-commit controller	T1, T8 (14)	E1, ENG1	동결사례의메커니즘 동작
C3	감사연결근거계층	T4, T7, T8 (6)	E1, ENG1	명명 fixture 의무결성 · 재생
C4	assignment-complete harness	T4, T6, T7 (18)	E1	설계사례정확집계
C5	반례유도연산자 ρ	T1, T8, T9 (8)	E1, E2	동결 class + 단일 regime screen

T1 = 근거게임세계; T2 = 검색 · 메모리예이저트; T3 = 구조생성; T4 = 환경 · 벤치마크; T5 = 플레이어경험; T6 = 인간 · LLM 평가; T7 = 통계 · 재현성; T8 = 계획 · 런타임개입; T9 = 피드백수리. 레인은표 IV에정의한다. 모든행은구현 · 작성 fixture 검증상태이며어떤 C-RESULT-* 효능 claim 도지지하지않는다.

- 4) **C4—harness**: proposal trace 가존재할수없는경우에도분류된 terminal row 를유지하는 assignment-complete 오프라인적합성 harness (V절; E1);
- 5) **C5—수리**: 동결 repairability class 에서 blind retry 및 state-reading oracle 과비교한 counterexample-guided operator $\rho(a, E)$ (IV-B절; E1, E2).

기계검증되는기여매트릭스에서생성한표 I은 C1–C5 를선행주제, 근거레인, 추론상한에결합하고, 표 IV는레인을정의한다.

레인은서로대체할수없다 (표 IV). **E1** 은단일작성 world 의결정론적적합성파일럿으로인코딩된메커니즘동작을측정하며모집단효능은측정하지않는다. **E2** 는셀당 5 회호출의라이브스크리닝으로, 고정되지않은 revision, 제어되지않는 seed label, 구성된 state 때문에 pilot-only 가상한이다. **E3** 는런타임검색없이 closed world 에서작성된 typed-link proposal 만채점한다. ENG1 은엔진로컬 Godot 4.7.1 적합성만추가하며, startup 이지배하는 frame sample(98.760–116.667 ms) 은 benchmark 가아니다. 참여자, 감정실험, live Python–Godot 왕복은없다.

II. 관련연구와연구공백

A. 인터랙티브내러티브와게임에이전트

KNUDGE 는퀘스트와엔터티명세에근거한분기형 NPC 대화를평가한다 [3]. 지식그래프보조퀘스트생성 [4], 메모리-성찰-계획에이전트 [11], 학습가능한역할연기 에이전트 [12] 는근거성과개연성있는행동의상호보완적측면을다룬다. 플레이어대상연구는 선호와지각된대화품질을평가한다 [13], [14]. Yin 등의 2026 년온라인레코드는서지감사당시미래시점의권호가배정되어있어제출시다시확인해야한다 [15]. 2025 년프리프린트는역할에따른안정성-즉흥성 trade-off 를보고하며 [16], 본논문은이를최근동기로만사용한다. 이연구들은하드허용가능성을선택적자연스러움및플레이어경험구성개념과분리할필요성을뒷받침한다.




Fig. 1. 생성이벤트하나의트랜잭션경로다. typed candidate 만신뢰검계를넘고, 외부 policy 와 c_t 를어섯상태상대계열의검사 7 개가확인한다. typed 오류 E 는 bounded ρ (점선) 또는변경없는 fallback 으로이어지고, 통과후보는재검사 ·commit-record-replay 된다. 태그는 claim 이아닌측정범위를표시하며, 아래 strip 은 committed snapshot 에서파생한 ledger 문법이다.

경험주도콘텐츠생성 [17] 과관찰자료식참여도 [18] 는미래적응트랙의동기가된다. 최근프린트는 vision-language model 의참여도추론한계를보고한다 [19]. 따라서감정은비권위적맥락으로유지되며현재구현거에는포함되지않는다.

B. 환경과벤치마크

TextWorld 와 ScienceWorld 는명시적인인터랙티브상태를제공하며 [1], [2], MineDojo 는개방형지식집약 embodied 과제를추가한다 [20]. General Video Game AI 는에이전트, 게임, 콘텐츠트랙을분리한다 [21]. AgentBench 는이질적인환경의에이전트를연구하고 [22], AgentBoard 는과정수준진단을추가하며 [23], SOTOPIA 는사회적상호작용을평가하고 [24], BALROG 는장기언어및시각게임추론을평가한다 [25]. 자동화된플레이스타일에이전트는상호보완적인시험선레이지만인간평가를대체하지않는다 [26]. 이벤치마크는미래평가설계에정보를주지만트랜잭션승인경계를규정하지는않는다.

C. 제약, 신경-기호검증, 검색

제약디코더는출력구조를개선한다 [5], [6], [7]. 반면 TRACE-RPG 은구조를독립적인상태상대승인의입력조건으로취급한다. 같은 generate-and-verify 분업은게임밖에서확립되어있다. LLM-Modulo 프레임워크는모델이제한한계획을외부의 sound critic 이수락또는거부하게하고 [27], SayCan 은언어로제한된 skill 을상태의존 affordance 검사뒤에만허용한다 [28]. AgentSpec 은 LLM 에이전트의런타임규칙을 trigger-predicate-enforcement 삼중항으로표현하고 [29], TRACE-RPG 은술어를게임상태에고정하며수리계약과리플레이가능한레코드를추가한다. Setting the DC 는 D&D 에이전트를 precondition 검사가능한 tool call 예근거시키는반면 [30], TRACE-RPG 은자유텍스트제안을 parsing 과외부 policy 평가뒤에만허용한다. STORY2GAME 은플레이에쓰이는 action precondition 과 effect 를 LLM 스스로생성하

게하지만 [31], 여기서는 policy 가제안자와독립적으로저장된다. TRACE-RPG 은이 critic 을 typed 반례를반환하는결정론적상태상대 commit gate 로구체화한다. 게임특화비교대상은서로다른경계를보여준다. PANGeA 는 LLM 이설계자규칙에따라콘텐츠를판정하고수정하도록해검증하고 [32], 비아카이벌 ICC 2026 자료와연계된프린트 IVIE 는기호검증으로인터랙티브픽션세계를점진적으로생성하며 [33], 같은계보의 2026 년후속시스템은 LLM 을저작된 world-state transformation 선택으로제한해 [34] 트랜잭션게이트, 감사연결레코드, 수리연산자근거없이구성상일관성을얻는다. 어느비교도우월성을뜻하지않으며, 유효성은각시스템이인코딩한술어에한정된다.

G-Retriever, HippoRAG, Mem0 는관련하위그래프검색과장기메모리를다루고 [8], [9], [10], Generative Agents 와 Character-LLM 은행동메모리와 persona 를다룬다 [11], [12]. TRACE-RPG 은향후이러한맥락을사용할수있지만직접적인커밋권한은부여하지않는다. 검색과시간적메모리효익은여기에서측정하지않는다.

D. 감사가능성과재현성

과정지표는중간실패를보존할동기를제공하고 [23], 강건한평가는소수확률적실행의과도한해석을경고한다 [35]. 재현성과환경보고지침은동결된산출물과명시적측정경계를뒷받침한다 [36], [37]. 인간및 LLM 평가는구성개념, 평가자, 편향통제를요구하며 [38], [39], [40], [41], 향후비열등성과참여자분석에는정당화된 margin 과 random-effects 구조가필요하다 [42], [43]. Record-and-replay 는경험재사용을위한확립된에이전트패러다임이지만 [44], TRACE-RPG 은승인된상태전이의의미적리플레이만주장한다.

제한된 novelty 는개별구성요소의발명이아니라구현된결합이다. 선행연구는범용에이전트의런타임강제 [29], 생성된게임세계의기호적상태관리 [30], [31], 피드백기반수리 [45], 에이전트 record-and-replay [44] 를각각따로보여준다. TRACE-RPG 은이들의교집합을게임상태 commit 경계에서연구한다. 즉 parsing 된제안을독립적인 policy 와결정론적술어로검사하고, bounded validator feedback 으로선택적으로수리하며, 의미적리플레이를위해기록한다. 행동개입 (interposition) 자체는오래된기법이다. 내러티브 mediation 은행동을실행전제가로채고 [46], 고전계획법은 precondition 과 effect 로적용가능성을정의하며 [47], 런타임강제는허용된전이만통과시키고 [48], 트랜잭션처리는 abort 시이전상태를그대로남기며 [49], 작성형논리기반인터랙티브드라마는캐릭터가할수있는발화를규율했고 [50], 신념인지내러티브계획법은캐릭터가아는바를추론한다 [51]. 후자는본논문의 knowledge/disclosure 술어가훨씬거칠게인코딩하는관심사다. C1-C2 는 strict contract 와 validate-repair-commit controller 를이계보위에배치하고, C3-C4 는 checksum-linked record, state-semantic replay, episode continuity, proposal trace 가없는사례까지보존하는 assignment-complete accounting 을더하며, C5 는실행된 typed validator error 만소비하는수리연산자를분리한다. 보고서에기능이없다고해서모든구현에그기능이없다고추론하지않는다.

III. 문제정의와보장경계

설명을위해시점 t 에서 validation 이사용하는 controller 입력을다음과같이분해한다.

$$c_t = (G_t, q_t), \quad (1)$$

여기서 G_t 는 typed snapshot field 를, q_t 는해당 snapshot 과함께저장되는외부작성 action-policy, disclosure, quest-stage 제약

을 나타낸다. 종단 record history $h_{<t}$ 는 WorldState snapshot 과 별도로 유지된다. Validation predicate 는 이를 읽지 않으며 구현 은 log 에서 상태를 재구성하지 않는다. 검색, 내러티브점수, 모델 rationale, 메모리 요약, 미래의 감정 추정 은 비권위적 proposal context 이다.

신뢰하지 않는 proposer 가 후보 a_t 를 출력한다. 타입 엄격 parsing 은 알 수 없는 top-level field 의 거부 를 포함 한 공유 candidate-key contract 를 먼저 강제 하고 선언 스키마를 확립 한다. validator 는 다음을 반환 한다.

$$V(c_t, a_t) = (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, v_{\text{disc}}, v_{\text{quest}}, E_t), \quad (2)$$

여기서 E_t 는 구조화 오류 집합이다. 상태 변경 은 다음과 같다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_i v_i = 1, \\ c_t, & \text{그외.} \end{cases} \quad (3)$$

Controller 는 인코딩된 계약 아래 다음 구현 불변량을 주장 한다. 파일럿 은 이를 일반 정리로 제시 하지 않고 deterministic valid, invalid, repair, fallback, replay, fault-injection fixture 로 해당 mechanism 을 시험 한다. **I1 (소진 실패 불변성):** 예산 K 까지 반환 되면 후보도 검증을 통과 하지 못 하거나 proposal/controller 실행이 commit 전에 실패 하면 반환 상태는 공급된 prior state 와 같다. **I2 (제한된 기록 시도):** 모든 proposal 과 repair callback 이 반환 한다는 조건에서 repair budget $K \geq 0$ 은 최대 $K + 1$ 개의 candidate attempt 를 기록 한다. 성공적인 commit 은 변경 전 수락 후보에 대한 방어적 validation 을 한번 추가 한다. Runtime 은 callback deadline 을 강제 하지 않으므로 I2 는 wall-clock 종료 보장 이 아니다. **I3 (효과 권한):** 수락 후보는 ActionPolicy.allowed_effects 밖의 선언된 fact effect 를 CandidateAction.effects 에 포함 하지 않으며, quest-stage target 도 해당 policy 에 의해 명시적으로 승인 된다. **I4 (상태의 의미적 리플레이):** 동결된 스키마와 결정론적 전이 아래 수락된 trace 는 명시된 terminal state 를 재구성 한다.

이 주장된 불변량은 올바른 정책 작성, 선언된 후보 필드로의 완전하고 충실한 추출, 결정론적 소프트웨어 버전, callback 반환, 단일 프로세스 파일 소유권을 가정한 다. 상태의 의미적 리플레이는 기록된 구조화 후보와 전이를 재검증 하지만, 중간 수리의 provenance, reasoning, prompt, 확률적 생성은 재현 하거나 검증 하지 않는다. 구조화 필드에서 누락된 자연어 함의는 보장 범위 밖이다.

IV. TRACE-RPG 아키텍처와 알고리즘

A. 신뢰 경계와 계약

그림 1 는 모델 또는 recorded adapter 를 canonical owner 밖에 둔다. Parser 는 알려진 필드의 모호한 숫자 또는 collection type 을 거부 하고 공유 key contract 에 따라 알 수 없는 top-level candidate field 도 거부 한다. action policy 는 candidate 와 별도로 공급되며 required precondition 과 allowed effect 를 정의 한다. Game bridge 는 observation, proposal, validation, rejection, fallback, commit 을 전달 할 수 있는 versioned event interface 이며, 정식 상태 변경은 유효한 commit 만 승인 한다. 이는 interface 를 분리 하지 만 상용 엔진으로의 portability 를 아직 입증 하지 않는다. 표 II 는 구현 검사 7 개를 여섯 개의 계열로 묶는다. Quest eligibility 와 quest-stage monotonicity 는 별도로 검사로 유지된다. 이 인코딩 경계는 의미적 완결성 주장이 아니다.

TABLE II
인코딩된 Validator 경계

술어	거부 대상	실패시 상태
Action policy	알 수 없는 action/type	변경 없음
Precondition	누락/거짓 requirement	변경 없음
Reachability	접근 불가 object	변경 없음
NPC knowledge	선언되지 않은 known fact	변경 없음
Disclosure	forbidden fact	변경 없음
Quest	부적격/후퇴 stage	변경 없음

```

1:   $a \leftarrow \text{Propose}(c); j \leftarrow 0$ 
2:  repeat
3:     $(ok, E) \leftarrow V(c, a); \text{Record}(a, E)$ 
4:    if  $ok$  then
5:      assert  $V(c, a).ok$ ; return  $\text{Commit}(c, a)$ 
6:    if  $j = K$  then return  $\text{Fallback}(c)$ 
7:     $a \leftarrow \text{Repair}(c, a, E); j \leftarrow j + 1$ 
8:  until terminal

```

Fig. 2. Validate-repair-commit 절차. 최대 $K + 1$ 개의 candidate attempt 를 기록하며, 성공 경로는 상태 변경 전 방어적 validation 을 수행 한다.

B. Validate-Repair-Commit

그림 2 은 제어기의 추가 패키지 없는 의사 코드를 제시 한다. “Record” 는 in-memory trace 표현에 추가 하는 것을 뜻 하며, 영속 쓰기는 종단 일관성 검사 뒤에 만 수행 한다.

검증 오류는 구조화된 error code 로 repair callback 에 노출 된다. repair 는 상태를 직접 변경 하지 않으며, 예산 소진 시 변경 없는 결정론적 fallback 을 반환 한다. 그림 1 이 종단 경로를 나타낸다. 파일럿 은 구현된 두 callback 을 비교 한다. 반례 유도 연산자는 이전 후보 a 와 validator 의 구조화 오류 집합 E 만을 소비 하며 권위 있는 상태 는 결코 읽지 않는다.

$$\rho(a, E) = a \oplus \bigcup_{e \in E} \delta(e), \quad (4)$$

여기서 각 $\delta(e)$ 는 표 III 의 오류 class 별 결정론적 edit 이고 $\oplus$ 는 그 field edit 들을 적용 한다. 각 edit 은 오류 entity 당 최대 하나의 candidate field 만 수정 하므로 시도 당 변경 field 수는 $|E|$ 로 유계 이고, 같은 오류 집합으로 ρ 를 두 번 적용 하면 고정점이며, 같은 field 에서 동시에 요구 되고 거부 되는 entity 는 수리 불가로 선언 되어 수정 되지 않는다. 상태를 읽는 참조 callback 은 반대로 오류 집합을 폐기 하고 정책이 규율 하는 field(precondition, effect, 두 quest-stage field) 를 권위 있는 상태에서 직접 재구성 한다. 이 callback 은 선언 무결성 field(required object, used fact, disclosed fact) 들의 도적으로 수정 하지 않는다. 의존성이나 disclosure 의 선언을 지우는 것은 후보를 수리 하는 것이 아니라 위반을 게이트 워로 세탁 하는 것이기 때문이다. 이는 상태 판독 가능 수리에 대한 oracle 상한이며, 그 결과 를 배포 가능한 수리 방법의 근거로 읽어서는 안 된다.

C. 무결성, 의미적 리플레이, 계수

각 result row 는 키 없는 SHA-256 무결성 체크섬을 가지며, proposal outcome 은 추가로 trace checksum 과 연결 된다. 이 hash 들은 우발적이거나 시험 대상 인 콘텐츠 변경을 탐지 하지만 signature, message-authentication code, writer identity 가 아니며 콘텐츠와 checksum 을 모두 다시 쓸 수 있는 행위자에 대한 보호도 아니다. 의미적 리플레이는 prior state 와 기록된 모든 candidate/validation pair 를 엄격히 parsing 하고, final 이 아닌 모든 attempt 가 invalid 임을 요구 하며, terminal transition 을 재계산 하고, 명시된 final state 와 비교 함으로써 byte 무결성을 넘어서 다. Episode replay

TABLE III
유도연산자 ρ 의 오류 class 별 edit

Validator 오류 class	후보에대한 edit $\delta(e)$
정책 precondition 누락	명명된 predicate 삽입
정책 effect 누락	명명된 effect 삽입
정책 effect 위반	명명된 effect 제거
불충족 precondition	명명된 predicate 제거
비인가 stage 변이	quest_stage_effect 초기화
알수없는 action type	no-op (등록된대안없음)
도달불가 object; knowledge, disclosure, stage class	no-op (후보국소 edit 은세탁이거나 상태지식필요)

TABLE IV
실험레인 요약: 설계, 단위, 비교, 추론상한 (실험매트릭스에서 생성)

레인	설계	단위 / 예산	비교	상한
E1	오프라인적합성: 작성 동결 fixture, 단일 world	gate 13; arm 당 repair 12; fault 10; adapter 7; guard 3	reject / blind / ρ / oracle	메커니즘적합성
E2	라이브 RQ2 스크리닝: hosted proposer 1 개, matched candidate	5 cell $\times$ 5 call; $K=1$	regime 별 ρ / blind	pilot-only 전이 screen
E3	KG/온톨로지시뮬레이션: closed-world typed-link holdout	node 43; 참조 edge 106; typed 24; score 210	degree baseline / 고정전략 6 종	구성결과만
ENG1	Godot/Web 엔지니어링: 엔진로컬 policy mirror, 참여자없음	fixture 4; check 52; smoke 8; archetype 5	작성 fixture 경로	엔진로컬적합성

E1-E3 와 ENG1 은 서로 대체할 수 없으며 분모가 다르다. 어떤 레인도 모집단 효능, 모델 순위, 플레이어 경험, 런타임 검색 효익, 상용 엔진 성능을 확립하지 않는다.

는 인접 JSONL record 사이의 상태 연속성도 요구한다. Replay 는 candidate $j + 1$ 을 만든 repair-generation 단계를 인증하거나 다시 실행하지 않는다.

Terminal record class 는 commit, symbolic fallback, adapter failure, controller failure 이다. Controller-failure row 는 동결된 assignment denominator 에 남고 상태를 변경하지 않지만, candidate outcome 이 생성되지 않았다면 완성된 proposal trace 가 없어도 된다. 따라서 result completeness 가 모든 terminal row 의 trace 존재를 뜻하지 않는다. 실행전 assignment key 는 (run, arm, scenario, seed, model, revision, $h_{\text{controller}}$, h_{input} , h_{prior}) 이다. 집계는 중복, 누락, 예기치 않은 key 를 거부하고 symbolic, adapter, controller failure 를 각각 보고한다.

V. 실험 레인과 근거리 경계

표 IV 는 어떤 count 를 읽기 전에 각 레인의 설계, 단위, 비교, 상한을 고정한다.

A. E1 오프라인적합성 설계

파일럿은 다음을 묻는다. (PQ1) 유효 후보는 commit 되고 명명된 invalid-policy 사례는 변경 없이 유지되는가? (PQ2) 동결된 모든 repairability class 의 작성 사례에서 rejection-only, 블라인드 동일 후보 retry, 반례 유도 연산자 ρ , 상태를 읽는 참조 callback 이 예상 결과를 만드는가? (PQ3) 동결된 checksum, state-semantic, linkage, continuity mutation 이 지정된 검사 연산에서 거부되고, 두 번째 파일 append 의 주입된 실패가 예상 pair-write rollback 검사를 작동시키는가? (PQ4) 엄격한 adapter 와 assignment manifest 가 할당 사례마다 정확히 하나의 분류된 terminal row 를 유지하거나 fail closed 하는가? (PQ5) proposal 및 replay parser 가 그 외에

는 완전하고 유효한 candidate 에 unknown top-level key 하나를 추가한 사례를 모두 거부하는가?

사례는 의도적으로 설계된 적합성 픽처이며 모델 또는 게임 모집단의 표본이 아니다. 네도메인은 validator/state isolation, repair-arm 비교, record/trace fault injection, adapter/accounting contract 이다. 모든 repair fixture 는 실행전에 동결된 repairability class 를 선언한다. *guided-repairable*(구조화 오류 payload 만으로 ρ 에 충분한 정보가 담김), *oracle-only*(수리에 권위 있는 상태 판독이 추가로 필요함), *irreparable*(구현된 어떤 arm 도 commit 할 수 없음)이며, class 별 arm 당 기대 결과는 설계 픽처 계약의 일부다. 반복된 결정론적 seed 가 아니라 고유 사례가 기술적 denominator 를 구성한다. 모든 기대 값은 실행전에 명시한다.

측정치는 정확한 count 이다. expected/observed validator-class agreement, rejected 또는 controller-failure 사례의 state mutation, repair arm 과 repairability 별 commit 및 attempt 결과, 지정된 연산에서 거부된/사전명세된 detectable fault, replayed/committed trace, rejected/injected manifest violation, 사전명세한 unknown-key 음성 회귀에 대한 proposal/replay 거부 일치를 센다. 마지막 측정치는 결정론적 parser-contract parity 이며 실증적 safety outcome 이 아니다. Exception class 만으로 안정적 detector layer 를 식별할 수 없으므로 detector 귀속 결과는 보고하지 않는다. 의도적으로 설계된 픽처에 p -value 나 모집단 confidence interval 을 부여하지 않는다. Adapter 사례가 지닌 latency 및 token 상수는 입력 스키마가 JSON-Schema const 로 고정된 합성값이다. 이 값들은 계수 필드 전파만 확인하며 provider, runtime, device 에 대한 측정값이 아니다.

릴리스 패킷은 fixture 및 assignment manifest, schema, outcome/trace record 를 포함한 result JSON 산출물, 환경과 코드 revision, 생성 table, checksum 을 동결한다. 보고는 재현성과 측정 경계 지침을 따른다 [36], [37].

B. E2 라이브 RQ2 스크리닝

라이브 확장은 블라인드 동일 후보 retry 와 ρ 를 동일한 $K=1$ 에서 비교한다. 각 셀에서 seed 로 구분한 Codex CLI 호출 5 회가 gpt-5.6-sol 후보 하나씩을 만들고, 두 arm 은 같은 최초 후보를 받아 호출 내제 안 차이를 제거한다. 조건은 policy 공개 여부와 자명 한 효과 0 경로의 존재를 바꾼다. 승격 패킷은 정정된 현재 셀과 폐기된 v1 진단을 함께 보존하고 모든 JSON/JSONL 영수증을 SHA-256 으로 결합하며 근거를 screening-pilot-only 로 표시한다. Seed label 은 hosted sampler 를 제어하지 않고, hosted revision 은 고정되지 않았으며, token 회계는 없고, 구성 상태는 모집단 표본이 아니다. 따라서 p -value, confidence interval, 모델 순위 없이 정확한 기술 count 와 실패 class 만 보고한다.

C. E3 KG/온톨로지 링크제안 시뮬레이션

SL-KG-ONTOLOGY-SIM-001 은 Graphify 문서 탐색 그래프 및 권한을 가진 typed WorldState 와 분리된 engineering-only closed-world 레인이다. 저장소 로컬 OKF node 43 개와 reference edge 106 개를 내보내고, 검토된 typed edge 24 개를 overlay 하며, type/domain/range 무결성과 source 별 competency question 6 개를 검사하고, 권한이 없는 SQLite mirror 를 생성한다. 고정 전략 7 개는 작성형질의 6 개와 질의 당 후보 5 개를 평가했다. Retained S2-typed-lexical-loose 는 holdout 6/6 을 복원했고 ($P = R = F_1 = 1.000$, realistic-tie MRR = 0.944, Brier = 0.131, Sem@3 = 1.000), degree baseline 은 하나도 복원하지 못했다. Machine-generated JSON, TSV, TeX, SVG 산출물 이전 체 수식과 trial 을 보존한다. 이는 구성

결과이며 OWL/SHACL 적합성, 의미완전성, runtime retrieval, 장기모순감소, 어떤 C-RESULT-* claim 의근거도아니다.

VI. 파일럿결과

A. 구조필드게이트적합성

파일럿 loader 는 구현된 validator code 를정확히한번씩고립시키는 fixture 집합과유효 control 1 개만을허용한다. 따라서 13/13 일치와구현된오류코드 12 종의관찰은측정된성공률이아니라 하니스의구성불변량이다. 이실행이보여주는것은 loader 가강제하지않는부분, 즉고립된유효성 fixture 12 개가각각다른코드가아니라작성된기대코드와일치했고비 commit 경로가전체정준상태를유지했다는관찰이다. 이는단일 world state 에서저자가설계한구조필드 oracle 에대한구현적합성이며독립의미판정의정확도가아니다.

B. 설계픽처에서의수리 arm 비교

처음부터유효하지않는설계 case 12 개는 guided-repairable 5 개, oracle-only 1 개, irreparable 6 개의동결된 repairability class 로분할된다. Rejection-only 와블라인드동일후보 retry 는각각 0/12 commit 이었다. 반례유도연산자 ρ 는 guided-repairable case 5/5 를 commit 했고, 설계상 oracle-only 0/1, irreparable 0/6 었다. 모든 ρ commit 은 candidate field 를평균 1.0 개수정했으며, 실패한모든 arm 실행은정준상태를변경없이유지했다. 상태를읽는참조 callback 은 guided-repairable 5/5 와 oracle-only 1/1 를 commit 했고 irreparable 은 0/6 었다. 이정확한 count 는세메커니즘을설계픽처위에서분리한다. 블라인드 retry 는반례를 commit 으로전환하지못하고, ρ 는오류 payload 에충분한정보가담긴 case 만전환하며, oracle 은상태지식이필요한 case 를추가로전환한다. commit 된 guided case 5 건이처음받은 validator code 는각각 POLICY_PRECONDITION_OMISSION+UNSATISFIED_PRECONDITION, POLICY_EFFECT_OMISSION, POLICY_EFFECT_VIOLATION, UNSATISFIED_PRECONDITION, POLICY_QUEST_STAGE_EFFECT_VIOLATION 이며, 각 case 는표 III의해당 edit $\delta(e)$ 만으로유효해졌다. 이는동결픽처에대한연산자적합성이며, 어떤 live model 의수리품질도아니다.

C. 무결성, 경계, 배정회계

현재명세가검출가능하다고지정한 10 개 fault fixture 는모두지정된검사연산에서거부됐다 (10/10). 이파일럿은안정적인 typed detector code 까지대조하지않으므로 detector layer 귀속을입증하지않는다. 별도로, 동일하게기록된유효수리앞의무효선행후보를다른무효후보로치환하고체크섬을재계산한알려진 provenance 경계는예상대로재생을통과했다 (1/1 미검출). 따라서키없는체크섬을재계산할수있는작성자를방어하지않으며, 재생은 repair 생성연산의출처를인증하지않는다. 열린경계 sentinel 두건—자연어 disclosure 미추출과 required object 의후보 · 정책동시누락—은 2/2 가의도대로인코딩상허용됐고 safety pass 는 0 건이었다. 과거 unknown top-level field 허용경계는 Stage 8 이후단일유효성회귀로재분류되었으며, 완전한 12-field candidate 에 unknown key 하나를추가한 fixture 를 proposal-replay parser 모두구체적으로거부했다 (1/1). 이는 parser rejection parity 이지의미안전성의증거가아니다. Adapter/accounting 7 개배정에서는 commit 1, 기호 fallback 1, adapter failure 5 었다. 합성 telemetry 필드는 2/7 배정에서채워져전파됐으며, 이는측정값이아니라회계필드전파확인이다. 배정 guard 3/3 가중복 · 누락을거부했다. 이수치는모두합성 offline fixture 의 raw count 다.

TABLE V
수리 arm 별 repairability class 정확집계 (설계픽처)

Arm	정보원	Commit / 사례			평균수정 ^e
		G-rep. ^f	O-only ^f	Irrep. ^f	
Rejection-only ($K=0$)	없음	0/5	0/1	0/6	—
블라인드 retry	없음	0/5	0/1	0/6	—
반례유도 ρ	오류집합 E	5/5	0/1	0/6	1.0
상태판독 oracle	권위상태 + 정책	5/5	1/1	0/6	1.0

^eCommit 된수리의변경 candidate field 평균개수 (최소성 proxy); 실패한 arm 실행은상태를변경하지않았다. ^fCommit/사례수. G-rep. = guided-repairable, O-only = oracle-only, Irrep. = irreparable(동결 repairability class).

TABLE VI
동결파일럿검사와중단결과 (행간직접비교불가)

검사또는중단군	정확결과	해석범위
게이트 fixture 일치	13/13	저자 oracle 일치
알려진경계허용	2/2	인코딩한계, safety pass 아님
단한 unknown-key 거부	1/1	proposal/replay parser parity
탐지가능무결성결함거부	10/10	지정된검사연산
알려진 provenance 경계허용	1/1	repair 생성출처미인증
Adapter 중단 class	1 commit; 1 fallback; 5 실패 / 배정 7	배정 7 건의분류완전성
Manifest guard 거부	3/3	주입결함 fail-closed

행마다분모와성공방향이 다르므로비율처럼순위를비교하지않는다. 모든값은설계픽처의정확한감사사실이다.

표 V와 VI은정확한설계픽처 count 를보고한다. 수리표는동결된 repairability class 별로네 arm 을분리하며, 어느표도모집단또는 live-model 추정을지지하지않는다.

D. 라이브스크리닝파일럿 (pilot-only)

별도스크리닝파일럿은 Codex CLI 를통해 gpt-5.6-sol 을호출했다. 셀마다 seed 로구분한제한호출 5 회와수리예산 $K=1$ 을사용했고, 각호출의최초후보하나를블라인드동일후보 retry 와 ρ 가공유했다. Hosted revision 은고정되지않았고 token 회계는제공되지않았으며 seed 는 hosted sampler 를제어하지않으므로이호출들은독립무작위표본이아니라준반복이다. 따라서추론통계나모델순위를보고하지않는다.

표 VII에서유도우위는의도적으로 guided-repairable 오류가나오도록구성한 signal-repair-v2 의 policy-blind 셀에서만나타났다. 최초후보 5/5 가모두무효였고 ρ 는 5/5, 블라인드는 0/5 를 commit 했다. 나머지현재셀 4 개는유도우위를보이지않았다. 세셀은최초후보가이미유효했고, 동결기저의 goal-directed 셀은수리불가 quest-stage regression 이었다. 현재셀의 모든 noncommit arm 결과 15/15 가 prior-state hash 를보존했다. 이결과해당유류 regime 에서의 mechanism transfer 만지하며모집단호능, 모델승격, 표본호출일반화는지지하지않는다. 따라서 C-PILOT-007 과 C-PILOT-008 은 pilot-only 이고 C-RESULT-003 은 TODO-RESULT 로남는다. 폐기된 v1 진단에서는동반유류가최대 3 개에서수리불가 knowledge 유류 1 개로줄었지만 commit 되지않아, 오류하나라도수리불가이면부분수리가합성되지않음을보여주었다.

보고경계는명시적이다. 동결 fixture 와지정검사연산이허용한 row 만오프라인생성표에들어가고, 라이브표는 SHA-256 으로결합한 screening promotion manifest 를통과하는별도경로를사용하며 row 는동결오프라인 denominator 에들어가지않는다. 각 lane 이측정하지않은항목은표 IV가나열한다.

OBSERVATION		FALLBACK · NO MUTATION		COMMIT · REPLAY-BOUND	
EVENT evt-000-observe		EVENT evt-002-fallback-secret		EVENT evt-005-commit-hint	
(1) 관찰		(2) 보류, 상태불변		(3) commit, 상태변경	
패널	캡처	이벤트 id	검증	이벤트후상태	
(1)	s1-rc-001-arrival	evt-000-observe	not applicable	= before	
(2)	s1-rc-002-rejected-secret	evt-002-fallback-secret	invalid: forbidden, stage-gated disclosure	= before	
(3)	s1-rc-003-authorized-hint	evt-005-commit-hint	valid	facts += tide_marks_hint; ≠ before	

Fig. 3. 작성형 Godot render replay 의인과순서화. (1) 도착관찰, (2) 금지된 disclosure 가보류되어 state hash 불변, (3) 승인된 hint 가 commit 되어 state hash 변경. 각행은 godot-4.7.1-20260813t115916z-sealed-lighthouse-render-v5/ 아래의결합된 v5 capture manifest 와 event log 에서읽었고, crop 은작성된 status/event callout 만확대한다. 이 trace-bound 대응은 live transport, 성능, usability, efficacy 근거가아니다.

TABLE VII
라이브스크리닝파일럿정확집계 (셀당제한 5 회, $K=1$)

기저 / 조건	최초유효	ρ vs blind commit	Δ	최초오류
동결 / 공개	5/5	5/5 vs 5/5	+0	—
동결 / 비공개	5/5	5/5 vs 5/5	+0	—
동결 / 목표-비공개	0/5	0/5 vs 0/5	+0	QSR
Signal-v2 / 공개	5/5	5/5 vs 5/5	+0	—
Signal-v2 / 비공개	0/5	5/5 vs 0/5	+5	PEO+PEV+PPO

QSR = quest-stage regression, PEO = policy-effect omission, PEV = policy-effect violation, PPO = policy-precondition omission. Δ 는 동일후보에서 ρ commit 수 minus blind commit 수다. 모든수치는 screening-pilot-only 이며추론통계가아니다. 폐기된 v1 진단은표에서제외한다.

ENG1. Godot 4.7.1 은보존한 *Sealed Lighthouse* 정식 trace 를 non-headless 1280×720 SubViewport 에서리플레이했다. 그림 3(2) 는변경전 hash 를보존하고, (3) 은 valid commit 뒤 이를변경한다. 플레이가능 slice 의 ledger 판독 (case chain, rules learned, commit 별 contribution 절; 그림 1 아래 strip) 은 committed snapshot 에서만파생되며, 결합엔지니어링검사 52 개 중 presentation 불변량 12 개가이를다룬다. 이수치는엔지니어링 적합성 count 이지재미, usability, efficacy 근거가아니다. 선택 v5 packet 은하나의 scripted fixture 의 render/state 대응만확립 하며 live model 또는 Python transport, participant 또는 player input, adaptation intervention, narrative-quality result 를추가 하지않는다.

VII. 논의

A. 확립가능한범위

설계파일럿은동결된사례에대해서만 mechanism behavior 를확립할수있다. 인코딩된검사가상태를격리하는지, bounded repair 와 fallback 이선언경로를따르는지, 명명된 corruption 이 지정된 검사연산에서거부되는지, assigned row 가집계를위해분류된상태로남는지를평가한다. 거부를안정적인 typed detector code 에귀속하지않는다. 이는 authoring-time validation, continuous-integration regression, recorded-adaptor test, engine 이전 replay inspection 에유용하다.

오프라인수리비교의정직한해석은 guided-대-oracle 경계다. 상태를읽는 callback 이상한으로남는이유는권위있는상태를참조할수있어서 ρ 가구성상전환할수없는 oracle-only 사례를전환하기때문이다. 반례유도연산자는 validator 의구조화반례만소비하면서 guided-repairable class 에서 oracle 과정확히일치한다. 이 어라이브스크리닝확장은이 mechanism 이 hosted proposal 로전 이되는지를탐색했다. 구성상태가모든제안을 guided-repairable class 로유도했을때만 ρ 와 blind retry 가분리됐고, 최초유효

및 guided-irreparable regime 은귀무였다. 이 regime 의존성, 고정되지않은 hosted revision, 준반복호출때문에일반표본효율이 나모델능력을주장할수없다. Feedback 을소비하는수리루프에 는선례가있다. Self-Refine 은같은신뢰하지않는모델이생성한언어를 feedback 으로되먹이고 [45], Reflexion 은시도간 verbal self-reflection 을저장하며 [52], Self-Debugging 은신뢰되는전체프로그램 runtime 의실행결과를소비한다 [53]. ρ 는 channel 과권위에서다르다. Feedback 은실행전에결정론적 validator 가 계산한 typed 오류집합이고, 실패한모든 live arm 은상태를격리한다. 이름은명세의전체상태가아니라 verifier 의반례가다음후보를이끄는 counterexample-guided inductive synthesis 를따르며 [54], 여기서 verifier 는 commit gate 자체다.

B. 선행연구와의관계

TRACE-RPG 은 constrained decoder [5], [6], [7], 검색및메모리구성요소 [8], [9], [10], 실행가능한환경과 benchmark [1], [2], [22], [25] 를대체하지않고보완한다. Process-linked trace 는 AgentBoard 의측정관심을구현하지만 [23] 우월성의근거는아니다. 확증연구, 즉독립 semantic oracle 과실제 blind-retry comparator 를갖춘사전등록다중모델비교, 인코딩된 validity 를맞춘 retrieval 및 memory ablation, 정당화된검정력과 mixed-effects 분석을갖춘 blinded matched-validity 인간연구는여전히 본논문의범위밖이며, 스크리닝파일럿은어느연구도대체하지않는다 [22], [38], [35], [43].

VIII. 타당성위험, 윤리, 산출물범위

근거에는명시적경계 9 개가있다. **L1:** encoded predicate 는 structured field 에서빠진의미를발견하지못하며, 상태일관성만으로는행동적 · 서사적일관성이성립하지않는다 [55]. **L2:** authored world 하나와 constructed live-state variant 하나로 cross-world, cross-policy, 규모일반화를말할수없다. **L3:** state-reading callback 은 oracle 이며 offline class 와 regime-dependent screening 은일반 repair 품질이나 sample efficiency 를확립하지않는다. **L4:** hosted proposer 하나는 revision 고정, token 회계, sampling 을제어하는 seed 가없고 live Python-Godot authorization round trip 도없다. **L5:** participant 와 affect data 가없다. **L6:** unkeyed hash 는 integrity 만제공하며 writer authentication 이나 adversarial tamper resistance 는제공하지않는다. **L7:** record consistency 는 single writer 를가정하며 concurrent-writer safety 는미검증이다. **L8:** engine evidence 는 startup-dominated sample 이 16.7 ms 를넘는 Godot fixture 하나이며 portability 나 real-time 결과가아니다. **L9:** 선택된 fixture 와 screening cell 은 population, safety-rate, model-ranking 추

론을 지지하지 않는다. Internal validity 는 독립 policy expectation 및 fixture leakage 부재에, reproducibility 는 고정 software 와 artifact 예의존한다.

파일럿은 participant 또는 personal telemetry 를 처리하지 않는다. 향후 human 및 affect 연구에는 해당 review, informed consent, compensation disclosure, minimization, retention/deletion rule, opt-out 이 필요하다. LLM judge 를 사용하더라도 automated 및 crowd judgement 모두 calibration 과 bias control 이 필요하므로 보조 수단으로 유지한다 [38], [39], [40], [41].

IX. 결론

TRACE-RPG 은 작성된 candidate-event payload 를 encoded 기호 commit gate 를 통해 canonical mutation 으로부터 격리하고, linked record 와 state-semantic replay 로 terminal outcome 을 감사 가능하게 만든다. 결정론적 오프라인 파일럿은 동결된 작성 fixture 에서 mechanism 적합성을 확립한다. 별도로 라이브 스크리닝 파일럿은 구성한 수리 가능 regime 에서만 guided 5/5 대 blind 0/5 분리를 관찰하고 다른 regime 에서는 귀무였으므로 pilot-only 로 남는다. Cross-model superiority, player-experience benefit, retrieval 또는 memory effectiveness, affect efficacy, commercial-engine performance 는 명시적인 확증 확장으로 남는다.

AI 사용고지

Large language model 은 prose, code 와 test drafting, command orchestration, evidence review, 결과 해석, simulated peer review, citation-identity check 를 보조했고, hosted model 은 별도 표기된 live-screening candidate 도 생성했다. 모든 보고 count 는 deterministic runner 또는 hash-bound receipt 에서이며 offline, live-screening, engine evidence 는 분리된다. 저자는 claim 을 source artifact 에 대조했고 내용에 대한 책임을 진다.

데이터 및 코드 가용성

Repository 에 는 implementation, build source, 분리된 offline/live-screening packet 과 contribution-evidence-matrix.csv, reference-topic-crosswalk.csv, experiment-evidence-matrix.csv 가 있다. Offline manifest 는 artifact 38 개, input 22 개, provenance row 121 개 (executed 85 개, aggregate 36 개) 를, live promotion manifest 는 JSON/JSONL receipt 14 개와 superseded v1 diagnostic 을 결합한다. Godot 4 Web slice 는 ledger 판독과 이들을 다루는 결정론적 평가 (결합 엔지니어링 검사 52 개, presentation 불변량 12 개) 와 함께 제공되며, 이는 엔지니어링 적합성이 재미나 usability 근거가 아니다. Portable offline invocation 에는 absolute clone path 가 없고 clean-Git input binding 은 tag trace-rpg-guided-repair-inputs-20260821-v1 에서 다 시성립한다. Anonymized reviewer archive 나 DOI deposit 은 주장하지 않는다.

References

- [1] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, "TextWorld: A learning environment for text-based games," in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.
- [2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, "ScienceWorld: Is your agent smarter than a 5th grader?" in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.

- [3] N. Weir, R. Thomas, R. d'Amore, K. Hill, B. Van Durme, and H. Jhamtani, "On-totally faithful generation of non-player character dialogues," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.
- [4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, "Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach," in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.
- [5] S. Geng, M. Josifoski, M. Peyrard, and R. West, "Grammar-constrained decoding for structured NLP tasks without finetuning," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10 932–10 952.
- [6] L. Beurer-Kellner, M. Fischer, and M. Vechev, "Prompting is programming: A query language for large language models," *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.
- [7] T. Scholak, N. Schucher, and D. Bahdanau, "PICARD: Parsing incrementally for constrained auto-regressive decoding from language models," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.
- [8] X. He, Y. Tian, Y. Sun *et al.*, "G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907.
- [9] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, "HippoRAG: Neurobiologically inspired long-term memory for large language models," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569.
- [10] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, "Mem0: Building production-ready AI agents with scalable long-term memory," in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, peer-reviewed ECAI 2025 record; page range was not exposed by the accessible Crossref or publisher metadata at audit time.
- [11] J. S. Park, J. C. O'Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, "Generative agents: Interactive simulacra of human behavior," in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.
- [12] Y. Shao, L. Li, J. Dai, and X. Qiu, "Character-LLM: A trainable agent for role-playing," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187.
- [13] N. Akoury, Q. Yang, and M. Iyyer, "A framework for exploring player perceptions of LLM-generated dialogue in commercial video games," in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.
- [14] M. Hochreiter, S. Kriglstein, and G. Wallner, "Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues," in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.
- [15] M. Yin, H. Zu, W. Gu *et al.*, "How contextualized generative AI shapes player experience in games," *Entertainment Computing*, vol. 58, p. 101194, 2026, online record with a future issue assignment at the 2026-08-12 audit; issue metadata must be rechecked at submission.
- [16] V. Figueiredo and D. Elumeze, "Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue," 2025, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [17] G. N. Yannakakis and J. Togelius, "Experience-driven procedural content generation," *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.
- [18] D. Melhart, D. Gravina, and G. N. Yannakakis, "Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch," in *International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.
- [19] Z. Wang, Q. Guo, R. Singh, and X. Hu, "Do vision language models understand human engagement in games?" 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [20] L. Fan, G. Wang, Y. Jiang *et al.*, "MineDojo: Building open-ended embodied agents with internet-scale knowledge," in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362.
- [21] D. Pérez-Liébana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, "General video game AI: A multitask framework for evaluating agents, games, and content generation algorithms," *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.
- [22] X. Liu, H. Yu, H. Zhang *et al.*, "AgentBench: Evaluating LLMs as agents," in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046, peer-reviewed official proceedings record; no publisher DOI assigned.
- [23] C. Ma, J. Zhang, Z. Zhu *et al.*, "AgentBoard: An analytical evaluation board of multi-turn LLM agents," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362.
- [24] X. Zhou, H. Zhu, L. Mathur *et al.*, "SOTOPIA: Interactive evaluation for social intelligence in language agents," in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019, peer-reviewed official proceedings record; no publisher DOI assigned.
- [25] D. Paglieri, B. Cupial, S. Coward *et al.*, "BALROG: Benchmarking agentic LLM and VLM reasoning on games," in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702, peer-reviewed official proceedings record; no publisher DOI assigned.
- [26] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, "Automated play-testing through RL-based human-like play-styles generation," *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.

- [27] S. Kambhampati, K. Valmeekam, L. Guan *et al.*, “Position: LLMs can’t plan, but can help planning in LLM-Modulo frameworks,” in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 235. PMLR, 2024, pp. 22 895–22 907.
- [28] B. Ichter, A. Brohan, Y. Chebotar *et al.*, “Do as I can, not as I say: Grounding language in robotic affordances,” in *Proceedings of the 6th Conference on Robot Learning (CoRL 2022)*, ser. Proceedings of Machine Learning Research, vol. 205. PMLR, 2023, pp. 287–318.
- [29] H. Wang, C. M. Poskitt, and J. Sun, “AgentSpec: Customizable runtime enforcement for safe and reliable LLM agents,” 2025, preprint (v3); the arXiv record states acceptance at ICSE 2026, but no proceedings DOI was resolvable as of 2026-09-02.
- [30] S. Li, Z. Zeng, J. Xi, A. Zhu, and P. Ammanabrolu, “Setting the DC: Tool-grounded D&D simulations to test LLM agents,” in *NeurIPS 2025 Workshop on Generative and Protective AI for Content Creation (GenProCC)*, 2025, non-archival workshop paper; identity confirmed through the official NeurIPS 2025 program record and the GenProCC accepted-paper list on 2026-09-02.
- [31] E. Zhou, S. Basavatia, M. Siam, Z. Chen, and M. O. Riedl, “STORY2GAME: Generating (almost) everything in an interactive fiction game,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-09-02.
- [32] S. Buongiorno, L. Klinkert, Z. Zhuang, T. Chawla, and C. Clark, “PANGeA: Procedural artificial narrative using generative AI for turn-based, role-playing video games,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 20, no. 1, pp. 156–166, 2024.
- [33] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, “TVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds,” 2026, preprint; accepted/forthcoming at ICCV 2026, whose available pre-proceedings were explicitly non-archival and unpublished at retrieval time.
- [34] S. Góngora, L. Chiruzzo, G. Méndez, and P. Gervás, “World-state transformations for neuro-symbolic interactive storytelling,” 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-21.
- [35] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320, peer-reviewed official proceedings record; no publisher DOI assigned.
- [36] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, “Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program,” *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021, peer-reviewed official journal article; no publisher DOI assigned.
- [37] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, “Towards the systematic reporting of the energy and carbon footprints of machine learning,” *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020, peer-reviewed official journal article; no publisher DOI assigned.
- [38] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Krahmer, “Best practices for the human evaluation of automatically generated text,” in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.
- [39] M. Karpinska, N. Akoury, and M. Iyyer, “The perils of using Mechanical Turk to evaluate open-ended text generation,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.
- [40] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623.
- [41] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, “Humans or LLMs as the judge? a study on judgement bias,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.
- [42] D. Lakens, A. M. Scheel, and P. M. Isager, “Equivalence testing for psychological research: A tutorial,” *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.
- [43] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, “Random effects structure for confirmatory hypothesis testing: Keep it maximal,” *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.
- [44] E. Feng, W. Zhou, Z. Liu *et al.*, “Get experience from practice: LLM agents with record & replay,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-09-02.
- [45] A. Madaan, N. Tandon, P. Gupta *et al.*, “Self-Refine: Iterative refinement with self-feedback,” in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 46 534–46 594.
- [46] M. O. Riedl, C. J. Saretto, and R. M. Young, “Managing interaction between users and agents in a multi-agent storytelling environment,” in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.
- [47] R. E. Fikes and N. J. Nilsson, “STRIPS: A new approach to the application of theorem proving to problem solving,” *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.
- [48] F. B. Schneider, “Enforceable security policies,” *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.
- [49] T. Haerder and A. Reuter, “Principles of transaction-oriented database recovery,” *ACM Computing Surveys*, vol. 15, no. 4, pp. 287–317, 1983.
- [50] R. Evans and E. Short, “Versu—a simulationist storytelling system,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.
- [51] S. G. Ware and C. Siler, “Sabre: A narrative planner supporting intention and deep theory of mind,” in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.
- [52] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, “Reflexion: Language agents with verbal reinforcement learning,” in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 8634–8652.
- [53] X. Chen, M. Lin, N. Schärli, and D. Zhou, “Teaching large language models to self-debug,” 2023, preprint; no archival venue or publisher DOI verified as of 2026-08-21.
- [54] A. Solar-Lezama, L. Tancau, R. Bodik, S. Seshia, and V. Saraswat, “Combinatorial sketching for finite programs,” in *Proceedings of the 12th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*. ACM, 2006, pp. 404–415.
- [55] Y. Huang, G. Chen, J. Yao *et al.*, “Beyond state consistency: Behavior consistency in text-based world models,” 2026, preprint; no archival venue or publisher DOI verified as of 2026-09-02.