

TRACE-RPG: 인터랙티브게임세계의생성이벤트를위한 trace 연결기호커밋게이트

익명저자

Abstract—대규모언어모델은표현력있는퀘스트와 NPC 대화를 생성할수있지만, 유창하거나스키마에맞는텍스트만으로제안이벤트의실행가능성, 권한적합성, 정식게임상태와의일관성이성립하지는않는다. 본논문은신뢰하지않는제안을상태변경으로부터격리하는기호커밋게이트 TRACE-RPG 을제안한다. 타입엄격 parser, 외부공급행동정책, 여섯개의결정론적상태대술어가모든허용전이를결정하며, 거부후보는제한수리로보낼수있고수락후보는변경직전에다시검증한다. 반례 유도연산자 ρ 는작전후보와구조화 validation error 만읽고권위있는상태는결코읽지않는다. 키없는 SHA-256 콘텐츠연결, 상태의미 replay, 에피소드연속성검사, 할당완전 outcome 계수가해당무결성경계안에서 trace 를감사가능하게만든다. 근거는세레인으로분리한다. 단일작성 world 의결정론적오프라인적합성과일릿, 단일모델라이브스 크리닝확장, 런타임권한이없는 engineering-only closed-world KG/온톨로지링크제안시물레이션이다. 오프라인레이언은인코딩된필드의 mechanism 적합성만확립한다. 라이브레이언은 $K=1$ 에서의도적으로수리가능하게만든 policy-blind regime 에한해 guided 5/5 대 blind 0/5 commit 을관찰했고다른 regime 은귀무였으므로 pilot-only 로남는다. 어느레이언도모집단효능, 모델유월성, 플레이어경험, 감정, 런타임검색 · 메모리이득, 상용엔진성능을확립하지않는다.

Index Terms—게임인공지능, 인터랙티브내러티브, 기호검증, 제약생성, 런타임검제, 재현성

I. 서론

인터랙티브생성은언어과제에그치지않는다. 후보이벤트가자연스러워도존재하지않는아이템을요구하거나, 화자가모르는사실을주장하거나, 금지된퀘스트정보를공개하거나, 허가되지않은효과를도입하거나, 퀘스트단계를후퇴시킬수있다. 실행가능한텍스트환경은그렇듯한발화와유효한전이의차이를명시한다 [1], [2]. 근거기반대화개입화퀘스트시스템은퀘스트, 엔터티, 그래픽맥락의가치를추가로보여주지만 [3], [4], 맥락자체가정식상태변경을승인하지는않는다.

구조적생성제약은인접한문제를해결한다. 문법제약디코딩, 언어모델질의언어, 점진파서는생성구조를제한할수있다 [5], [6], [7]. 그러나구문상허용되는이벤트도현재세계에대해서는거짓일수있다. 검색과메모리는유용한근거를공급할수있지만 [8], [9], [10], 검색된내용역시상태전이의권한주체가아니다.

본논문은이러한관심사를감사가능한트랜잭션프로토콜로결합한구현인 TRACE-RPG 을제시한다. 현재기여는다음과같다.

- 1) state, policy, candidate, record, game bridge 에대한버전형신뢰경계 *contract* 와, proposal/replay 경계에서 known field 의모호한타입및 candidate unknown key 를거부하는 type-strict parser;
- 2) 상태기준 predicate 6 개, bounded repair, unchanged fallback, defensive pre-commit revalidation 을갖춘 *validate-repair-commit controller*;
- 3) unkeyed SHA-256 content link, state-semantic replay, episode-continuity check 를묵은 감사근거 *layer*;

익명심사를위해제출된원고입니다.

- 4) 동결 assignment key, 분류된 terminal failure, proposal trace 가존재할수없는 failure 까지보존하는 assignment-complete accounting 을갖춘 오프라인적합성 *harness*;
- 5) prior candidate 와 structured error 만 읽는 *counterexample-guided operator* $\rho(a, E)$ 및 blind unchanged retry, state-reading oracle upper bound, 동결 repairability class 비교.

결정론적 parser, state-isolation, repair, fault-injection, manifest fixture 가이다섯구현기여의정확집계근거다. 근거지도는서로대체할수없는세레인으로구성된다. 첫째, 실증의중심은단일작성 world state 의결정론적적합성과일릿으로, 인코딩된 parser · validation · repair · replay · accounting 동작을측정하며모집단효능은측정하지않는다. 둘째, 셀당 5 회라이브스 크리닝확장은하나의 hosted proposer 에서 repair transfer 를탐색하지만, 고정되지않은 revision, sampling 을제어하지못하는 seed label, 의도적으로구성한 state 때문에 pilot-only 가상한이다. 셋째, closed-world KG/온톨로지시물레이션은작성된 typed-link proposal 을평가할뿐런타임검색을구현하지않고어떤 C-RESULT-* claim 도지지하지않는다. 보존한 Godot 4.7.1 policy-mirror trace 와 render replay 는엔진로컬적합성근거만추가한다. 네 fixture 실행모두에서 headless frame sample 5 개중최대값은첫 sample 이었고범위는 98.760–116.667 ms 로 16.7 ms budget 을넘었다. 이 startup-sensitive trace 는안정적인 frame benchmark 가아니다. 참여자, 감정또는런타임검색실험, live Python-Godot 승인왕복, 대표성있는 end-to-end 게임플레이성능측정은없다.

II. 관련연구와연구공백

A. 인터랙티브내러티브와게임에이전트

KNUDGE 는퀘스트와엔터티명세에근거한분기형 NPC 대화를평가한다 [3]. 지식그래프보조퀘스트생성 [4], 메모리-성찰-계획에이전트 [11], 학습가능한역할연기에이전트 [12] 는근거성과개연성있는행동의상호보완적측면을다룬다. 플레이어대상연구는선호와지각된대화품질을평가한다 [13], [14]. Yin 등의 2026 년온라인레코드는서지감사당시미래시점의권호가배정되어있어제출시다시확인해야한다 [15]. 2025 년프리프린트는역할에따른안정성-즉흥성 trade-off 를보고하며 [16], 본논문은이를최근동기로만사용한다. 이연구들은하드허용가능성을선택적자연스러움및플레이어경험구성개념과분리할필요성을뒷받침한다.

경험주도콘텐츠생성 [17] 과관찰자표식참여도 [18] 는미래적응트랙의동기가된다. 최근프리프린트는 vision-language model 의참여도추론한계를보고한다 [19]. 따라서감정은비권위적맥락으로유지되며현재구현근거에는포함되지않는다.

B. 환경과벤치마크

TextWorld 와 ScienceWorld 는명시적인인터랙티브상태를제공하며 [1], [2], MineDojo 는개방형지식집약 embodied 과제

를추가한다 [20]. General Video Game AI 는에이전트, 게임, 콘텐츠트랙을분리한다 [21]. AgentBench 는이질적인환경의에이전트를연구하고 [22], AgentBoard 는과정수준진단을추가하며 [23], SOTOPIA 는사회적상호작용을평가하고 [24], BALROG 는장기언어및시각게임추론을평가한다 [25]. 자동화된플레이스타일에이전트는상호보완적인시험선레이지만인간평가를대체하지않는다 [26]. 이벤치마크는미래평가설계에정보를주지만트랜잭션승인경계를규정하지는않는다.

C. 제약, 신경-기호검증, 검색

제약디코더는출력구조를개선한다 [5], [6], [7]. 반면 TRACE-RPG 은구조를독립적인상태상대승인의입력조건으로취급한다. 직접적인게임특화비교대상두시스템은서로다른경계를보여준다. PANGeA 는메모리, 검증, REST 서비스, Unity 통합을결합하지만, 공개된검증절차는 LLM 이설계자규칙에따라콘텐츠를판정하고반복수정하도록한다 [27]. 현재비아카이벌 ICC3 2026 자료와연계된프리프린트 IVIE 는기호검증을사용해인터랙티브픽션세계를점진적으로생성한다 [28]. 같은계보의 2026 년시스템은 LLM 을저작된 world-state transformation 선택으로제한하고 플레이어표현에대한탐색적 8 인연구를보고한다 [29]. 이시스템은구성상일관성을유지하지만트랜잭션게이트, 감사연결레코드, 수리연산자근거는제공하지않는다. 어느비교도우월성을뜻하지않으며, 각시스템의유효성은해당시스템이인코딩한목표와술어에한정된다.

G-Retriever, HippoRAG, Mem0 는관련하위그래프검색과장기메모리를다루고 [8], [9], [10], Generative Agents 와 Character-LLM 은행동메모리와 persona 를다룬다 [11], [12]. TRACE-RPG 은향후이러한맥락을사용할수있지만직접적인커밋권한은부여하지않는다. 검색과시간적메모리효익은여기에서측정하지않는다.

D. 감사가능성과재현성

과정지표는중간실패를보존할동기를제공하고 [23], 강건한평가는소수확률적실행의과도한해석을경고한다 [30]. 재현성과환경보고지침은동결된산출물과명시적측정경계를뒷받침한다 [31], [32]. 인간및 LLM 평가는구성개념, 평가자, 편향통제를요구하며 [33], [34], [35], [36], 향후비열등성과참여자분석에는정당화된 margin 과 random-effects 구조가필요하다 [37], [38].

제한된 novelty 는개별구성요소의발명이아니라구현된결합이다. 행동개입 (interposition) 자체는오래된기법이다. 내러티브 mediation 은사용자나에이전트의행동을실행전에게로채차단하거나계획을수정해수용하고 [39], 고전계획법은 precondition 과 effect 로적용가능성을정의하며 [40], 런타임강제는신뢰하지않는행위자를 monitor 로감싸싸용된전이만통과시키고 [41], 작성형논리기반인터랙티브드라마는본저널의전신에서캐릭터가할수있는발화를규율했으며 [42], 신념인지내러티브계획법은캐릭터가아는바를추론한다 [43]. 이는본문의 knowledge/disclosure 술어가훨씬거칠게인코딩하는관심사다. TRACE-RPG 은 interposition 을발명했다고주장하지않는다. 더좁은기여는신뢰하지않는생성 proposer 아래에서그게이트에결합된근거체중이다. 즉콘텐츠체크섬과연결된종단레코드, 기록된전이의상태의미재생, 에피소드연속성검증, 그리고 proposal trace 가존재할수없는사례까지보존하는할당완전실패계수다. 보고서에기능이없다고해서모든구현에그기능이없다고추론하지않는다.

III. 문제정의와보장경계

설명을위해시점 t 에서 validation 이사용하는 controller 입력을다음과같이분해한다.

$$c_t = (G_t, q_t), \quad (1)$$

여기서 G_t 는 typed snapshot field 를, q_t 는해당 snapshot 과함께저장되는외부작성 action-policy, disclosure, quest-stage 제약을나타낸다. 종단 record history $h_{<t}$ 는 WorldState snapshot 과별도로유지된다. Validation predicate 는이를읽지않으며구현은 log 에서상태를재구성하지않는다. 검색, 내러티브점수, 모델 rationale, 메모리요약, 미래의감정추정은비권위적 proposal context 이다.

신뢰하지않는 proposer 가후보 a_t 를출력한다. 타입엄격 parsing 은알수없는 top-level field 의거부를포함한공유 candidate-key contract 를먼저강제하고선언스키마를확립한다. validator 는다음을반환한다.

$$V(c_t, a_t) = (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, v_{\text{disc}}, v_{\text{quest}}, E_t), \quad (2)$$

여기서 E_t 는구조화오류집합이다. 상태변경은다음과같다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_i v_i = 1, \\ c_t, & \text{그외.} \end{cases} \quad (3)$$

Controller 는인코딩된계약아래다음구현불변량을주장한다. 파일럿은이를일반정리로제시하지않고 deterministic valid, invalid, repair, fallback, replay, fault-injection fixture 로해당 mechanism 을시행한다. **I1 (소진실패불변성)**: 예산 K 까지반환된어떤후보도검증을통과하지못하거나 proposal/controller 실행이 commit 전에실패하면반환상태는공급된 prior state 와같다. **I2 (제한된기록시도)**: 모든 proposal 과 repair callback 이반환한다는조건에서 repair budget $K \geq 0$ 은최대 $K + 1$ 개의 candidate attempt 를기록한다. 성공적인 commit 은변경직전수락후보에대한방어적 validation 을한번추가한다. Runtime 은 callback deadline 을강제하지않으므로 I2 는 wall-clock 종료보장이아니다. **I3 (효과관한)**: 수락후보는 ActionPolicy.allowed_effects 밖의선언된 fact effect 를 CandidateAction.effects 에포함하지않으며, quest-stage target 도해당 policy 에의해명시적으로승인된다. **I4 (상태의미적리플레이)**: 동결된스키마와결정론적전리아래수락된 trace 는명시된 terminal state 를재구성한다.

이주장된불변량은올바른정책작성, 선언된후보필드로의완전하고충실한추출, 결정론적소프트웨어버전, callback 반환, 단일프로세스파일소유권을가정한다. 상태의미적리플레이는기록된구조화후보와전이를재검증하지만, 중간수리의 provenance, reasoning, prompt, 확률적생성은재현하거나검증하지 않는다. 구조화필드에서누락된자연어함의는보장범위밖이다.

IV. TRACE-RPG 아키텍처와알고리즘

A. 신뢰경계와계약

그림 1는모델또는 recorded adapter 를 canonical owner 밖에둔다. Parser 는알려진필드의모호한숫자또는 collection type 을거부하고공유 key contract 에따라알수없는 top-level candidate field 도거부한다. action policy 는 candidate 와별도로공급되며 required precondition 과 allowed effect 를정의한다. Game bridge 는 observation, proposal, validation, rejection, fallback, commit 을전달할수있는 versioned event interface 이며, 정식상태변경은유효한 commit 만승인한다. 이

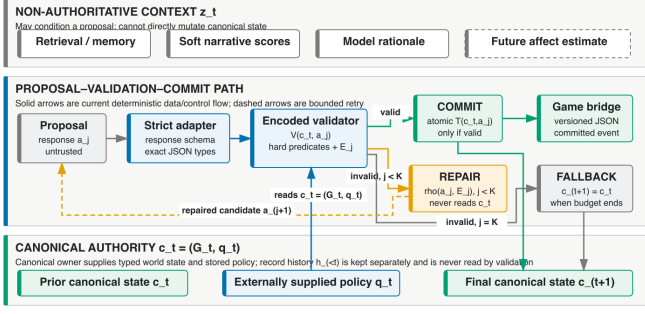


Fig. 1. 신뢰경계. 검색맥락과 생성 후보는 알려진 필드의 타입 검사와 상태상대 validation 이 완료될 때까지 비권위적이다.

TABLE I
인코딩된 VALIDATOR 경계

술어	거부대상	실패시상태
Action policy	알수없는 action/type	변경없음
Precondition	누락/거짓 requirement	변경없음
Reachability	접근불가 object	변경없음
NPC knowledge	선언되지않은 known fact	변경없음
Disclosure	forbidden fact	변경없음
Quest	부적격/후퇴 stage	변경없음

는 interface 를 분리하지만 상용 엔진으로의 portability 를 아직 입증하지 않는다. 표 I 은 인코딩된 거부 경계를 요약하며 의미적 완결성 주장이다.

B. Validate-Repair-Commit

그림 2 은 제어기의 추가 패키지 없는 의사 코드를 제시한다. “Record” 는 in-memory trace 표현에 추가하는 것을 뜻하며, 영속시키는 중단일 관성 검사 뒤에만 수행한다.

검증 오류는 구조화된 error code 로 repair callback 에 노출된다. repair 는 상태를 직접 변경하지 않으며, 예산 소진 시 변경 없는 결정론적 fallback 을 반환한다. 그림 3 은 중단 경로를 나타낸다. 파일럿은 구현된 두 callback 을 비교한다. 반례 유도 연산자는 직전 후보 a 와 validator 의 구조화 오류 집합 E 만을 소비하며 권위 있는 상태는 결코 읽지 않는다.

$$\rho(a, E) = a \oplus \bigcup_{e \in E} \delta(e), \quad (4)$$

여기서 각 $\delta(e)$ 는 표 II 의 오류 class 별 결정론적 edit 이고 $\oplus$ 는 그 field edit 들을 적용한다. 각 edit 은 오류 entity 당 최대 하나의 candidate field 만 수정하므로 시도당 변경 field 수는 $|E|$ 로 유계이고, 같은 오류 집합으로 ρ 를 두 번 적용하면 고정점이며, 같은 field 에서 동시에 요구되고 거부되는 entity 는 수리 불가로 선언되어 수정되지 않는다. 상태를 읽는 참조 callback 은 반대로 오류 집합을 폐기하고 정책이 유율하는 field (precondition, effect, 두 quest-stage field) 를 권위 있는 상태에서 직접 재구성한다. 이 callback 은 선언 무결성 field (required object, used fact, disclosed fact) 를 의도적으로 수정하지 않는다. 의존성이나 disclosure 의 선언을 지우는 것은 후보를 수리하는 것이 아니라 위반을 게이트 뒤로 세팅하는 것이기 때문이다. 이는 상태 판독 가능 수리에 대한 oracle 상한이며, 그 결과 배포 가능한 수리 방법의 근거로 읽어서 안 된다.

C. 무결성, 의미적 리플레이, 계수

각 result row 는 키 없는 SHA-256 무결성 체크섬을 가지며, proposal outcome 은 추가로 trace checksum 과 연결된다. 이

```

1:  $a \leftarrow \text{PROPOSE}(c); j \leftarrow 0$ 
2: repeat
3:    $(ok, E) \leftarrow V(c, a); \text{RECORD}(a, E)$ 
4:   if  $ok$  then
5:     assert  $V(c, a).ok$ ; return  $\text{COMMIT}(c, a)$ 
6:     if  $j = K$  then return  $\text{FALLBACK}(c)$ 
7:      $a \leftarrow \text{REPAIR}(c, a, E); j \leftarrow j + 1$ 
8: until terminal

```

Fig. 2. Validate-repair-commit 절차. 최대 $K + 1$ 개의 candidate attempt 를 기록하며, 성공 경로는 상태 변경 전 방어적 validation 을 수행한다.

TABLE II
유도 연산자 ρ 의 오류 CLASS 별 EDIT

Validator 오류 class	후보에 대한 edit $\delta(e)$
정책 precondition 누락	명명된 predicate 삽입
정책 effect 누락	명명된 effect 삽입
정책 effect 위반	명명된 effect 제거
불충족 precondition	명명된 predicate 제거
비인가 stage 변이	quest_stage_effect 초기화
알수없는 action type	no-op (등록된 대안 없음)
도달 불가 object; knowledge, disclosure, stage class	no-op (후보 국소 edit 은 세팅되거나 상태 지식 필요)

hash 들은 우발적이거나 시험 대상 인 콘텐츠 변경을 탐지하지만 signature, message-authentication code, writer identity 가 아니며 콘텐츠와 checksum 을 모두 다시 쓸 수 있는 행위자에 대한 보호도 아니다. 의미적 리플레이는 prior state 와 기록된 모든 candidate/validation pair 를 엄격히 parsing 하고, final 이 아닌 모든 attempt 가 invalid 임을 요구하며, terminal transition 을 재계산하고, 명시된 final state 와 비교함으로써 byte 무결성을 넘어서는다. Episode replay 는 인접 JSONL record 사이 의 상태 연속성도 요구한다. Replay 는 candidate $j + 1$ 을 만든 repair-generation 단계를 인증하거나 다시 실행하지 않는다.

Terminal record class 는 commit, symbolic fallback, adapter failure, controller failure 이다. Controller-failure row 는 동결된 assignment denominator 에 남고 상태를 변경하지 않지만, candidate outcome 이 생성되지 않았다면 완성된 proposal trace 가 없어진다. 따라서 result completeness 가 모든 terminal row 의 trace 존재를 뜻하지 않는다. 실행 전 assignment key 는 (run, arm, scenario, seed, model, revision, $h_{\text{controller}}, h_{\text{input}}, h_{\text{prior}}$) 이다. 집계는 중복, 누락, 예기치 않은 key 를 거부하고 symbolic, adapter, controller failure 를 각각 보고한다.

V. 파일럿 방법과 근거 경계

A. 질문과 설계 픽처

파일럿은 다음을 묻는다. (PQ1) 유효 후보는 commit 되고 명명된 invalid-policy 사례는 변경 없이 유지되는가? (PQ2) 동결된 모든 reparability class 의 작성 사례에서 rejection-only, 블라인드 동일 후보 retry, 반례 유도 연산자 ρ , 상태를 읽는 참조 callback 이 예상 결과를 만드는가? (PQ3) 동결된 checksum, state-semantic, linkage, continuity mutation 이 지정된 검사 연산에서 거부되고, 두 번째 파일 append 의 주입된 실패가 예상 pair-write rollback 검사를 작동시키는가? (PQ4) 엄격한 adapter 와 assignment manifest 가 할당 사례마다 정확히 하나의 분류된 terminal row 를 유지하거나 fail closed 하는가? (PQ5) proposal 및 replay parser 가 그 외에는 완전하고 유효한 candidate 에 unknown top-level key 하나를 추가한 사례를 모두 거부하는가?




Fig. 3. Proposal, validation, 제한된 repair, fallback, commit, replay 상태. Controller failure는 중단상태이며 완성된 proposal trace가 없을 수 있다.

사례는 의도적으로 설계된 적합성 픽처이며 모델 또는 게임 모 집단의 표본이 아니다. 네도메인은 validator/state isolation, repair-arm 비교, record/trace fault injection, adapter/accounting contract이다. 모든 repair fixture는 실행 전에 동결된 repairability class를 선언한다. *guided-repairable*(구조화 오류 payload만으로 ρ 에 충분한 정보가 담김), *oracle-only*(수리에 권위 있는 상태 판독이 추가로 필요함), *irreparable*(구현된 어떤 arm도 commit할 수 없음)이며, class별 arm당기대결과는 설계픽처계약의 일부다. 반복된 결정론적 seed가 아니라 고유 사례가 기술적 denominator를 구성한다. 모든 기대값은 실행 전에 명시한다.

B. 측정치와 재현성

측정치는 정확한 count이다. expected/observed validator-class agreement, rejected 또는 controller-failure 사례의 state mutation, repair arm과 repairability별 commit 및 attempt 결과, 지정된 연산에서 거부된/사전 명세된 detectable fault, replayed/committed trace, rejected/injected manifest violation, 사전 명세한 unknown-key 음성 회귀에 대한 proposal/replay 거부 일치를 센다. 마지막 측정치는 결정론적 parser-contract parity이며 실증적 safety outcome이 아니다. Exception class만으로 안정적인 detector layer를 식별할 수 없으므로 detector 귀속 결과는 보고하지 않는다. 의도적으로 설계된 픽처에 p -value나 모 집단 confidence interval을 부여하지 않는다. Adapter 사례가 지닌 latency 및 token 상수는 입력 스키마가 JSON-Schema const로 고정된 합성값이다. 이 값들은 계수 필드 전파만 확인하며 provider, runtime, device에 대한 측정값이 아니다.

릴리스 패킷은 fixture 및 assignment manifest, schema, outcome/trace record를 포함한 result JSON 산출물, 환경과 코드 revision, 생성 table, checksum을 동결한다. 보고는 재현성과 측정 경계 지침을 따른다 [31], [32].

C. 별도 KG/온톨로지 링크 제약 시뮬레이션

SL-KG-ONTOLOGY-SIM-001은 Graphify 문서 탐색 그래프 및 권한을 가진 typed WorldState와 분리된 engineering-only closed-world 레인이다. 저장소 로컬 OKF node 43개와 reference edge 106개를 내보내고, 검토된 typed edge 24개를 overlay하며, type/domain/range 무결성과 source별 competency question 6개를 검사하고, 권한이 없는 SQLite mirror를 생성한다. 고정 전략 7개는 작성형질의 6개와 질의당후

보 5개를 평가했다. Retained S2-typed-lexical-loose는 holdout 6/6을 복원했고 ($P = R = F_1 = 1.000$, realistic MRR = 0.944, Brier = 0.131, Sem@3 = 1.000), degree baseline은 하나도 복원하지 못했다. Machine-generated JSON, TSV, TeX, SVG 산출물 이전 체수식과 trial을 보존한다. 이는 구성 결과이며 OWL/SHACL 적합성, 의미 완전성, runtime retrieval, 장기 모순 감소, 어떤 C-RESULT-* claim의 근거도 아니다.

D. 별도 라이브러리 스크리닝 확장

라이브 확장은 블라인드 동일 후보 retry와 ρ 를 동일한 $K=1$ 에서 비교한다. 각 셀에서 seed로 구분한 Codex CLI 호출 5회가 gpt-5.6-sol 후보 하나씩을 만들고, 두 arm은 같은 최초 후보를 받아 호출 내 제안 차이를 제거한다. 조건은 policy 공개 여부와 자명한 효과 0 경로의 존재를 바꾼다. 승격 패킷은 정정된 현재 샘플과 폐기된 v1 진단을 함께 보존하고 모든 JSON/JSONL 영수증을 SHA-256으로 결합하며 근거를 screening-pilot-only로 표시한다. Seed label은 hosted sampler를 제어하지 않고, hosted revision은 고정되지 않았으며, token 회계는 없고, 구성 상태는 모 집단 표본이 아니다. 따라서 p -value, confidence interval, 모델 순위 없이 정확한 기술 count와 실패 class만 보고한다.

VI. 파일럿 결과

A. 구조 필드 게이트 적합성

파일럿 loader는 구현된 validator code를 정확히 한 번씩 고립시키는 fixture 집합과 유효 control 1개만을 허용한다. 따라서 13/13 일치와 구현된 오류 코드 12종의 관찰은 측정된 성공률이 아니라 하니스의 구성 불변량이다. 이 실행이 보여주는 것은 loader가 강제하지 않는 부분, 즉 고립된 음성 fixture 12개가 각각 다른 코드거나 아니라 작성된 기대 코드와 일치했고 비 commit 경로가 전체 정준 상태를 유지했다는 관찰이다. 이는 단일 world state에서 저자가 설계한 구조 필드 oracle에 대한 구현적 합성이며 독립 의미 판정의 정확도가 아니다.

B. 설계 픽처에서의 수리 arm 비교

처음부터 유효하지 않은 설계 case 12개는 guided-repairable 5개, oracle-only 1개, irreparable 6개의 동결된 repairability class로 분할된다. Rejection-only와 블라인드 동일 후보 retry는 각각 0/12 commit이었다. 반례 유도 연산자 ρ 는 guided-repairable case 5/5를 commit했고, 설계상 oracle-only 0/1, irreparable 0/6였다. 모든 ρ commit은 candidate field를 평균 1.0개 수정했으며, 실패한 모든 arm 실행은 정준 상태를 변경 없이 유지했다. 상태를 읽는 참조 callback은 guided-repairable 5/5와 oracle-only 1/1를 commit했고 irreparable은 0/6였다. 이 정확한 count는 세 메커니즘을 설계 픽처 위에서 분리한다. 블라인드 retry는 반례를 commit으로 전환하지 못하고, ρ 는 오류 payload에 충분한 정보가 담긴 case만 전환하며, oracle은 상태 지식이 필요한 case를 추가로 전환한다. 이는 동결 픽처에 대한 연산자 적합성이며, 어떤 live model의 수리 품질도 아니다.

C. 무결성, 경계, 배정 회계

현재 명세가 검증 가능하다고 지정한 10개 fault fixture는 모두 지정된 검사 연산에서 거부됐다 (10/10). 이 파일럿은 안정적인 typed detector code까지 대조하지 않으므로 detector layer 귀속을 입증하지 않는다. 별도로, 동일하게 기록된 유효 수리 앞의 무효 선행 후보를 다른 무효 후보로 치환하고 체크섬을 재계산한 알려

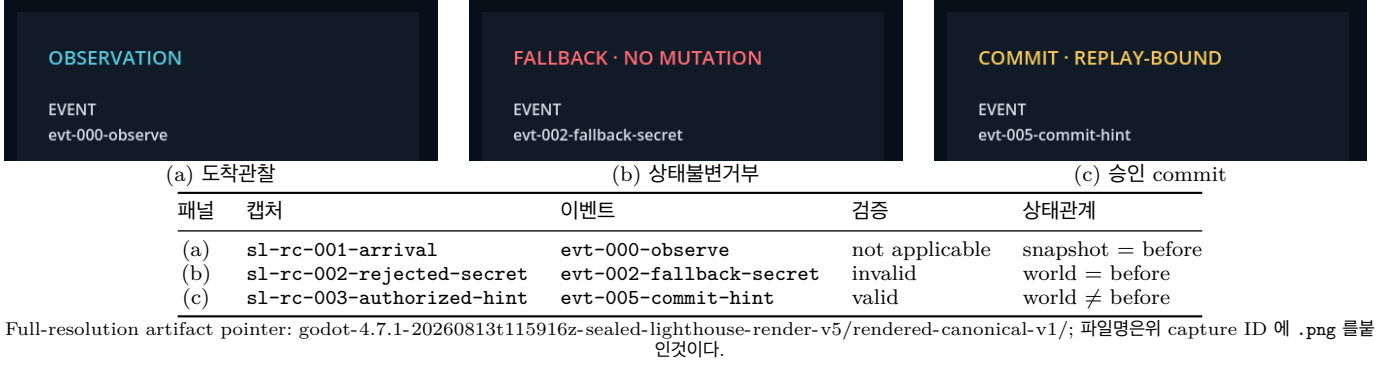


Fig. 4. 작성형 Godot render replay 에서 status/event 를확대한 illustrative crop 과 manifest metadata. 이 trace-bound 대응은 live transport, 성능, usability, immersion, efficacy 근거가아니다.

TABLE III
수리 ARM $\times$ REPAIRABILITY CLASS 정확집계 (설계픽처)

Arm	정보원	G-rep. ^f	O-only ^f	Irrep. ^f	수정 ^e
Rejection-only ($K=0$)	없음	0/5	0/1	0/6	—
블라인드 retry	없음	0/5	0/1	0/6	—
반례유도 ρ	오류집합 E	5/5	0/1	0/6	1.0
상태판독 oracle	권위상태 + 정책	5/5	1/1	0/6	1.0

TABLE IV
동결파일럿원시집계

검사	분자	분모
게이트 fixture 일치 ^c	13	13
알려진경계허용 ^a	2	2
닫힌 unknown-key 경계거부 ^d	1	1
탐지가능무결성결함거부	10	10
알려진무결성경계 replay 허용 ^b	1	1
Adapter 커밋	1	7
기호 fallback	1	7
Adapter 실패	5	7
Manifest guard 거부	3	3

^a 경계허용은의미추출과정정책완결성한계를문서화하며 safety pass 가아니다. ^b Replay 는 repair 생성을인증하거나다시실행하지않는다. ^c Loader 가이일치를강제하므로측정값이아니라구성불변량이다. ^d Stage 8 이후의 parser 거부 parity 이머의미안전성증거가아니다. ^e commit 된수리의변경 candidate field 평균계수 (최소성 proxy); 실패한 arm 실행은상태를변경하지않았다. ^f commit/사례수. G-rep. = guided-repairable, O-only = oracle-only, Irrep. = irreparable(동결된 repairability class).

진 provenance 경계는예상대로재생을통과했다 (1/1 미검출). 따라서키없는체크섬을재계산할수있는작성자를방어하지않으며, 재생은 repair 생성연산의출처를인증하지않는다. 열린경계 sentinel 두건—자연어 disclosure 미추출과 required object 의후보 · 정책동시누락—은 2/2 가의도대로인코딩상허용됐고 safety pass 는 0 건이었다. 과거 unknown top-level field 허용경계는 Stage 8 이후닫힌음성회귀로재분류되었으며, 완전한 12-field candidate 에 unknown key 하나를추가한 fixture 를 proposal · replay parser 모두구체적으로거부했다 (1/1). 이는 parser rejection parity 이지의미안전성의증거가아니다. Adapter/accounting 7 개배정에서는 commit 1, 기호 fallback 1, adapter failure 5 었다. 합성 telemetry 필드는 2/7 배정에서채워져전파됐으며, 이는측정값이아니라회계필드전파확인이다. 배정 guard 3/3 가중복 · 누락을거부했다. 이수치는모두합성 offline fixture 의 raw count 다.

표 III와 IV은정확한설계픽처 count 를보고한다. 수리표는

TABLE V
라이브스크리닝파일럿정확집계 (셀당제한 5 회, $K=1$)

기저 / 조건	최초유효	ρ commit	Blind commit	최초오류
동결 / 공개	5/5	5/5	5/5	—
동결 / 비공개	5/5	5/5	5/5	—
동결 / 목표-비공	0/5	0/5	0/5	QSR
개				
Signal-v2 / 공	5/5	5/5	5/5	—
개				
Signal-v2 / 비	0/5	5/5	0/5	PEO+PEV+PPO
공개				

QSR = quest-stage regression, PEO = policy-effect omission, PEV = policy-effect violation, PPO = policy-precondition omission. 모든수치는 screening-pilot-only 이며추론통계가아니다. 폐기된 v1 진단은표에서제외한다.

동결된 repairability class 별로네 arm 을분리하며, 어느표도모집단또는 live-model 추정을지지하지않는다.

D. 라이브스크리닝파일럿 (pilot-only)

별도스크리닝파일럿은 Codex CLI 를통해 gpt-5.6-sol 을호출했다. 셀마다 seed 로구분한제한호출 5 회와수리예산 $K=1$ 을사용했고, 각호출의최초후보하나를블라인드동일후보 retry 와 ρ 가공유효했다. Hosted revision 은고정되지않았고 token 회계는제공되지않았으며 seed 는 hosted sampler 를제어하지않으므로이호출들은독립무작위표본이아니라준반복이다. 따라서추론통계나모델순위를보고하지않는다.

표 V에서유도우위는의도적으로 guided-repairable 오류가나오도록구성한 signal-repair-v2 의 policy-blind 셀에서만나타났다. 최초후보 5/5 가모두무효였고 ρ 는 5/5, 블라인드는 0/5 를 commit 했다. 나머지현재셀 4 개는유도우위를보이지않았다. 세셀은최초후보가이미유효했고, 동결기저의 goal-directed 셀은수리불가 quest-stage regression 이었다. 현재셀의모든 noncommit arm 결과 15/15 가 prior-state hash 를보존했다. 이결과해당오류 regime 에서의 mechanism transfer 만지키하며모집단효능, 모델승격, 표본효율일반화는지지하지않는다. 따라서 C-PILOT-007 과 C-PILOT-008 은 pilot-only 이고 C-RESULT-003 은 TODO-RESULT 로남는다. 폐기된 v1 진단에서는동반오류가최대 3 개에서수리불가 knowledge 오류 1 개로줄었지만 commit 되지않아, 오류하나라도수리불가이면부분수리가합성되지않음을보여주었다.

그림 5는오프라인보고경계를명시한다. 동결 fixture 와지정검사연산이허용한 row 만오프라인생성표에들어간다. 라이브표는 SHA-256 으로결합한 screening promotion manifest 를통과




Fig. 5. 동결된 fixture 에서 지정된 검사연산과 생성 table 로 이어지는 근거경계. 수치는 생성산출물을 통해서만 반영한다.

하는 별도 경로를 사용하며, 그 row 는 동결 오프라인 denominator 에 들어가지 않는다.

Godot 4.7.1 은 보존한 *Sealed Lighthouse* 정식 trace 를 non-headless 1280×720 SubViewport 에서 리플레이했다. Manifest 는 각 PNG 를 event/delivery index, validation, state hash 에 결합한다. 그림 4(b) 는 변경 전 hash 를 보존하고, (c) 는 valid commit 뒤를 변경한다. 모든 원본 panel 은 생성 자산이 없는 primary-track render 이며, 아래 illustrative crop 은 작성된 status/event callout 만 확대한다.

선택 v5 packet 은 하나의 scripted fixture 의 render/state 대응만 확립하며 live model 또는 Python transport, participant 또는 player input, adaptation intervention, narrative-quality result 를 추가하지 않는다.

VII. 논의

A. 확립 가능한 범위

설계 파일럿은 동결된 사례에 대해서만 mechanism behavior 를 확립할 수 있다. 인코딩된 검사 가상 상태를 격리하는지, bounded repair 와 fallback 이선 연결 경로를 따르는지, 명명된 corruption 이 지정된 검사 연산에서 거부되는지, assigned row 가 집계를 위해 분류된 상태로 남는지를 평가한다. 거부를 안정적인 typed detector code 에 귀속하지는 않는다. 이는 authoring-time validation, continuous-integration regression, recorded-adaptor test, engine 이전 replay inspection 에 유용하다.

오프라인 수리 비교의 정직한 해석은 guided-대-oracle 경계다. 상태를 읽는 callback 이상한으로 남는 이유는 권위 있는 상태를 참조할 수 있어서 ρ 가 구성상 전환할 수 없는 oracle-only 사례를 전환하기 때문이다. 반례 유도 연산자는 validator 의 구조화 반례만 소비하면서 guided-repairable class 에서 oracle 과정 확히 일치한다. 이어라이브 스크리닝 확장은 이 mechanism 이 hosted proposal 로 전이되는지를 탐색했다. 구성 상태가 모든 제안을 guided-repairable class 로 유도했을 때만 ρ 와 blind retry 가 분리됐고, 최초 유효 및 guided-irreparable regime 은 귀무였다. 이 regime 의 존성, 고정되지 않은 hosted revision, 준반복 호출 때문에 일관된 표본 효율이나 모델 능력을 주장할 수 없다. Feedback 을 소비하는 수리 루프에는 선례가 있다. Self-Refine 은 같은 신뢰하지 않는 모델이 생성한 언어를 feedback 으로 되먹이고 [44], Self-Debugging 은 신뢰되는 전체 프로그램 runtime 의 실행 결과를 소비한다 [45]. ρ 는 channel 과 권위에서 다르다. Feedback 은 실행 전에 결정론적 validator 가 계산한 typed 오류 집합이고, 실패한 모든 live arm 은 상태를 격리한다.

B. 선행 연구와의 관계

TRACE-RPG 은 parsing 후 state-relative authorization 을 적용하여 constrained decoder 를 보완한다 [5], [6], [7]. 검색 및 메모리 구성 요소에는 commit authority 를 부여하지 않는다는 점에서 구별된다 [8], [9], [10]. 실행 가능한 환경과 benchmark 를 대체하지 않고 보완한다 [1], [2], [22], [25]. Process-linked trace 는 AgentBoard 가 강조한 측정 관심사를 구현하지만 [23], TRACE-RPG 이해당시 시스템이나 다른 시스템보다 우월하다는 근거는 아니다.

확증 효능을 검증할 연구, 즉 독립적으로 label 된 semantic oracle 과 실제 blind-retry comparator 를 갖춘 사전 등 록 다중 모델 비교, 인코딩된 validity 를 맞춘 retrieval 및 memory ablation, 정당화된 검증력과 mixed-effects 분석을 갖춘 blinded matched-validity 인간 연구는 여전히 기본 논문의 범위 밖이다. 스크리닝 파일럿은 어느 연구도 대체하지 않는다 [22], [33], [30], [38].

VIII. 타당성 위험, 윤리, 산출물 범위

근거에는 명시적 경계 9 개가 있다. **L1:** encoded predicate 는 structured field 에서 빠진 의미를 발견하지 못한다. **L2:** authored world 하나와 constructed live-state variant 하나로 cross-world, cross-policy, 규모 일반화를 말할 수 없다. **L3:** state-reading callback 은 oracle 이며 offline class 와 regime-dependent screening 은 일반 repair 품질이나 sample efficiency 를 확립하지 않는다. **L4:** hosted proposer 하나는 revision 고정, token 회계, sampling 을 제어하는 seed 가 없고 live Python-Godot authorization round trip 도 없다. **L5:** participant 와 affect data 가 없다. **L6:** unkeyed hash 는 integrity 만 제공하며 writer authentication 이나 adversarial tamper resistance 는 제공하지 않는다. **L7:** record consistency 는 single writer 를 가정하며 concurrent-writer safety 는 미검증이다. **L8:** engine evidence 는 startup-dominated sample 이 16.7 ms 를 넘는 Godot fixture 하나이며 portability 나 real-time 결과가 아니다. **L9:** 선택된 fixture 와 screening cell 은 population, safety-rate, model-ranking 추론을 지지하지 않는다. Internal validity 는 독립 policy expectation 및 fixture leakage 부재에, reproducibility 는 고정 software 와 artifact 에 의존한다.

파일럿은 participant 또는 personal telemetry 를 처리하지 않는다. 향후 human 및 affect 연구에는 해당 review, informed consent, compensation disclosure, minimization, retention/deletion rule, opt-out 이 필요하다. LLM judge 를 사용하더라도 automated 및 crowd judgement 모두 calibration 과 bias control 이 필요하므로 보조 수단으로 유지한다 [33], [34], [35], [36].

IX. 결론

TRACE-RPG 은 작성된 candidate-event payload 를 encoded 기호 commit gate 를 통해 canonical mutation 으로부터 격리하고, linked record 와 state-semantic replay 로 terminal outcome 을 감사 가능하게 만든다. 결정론적 오프라인 파일럿은 동결된 작성 fixture 에서 mechanism 적합성을 확립한다. 별도 라이브 스크리닝 파일럿은 구성한 수리 가능 regime 에서만 guided 5/5 대 blind 0/5 분리를 관찰하고 다른 regime 에서는 귀무였으므로 pilot-only 로 남는다. Cross-model superiority, player-experience benefit, retrieval 또는 memory effectiveness, affect efficacy, commercial-engine performance 는 명시적인 확증 확장으로 남는다.

AI 사용고지

Large language model 은 prose, code 와 test drafting, command orchestration, evidence review, 결과해석, simulated peer review, citation-identity check 를보조했고, hosted model 은별도표기된 live-screening candidate 도 생성했다. 모든보고 count 는 deterministic runner 또는 hash-bound receipt 에서오며 offline, live-screening, engine evidence 는분리된다. 저자는 claim 을 source artifact 에대조 했고내용에대한책임을진다.

데이터및코드가용성

Repository 에는 implementation, build source, 분리된 offline/live-screening packet 이있다. Offline manifest 는 artifact 38 개, input 22 개, provenance row 121 개 (executed 85 개, aggregate 36 개) 를, live promotion manifest 는 JSON/JSONL receipt 14 개와 superseded v1 diagnostic 을결합한다. Portable offline invocation 에는 absolute clone path 가없고 clean-Git input binding 은 tag trace-rpg-guided-repair-inputs-20260821-v1 에서다 시성립한다. Anonymized reviewer archive 나 DOI deposit 은주장하지않는다.

REFERENCES

- [1] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, “TextWorld: A learning environment for text-based games,” in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.
- [2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, “ScienceWorld: Is your agent smarter than a 5th grader?” in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.
- [3] N. Weir, R. Thomas, R. d’Amore, K. Hill, B. Van Durme, and H. Jhamtani, “Ontologically faithful generation of non-player character dialogues,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.
- [4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, “Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach,” in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.
- [5] S. Geng, M. Josifoski, M. Peyrard, and R. West, “Grammar-constrained decoding for structured NLP tasks without finetuning,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10932–10952.
- [6] L. Beurer-Kellner, M. Fischer, and M. Vechev, “Prompting is programming: A query language for large language models,” *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.
- [7] T. Scholak, N. Schucher, and D. Bahdanau, “PICARD: Parsing incrementally for constrained auto-regressive decoding from language models,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.
- [8] X. He, Y. Tian, Y. Sun *et al.*, “G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907.
- [9] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, “HippoRAG: Neurobiologically inspired long-term memory for large language models,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569.
- [10] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, “Mem0: Building production-ready AI agents with scalable long-term memory,” in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, peer-reviewed ECAI 2025 record; page range was not exposed by the accessible Crossref or publisher metadata at audit time.
- [11] J. S. Park, J. C. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, “Generative agents: Interactive simulacra of human behavior,” in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.
- [12] Y. Shao, L. Li, J. Dai, and X. Qiu, “Character-LLM: A trainable agent for role-playing,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187.
- [13] N. Akoury, Q. Yang, and M. Iyyer, “A framework for exploring player perceptions of LLM-generated dialogue in commercial video games,” in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.
- [14] M. Hochreiter, S. Kriglstein, and G. Wallner, “Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues,” in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.
- [15] M. Yin, H. Zu, W. Gu *et al.*, “How contextualized generative AI shapes player experience in games,” *Entertainment Computing*, vol. 58, p. 101194, 2026, online record with a future issue assignment at the 2026-08-12 audit; issue metadata must be rechecked at submission.
- [16] V. Figueiredo and D. Elumeze, “Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [17] G. N. Yannakakis and J. Togelius, “Experience-driven procedural content generation,” *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.
- [18] D. Melhart, D. Gravina, and G. N. Yannakakis, “Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch,” in *International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.
- [19] Z. Wang, Q. Guo, R. Singh, and X. Hu, “Do vision language models understand human engagement in games?” 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [20] L. Fan, G. Wang, Y. Jiang *et al.*, “MineDojo: Building open-ended embodied agents with internet-scale knowledge,” in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362.
- [21] D. Pérez-Liéñana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, “General video game AI: A multitask framework for evaluating agents, games, and content generation algorithms,” *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.
- [22] X. Liu, H. Yu, H. Zhang *et al.*, “AgentBench: Evaluating LLMs as agents,” in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046, peer-reviewed official proceedings record; no publisher DOI assigned.
- [23] C. Ma, J. Zhang, Z. Zhu *et al.*, “AgentBoard: An analytical evaluation board of multi-turn LLM agents,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362.
- [24] X. Zhou, H. Zhu, L. Mathur *et al.*, “SOTOPIA: Interactive evaluation for social intelligence in language agents,” in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019, peer-reviewed official proceedings record; no publisher DOI assigned.
- [25] D. Paglieri, B. Cupiał, S. Coward *et al.*, “BALROG: Benchmarking agentic LLM and VLM reasoning on games,” in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702, peer-reviewed official proceedings record; no publisher DOI assigned.
- [26] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, “Automated play-testing through RL-based human-like play-styles generation,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.
- [27] S. Buongiorno, L. Klinkert, Z. Zhuang, T. Chawla, and C. Clark, “PANGeA: Procedural artificial narrative using generative AI for turn-based, role-playing video games,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 20, no. 1, pp. 156–166, 2024.
- [28] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, “IVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds,” 2026, preprint; accepted/forthcoming at ICCG 2026, whose available pre-proceedings were explicitly non-archival and unpublished at retrieval time.
- [29] S. Góngora, L. Chiruzzo, G. Méndez, and P. Gervás, “World-state transformations for neuro-symbolic interactive storytelling,” 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-21.
- [30] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320, peer-reviewed official proceedings record; no publisher DOI assigned.
- [31] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, “Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program,” *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021, peer-reviewed official journal article; no publisher DOI assigned.
- [32] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, “Towards the systematic reporting of the energy and carbon footprints of machine learning,” *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020, peer-reviewed official journal article; no publisher DOI assigned.
- [33] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Kraemer, “Best practices for the human evaluation of automatically generated text,” in *Proceedings of the 12th International Conference*

- on *Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.
- [34] M. Karpinska, N. Akoury, and M. Iyyer, “The perils of using Mechanical Turk to evaluate open-ended text generation,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.
 - [35] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623.
 - [36] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, “Humans or LLMs as the judge? a study on judgement bias,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.
 - [37] D. Lakens, A. M. Scheel, and P. M. Isager, “Equivalence testing for psychological research: A tutorial,” *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.
 - [38] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, “Random effects structure for confirmatory hypothesis testing: Keep it maximal,” *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.
 - [39] M. O. Riedl, C. J. Saretto, and R. M. Young, “Managing interaction between users and agents in a multi-agent storytelling environment,” in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.
 - [40] R. E. Fikes and N. J. Nilsson, “STRIPS: A new approach to the application of theorem proving to problem solving,” *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.
 - [41] F. B. Schneider, “Enforceable security policies,” *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.
 - [42] R. Evans and E. Short, “Versu—a simulationist storytelling system,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.
 - [43] S. G. Ware and C. Siler, “Sabre: A narrative planner supporting intention and deep theory of mind,” in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.
 - [44] A. Madaan, N. Tandon, P. Gupta *et al.*, “Self-Refine: Iterative refinement with self-feedback,” 2023, preprint; commonly indexed as NeurIPS 2023 but proceedings identity not re-verified as of 2026-08-21.
 - [45] X. Chen, M. Lin, N. Schärli, and D. Zhou, “Teaching large language models to self-debug,” 2023, preprint; no archival venue or publisher DOI verified as of 2026-08-21.