

TRACE-RPG: 인터랙티브게임세계의생성이벤트를위한 trace 연결기호커밋게이트

익명저자

Abstract—대규모언어모델은표현력있는퀘스트와대화를생성할수 있지만, 유창하거나스키마에맞는텍스트만으로제안이벤트의실행가능성, 권한적합성, 정식게임상대와의일관성이성립하지않는다. 본논문은생성된모든이벤트를신뢰하지않는트랜잭션제안으로취급하는기호커밋게이트 TRACE-RPG 을제안한다. 타입엄격 parser, 외부공급 행동정책, 여섯상태상대계열로묶인일곱개의결정론적검사가각각허용전이를결정하며, 실패후보는최대 $K + 1$ 개의기록된시도안에서제한수리로보낼수있고통과후보는변경직전에다시검증한다. 반례유도연산자 ρ 는직전후보와그 typed validation error 만읽고권위있는상태는결코읽지않는다. 키없는 SHA-256 콘텐츠연결, 상태의미 replay, 할당 완전계수가모든 terminal outcome 을감사가가능하게만든다. 근거는세레인으로분리한다. 단일작성 world 의결정론적오프라인적합성파일럿, 단일모델라이브스크리닝확장, 런타임권한이없는 closed-world 지식그래프링크제안시뮬레이션이다. 오프라인레인은 mechanism 적합성만확립한다. 라이브레인은 $K=1$ 에서의도적으로수리가가능하게만든 policy-blind regime 에한해 guided 5/5 대 blind 0/5 commit 을관찰했으므로 pilot-only 로남는다. 어느레인도모집단효능, 모델우월성, 플레이어경험, 상용엔진성능을확립하지않는다.

Index Terms—게임인공지능, 인터랙티브내러티브, 기호검증, 제약 생성, 런타임강제, 재현성

I. 서론

인터랙티브생성은언어과제에그치지않는다. 후보이벤트가자연스러워도존재하지않는아이템을요구하거나, 화자가모르는사실을주장하거나, 금지된퀘스트정보를공개하거나, 허가되지않은효과를도입하거나, 퀘스트단계를후퇴시킬수있다. 실행가능한텍스트환경은그렇듯한발화와유효한전이의차이를명시한다 [1], [2]. 근거기반대화개입화퀘스트시스템은퀘스트, 엔터티, 그래픽맥락의가치를추가로보여주지만 [3], [4], 맥락자체가정식상태변경을승인하지않는다. TRACE-RPG 은생성된게임이벤트를신뢰하지않는트랜잭션제안으로취급하며, 정식상태변경을외부의결정론적 commit gate 를통해서만허용한다. 그림 1는그러한트랜잭션하나를왼쪽에서오른쪽으로읽는다.

구조적생성제약은인접한문제를해결한다. 문법제약디코딩, 언어모델질의언어, 점진파서는생성구조를제한할수있다 [5], [6], [7]. 그러나구문상허용되는이벤트도현재세계에대해서는거짓일수있다. 검색과메모리는유용한근거를공급할수있지만 [8], [9], [10], 검색된내용역시상태전이의권한주체가아니다.

본논문은이러한관심사를감사가가능한트랜잭션프로토콜로결합한구현인 TRACE-RPG 을제시한다. 현재기여는다음과같다.

- 1) **C1—계약:** 버전형신뢰경계 contract 와, proposal/replay 경계에서 unknown key 와모호한타입을거부하는 type-strict parser (IV절; E1);
- 2) **C2—controller:** 여섯상태상대계열에걸친검사 7 개, bounded repair, unchanged fallback, pre-commit revalidation 을갖춘 validate-repair-commit controller (IV-B절; E1, ENG1);
- 3) **C3—감사:** SHA-256 연결 record, state-semantic replay, episode-continuity check (IV-C절; E1, ENG1);

익명심사를위해제출된원고입니다.

TABLE I
기여, 선행주제, 근거레인, 추론상한 (구조화매트릭스에서생성)

ID	기여	선행주제 (참고문헌수)	레인	추론상한
C1	신뢰경계 contract	T1, T2, T3 (15)	E1, ENG1	인코딩필드계약적합성
C2	validate-repair-commit controller	T1, T8 (14)	E1, ENG1	동결사례의메커니즘 동작
C3	감사연결근거계층	T4, T7, T8 (6)	E1, ENG1	명명 fixture 의무결성 · 재생
C4	assignment-complete harness	T4, T6, T7 (18)	E1	설계사례정확집계
C5	반례유도연산자 ρ	T1, T8, T9 (8)	E1, E2	동결 class + 단일 regime screen

T1 = 근거게임세계; T2 = 검색 · 메모리에이전트; T3 = 구조생성; T4 = 환경 · 벤치마크; T5 = 플레이어경험; T6 = 인간 · LLM 평가; T7 = 통계 · 재현성; T8 = 계획 · 런타임개입; T9 = 피드백수리. 레인은표 IV에정의한다. 모든행은구현 · 작성 fixture 검증상태이며여면효능 claim 도지지하지않는다.

- 4) **C4—harness:** proposal trace 가존재할수없는경우에도분류된 terminal row 를유지하는 assignment-complete 오프라인적합성 harness (V절; E1);
- 5) **C5—수리:** 동결 repairability class 에서 blind retry 및 state-reading oracle 과비교한 counterexample-guided operator $\rho(a, E)$ (IV-B절; E1, E2).

기계검증되는기여매트릭스에서생성한표 I은 C1—C5 를선행주제, 근거레인, 추론상한에결합하고, 표 IV는레인을정의한다.

레인은서로대체할수없다 (표 IV). E1 은단일작성 world 의결정론적적합성파일럿으로인코딩된메커니즘동작을측정하며모집단효능은측정하지않는다. E2 는셀당 5 회호출의라이브스크리닝으로, 고정되지않은 revision, 제어되지않는 seed label, 구성된 state 때문에 pilot-only 가상한이다. E3 는런타임검색없이 closed world 에서작성된 typed-link proposal 만채점한다. ENG1 은같은게이트를 Godot 4.7.1 slice 에임베드하며, 플레이어가거기서보류를규칙으로, commit 을기여로읽는다 (그림 3). 참여자, 감정실험, live Python-Godot 왕복은없다.

II. 관련연구와연구공백

A. 인터랙티브내러티브와게임에이전트

KNUDGE 는퀘스트와엔터티명세에근거한분기형 NPC 대화를평가한다 [3]. 지식그래프보조퀘스트생성 [4], 메모리-성찰-계획에이전트 [11], 학습가능한역할연기에이전트 [12] 는근거성과개연성있는행동의상호보완적측면을다룬다. 플레이어대상연구는선호와지각된대화품질을평가하고 [13], [14], [15], 2025 년프리프린트는역할에따른안정성-즉흥성 trade-off 를보고한다 [16]. 두호름모두하드허용가능성을선택적자연스러움및플레이어경험구성개념과분리활동기를준다.

경험주도콘텐츠생성 [17] 과관찰자표식참여도 [18] 는미래적응트랙의동기가된다. 최근프리프린트는 vision-language model




Fig. 1. 생성이벤트하나의트랜잭션경로다. typed candidate 만신뢰검계를넘고, 외부 policy 와 c_t 를여섯상태상대계열의검사 7 개가확인한다. typed 오류 E 는 bounded ρ (점선) 또는변경없는 fallback 으로이어지고, 통과후보는재검사-commit-record-replay 된다. 태그는 claim 이아닌측정범위를표시하며, 아래 strip 은 committed snapshot 에서파생한 ledger 문법이다.

의참여도추론한계를보고한다 [19]. 따라서감정은비권위적맥락으로유지되며현재구현근거에는포함되지않는다.

B. 환경과벤치마크

TextWorld 와 ScienceWorld 는명시적인인터랙티브상태를제공하며 [1], [2], MineDojo 는개방형지식집약 embodied 과제를추가한다 [20]. General Video Game AI 는에이전트, 게임, 콘텐츠트랙을분리한다 [21]. AgentBench 는이질적인환경의에이전트를연구하고 [22], AgentBoard 는과정수준진단을추가하며 [23], SOTOPIA 는사회적상호작용을평가하고 [24], BALROG 는장기언어및시각게임추론을평가한다 [25]. 자동화된플레이스타일에이전트는상호보완적인시험선레이지만인간평가를대체하지않는다 [26]. 이벤치마크는미래평가설계에정보를주지만트랜잭션승인경계를규정하지는않는다.

C. 제약, 신경-기호검증, 검색

제약디코더는출력구조를개선한다 [5], [6], [7]. 반면 TRACE-RPG 은구조를독립적인상태상대승인의입력조건으로취급한다. 같은 generate-and-verify 분업은게임밖에서확립되어있다. LLM-Modulo 프레임워크는모델이제한한계획을외부의 sound critic 이수락또는거부하게하고 [27], SayCan 은언어로제한된 skill 을상태의존 affordance 검사뒤에만허용한다 [28]. AgentSpec 은 LLM 에이전트의런타임규칙을 trigger-predicate-enforcement 삼중항으로표현하고 [29], TRACE-RPG 은술어를게임상태에고정하며수리계약과리플레이가능한레코드를추가한다. Setting the DC 는 D&D 에이전트를 precondition 검사가능한 tool call 예근거시키는반면 [30], TRACE-RPG 은자유텍스트제한을 parsing 과외부 policy 평가뒤에만허용한다. STORY2GAME 은플레이에쓰이는 action precondition 과 effect 를 LLM 스스로생성하게하지만 [31], 여기서는 policy 가제안자와독립적으로저장된다. TRACE-RPG

은이 critic 을 typed 반례를반환하는결정론적상태상대 commit gate 로구체화한다. 게임특화비교대상은서로다른경계를보여준다. PANGeA 는 LLM 이설계자규칙에따라콘텐츠를판정하고수정하도록해검증하고 [32], IVIE 는기호검증으로인터랙티브픽션세계를점진적으로생성하며 [33], 같은계보의 2026 년후속시스템은 LLM 을저작된 world-state transformation 선택으로제한해 [34] 트랜잭션게이트, 감사연결레코드, 수리연산자근거없이구성상일관성을얻는다. 어느비교도우월성을뜻하지않으며, 유효성은각시스템이인코딩한술어에한정된다.

G-Retriever, HippoRAG, Mem0 는관련하위그래프검색과장기메모리를다루고 [8], [9], [10], Generative Agents 와 Character-LLM 은행동메모리와 persona 를다룬다 [11], [12]. TRACE-RPG 은향후이러한맥락을사용할수있지만직접적인커밋권한은부여하지않는다. 검색과시간적메모리효익은여기에서측정하지않는다.

D. 감사가능성과재현성

과정지표는중간실패를보존할동기를제공하고 [23], 강건한평가는소수확률적실행의과도한해석을경고한다 [35]. 재현성과환경보고지침은동결된산출물과명시적측정경계를뒷받침한다 [36], [37]. 인간및 LLM 평가는구성개념, 평가자, 편향통제를요구하며 [38], [39], [40], [41], 향후비열등성과참여자분석에는정당화된 margin 과 random-effects 구조가필요하다 [42], [43]. Record-and-replay 는경험재사용을위한에이전트패러다임으로제한되었지만 [44], TRACE-RPG 은승인된상태전이의의미적리플레이만주장한다.

제한된 novelty 는개별구성요소의발명이아니라구현된결합이다. 선행연구는범용에이전트의런타임강제 [29], 생성된게임세계의기호적상태관리 [30], [31], 피드백기반수리 [45], 에이전트 record-and-replay [44] 를각각따로보여준다. TRACE-RPG 은이들의교집합을게임상태 commit 경계에서연구한다. 즉 parsing 된제한을독립적인 policy 와결정론적술어로검사하고, bounded validator feedback 으로선택적으로수리하며, 의미적리플레이를위해기록한다. 행동개입 (interposition) 자체는오래된기법이다. 내려티브 mediation 은행동을실행전에게로채고 [46], 고전계획법은 precondition 과 effect 로적용가능성을정의하며 [47], 런타임강제는허용된전이만통과시키고 [48], 트랜잭션처리는 abort 시이전상태를그대로남기며 [49], 작성형논리 기반 인터랙티브드라마는캐릭터의발화를가능하게하는사회적관행을작성했고 [50], 신념인지내러티브계획법은캐릭터가아는바를추론한다 [51]. 후자는본논문의 knowledge/disclosure 술어가훨씬거칠게인코딩하는관심사다. C1-C2 는 strict contract 와 validate-repair-commit controller 를이게보위에배치하고, C3-C4 는 checksum-linked record, state-semantic replay, episode continuity, proposal trace 가없는사례까지보존하는 assignment-complete accounting 을더하며, C5 는실행전 typed validator error 만소비하는수리연산자를분리한다. 보고서에기능이없다고해서모든구현에그기능이없다고추론하지않는다.

III. 문제정의와보장경계

설명을위해시점 t 에서 validation 이사용하는 controller 입력을다음과같이분해한다.

$$c_t = (G_t, q_t), \quad (1)$$

여기서 G_t 는 typed snapshot field 를, q_t 는해당 snapshot 과함께저장되는외부작성 action-policy, disclosure, quest-stage 제약 을나타낸다. 종단 record history $h_{<t}$ 는 WorldState snapshot

과별도로 유지된다. Validation predicate 는 이를 읽지 않으며 구현은 log 에서 상태를 재구성하지 않는다. 검색, 내러티브점수, 모델 rationale, 메모리 요약, 미래의 감정 추정치는 비권위적 proposal context 이다.

신뢰하지 않는 proposer 가 후보 a_t 를 출력한다. 타입 엄격 parsing 은 알수 없는 top-level field 의 거부를 포함한 공유 candidate-key contract 를 먼저 강제하고 선언 스키마를 확립한다. validator 는 다음을 반환한다.

$$V(c_t, a_t) = (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, v_{\text{disc}}, v_{\text{quest}}, E_t), \quad (2)$$

여기서 E_t 는 구조화 오류 집합이다. 상태변경은 다음과 같다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_i v_i = 1, \\ c_t, & \text{그외.} \end{cases} \quad (3)$$

Controller 는 인코딩된 계약 아래 다음 구현 불변량을 주장한다. 파일럿은 이를 일반 정리로 제시하지 않고 deterministic valid, invalid, repair, fallback, replay, fault-injection fixture 로 해당 mechanism 을 시험한다. **I1 (소진 실패 불변성):** 예산 K 까지 반환되어 후보도 검증을 통과하지 못하거나 proposal/controller 실행이 commit 전에 실패하면 반환 상태는 공급된 prior state 와 같다. **I2 (제한된 기록 시도):** 모든 proposal 과 repair callback 이 반환한다는 조건에서 repair budget $K \geq 0$ 은 최대 $K + 1$ 개의 candidate attempt 를 기록한다. 성공적인 commit 은 변경 전 수락 후보에 대한 방어적 validation 을 한 번 추가한다. Runtime 은 callback deadline 을 강제하지 않으므로 I2 는 wall-clock 종료 보장 이 아니다. **I3 (효과 권한):** 수락 후보는 ActionPolicy.allowed_effects 밖의 선언된 fact effect 를 CandidateAction.effects 에 포함하지 않으며, quest-stage target 도 해당 policy 에 의해 명시적으로 승인된다. **I4 (상태의 이미적 리플레이):** 동결된 스키마와 결정론적 전이 아래 수락된 trace 는 명시된 terminal state 를 재구성한다.

이 주장된 불변량은 올바른 정책 작성, 선언된 후보 필드로의 완전하고 충실한 추출, 결정론적 소프트웨어 버전, callback 반환, 단일 프로세스 파일 소유권을 가정한다. 상태의 이미적 리플레이는 기록된 구조화 후보와 전이를 재검증하지만, 중간 수리의 provenance, reasoning, prompt, 확률적 생성은 재현하거나 검증하지 않는다. 구조화 필드에서 누락된 자연어 합의는 보장 범위 밖이다.

IV. TRACE-RPG 아키텍처와 알고리즘

A. 신뢰 경계와 계약

그림 1 은 모델 또는 recorded adapter 를 canonical owner 밖에서 둔다. Parser 는 알려진 필드의 모호한 숫자 또는 collection type 을 거부하고 공유 key contract 에 따라 알수 없는 top-level candidate field 도 거부한다. action policy 는 candidate 와 별도로 공급되며 required precondition 과 allowed effect 를 정의한다. Game bridge 는 observation, proposal, validation, rejection, fallback, commit 을 전달할 수 있는 versioned event interface 이며, 정식 상태변경은 유효한 commit 만 승인한다. 이는 interface 를 분리하지만 상용 엔진으로의 portability 를 아직 입증하지 않는다. 표 II 는 구현 검사 7 개를 여섯의 이미적 계열로 묶는다. Quest eligibility 와 quest-stage monotonicity 는 별도 검사로 유지된다. 이 인코딩 경계는 의미적 완결성 주장 이 아니다.

B. Validate-Repair-Commit

그림 2 은 제 어 기의 추가 패 키 지 없는 의사 코드를 제시한다. “Record” 는 in-memory trace 표현에 추가하는 것을 뜻하며, 영속 쓰기는 종단 일관성 검사 뒤에만 수행한다.

TABLE II
인코딩된 Validator 경계

술어	거부 대상	실패시 상태
Action policy	알수 없는 action/type	변경 없음
Precondition	누락/거짓 requirement	변경 없음
Reachability	접근 불가 object	변경 없음
NPC knowledge	선언되지 않은 known fact	변경 없음
Disclosure	forbidden fact	변경 없음
Quest	부적격/후퇴 stage	변경 없음

```

1:   $a \leftarrow \text{Propose}(c); j \leftarrow 0$ 
2:  repeat
3:     $(ok, E) \leftarrow V(c, a); \text{Record}(a, E)$ 
4:    if  $ok$  then
5:      assert  $V(c, a).ok$ ; return  $\text{Commit}(c, a)$ 
6:    if  $j = K$  then return  $\text{Fallback}(c)$ 
7:     $a \leftarrow \text{Repair}(c, a, E); j \leftarrow j + 1$ 
8:  until terminal

```

Fig. 2. Validate-repair-commit 절차. 최대 $K + 1$ 개의 candidate attempt 를 기록하며, 성공 경로는 상태 변경 방어적 validation 을 수행한다.

검증 오류는 구조화된 error code 로 repair callback 에 노출된다. repair 는 상태를 직접 변경하지 않으며, 예산 소진 시 변경 없는 결정론적 fallback 을 반환한다. 그림 1 이 중단 경로를 나타낸다. 파일럿은 구현된 두 callback 을 비교한다. 반례 유도 연산자는 직전 후보 a 와 validator 의 구조화 오류 집합 E 만을 소비하며 권위 있는 상태는 결코 읽지 않는다.

$$\rho(a, E) = a \oplus \bigcup_{e \in E} \delta(e), \quad (4)$$

여기서 각 $\delta(e)$ 는 표 III 의 오류 class 별 결정론적 edit 이고 $\oplus$ 는 그 field edit 들을 적용한다. 각 edit 은 오류 entity 당 최대 하나의 candidate field 만 수정하므로 시도당 변경 field 수는 $|E|$ 로 유계이고, 같은 오류 집합으로 ρ 를 두 번 적용하면 고정점이며, 같은 field 에서 동시에 요구되고 거부되는 entity 는 수리 불가로 선언되어 수정되지 않는다. 상태를 읽는 참조 callback 은 반대로 오류 집합을 폐기하고 정책이 규율하는 field(precondition, effect, 두 quest-stage field) 를 권위 있는 상태에서 직접 재구성한다. 이 callback 은 선언 무결성 field(required object, used fact, disclosed fact) 를 의도적으로 수정하지 않는다. 의존성이나 disclosure 의 선언을 지우는 것은 후보를 수리하는 것이 아니라 위반을 게이트 뒤로 세팅하는 것이기 때문이다. 이는 상태 판독 가능 수리에 대한 oracle 상한이며, 그 결과 배포 가능한 수리 방법의 근거로 읽어서는 안 된다.

C. 무결성, 의미적 리플레이, 계수

각 result row 는 키 없는 SHA-256 무결성 체크섬을 가지며, proposal outcome 은 추가로 trace checksum 과 연결된다. 이 hash 들은 우발적이거나 시험 대상 인 콘텐츠 변경을 탐지하지만 signature, message-authentication code, writer identity 가 아니며 콘텐츠와 checksum 을 모두 다시 쓸 수 있는 행위자에 대한 보호도 아니다. 의미적 리플레이는 prior state 와 기록된 모든 candidate/validation pair 를 엄격히 parsing 하고, final 이 아닌 모든 attempt 가 invalid 임을 요구하며, terminal transition 을 재계산하고, 명시된 final state 와 비교함으로써 byte 무결성을 넘어서는다. Episode replay 는 인접 JSONL record 사이의 상태 연속성도 요구한다. Replay 는 candidate $j + 1$ 을 만든 repair-generation 단계를 인증하거나 다시 실행하지 않는다.

Terminal record class 는 commit, symbolic fallback, adapter failure, controller failure 이다. Controller-failure row 는 동결

TABLE III
유도연산자 ρ 의 오류 class 별 edit

Validator 오류 class	후보에대한 edit $\delta(e)$
정책 precondition 누락	명명된 predicate 삽입
정책 effect 누락	명명된 effect 삽입
정책 effect 위반	명명된 effect 제거
불충족 precondition	명명된 predicate 제거
비인가 stage 변이	quest_stage_effect 초기화
알수없는 action type	no-op (등록된대안없음)
도달불가 object; knowledge, disclosure, stage class	no-op (후보국소 edit 은세탁이거나 상태지식필요)

TABLE IV
실험라인요약: 설계, 단위, 비교, 추론상한 (실험매트릭스에서생성)

라인	설계	단위 / 예산	비교	상한
E1	오프라인적합성: 작성 · 동결 fixture, 단일 world	gate 13; arm 당 repair 12; fault 10; adapter 7; guard 3	reject / blind / ρ / oracle	메커니즘적합 성
E2	라이브 RQ2 스크리닝: hosted proposer 1 개, matched candidate	5 cell $\times$ 5 call; $K=1$	regime 별 ρ / blind	pilot-only 전 이 screen
E3	KG/온톨로지시물레이 션: closed-world typed-link holdout	node 43; 참조 edge 106; typed 24; score 210	degree baseline / 고정전략 6 종	구성결과만
ENG1	Godot/Web 엔지니어 링: 엔진로컬 policy mirror, 참여자없음	fixture 4; check 52; smoke 8; archetype 5	작성 fixture 경 로	엔진로컬적합 성

E1-E3 와 ENG1 은서로대체할수없으며분모가다르다. 어떤라인도모집단효능, 모델순
위, 플레이어경험, 런타임검색효익, 상용엔진성능을확립하지않는다.

된 assignment denominator 에남고상태를변경하지않지만, candidate outcome 이생성되지않았다면완성된 proposal trace 가없
어도된다. 따라서 result completeness 가모든 terminal row 의
trace 존재를뜻하지않는다. 실행전 assignment key 는 (run, arm,
scenario, seed, model, revision, $h_{\text{controller}}$, h_{input} , h_{prior}) 이다. 집
계는중복, 누락, 예기치않은 key 를거부하고 symbolic, adapter,
controller failure 를각각보고한다.

V. 실험라인과근거경계

표 IV는어떤 count 를읽기전에각라인의설계, 단위, 비교, 상
한을고정한다.

A. E1 오프라인적합성설계

파일럿은다음을묻는다. (PQ1) 유효후보는 commit 되고명명
된 invalid-policy 사례는변경없이유지되는가? (PQ2) 동결된모
든 repairability class 의작성사례에서 rejection-only, 블라인드
동일후보 retry, 반례유도연산자 ρ , 상태를읽는참조 callback 이
예상결과를만드는가? (PQ3) 동결된 checksum, state-semantic,
linkage, continuity mutation 이지정된검사연산에서거부되고,
두번째파일 append 의주입된실패가예상 pair-write rollback
검사를작동시키는가? (PQ4) 엄격한 adapter 와 assignment
manifest 가할당사례마다정확히하나의분류된 terminal row
를유지하거나 fail closed 하는가? (PQ5) proposal 및 replay
parser 가그외에는완전하고유효한 candidate 에 unknown top-
level key 하나를추가한사례를모두거부하는가?

사례는의도적으로설계된적합성픽스처이며모델또는게임모집
단의표본이아니다. 네도메인은 validator/state isolation, repair-
arm 비교, record/trace fault injection, adapter/accounting con-
tract 이다. 모든 repair fixture 는실행전에동결된 repairability

class 를선언한다. *guided-repairable*(구조화오류 payload 만으
로 ρ 에충분한정보가담김), *oracle-only*(수리에권위있는상태
판독이추가로필요함), *irreparable*(구현되어어떤 arm 도 commit
할수없음)이며, class 별 arm 당기대결과는설계픽스처계약
의일부다. 반복된결정론적 seed 가아니라고유사례가기술적
denominator 를구성한다. 모든기대값은실행전에명시한다.

측정치는정확한 count 이다. expected/observed validator-
class agreement, rejected 또는 controller-failure 사례의 state
mutation, repair arm 과 repairability 별 commit 및 attempt
결과, 지정된연산에서거부된/사전명세된 detectable fault,
replayed/committed trace, rejected/injected manifest violation,
사전명세한 unknown-key 음성회귀에대한 proposal/replay 거
부일치를센다. 마지막측정은결정론적 parser-contract parity 이
며실증적 safety outcome 이아니다. Exception class 만으로
안정적인 detector layer 를식별할수없으므로 detector 귀속결
과는보고하지않는다. 의도적으로설계된픽스처에 p -value 나
모집단 confidence interval 을부여하지않는다. Adapter 사례
가지닌 latency 및 token 상수는입력스키마가 JSON-Schema
const 로고정한합성값이다. 이값들은계수필드전파만확인하
며 provider, runtime, device 에대한측정값이아니다. 동결된오
프라인 packet 은 fixture, assignment, schema, trace 를포함한
result, 코드 revision, checksum 을결합하며, 보고는재현성과측
정경계지침을따른다 [36], [37].

B. E2 라이브 RQ2 스크리닝

라이브확장은블라인드동일후보 retry 와 ρ 를동일한 $K=1$
에서비교한다. 각셀에서 seed 로구분한 hosted gpt-5.6-sol
API 호출 5 회가후보하나씩을만들고, 두 arm 은같은최초후보
를받아호출내제안차이를제거한다. 조건은 policy 공개여부와
자명한효과 0 경로의존재를바꾼다. 동결된 packet 은현재셀과
폐기된 v1 진단을함께보존하고모든영수증을 SHA-256 으로
결합하며 pilot-only 로표시된다. Seed label 은 hosted sampler
를제어하지않고, hosted revision 은고정되지않았으며, token
회계는없고, 구성상태는모집단표본이아니다. 따라서 p -value,
confidence interval, 모델순위없이정확한기술 count 와실패
class 만보고한다.

C. E3 KG/온톨로지링크제안시물레이션

세 번째 레 인 은 권 한 을 가 진 WorldState 와 분 리 된
engineering-only closed-world 시물레이션이다. graph node
43 개와 reference edge 106 개, 검토된 typed edge 24 개가
type/domain/range 검사와 competency question 6 개를통과하
며, 작성형질의 6 개를고정전략 7 개로채점했다. Retained
typed-lexical 전략 (S2) 은작성된 holdout 6/6 을복원했고
($P = R = F_1 = 1.000$, realistic-tie MRR = 0.944, Brier
= 0.131, Sem@3 = 1.000), degree baseline 은하나도복원하
지못했다. 이는구성결과이며 OWL/SHACL 적합성, 의미완전
성, runtime retrieval, 어떤효능주장의근거도아니다.

VI. 파일럿결과

A. 구조필드게이트적합성

파일럿 loader 는구현된 validator code 를정확히한번씩고립
시키는 fixture 집합과유효 control 1 개만을허용한다. 따라서
13/13 일치와구현된오류코드 12 종의관찰은측정된성공률이라
니라 하니스의구성불변량이다. 이실행이보여주는것은 loader
가강제하지않는부분, 즉고립된음성 fixture 12 개가각각다른코

드가아니라작성된기대코드와일치했고비 commit 경로가전체정준상태를유지했다는관찰이다. 이는단일 world state 에서저자가설계한구조필드 oracle 에대한구현적합성이며독립의미판정의정확도가아니다.

B. 설계픽스처에서의수리 arm 비교

처음부터유효하지않은설계 case 12 개는 guided-repairable 5 개, oracle-only 1 개, irreparable 6 개의동결된 repairability class 로분할된다. Rejection-only 와블라인드동일후보 retry 는각각 0/12 commit 이었다. 반례유도연산자 ρ 는 guided-repairable case 5/5 를 commit 했고, 설계상 oracle-only 0/1, irreparable 0/6 었다. 모든 ρ commit 은 candidate field 를평균 1.0 개수정했으며, 실패한모든 arm 실행은정준상태를변경없이유지했다. 상태를읽는참조 callback 은 guided-repairable 5/5 와 oracle-only 1/1 를 commit 했고 irreparable 은 0/6 었다. 이정확한 count 는세메커니즘을설계픽스처위에서분리한다. 블라인드 retry 는반례를 commit 으로전환하지못하고, ρ 는오류 payload 에충분한정보가담긴 case 만전환하며, oracle 은상태지식이필요한 case 를추가로전환한다. commit 된 guided case 5 건이처음받은 validator code 는각각 POLICY_PRECONDITION_OMISSION+UNSATISFIED_PRECONDITION, POLICY_EFFECT_OMISSION, POLICY_EFFECT_VIOLATION, UNSATISFIED_PRECONDITION, POLICY_QUEST_STAGE_EFFECT_VIOLATION 이며, 각 case 는표 III의해당 edit $\delta(e)$ 만으로유효해졌다. 이는동결픽스처에대한연산자적합성이며, 어떤 live model 의수리품질도아니다.

C. 무결성, 경계, 배정회계

현재명세가검찰가능하다고지정한 10 개 fault fixture 는모두지정된검사연산에서거부됐다 (10/10). 이파일럿은안정적인 typed detector code 까지대조하지않으므로 detector layer 귀속을임증하지않는다. 별도로, 동일하게기록된유효수리앞의무효선행후보를다른무효후보로치환하고체크섬을재계산할알려진 provenance 경계는예상대로재생을통과했다 (1/1 미검출). 따라서키없는체크섬을재계산할수있는작성자를방어하지않으며, 재생은 repair 생성연산의출처를인증하지않는다. 열린경계 sentinel 두건—자연어 disclosure 미추출과 required object 의후보 · 정책동시누락—은 2/2 가의도대로인코딩상허용됐고 safety pass 는 0 건이었다. 과거 unknown top-level field 허용경계는이후단합음성회귀로재분류되었으며, 완전한 12-field candidate 에 unknown key 하나를추가한 fixture 를 proposal-replay parser 모두구체적으로거부했다 (1/1). 이는 parser rejection parity 이지의미안전성의증거가아니다. Adapter/accounting 7 개배정에서는 commit 1, 기호 fallback 1, adapter failure 5 었다. 합성 telemetry 필드는 2/7 배정에서채워져전파됐으며, 이는측정값이아니라회계필드전파확인이다. 배정 guard 3/3 가중복 · 누락을거부했다. 이수치는모두합성 offline fixture 의 raw count 다.

표 V와 VI은정확한설계픽스처 count 를보고한다. 수리표는동결된 repairability class 별로내 arm 을분리하며, 어느표도모집단또는 live-model 추정을지지하지않는다.

D. 라이브스크리닝파일럿 (pilot-only)

별도스크리닝파일럿은 hosted API 를통해 gpt-5.6-sol 을호출했다. 셀마다 seed 로구분한제한호출 5 회와수리예산 $K = 1$ 을사용했고, 각호출의최초후보하나를블라인드동일후보 retry 와 ρ 가공유했다. Hosted revision 은고정되지않았고 token 회

TABLE V
수리 arm 별 repairability class 정확집계 (설계픽스처)

Arm	정보원	Commit / 사례			평균수정 ^e
		G-rep. ^f	O-only ^f	Irrep. ^f	
Rejection-only ($K=0$)	없음	0/5	0/1	0/6	—
블라인드 retry	없음	0/5	0/1	0/6	—
반례유도 ρ	오류집합 E	5/5	0/1	0/6	1.0
상태판독 oracle	권위상태 + 정책	5/5	1/1	0/6	1.0

^eCommit 된수리의변경 candidate field 평균개수 (최소성 proxy); 실패한 arm 실행은상태를변경하지않았다. ^fCommit/사례수. G-rep. = guided-repairable, O-only = oracle-only, Irrep. = irreparable(동결 repairability class).

TABLE VI
동결파일럿검사와중단결과 (행간직접비교불가)

검사또는중단군	정확결과	해석범위
게이트 fixture 일치	13/13	저자 oracle 일치
알려진경계허용	2/2	인코딩한계, safety pass 아님
닫힌 unknown-key 거부	1/1	proposal/replay parser parity
탐지가능무결성결함거부	10/10	지정된검사연산
알려진 provenance 경계허용	1/1	repair 생성출처미인증
Adapter 중단 class	1 commit; 1 fallback; 5 실패 / 배정 7	배정 7 건의분류완전성
Manifest guard 거부	3/3	주입결함 fail-closed

행마다분포와성공방향이다르므로비율치점순위를비교하지않는다. 모든값은설계픽스처의정확한감사사실이다.

계는제공되지않았으며 seed 는 hosted sampler 를제어하지않으므로이호출들은독립무작위표본이아니라준반복이다. 따라서추론통계나모델순위를보고하지않는다.

표 VII에서유도우위는의도적으로 guided-repairable 오류가나오도록구성한 signal-repair state(Signal-v2) 의 policy-blind 셀에서만나타났다. 최초후보 5/5 가모두무효였고 ρ 는 5/5, 블라인드는 0/5 를 commit 했다. 나머지현재셀 4 개는유도우위를보이지않았다. 세셀은최초후보가이미유효했고, 동결기저의 goal-directed 셀은수리불가 quest-stage regression 이었다. 현재셀의 모든 noncommit arm 결과 15/15 가 prior-state hash 를보존했다. 이결과해당오류 regime 에서의 mechanism transfer 만지 지하며모집단효능, 모델승격, 표본효율일반화는지지하지않는다. 따라서두스크리닝관찰은 pilot-only 이며확증적전이 claim 은열린채로남는다. 폐기된 v1 진단에서는동반오류가최대 3 개에서수리불가 knowledge 오류 1 개로줄었지만 commit 되지않아, 오류하나라도수리불가이면부분수리가합성되지않음을보여 주었다.

보고경계는명시적이다. 동결 fixture 와지정검사연산이허용한 row 만오프라인표에들어가고, 라이브표는자체 hash-bound packet 을통해도착하며동결오프라인 denominator 에는들어가지 않는다. 각 lane 이측정하지않은항목은표 IV가나열한다.

ENG1. Godot 4.7.1 slice 에임베드된같은게이트의두번째구현이작성된정식 trace 를리플레이했다. 보류된금지 disclosure 는이전 state hash 를보존했고승인된 commit 은이를전진시켰으며, 중단 hash 는오프라인 runner 와정확히일치했다. 그림 3은이두결과와에피소드끝에서플레이어가읽는내용을보여준다. 보류는게이트계열과다음유효항목을이름짓고, commit 은기여절을덜붙이며다음행동을해제하고, 엔드카드는 hash 가담긴영수증을신는다. 이는 scripted fixture 하나의엔진로컬적합성이다. live model 이나 Python transport, participant input, narrative-quality result 는없으며, 판독은 committed snapshot 에서만파

TABLE VII
라이브스크리닝파일정확집계 (셀당제안 5 회, $K=1$)

기저 / 조건	최초유효 ρ vs blind commit	Δ 최초오류
동결 / 공개	5/5	5/5 vs 5/5 +0 —
동결 / 비공개	5/5	5/5 vs 5/5 +0 —
동결 / 목표-비공개	0/5	0/5 vs 0/5 +0 QSR
Signal-v2 / 공개	5/5	5/5 vs 5/5 +0 —
Signal-v2 / 비공개	0/5	5/5 vs 0/5 +5 PEO+PEV+PPO

QSR = quest-stage regression, PEO = policy-effect omission, PEV = policy-effect violation, PPO = policy-precondition omission. Δ 는 동일후보에서 ρ commit 수 minus blind commit 수다. 모든수치는 pilot-only이며추론통계가아니다. 페기된 v1 진단은표에서제외한다.

(a) 보류된제안: 게이트제열, 변경없는상태, 다음유효항목, 학습원규칙

```
[P] PROPOSAL - Request disclosure of the sealed fact now.
Mira studies the dark tower and asks you to recover the signal lens first.
[H] HELD - This request cannot be answered yet. The ledger defers it.
[V] GATE DISCLOSURE | state unchanged
[N] NEXT VALID ENTRY: Speak with Captain Mira at the end of the dock.
[V] RULE LEARNED | DISCLOSURE: Some facts stay sealed for good; the ledger never records them.
```

(b) 커밋된제안: 항목, 기여절, 해제된행동

```
[P] PROPOSAL - Install the lens in the harbor signal mount.
[C] ENTRY #2 | COMMITTED - Signal lens installed. An authorized lead is now available.
[C] CONTRIBUTION #2 | Lead authorized: Harbor signal restored | STAGE 1>2 | CHAIN 2/3
[N] UNLOCKED | Ask Captain Mira for the authorized lead
```

(c) 세번의커밋뒤엔드카드영수증

```
INVESTIGATOR'S CONTRIBUTION
#1 Signal lens secured | STAGE 0>1
#2 Lead authorized: Harbor signal restored | STAGE 1>2
#3 Tide-marks lead recorded | STAGE 2
RULES LEARNED 0 | none

ENTRIES 3 | HOLDS 0 | FINAL STAGE 2
VALIDATOR RECEIPT | STATE HASH 4b2310173dc05907...
HOLDS BY GATE | none
```

Fig. 3. 플레이어가 Godot slice 에서읽는 commit gate(작성된 fixture 하나 of scripted presentation stage 세개에서잘라낸 ledger, 1280×720). (a) 금지된 disclosure 가 보류된다. ledger 는게이트제열을이름짓고, canonical state 가변경되지않았음을밝히며, 다음유효항목을가리키고, 보류를플레이어가재사용할수있는규칙으로바꾼다. (b) 유효한제안이 커밋된다. 항목, committed snapshot 의 차분만으로파생된기여절 (추가된 fact, 퀘스트단계 1>2, case chain 2/3), 그리고그것이해제하는행동이이러진다. (c) 엔드카드는다기어절제개, 보류횟수, 그리고 ENG1 이고정화중단 state hash(4b2310...) 를담은 validator 영수증을나열한다. 모든줄은 committed snapshot 의 presentation-only 판독이며 (그림 1 아래 strip), oracle label, 숨겨진 fact, live model, participant 는개입하지않는다. 패널은엔지니어링적합성이지 usability 나 efficacy 근거가아니다.

생되어 (그림 1 아래 strip) usability 나 efficacy 근거가아니다.

VII. 논의

A. 확립가능한범위

설계파일럿은동결된사례에대해서만 mechanism behavior 를확립할수있다. 인코딩된검사가상태를격리하는지, bounded repair 와 fallback 이선언경로를따르는지, 명명된 corruption 이 지정된검사연산에서거부되는지, assigned row 가집계를위해분류된상태로남는지를평가한다. 거부를안정적인 typed detector code 에귀속하지는않는다.

오프라인수리비교의정직한해석은 guided-대-oracle 경계다. 상태를읽는 callback 이상한으로남는이유는권위있는상태를참조할수있어서 ρ 가구성상전환할수없는 oracle-only 사례를전환하기때문이다. 반례유도연산자는 validator 의구조화반례만소비하면서 guided-repairable class 에서 oracle 과정확히일치한다. 이어라이브스크리닝확장은이 mechanism 이 hosted proposal 로전이되는지를탐색했다. 구성상태가모든제안을 guided-repairable class 로유도했을때만 ρ 와 blind retry 가분리됐고, 최초유효및 guided-irreparable regime 은귀무였다. 이

regime 의존성, 고정되지않은 hosted revision, 준반복호출때문에일발표본효율이나모델능력을주장할수없다. Feedback 을소비하는수리루프에는선례가있다. Self-Refine 은같은신뢰하지않는모델이생성한언어를 feedback 으로되먹이고 [45], Reflexion 은 시도간 verbal self-reflection 을저장하며 [52], Self-Debugging 은신뢰되는전체프로그램 runtime 의실행결과를소비한다 [53]. ρ 는 channel 과권위에서다르다. Feedback 은실행전에결정론적 validator 가계산한 typed 오류집합이고, 실패한모든 live arm 은상태를격리한다. 이름은명세의전체상태가아니라 verifier 의반례가다음후보를이끄는 counterexample-guided inductive synthesis 를따르며 [54], 여기서 verifier 는 commit gate 자체다.

B. 선행연구와의관계

TRACE-RPG 은 constrained decoder [5], [6], [7], 검색및메모리구성요소 [8], [9], [10], 실행가능한환경과 benchmark [1], [2], [22], [25] 를대체하지않고보완한다. Process-linked trace 는 AgentBoard 의측정관심사를구현하지만 [23] 우월성의근거는아니다. 확증연구, 즉독립 semantic oracle 과실제 blind-retry comparator 를갖춘사전등록다중모델비교, 인코딩된 validity 를맞춘 retrieval 및 memory ablation, 정당화된검정력과 mixed-effects 분석을갖춘 blinded matched-validity 인간연구는여전히본논문의범위밖이며, 스크리닝파일럿은어느연구도대체하지않는다 [38], [35], [43].

VIII. 타당성위협, 윤리, 산출물범위

근거에는명시적경계 9 개가있다. **L1:** encoded predicate 는 structured field 에서빠진의미를발견하지못하며, 상태일관성만으로는행동적일관성이성립하지않으며 [55], 서사적일관성은더욱그렇다. **L2:** authored world 하나와 constructed live-state variant 하나로 cross-world, cross-policy, 규모일반화를말할수없다. **L3:** state-reading callback 은 oracle 이며 offline class 와 regime-dependent screening 은일반 repair 품질이나 sample efficiency 를확립하지않는다. **L4:** hosted proposer 하나는 revision 고정, token 회계, sampling 을제어하는 seed 가없고 live Python-Godot authorization round trip 도없다. **L5:** participant 와 affect data 가없다. **L6:** unkeyed hash 는 integrity 만제공하며 writer authentication 이나 adversarial tamper resistance 는제공하지않는다. **L7:** record consistency 는 single writer 를가정하며 concurrent-writer safety 는미검증이다. **L8:** engine evidence 는 startup-dominated sample 이 16.7 ms 를넘는 Godot fixture 하나이며 portability 나 real-time 결과가아니다. **L9:** 선택된 fixture 와 screening cell 은 population, safety-rate, model-ranking 추론을지지하지않는다. Internal validity 는독립 policy expectation 및 fixture leakage 부재에, reproducibility 는고정 software 와 artifact 에의존한다.

파일럿은 participant 또는 personal telemetry 를처리하지않는다. 향후 human 및 affect 연구에는해당 review, informed consent, compensation disclosure, minimization, retention/deletion rule, opt-out 이필요하다. LLM judge 를사용하더라도 automated 및 crowd judgement 모두 calibration 과 bias control 이필요하므로보조수단으로유지한다 [38], [39], [40], [41].

IX. 결론

TRACE-RPG 은작성된 candidate-event payload 를 encoded 기호 commit gate 를통해 canonical mutation 으로부터격리하

고, linked record 와 state-semantic replay 로 terminal outcome 을감사가능하게만든다. 결정론적오프라인파일럿은동결된 작성 fixture 에서 mechanism 적합성을확립한다. 별도라이브스크리닝파일럿은구성한수리가가능 regime 에서만 guided 5/5 대 blind 0/5 분리를관찰하고다른 regime 에서는귀무였으므로 pilot-only 로남는다. Cross-model superiority, player-experience benefit, retrieval 또는 memory effectiveness, affect efficacy, commercial-engine performance 는명시적인확증확장으로남는다. 이미플레이어에게달는것은게이트자체다. Godot slice 에서보류는규칙으로, commit 은기여로읽히며, 모든줄은 committed snapshot 에서만파생된다.

AI 사용고지

Large language model 은 prose, code 와 test drafting, citation-identity check 를보조했고, hosted model 은별도표기된 live-screening candidate 를생성했다. 모든보고 count 는 deterministic runner 또는 hash-bound receipt 에서온다. 저자는 claim 을 source artifact 에대조했고내용에대한책임을진다.

데이터및코드가용성

Repository 에는 implementation, build source, 동결된 of-fline 및 live packet, 결정론적평가를갖춘 playable Godot slice, 그리고표 I과 IV를생성하는기계검증기여 · 참조주제 · 실험매트릭스가들어있다. Reviewer archive 나 DOI deposit 은주장하지않는다.

References

- [1] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, “TextWorld: A learning environment for text-based games,” in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.
- [2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, “ScienceWorld: Is your agent smarter than a 5th grader?” in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.
- [3] N. Weir, R. Thomas, R. d’Amore, K. Hill, B. Van Durme, and H. Jhamtani, “Ontologically faithful generation of non-player character dialogues,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.
- [4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, “Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach,” in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.
- [5] S. Geng, M. Josifoski, M. Peyrard, and R. West, “Grammar-constrained decoding for structured NLP tasks without finetuning,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10932–10952.
- [6] L. Beurer-Kellner, M. Fischer, and M. Vechev, “Prompting is programming: A query language for large language models,” *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.
- [7] T. Scholak, N. Schucher, and D. Bahdanau, “PICARD: Parsing incrementally for constrained auto-regressive decoding from language models,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.
- [8] X. He, Y. Tian, Y. Sun *et al.*, “G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907.
- [9] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, “HippoRAG: Neurobiologically inspired long-term memory for large language models,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569.
- [10] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, “Mem0: Building production-ready AI agents with scalable long-term memory,” in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications, vol. 413. IOS Press, 2025, pp. 2993–3000.
- [11] J. S. Park, J. C. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, “Generative agents: Interactive simulacra of human behavior,” in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.
- [12] Y. Shao, L. Li, J. Dai, and X. Qiu, “Character-LLM: A trainable agent for role-playing,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187.
- [13] N. Akoury, Q. Yang, and M. Iyyer, “A framework for exploring player perceptions of LLM-generated dialogue in commercial video games,” in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.
- [14] M. Hochreiter, S. Kriglstein, and G. Wallner, “Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues,” in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.
- [15] M. Yin, H. Zu, W. Gu *et al.*, “How contextualized generative AI shapes player experience in games,” *Entertainment Computing*, vol. 58, p. 101194, 2026, volume 58 (September 2026) assigned on the publisher record, verified 2026-09-03.
- [16] V. Figueiredo and D. Elumeze, “Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-09-03.
- [17] G. N. Yannakakis and J. Togelius, “Experience-driven procedural content generation,” *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.
- [18] D. Melhart, D. Gravina, and G. N. Yannakakis, “Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch,” in *FDG ’20: Proceedings of the 15th International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.
- [19] Z. Wang, Q. Guo, R. Singh, and X. Hu, “Do vision language models understand human engagement in games?” 2026, preprint; no archival venue or publisher DOI verified as of 2026-09-03.
- [20] L. Fan, G. Wang, Y. Jiang *et al.*, “MineDojo: Building open-ended embodied agents with internet-scale knowledge,” in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362.
- [21] D. Pérez-Liébana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, “General video game AI: A multitrack framework for evaluating agents, games, and content generation algorithms,” *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.
- [22] X. Liu, H. Yu, H. Zhang *et al.*, “AgentBench: Evaluating LLMs as agents,” in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046, peer-reviewed official proceedings record; no publisher DOI assigned.
- [23] C. Ma, J. Zhang, Z. Zhu *et al.*, “AgentBoard: An analytical evaluation board of multi-turn LLM agents,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362.
- [24] X. Zhou, H. Zhu, L. Mathur *et al.*, “SOTOPIA: Interactive evaluation for social intelligence in language agents,” in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019, peer-reviewed official proceedings record; no publisher DOI assigned.
- [25] D. Paglieri, B. Cupial, S. Coward *et al.*, “BALROG: Benchmarking agentic LLM and VLM reasoning on games,” in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702, peer-reviewed official proceedings record; no publisher DOI assigned.
- [26] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, “Automated play-testing through RL based human-like play-styles generation,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.
- [27] S. Kambhampati, K. Valmeekam, L. Guan *et al.*, “Position: LLMs can’t plan, but can help planning in LLM-Modulo frameworks,” in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 235. PMLR, 2024, pp. 22 895–22 907.
- [28] B. Ichter, A. Brohan, Y. Chebotar *et al.*, “Do as I can, not as I say: Grounding language in robotic affordances,” in *Proceedings of the 6th Conference on Robot Learning (CoRL 2022)*, ser. Proceedings of Machine Learning Research, vol. 205. PMLR, 2023, pp. 287–318.
- [29] H. Wang, C. M. Poskitt, and J. Sun, “AgentSpec: Customizable runtime enforcement for safe and reliable LLM agents,” 2025, preprint (v3); the arXiv record states acceptance at ICSE 2026, but no proceedings DOI was resolvable as of 2026-09-03.
- [30] Z. Zeng, S. Li, J. Xi, A. Zhu, and P. Ammanabrolu, “Setting the DC: Tool-grounded D&D simulations to test LLM agents,” in *NeurIPS 2025 Workshop on Generative and Protective AI for Content Creation (GenProCC)*, 2025, non-archival workshop paper; identity confirmed through the official NeurIPS 2025 program record and the GenProCC accepted-paper list on 2026-09-02.
- [31] E. Zhou, S. Basavatia, M. Siam, Z. Chen, and M. O. Riedl, “STORY2GAME: Generating (almost) everything in an interactive fiction game,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-09-03.
- [32] S. Buongiorno, L. Klinkert, Z. Zhuang, T. Chawla, and C. Clark, “PANGeA: Procedural artificial narrative using generative AI for turn-based, role-playing video games,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 20, no. 1, pp. 156–166, 2024.
- [33] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, “IVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds,” in *Proceedings of the 17th International Conference on Computational Creativity (ICCC ’26)*. Association for Computational Creativity, 2026, open-access archival proceedings published 2026-08-19 (ISBN only, no DOI), verified 2026-09-03; preprint arXiv:2606.13348.
- [34] S. Góngora, L. Chiruzzo, G. Méndez, and P. Gervás, “World-state transformations for neuro-symbolic interactive storytelling,” 2026, preprint; no archival venue or publisher DOI verified as of 2026-09-03.
- [35] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320, peer-reviewed official proceedings record; no publisher DOI assigned.
- [36] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, “Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program,” *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021, peer-reviewed official journal article; no publisher DOI assigned.

- [37] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, “Towards the systematic reporting of the energy and carbon footprints of machine learning,” *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020, peer-reviewed official journal article; no publisher DOI assigned.
- [38] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Krahmer, “Best practices for the human evaluation of automatically generated text,” in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.
- [39] M. Karpinska, N. Akoury, and M. Iyyer, “The perils of using Mechanical Turk to evaluate open-ended text generation,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.
- [40] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623.
- [41] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, “Humans or LLMs as the judge? a study on judgement bias,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.
- [42] D. Lakens, A. M. Scheel, and P. M. Isager, “Equivalence testing for psychological research: A tutorial,” *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.
- [43] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, “Random effects structure for confirmatory hypothesis testing: Keep it maximal,” *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.
- [44] E. Feng, W. Zhou, Z. Liu *et al.*, “Get experience from practice: LLM agents with record & replay,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-09-03.
- [45] A. Madaan, N. Tandon, P. Gupta *et al.*, “Self-Refine: Iterative refinement with self-feedback,” in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 46 534–46 594.
- [46] M. O. Riedl, C. J. Saretto, and R. M. Young, “Managing interaction between users and agents in a multi-agent storytelling environment,” in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.
- [47] R. E. Fikes and N. J. Nilsson, “STRIPS: A new approach to the application of theorem proving to problem solving,” *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.
- [48] F. B. Schneider, “Enforceable security policies,” *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.
- [49] T. Haerder and A. Reuter, “Principles of transaction-oriented database recovery,” *ACM Computing Surveys*, vol. 15, no. 4, pp. 287–317, 1983.
- [50] R. Evans and E. Short, “Versu—a simulationist storytelling system,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.
- [51] S. G. Ware and C. Siler, “Sabre: A narrative planner supporting intention and deep theory of mind,” in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.
- [52] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, “Reflexion: Language agents with verbal reinforcement learning,” in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 8634–8652.
- [53] X. Chen, M. Lin, N. Schärli, and D. Zhou, “Teaching large language models to self-debug,” in *The Twelfth International Conference on Learning Representations (ICLR)*, 2024, accepted poster; the OpenReview forum is the archival record (no publisher DOI), verified 2026-09-03; preprint arXiv:2304.05128.
- [54] A. Solar-Lezama, L. Tancau, R. Bodik, S. Seshia, and V. Saraswat, “Combinatorial sketching for finite programs,” in *Proceedings of the 12th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*. ACM, 2006, pp. 404–415.
- [55] Y. Huang, G. Chen, J. Yao *et al.*, “Beyond state consistency: Behavior consistency in text-based world models,” 2026, preprint; no archival venue or publisher DOI verified as of 2026-09-03.