TRACE-RPG: 대화형 게임의 감사 가능한 제안-커밋 경계와 출처 결속 읽기 전용 온톨로지 관측

정장영 [1], 강신진 [2,*]
[1] 홍익대학교 게임학과 (제 1 저자)
[2] 홍익대학교 교수 (교신저자)
[*] 교신저자

***Abstract*—스키마에 부합하는 게임 내 행동 제안이라도 접근할 수 없는 물체를 요구하거나 현재 시점에서 공개할 수 없는 사실을 포함할 수 있다. 본 논문은 스키마 적합성, 상태 상대 권한, 목표 달성을 엄격히 구분하는 TRACE-RPG 의 제안–커밋 경계를 정의한다. 생성 모델은 구조화된 후보만을 제안하고, 외부의 결정론적 게이트가 행동 정책, 선행조건, 도달 가능성, NPC 지식, 정보 공개, 퀘스트 단계 제약을 검사한다. 게이트는 제한된 반례 유도 수리 이후에도 동일한 행동 전 상태에서 후보를 재검증하며, 해시 연결 기록과 의미적 리플레이를 통해 커밋 및 보류의 근거를 보존한다.**

별도의 오프라인 감사는 유한 그래프 32 개 상태와 후보 변형 13 종을 교차해 네 실행 조건에서 평가했다. 스키마 전용 조건은 기준상 무효인 최종 후보 260/416 건의 커밋을 허용한 반면, 세 의미 검증 조건은 모두 0/416 건을 기록했다. 반례 유도 수리는 최초 무효 후보 260 건 가운데 128 건을 유효하게 수리해 커밋했고, 나머지 132/416 건은 보류했다. 또한 최초 유효 사례 156/156 건과 고유한 구조 서명 11/11 종을 모두 보존했으며, 도달 가능성 폐쇄 연산과 너비 우선 탐색 (BFS) 비교도 32/32 건에서 일치했다. 별도의 표면 센티널 검사에서는 세 의미 검증 조건 모두 미선언 우회 표현 6/6 건을 통과시키고 금지 사실이 명시된 후보 6/6 건을 보류함으로써, 구조화된 권한 검사와 자연어 함의 검사의 경계를 드러냈다. 이 결과의 범위는 저작된 유한 사례와 구현을 분리한 기준 검사에 한정되며, 창의성, 자유 언어 안전성, 또는 언어 모델과 사람의 효능을 입증하지는 않는다.

***Index Terms*—게임 인공지능, 인터랙티브 내러티브, 기호 검증, 제약 생성, 재현성**

I. 서론

게임 속 관리인이 비밀을 알고 있다고 해서 지금 바로 플레이어에게 말할 권한까지 생기지는 않는다. JSON 형식에 맞는 퀘스트 제안이라도 잠긴 방 안의 열쇠를 요구할 수 있으며, 허용된 관찰 행동이라 하더라도 게임 목표를 달성하지 못할 수 있다. 서사적 개연성이나 퀘스트 · 개체 정합성 (grounding) [1], [2] 과는 별개로, 게임 시스템은 현재 상태에서 어떤 행동과 정보 공개가 허용되는지를 판정해야 한다.

TRACE-RPG 은 이 문제를 제안 권한과 상태 변경 권한의 분리로 다룬다 (그림 1). 생성 모델은 구조화된 후보만 제출하며, 외부에서 저작한 정책에 기반한 결정론적 게이트만이 상태 커밋을 승인한다. 검증에서 반환된 오류 정보는 후보 수리를 안내할 뿐 상태 변경 권한을 부여하지 않는다. 게이트는 수리된 후보 역시 동일한 행동 전 상태에서 다시 검사하며, 재검증을 통과하지 못하면 상태를 변경하지 않는다. 읽기 전용 한 · 영 온톨로지 관측 모듈은 어떤 선언과 규칙이 각 결정에 연결되는지를 가시화한다.

이 논문은 스키마 적합성, 상태 상대 권한, 목표 달성을 구분하는 실행 계약과 근거 설계를 제시한다. v5 수집의 배정 20 건에서 응답 수신, 파싱 실패 10 건, 게이트 통과 8 건, 목표 달성 7 건은 서로 다른 검증 단계의 결과다. 동결된 공개 사례의 60/60 건 결정 일치는 온톨로지 관측을 추가했을 때 기존 판단에 회귀가 없었음을 보이는 근거로 한정한다. 새로운 결정론적 감사는 실제 스키마 전용 대조군, 구현을 분리한 기준 검사, 과잉 거부와 구조 서명 보존, 그리고 자연어 표면 경계를 동일한 동결 입력 위에서 구분해 평가한다 (V-B절).

TABLE I
기여, 선행 주제, 근거 레인, 추론 상한 (구조화 매트릭스에서 생성)

ID	기여	선행 주제 (참고 문헌 수)	레인	추론 상한
C1	신뢰경계 contract	T1, T2, T3 (17)	E1, ENG1	인코딩 필드 계약 적합성
C2	validate–repair–commit controller	T1, T8 (14)	E1, ENG1	동결 사례의 메커니즘 동작
C3	감사 연결 근거 계층	T4, T7, T8 (6)	E1, ENG1	명명 fixture 의 무결성 · 재생
C4	assignment-complete harness	T1, T4, T6, T7 (20)	E1	설계 사례 정확 집계
C5	반례 유도 연산자 ρ	T1, T8, T9 (8)	E1	동결 offline repairability class

T1 = 근거 게임 세계; T2 = 검색 · 메모리 에이전트; T3 = 구조 생성; T4 = 환경 · 벤치마크; T5 = 플레이어 경험; T6 = 인간 ·LLM 평가; T7 = 통계 · 재현성; T8 = 계획 · 런타임 개입; T9 = 피드백 수리. 레인은 표 V에 정의한다. 모든 행은 구현 · 작성 fixture 검증 상태이며 어떤 효능 claim 도 지지하지 않는다.

표 I은 **C1—계약**, **C2—검증 및 수정**, **C3—무회귀 감사 바인딩**, **C4—배정 계수**, **C5—수정 안내** 각각의 근거와 추론 한계를 정리한다.

II. 관련 연구와 연구 공백

선행 정합성 (grounding) 및 서사 개연성 연구는 퀘스트와 개체의 연결, 그래프 기반 퀘스트 구조, 기억–성찰–계획 아키텍처, 학습형 역할 수행을 주로 다룬다. 또한 플레이어 대화 및 역할 에이전트 연구는 행동의 허용 가능성 (admissibility) 과 경험적 품질을 구분하여 다룬다 [1], [2], [3], [4], [5], [6], [7], [8]. 반면 몰입도 및 정서 (affect) 평가는 향후 연구 과제이며 현재 구현이나 상태 변경 권한에는 포함되지 않는다 [9], [10], [11]. 본 논문은 출처가 결속된 제안–커밋 (proposal-to-commit) 경로에서 상태 변경 권한, 수리 안내 정보, 리플레이 근거를 어떻게 분리해 구조화할지 다룬다. 이는 선행 연구에 이러한 구성 요소가 부재하다는 주장이 아니다.

TextWorld 와 ScienceWorld, MineDojo, GVGAI, AgentBench, AgentBoard, SOTOPIA, BALROG 및 자동 플레이테스팅 연구는 상태 기반 평가, 체화 환경, 에이전트 및 게임 콘텐츠 검증, 실행 과정, 사회적 상호작용, 장기 과업 환경을 폭넓게 다룬다 [12], [13], [14], [15], [16], [17], [18], [19], [20]. 한편 NCP-Bench 는 플레이어의 최종 성과가 아니라 서사적 일관성과 사실 정합성을 평가한다 [21]. 본 연구는 구조 제약, 비평가 (critic), 행위 가능성 (affordance), 트리거 규칙, 선행조건과 효과, 규칙 정제, 점진적 검증, 저작된 상태 변환, 그리고 JSONSchemaBench 에 관한 선행 기법들 [22], [23], [24], [25], [26], [27], [28], [29], [30], [31], [32], [33] 을 참조하나

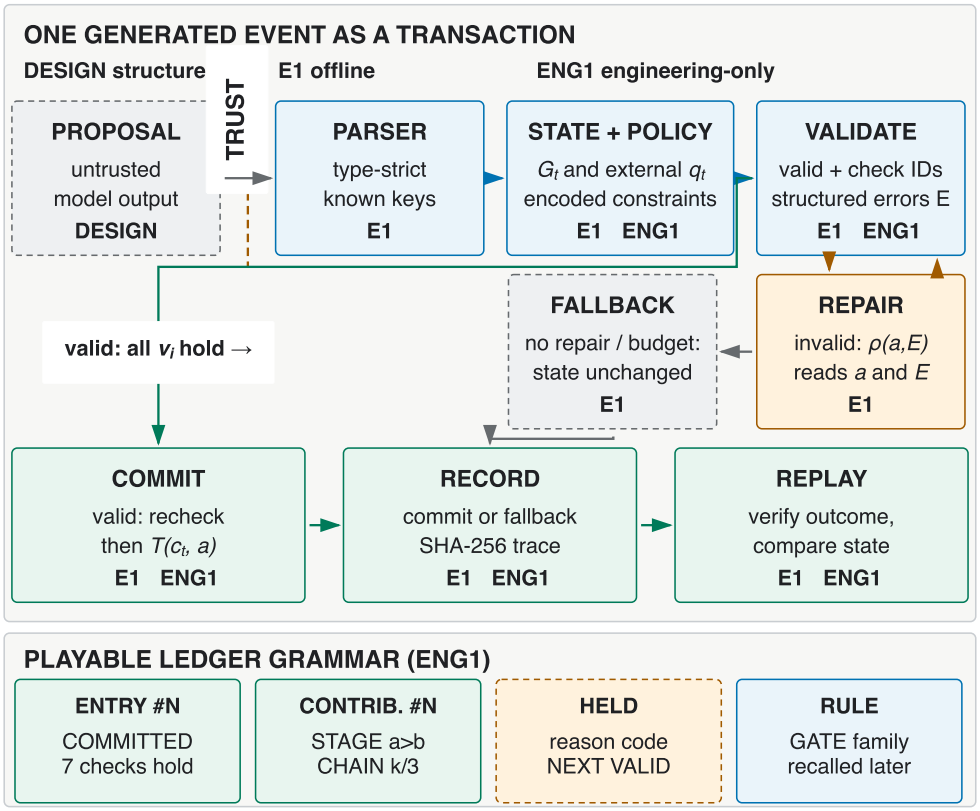


Fig. 1. 외부 정책과 c_t 가 제안의 허용 여부를 판단한다. Typed 오류는 제한된 ρ(점선) 수리나 상태 불변 fallback 으로 이어진다. 게이트는 통과 후보를 다시 검사한 뒤 commit·record·replay 한다. 과거 코호트와 legacy ENG1 은 보관한 역사 자료이며 활성 모델 근거가 아니다. 하단 strip 은 committed-snapshot ledger 문법이다.

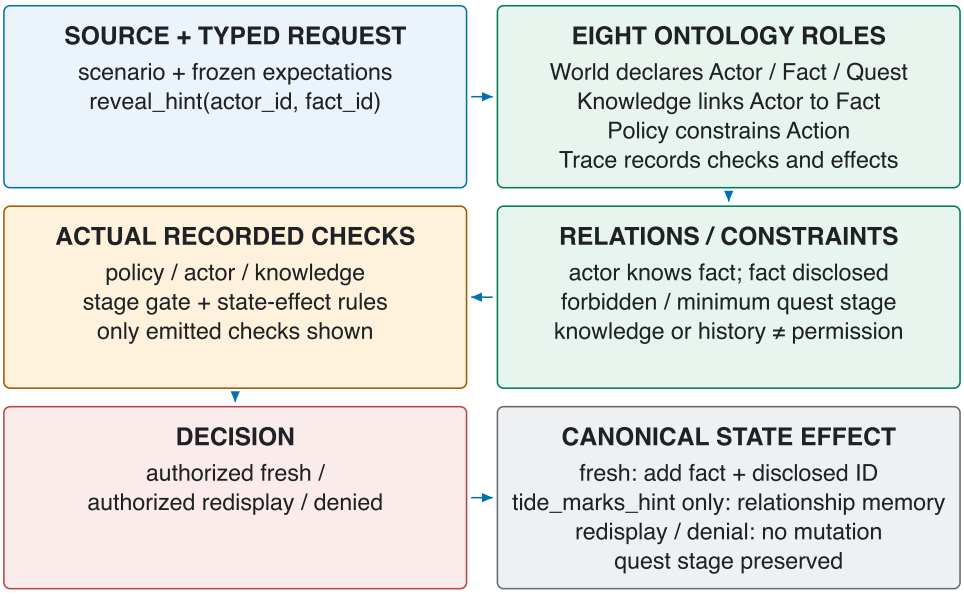


Fig. 2. 여덟 역할 온톨로지 구조 (표 III): World, Actor, Knowledge, Fact, Policy, Quest, Action, Trace 가 선언된 source field 를 저작된 검사와 관측된 결정에 연결한다. 승인된 전이만 canonical state 를 바꾸며, 도식은 live capture 나 hidden-state 근거가 아니다.

이들에 대한 우월성을 입증한 것은 아니다. 또한 G-Retriever, HippoRAG, Mem0 같은 검색 · 기억 시스템 [34], [35], [36] 역시 맥락을 제공할 뿐 상태 변경에 대한 커밋 권한은 갖지 않는다.

재현성과 평가 방법론 연구는 동결된 산출물의 보존, 실패 사례의 누락 방지, 구성 타당도와 평가자 편향의 통제, 그리고 정당화된 동등성 한계 및 무선 효과 (random effects) 반영을 요구하며 [37], [38], [39], [40], [41], [42], [43], [44], 자원 회계 보고는 에너지 · 탄소 배출 보고 연구에서 착안하였다 [45]. 리플레이와 데이터 누출 검사는 배정 분모의 무결성을 점검할 뿐 모델 효능을 입증하지 않으며, 리플레이 검증에는 최종 커밋에 이르지 못한 무효 시도도 포함된다 [46], [47]. 본 논문의 기여 C1–C5 는 기존에 확립된 규칙 강제, 게임 상태 관리, 피드백 기반 수리, 리플레이, 행위 중재, 선행조건과 효과 모델링, 트랜잭션 중단, 사회적 논리 및 신념 기반 계획 기법들을 결합한 것이며 [27], [28], [29], [48], [46], [49], [50], [51], [52], [53], [54], 개별 알고리즘의 발명이나 최초 결합을 주장하지는 않는다.

기여의 위치. 구성 알고리즘 자체의 발명이나 최초성을 기여로 삼지 않는다. 이 논문은 기존 기법들을 결합한 상태 상대 권한 계약, 출처가 결속된 수리 · 커밋 경로, 그리고 실패 사례를 누락 없이 보존하는 계수 체계를 제시한다. 새 스키마 전용 조건은 공유된 엄격 구문 분석기 (strict parser) 를 실제로 적용하는 대조 개입이며, XGrammar 실행이나 토큰 마스킹의 성능 비교가 아니다. 플랫폼 통합과 시각화 화면 구현 역시 이 계약을 관측하기 위한 공학적 산출물로 구분한다.

III. 문제 정의와 보장 경계

입력 $c_t = (G_t, q_t)$ 는 형식이 지정된 게임 상태 스냅샷 G_t 와 외부에서 저작된 행동 정책 · 공개 제한 · 퀘스트 단계 제약 q_t 를 개념적으로 구분한다. Python 구현에서는 두 요소를 모두 `WorldState` 구조에 함께 담는다. 구체적으로 장소와 도달 가능한 위치, 물체 배치, 소지품, 사실 집합, NPC 의 지식, 현재 퀘스트 단계가 인코딩된 상태를 기술하고, 행동 정책과 금지된 공개 목록이 이를 제약한다. 각 `ActionPolicy` 는 필수 선행조건, 허용 및 필수 효과, 그리고 허용된 퀘스트 단계 전이 대상을 정의한다. 이러한 구분은 개념적 역할의 분리일 뿐 Python 이 두 개의 독립 객체를 별도로 저장한다는 뜻은 아니다. 검증 술어는 직전 이력 $h_{<t}$ 나 로그로부터 `WorldState` 를 역산하지 않으며, 승인된 전이는 정책 교체 없이 스냅샷 G_t 만 갱신한다. 검색 결과, 점수, 생성 근거, 기억, 또는 향후 도입할 정서 지표는 상태 변경 권한을 부여하지 않는다.

A. 스키마, 상태 상대 권한, 목표의 구분

행동 전 상태 c_t 와 저작 정책을 고정하자. $\mathcal{S}$ 는 공유 strict parser 의 스키마를 만족하는 후보 집합이다. $\mathcal{A}(c_t)$ 는 그중 모든 인코딩된 술어를 통과한 후보, $\mathcal{G}(c_t)$ 는 인코딩된 전이 T 가 정의되는 후보 중 목표를 달성하는 후보, $\mathcal{H}(c_t)$ 는 권한과 목표를 모두 만족하는 후보로 둔다.

$$\begin{aligned} \mathcal{A}(c_t) &= \{a \in \mathcal{S} : V(c_t, a).\text{valid}\}, \\ \mathcal{G}(c_t) &= \{a \in \mathcal{S} : \text{Goal}(T(c_t, a))\}, \\ \mathcal{H}(c_t) &= \mathcal{A}(c_t) \cap \mathcal{G}(c_t), \\ \mathcal{H}(c_t) &\subseteq \mathcal{A}(c_t) \subseteq \mathcal{S}. \end{aligned} \tag{1}$$

마지막 포함 관계는 첫 집합의 스키마 제한과 교집합 정의에서 바로 따르며 새로운 정리가 아니다. $\mathcal{A}(c_t) \subseteq \mathcal{G}(c_t)$ 도 그 역도 일반적으로 성립하지 않는다. 단계 0 의 비밀 공개 후보는 스키마에는 맞아도 공개 권한을 얻지 못한다. 반대로 허용된 `observe` 는 사실 `observed` 만 추가하므로 유효하더라도 목표 `signal_restored` 를 달성하지 못한다. 목표 효과를 추가해도 금지 효과의 권한은 생기지 않는다. 이 집합 관계는 인코딩된 상태와 정책, 전이 정의에 조건부로 성립하며 모든 자연어 의미를 포괄하지는 않는다.

NPC 의 지식 보유는 사용하거나 공개하려는 사실을 NPC 가 알고 있는지를 가리키고, 공개 권한은 현재 퀘스트 단계와 정책이 그 사실의 공개를 허용하는지를 가리킨다. 새 감사에서 `keeper` 의 지식은 단계 0 과 1 에 걸쳐 같지만, `keeper_secret` 의 공개는 단계 0 에서 금지되고 단계 1 에서 허용된다. 따라서 이미 알려진 참인 사실이라도 현재 단계에서는 공개할 수 없을 수 있다. MBTI 성격 정렬, 말투, 정서, 선호도 및 검색 점수는 별도의 연성 신호에 속한다. 이들은 엄격한 검증 집합 $\mathcal{A}(c_t)$ 를 완화하거나 거부된 행동을 승인하지 않으며, MBTI 설문 정렬만으로 NPC 말투의 안정성이나 정서적 편익을 추론할 수도 없다.

신뢰할 수 없는 모델의 제안 a_t 가 엄격 구문 분석을 통과하면 검증기는 일곱 개의 결정론적 술어를 평가하여 `ValidationResult(valid, errors, checks_run)` 을 반환한다. 반환값은 다음과 같다.

$$\begin{aligned} V(c_t, a_t) &= (\text{valid}, E_t, C_{\text{run}}), \\ \boldsymbol{v} &= (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, \\ &\qquad v_{\text{disc}}, v_{\text{elig}}, v_{\text{stage}}) \in \{0,1\}^7, \end{aligned} \tag{2}$$

여기서 E_t 는 오류 코드, 대상 개체, 사유, 수리 힌트를 담은 구조화된 오류 목록이고, C_{run} 은 실행된 일곱 개 검사의 식별자 목록이다. 또한 $\text{valid} \equiv \bigwedge_{i=1}^{7}(v_i = 1)$ 은 행동 정책, 선행조건, 도달 가능성, NPC 지식, 금지 공개, 단계 적격성, 단계 단조성의 일곱 잠재 술어 결과를 모두 만족하는 논리곱을 뜻한다. 런타임 계약이 일곱 개의 개별 불리언 값 대신 통합 `valid` 플래그와 실행 검사 ID 목록을 반환하므로, 검사별 추적 기록이나 필드가 누락된 경우에는 통과나 실패가 아닌 미관측 상태로 처리한다. 다음 식은 최초 제안의 전체 트랜잭션이 아니라 현재 단일 후보에 적용되는 게이트다. 여기서 a_t 는 수리를 거쳐 수정될 수 있는 현재 후보이며, $\boldsymbol{v}$ 는 변경되지 않은 c_t 에 대해 해당 후보를 검사한 결과다. 검증에서 거부된 시도는 c_t 를 바꾸지 않고 제한된 수리나 상태 불변 대체 경로 (fallback) 로 넘어가며, 동일 정책에 대한 재검증을 통과한 경우에만 상태 변경이 허용된다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_{i=1}^{7}(v_i = 1), \\ c_t, & \text{그 외.} \end{cases} \tag{3}$$

실제 실행 경로는 후보 제안 → 결정론적 검증 → 유효성 · 검사 ID· 구조화 오류 관측 → 선택적 제한 수리 → 동일 상태 재검증 → 커밋 또는 상태 불변 대체 경로 순으로 진행된다. 검증을 통과한 후보 역시 상태를 갱신하기 직전에 다시 검사하며, 수리기가 없거나 수리 예산이 소진되면 상태는 변경되지 않는다. 아래의 반례 유도 수리 연산자는 후보 제안과 오류 정보만 입력받지만, 일반 Python 수리 콜백에는 `WorldState` 도 함께 전달되므로 이러한 입력 제한을 모든 콜백의 보편적 성질로 일반화할 수 없다. 통제된 실험 비교에서는 결정론적 상세 수리 조건과 모델 기반 상세 수리 조건에 동일한 후보 제안과 상세 오류를 제공하고, 동일 모델의 일반 오류 조건에는 간략한 일반 거부 신호만 제공한다. 다만 이 실험 설계 자체가 특정 비교 우위를 의미하지는 않는다.

TABLE II
인코딩된 Validator 경계

술어	거부 대상	실패 시 상태
Action policy	알 수 없는 action/type; policy-required preconditions/effects 누락; 비허용 effects 또는 비인가 quest-stage effects	변경 없음
Precondition	누락/거짓 requirement	변경 없음
Reachability	접근 불가 object	변경 없음
NPC knowledge	사용 · 공개 사실이 행위자의 지식 집합에 없음	변경 없음
Disclosure	forbidden fact	변경 없음
Quest stage (`quest_stage`)	required stage 가 current stage 보다 높음	변경 없음
Quest-stage monotonicity (`quest_stage_monotonicity`)	regressive stage	변경 없음

TABLE III
여덟 온톨로지 역할과 구체적인 출처 관계

역할	Source 선언 또는 관계 예시
World	초기 객체 위치는 신호 렌즈를 등대 램프 보관소에 둔다.
Actor	미라 선장이 허용된 유일한 actor 다.
Knowledge	Actor 의 지식이 canonical Fact ID 를 가리킴; 지식은 허가가 아니다.
Fact	초기 사실에는 `dock_saved`, `lighthouse_dark` 가 포함되며 `keeper_betrayal` 은 ID 이지 비밀 payload 가 아니다.
Policy	공개 정책은 `keeper_betrayal` 을 금지하고 `tide_marks_hint` 에 최소 quest stage 2 를 요구한다.
Quest	초기 quest 는 stage 0, flag `dock_saved`; 공개는 stage 불변.
Action	`reveal_hint(actor_id,fact_id)` 는 Fact/disclosed ID 를 추가하며 조석 단서만 relationship memory 를 추가한다. 최초 공개는 revision $+1$; 재표시는 불변이다.
Trace	이전 · 다음 상태 hash, 규칙 ·template·case ID 가 packet 과 version 을 근거에 결속하며 누락은 PASS 가 아니다.

검증 픽스처는 수학적 정리가 아니라 다음 네 가지 구현 불변량을 시험한다. **I1:** 수리 예산이 소진되거나 커밋 이전에 제안 또는 컨트롤러 단계에서 실패하더라도 상태는 변하지 않는다. **I2:** 정상 반환되는 수리 콜백과 수리 예산 $K \in \mathbb{Z}_{\geq 0}$ 가 주어지면 최대 $K+1$ 회 시도와 커밋 전 재검증으로 횟수가 제한되나, 별도 마감 시간이 없으면 실제 경과 시간 (wall-clock) 내 종료까지는 보장하지 않는다. **I3:** 승인된 `CandidateAction.effects` 는 인가된 퀘스트 단계 전이 대상을 포함하여 모두 `ActionPolicy.allowed_effects` 범위 안에 머문다. **I4:** 기록된 초기 스냅샷, 누락 없이 순서가 보존된 전이 로그, 동결된 스키마, 그리고 결정론적 전이 규칙 버전이 주어지면 리플레이를 통해 기록된 최종 구조화 상태를 복원할 수 있다. 이는 조건부 상태 복원을 뜻할 뿐, 기록의 진위 인증이나 의미적 정확성, 또는 모델 생성 과정의 재현을 보장하지는 않는다.

이러한 불변량은 정책과 상태 추출의 정확성, 결정론적 버전 고정, 콜백의 정상 반환, 그리고 단일 프로세스의 파일 소유권을 전제로 한다. 또한 리플레이는 구조화된 상태 전이만 검증하며, 수리 과정의 출처나 프롬프트, 확률적 생성 과정, 선언되지 않은 자연어 함의까지는 검사하지 않는다.

IV. TRACE-RPG 아키텍처와 알고리즘

A. 신뢰 경계와 계약

모델과 어댑터는 행동을 제안할 뿐이며, 구문 분석기는 모호한 자료형이나 미정의 키를 거부하고 외부 정책이 선행 조건과 효과를 정의한다. 버전이 명시된 브리지는 관측 상태, 후보 제안, 검증 결과, 거부 사유, 대체 경로, 커밋 결과를 계층 간에 전달한다. 이때 미정의 키 거부 동작의 일치가 구문 분석기 전체의 동등성이나 상용 호환성을 뜻하지는 않는다. Python 계층의 일곱 개의 결정론적 검사 식별자는 `action_policy`, `precondition`, `object_reachability`, `npc_knowledge`, `forbidden_disclosure`, `quest_stage`, `quest_stage_monotonicity` 다. 반면 Godot 계층의 여섯 상태 상대 계열과 일곱 개의 DISC 규칙은 이들과 일대일로 대응하지 않으며, 하나의 `QUEST STAGE` 표시 계열이 Python 의 두 퀘스트 단계 검사를 함께 포괄한다.

읽기 전용 온톨로지 역할 매핑은 원천 선언과 동결된 기대값을 연결할 뿐, 실시간 상태를 판정하거나 권한을 추론하지 않는다. 온톨로지 뷰는 적용 규칙을 가시화하고 오류 정보는 후보 수리를 안내하지만, 실제 상태 변경 권한은 이 둘과 완전히 분리되어 있다. 표 III의 `reveal_hint(actor_id,fact_id)` 사례에서 온톨로지 뷰는 `tide_marks_hint` 와 stage-2 공개 정책을 표시하고, 반례 유도 수리 연산자는 후보 a_t 와 오류 E_t 만을 읽어 명명된 술어를 삽입하며 `WorldState` 에는 접근하지 않는다. 일곱 개 검사를 모두 통과한 후보만 전이 T 에 도달해 Godot 엔진이 최종 커밋을 수행하며, 최초 공개 시에는 상태 버전이 1 증가하고 동일 사실의 재표시에서는 변하지 않는다.

1) 무회귀 감사 바인딩 *(C3):* 여덟 역할의 읽기 전용 계약은 선언된 검사, 판단, 상태 효과, 리플레이 근거를 출처에 결속하되, 새로운 상태 변경 권한을 부여하지 않는다. NPC-DISC-1 의 동일한 동결 규칙과 60 개 사례에서 `general_rule` 과 `ontology_gate` 의 판단 결과는 60/60 건 모두 일치했고 관측된 회귀는 0 건이었다 (표 XIII–XV). 이 공학적 결과는 해당 범위에서 감사 바인딩을 추가해도 기존 결정이 그대로 유지되었음을 보여줄 뿐, 온톨로지 표현의 의미적 우월성이나 추적성 향상 폭을 입증하지는 않는다. `TR01--TR06` 루브릭은 여전히 미검증 제안 상태 (`PROPOSED_NOT_VALIDATED`) 이며 실측 점수나 추적성 비율은 산출하지 않았다.

B. 고정 목표 *NPC* 통합

`npc-goal-recovery/1.1.0` 구성에서는 Codex 가 의도 (intent) 를 제안하고, Python 계층이 공개 주장과 계획을 검증하며, Godot 엔진만이 상태 쓰기를 담당한다. 모델은 고정된 항구 복구 및 승인된 조석 단서 목표를 변경할 수 없다. 상태 쓰기 바인딩에는 세션, 에폭, 요청, 시나리오, NPC, 목표, 버전, 정책 · 설정 해시, 상태 버전 · 스냅샷 해시, 제한 시간 · 예산, 그리고 발행된 행동 정보가 포함된다. 로컬 서비스는 루프백 주소 `127.0.0.1:8768` 에서 동작하며, 허용된 브라우저 출처는 `localhost` 와 `127.0.0.1:8877` 로 제한된다.

1) NPC-DISC-1 공개 계약과 권위 경계*:* 선언 유도형 NPC-DISC-1 `reveal_hint` 의 60 개 사례는 과거 `verified-run-006` 분모를 재실행하거나 확장하지 않는다. 생성된 결과와 표 XIII–XV는 층화 구조, 바인딩 정보, 그리고 입력과 검사 간의 대응 관계를 명시하며, Godot 엔진만 서비스 바인딩을 재검증한 뒤 상태를 변경한다. 이 60 개 사례는 유한하게 저작된 상태 · 정책 픽스처일 뿐 독립적으로 표집한 NPC 대화나 실제 플레이어 시행이 아니다. 따라서 60/60 일치는 해당 픽스처 내에서의 결정 동등성을 뜻할 뿐 모집단 효능이나 일반화 성능을 보여주지는 않는다.

1: $a \leftarrow \text{Propose}(c)$; $j \leftarrow 0$
2: **repeat**
3: $(\text{ok}, E) \leftarrow V(c, a)$; $\text{Record}(a, E)$
4: **if** ok **then**
5: **assert** $V(c, a).\text{ok}$; **return** $\text{Commit}(c, a)$
6: **if** $j = K$ **then return** $\text{Fallback}(c)$
7: $a \leftarrow \text{Repair}(c, a, E)$; $j \leftarrow j + 1$
8: **until terminal**

Fig. 3. Validate–repair–commit 절차. 최대 $K + 1$ 개의 후보 시도를 기록하며 성공 경로에서는 상태 변경 전에 다시 검증한다.

TABLE IV
유도 연산자 ρ 의 오류 유형별 수정

Validator 오류 class	**후보에 대한 edit $\delta(e)$**
정책 precondition 누락	명명된 predicate 삽입
정책 effect 누락	명명된 effect 삽입
정책 effect 위반	명명된 effect 제거
불충족 precondition	명명된 predicate 제거
비인가 stage 변이	`quest_stage_effect` 초기화
알 수 없는 action type	no-op (등록된 대안 없음)
도달 불가 object; knowledge, disclosure, stage class	no-op (후보 국소 edit 은 세탁이거나 상태 지식 필요)

C. Validate–Repair–Commit

그림 3의 의사코드는 외부 의존성 없이 수리 예산 $K \in \mathbb{Z}_{\geq 0}$ 하에서의 검증–수리–커밋 절차를 정의한다. 각 시도는 먼저 메모리의 기록 버퍼에 누적되고, 최종 일관성 검사를 통과한 뒤에야 영속 저장소에 기록된다. 여기서 (ok, E) 는 검증기 V 의 결과와 $\text{ok} := \bigwedge_{i=1}^{7}(v_i = 1)$ 을 줄여 쓴 표기이며, $V(c, a).\text{ok}$ 는 커밋 직전의 재검증을 나타낸다.

수리 단계는 상태를 변경하지 않으며, 예산이 소진되면 상태를 그대로 유지하는 대체 경로를 반환한다. 형식이 지정된 오류 기반 연산자 (`counterexample_guided_repair`) 는 후보 a 와 상태로부터 도출된 유일한 입력인 오류 E 만 읽으며, 권한이 있는 `WorldState` 에는 직접 접근하지 않는다.

$$\rho(a, E) = a \oplus \bigcup_{e \in E} \delta(e), \tag{4}$$

표 IV의 결합 연산 $\oplus$ 는 오류 개체당 한 필드에 결정론적 수정 $\delta(e)$ 를 적용하며, 시도당 수정 횟수는 최대 $|E|$ 회로 제한된다. 서로 충돌하는 요구와 거부 사유에 대해서는 필드를 바꾸지 않고 유지한다. 고정점 도달은 동일한 오류 집합 E 가 반복될 때를 가리킬 뿐 수렴성을 보장하지 않는다. 한편 비배포용 상태 판독 오라클은 오류 대신 실제 상태에서 선행조건과 효과, 두 퀘스트 단계 필드를 복원하되, 필수 물체나 사용 · 공개 사실을 삭제하여 정책 위반을 은폐하지 않는다.

D. 무결성, 의미적 리플레이, 계수

서명 키가 없는 SHA-256 해시 연결만으로는 기록 주체의 신원을 인증하거나 공모에 의한 기록 재작성을 막을 수 없다. 의미적 리플레이는 직전 상태와 후보 및 검증 결과의 구문 분석, 최종 커밋에 이르지 못한 무효 시도, 최종 상태의 재계산과 일치 여부, 그리고 JSONL 로그의 연속성을 확인하지만 수리 생성 과정 자체를 재실행하지는 않는다. 요청–결정–결과 연결과 최초 발행 행동 및 단일 영수증 규칙 역시 식별자 중복이나 사칭을 방어하지는 못한다. 종단 결과 유형은 커밋, 기호적 대체 경로, 어댑터 실패, 컨트롤러 실패로 구분하며, 실패 유형은 완

TABLE V
기존 보존 실험 레인 요약: 설계, 단위, 비교, 추론 상한 (실험 매트릭스에서 생성)

레인	**설계**	**단위 / 예산**	**비교**	**상한**
E1	오프라인 적합성: 작성 · 동결 fixture, 단일 world	gate 13; arm 당 repair 12; fault 10; adapter 7; guard 3	reject / blind / ρ / oracle	메커니즘 적합성
E3	KG/온톨로지 시뮬레이션: closed-world typed-link holdout	node 43; 참조 edge 106; typed 24; score 210	degree baseline / 고정 전략 6 종	구성 결과만
ENG1	Engineering-only Godot/Web: 엔진 로컬 policy mirror, 참여자 없음	fixture 4; check 52; 정의된 smoke 술어 8; archetype 5	작성 fixture 경로	엔진 로컬 engineering-only 적합성

이 표는 기존 E1/E3/ENG1 패킷을 요약한다. 신규 그래프 감사의 arm 당 416 건과 별도 표면 sentinel 의 arm 당 12 건은 절 VI-D에서 독립 분모로 보고한다. E1, E3, ENG1 은 서로 대체할 수 없으며 분모가 다르다. 역사적 E2 receipt 는 활성 생성에서 제외된다. 어떤 활성 레인도 모집단 효능, 모델 순위, 플레이어 경험, 런타임 검색 효익, 상용 엔진 성능을 확립하지 않는다.

성된 제안 추적 없이도 상태와 배정 정보를 보존한다. 실행 전 키는 실행 단위, 실험 조건, 시나리오, 시드, 모델, 리비전, 그리고 설정 · 입력 · 이전 상태 해시를 하나로 결속하며, 집계 단계에서는 중복 · 누락 · 미정의 키를 거부하거나 별도로 분리한다.

재현의 두 계층. 첫째는 보존된 구조화 입력과 영수증을 이용한 스키마 · 의미 게이트 재검증 및 결정론적 상태 리플레이다. 이 계층은 기록이 지지하는 판정과 전이를 확인하며, 보존하지 않은 제공자 응답 원문이나 생성 과정까지 복원하지는 않는다. 둘째는 제공자에 다시 접속해 원래 모델 응답을 재수집하는 계층이다. 여기에는 실제 제공 모델의 동일성과 리비전 확인, 호출 허가와 비용, 동결 프로토콜의 편입 요건이 별도로 필요하다. 이번 추가 검증에서는 제공자 응답 재수집을 수행하지 않았다. 바이트 동일성은 실제로 고정 · 검증한 소스와 도구체인의 해당 산출물에만 적용되며, 모든 실행 환경에서 모든 출력이 100% 동일하다는 주장이 아니다.

V. 실험 레인과 근거 경계

세 수준의 근거는 서로 합산하지 않는다. Level 1 은 저작된 유한 사례에 대한 메커니즘 · 적합성 검사로, 기존 E1 게이트 및 수리 가능성 픽스처와 별도의 32 개 상태 · 조건별 416 개 배정 경계 감사를 포함한다. Level 2 는 저작된 폐쇄 세계 구성 시뮬레이션 (E3 의 그래프 간선 은닉 목표 6 개) 이며, Level 3 는 기존 NPC 적합성 검사 (ENG1, NPC-ENG1, NPC-SCR1) 와 범위를 제한한 단일 개발 보조 관측 (DEV-CASE) 으로 구성된다. Level 1 의 기존 E1 과 새 감사는 분모가 서로 다른 별개 코호트이므로, 새 감사를 기존 단일 월드 E1 의 다중 월드 확장 결과로 재해석해서는 안 된다. 각 수준에서는 실패 사례와 구버전 통제군 (stale control) 결과를 누락 없이 보존하며, 이들은 서로 다른 질문에 답할 뿐 모델 능력이나 효능의 추정치가 아니다.

A. *E1* 오프라인 적합성 설계

PQ1–PQ5 검증 항목은 상태 불변성, 고정된 오류 유형의 수리, 체크섬 · 의미 · 연결 · 연속성 결함 탐지, 중복 추가 시의 롤백, 실패 시 차단 (fail-closed) 방식의 배정 · 어댑터 · 매니페스트 회계, 그리고 제안 및 리플레이 단계에서의 미정의 키 거부를 시험한다.

게이트 픽스처는 13 개 (유효 1 개, 음성 12 개) 이고 수리 픽스처는 12 개다. 모든 실험 조건에서 사례는 오류 정보만으로 수리 가능한 *guided-repairable*, 상태 판독이 필요한 *oracle-only*,

커밋이 불가능한 *irreparable* 로 구분한다. 지연 시간과 토큰 수치는 자원 회계 점검용 상수이지 모집단 성능이나 탐지기 성능 지표가 아니다. 증거 패킷은 픽스처, 배정, 스키마, 결과, 코드를 하나로 결속한다 [38], [45]. E1 의 수리 예산은 조건별로 다르다. `rejection_only` 는 $K = 0$ 이고, `unchanged_retry`, `guided_repair`, 상태 판독 오라클 `structured_repair` 는 각각 $K = 1$ 이다. 따라서 네 조건 모두를 동일한 $K = 1$ 비교로 해석해서는 안 된다. E1 의 의미적 음성 픽스처 12 개는 모두 후보 계약의 구문 분석을 통과한 뒤 의미 검사에서 거부되었다. 따라서 같은 후보에 스키마 경계만 적용했다면 거부 건수는 0/12 건이었을 것이다. 이 0/12 건은 저장된 후보와 검사 결과, 그리고 구문 분석기의 선행 순서에서 도출한 반사실적 대조치이며, 별도로 실행해 측정한 스키마 전용 절제 실험 결과가 아니다.

B. 동결된 오프라인 경계 감사

별도 감사의 기준이 되는 동결 프로토콜은 `research/academic-pipeline/gemini-review-20261113/protocol-v2.json` 이다. 이 감사는 설계자가 작성한 유한 사례의 결정론적 전수 열거이며 모델이나 참가자를 호출하지 않는다. 방 수 2 종 (4 개와 8 개), 연결 형태 2 종 (잠금 사슬과 우회 분기), 두 열쇠의 시작점 · 목표점 배치 4 종, 퀘스트 단계 2 종 (0 과 1) 을 교차해 32 상태를 구성한다. 정상 행동과 정책 · 선행조건 · 효과 · 물체 · 지식 · 공개 · 단계 경계를 다루는 13 종의 후보 변형을 적용하므로 조건별 배정 분모는 $32 \times 13 = 416$ 이다. 반복 표본이나 난수 시드는 추가하지 않는다.

그래프는 `rooms`, `start`, 열쇠 요건을 가진 양방향 `edges`, 물체 `placements` 를 명시한다. 시작 방은 r_0, 목표 방은 r_{n-1} 이며, 사슬의 중간 방 진입과 목표 방 진입에는 각각 `key0`, `key1` 이 필요하다. 우회형에는 시작 방과 중간 방 사이의 무잠금 간선을 추가한다. 지도는 시작점, 유물은 목표점에 놓인다. 방문한 방에서 얻은 열쇠는 계속 보유하고 재사용한다. 이 유한 무방향 그래프에는 소모품, 무작위 전이, 동적 간선, 용량 제한, 비가역 분기가 없다. 이 감사의 도달 가능성은 이 프로파일에 한정되며 전체 게임의 플레이 가능성을 뜻하지 않는다.

네 조건은 같은 후보에 서로 다른 실행 경로를 적용한다. `schema_only`($K = 0$) 는 공유된 엄격 구문 분석기만 거쳐 의미 게이트 없이 격리된 연구 시뮬레이터에 효과와 단계를 적용한다. `semantic_rejection`($K = 0$) 은 의미 검증 후 수리 없이 거부한다. `unchanged_retry`($K = 1$) 는 같은 후보로 다시 시도하고, `guided_repair`($K = 1$) 는 기존 반례 유도 연산자 ρ 를 사용한다. E1 과 달리 새 감사에는 상태 판독 오라클 수리 조건이 없다.

기준과 평가 시점. 실행 경로는 별도로 구현한 단조 폐쇄 연산으로 `WorldState.reachable_locations` 를 계산하며 물체 이름이나 서술문에서 연결을 추측하지 않는다. 기준 모듈은 표준 라이브러리만 사용하여 (현재 방, 수집한 재사용 열쇠 집합) 에 대한 너비 우선 탐색 (BFS) 을 수행하고 기존 일반 규칙 판정식을 분리해 평가한다. 기준 모듈은 운영 검증기, 런타임, 수리, 폐쇄 구현을 가져오거나 호출하지 않는다. 최초 후보와 수리 후 최종 후보는 모두 동일한 불변의 행동 전 기준 상태에서 평가한다. 이 상태와 실행 경로의 행동 전 상태는 BFS 로 산출한 도달 가능 위치만 다르다. 목표 달성 여부는 커밋 후 결과 상태에서 별도로 판정한다. 이 비교는 구현 분리를 통한 교차검사일 뿐 독립적이고 블라인드된 정답 기준이나 사람의 의미 판단은 아니다.

퍼널과 분모. 전체 배정 $N = 416$, 기준상 최초 무효 N_I, 최초 유효 N_V, 커밋 N_C 를 구분한다. 게이트 전 위반율은 N_I/N 이다. Repair@1 은 최초 무효 중 최종 후보가 기준상 유효하게 커밋된 수를 N_I 로 나누며 $K = 0$ 대조군도 계수를 남긴다. 종단 보류와 목표 달성은 각각 전체 N 을 분모로 한다. 비안전 커밋은 최종 후보가 기준상 무효인 커밋이며 N 대비와 N_C 대비를 따로 보고한다. 오거부 (false rejection) 는 최초 기준 유효 후보 가운데 보류된 건수를 N_V 로 나눈 값이다. 실행 실패는 보류나 유효 판정으로 바꾸지 않고 별도 실패 배정으로 남긴다.

정확한 구조 서명 보존은 최초 기준 유효 사례의 서로 다른 서명 가운데 안전한 커밋에서도 동일하게 유지된 서명 수를 최초 서로 다른 유효 서명 수로 나눈 비율로 정의하고, 사례 단위 보존도 함께 보고한다. 서명은 행동 유형, 선행조건, 효과, 필수 물체, 사용 · 공개 사실, 요구 단계와 단계 효과를 포함하며, 식별자, 서술문, 메타데이터, 위치명, 그래프 표지는 제외한다. 최초 무효 서명 수와 수리 후 유효 커밋 서명 수는 따로 센다. 이 척도는 규칙상 허용된 구조의 보존을 측정하며 어휘 다양성, 창의성, 재미는 측정하지 않는다.

짝지은 표면 센티널. 본 감사와 분모를 분리해 단계 0 에서 비밀의 고정 우회 표현 6 개 (영어 3 개, 한국어 3 개) 를 작성한다. 각 문장을 `disclosed_facts` 가 비어 있는 후보와 비밀 ID 를 명시한 후보에 짝지어 조건별 12 건을 배정한다. 두 후보의 차이는 구조화된 공개 선언뿐이며 서술문은 같다. 이 설계는 구조화 게이트의 미선언 자연어 함의 검출 범위를 점검하고 서술문 자체가 사실이나 단계를 직접 바꾸지 않는지도 확인한다. 자유 언어 누출의 발생률이나 렌더러 수준 안전성, 자연어 추론 (NLI) 기반 검출 성능은 측정하지 않는다.

실행 전 정확한 입력, 배정 목록, 입력 · 소스 해시를 새 결과 디렉터리에 동결한다. 모든 배정에는 후보, 검사, 수리, 최종 상태, 실행 전후 해시, 생성된 경우의 네이티브 리플레이, 실패 여부, 그리고 로컬 경과 시간을 기록한다. 모델 호출은 수행하지 않으므로 모델 리비전, 시드, 비용은 모두 `null` 이다. 로컬 경과 시간은 언어 모델의 지연이나 상용 성능으로 해석하지 않는다.

C. 보존된 *live-screening* 자료

보존된 라이브 스크리닝 자료는 변경하지 않는 출처 및 해시 기록에 해당한다. 이 자료는 활성 표와 집계, 본문 주장에서 제외하며 `gpt-6.1-sol` 로 이전하지 않는다.

D. NPC-ENG1/NPC-SCR1: 88 개 배정*, 28* 개 정의

안정화 (stable) v5 모음은 **NPC-ENG1** 공학 배정 16 개와 **NPC-SCR1** 스크리닝 레시피 12 개 ($12 \times 2 \times 3 = 72$; 전체 합계 $R/P/O = 40/24/24$) 로 초기 구성을 만들고 신원 · 해시 결속, 의도 · 계획 · 역할 · 결과 처리, 음성 · 구버전 · 중복 · 시간 초과 사례, 그리고 리플레이를 시험한다. 여기서 P 는 대체 경로 없는 인증된 Codex OAuth 를 사용하며, O 는 100% 보조 출처 (auxiliary-source) 일 뿐 독립적인 정답 기준 (gold) 이 아니다. `verified-run-006` 기록은 상태, 계수, 지연 및 재현 정보를 보존하며 002/003/004 는 과거 이력 자료다. ENG-X01/SCR-X01, D02/QA-001, C-RESULT, Frozen8/Frozen16, v1–v4, `native012` 는 C6 의 근거가 아닌 출처 기록이다.

E. ***E3*** *KG/*온톨로지 링크 제안 시뮬레이션

E3 는 저작된 폐쇄 세계에 대한 공학적 시뮬레이션일 뿐 상태 변경 권한을 갖지 않는다. 그래프 간선이 은닉된 6 개의 저작 목표는 고정된 7 가지 선택 · 요약 전략을 채점하고 비교하는 데 쓰이며, 미접촉 (untouched) 시험이나 외부 평가 데이터셋이

TABLE VI
동결된 타입 링크 holdout 에서의 시뮬레이션 전용 제안 전략 평가

전략	정밀도	재현율	MRR	Brier	Sem@3
S0 degree baseline	0.000	0.000	0.282	0.315	0.556
S2 typed-lexical	1.000	1.000	0.944	0.131	1.000

TABLE VII
E1 오프라인 적합성: 수리 가능성 class 별 정확 count (설계 fixture)

Arm	정보원	Commit / 사례			평균 수정 [e]
		G-rep.[f]	O-only[f]	Irrep.[f]	필드 수
Rejection-only (K=0)	없음	0/5	0/1	0/6	—
블라인드 retry	없음	0/5	0/1	0/6	—
Validator-error-guided ρ	오류 집합 E	5/5	0/1	0/6	1.0
상태 판독 oracle	권위 상태 + 정책	5/5	1/1	0/6	1.0

[e] Commit 된 수리의 변경 candidate field 평균 개수 (최소성 proxy); 실패한 arm 실행은 상태를 변경하지 않았다. E1 은 처음부터 invalid 한 12 개 설계 case 를 사용하며 rejection-only/blind 는 0/12, 0/12, validator-error-guided ρ 는 5/12, state-reading oracle 은 6/12 commit 이다. [f] Commit/사례 수. G-rep. = guided-repairable, O-only = oracle-only, Irrep. = irreparable(동결 repairability class); 모집단 효능이나 live-model 품질을 뜻하지 않는다.

TABLE VIII
E1 오프라인 적합성: 동결 파일럿 검사와 종단 결과 (행 간 직접 비교 불가)

검사 또는 종단군	정확 결과	해석 범위
게이트 fixture 일치	13/13	저자 oracle 일치
알려진 경계 허용	2/2	인코딩 한계, safety pass 아님
닫힌 unknown-key 거부	1/1	proposal/replay parser parity
탐지 가능 무결성 결함 거부	10/10	지정된 검사 연산
알려진 provenance 경계 허용	1/1	repair 생성 출처 미인증
Adapter 종단 class	1 commit; 1 fallback; 5 실패 / 배정 7	배정 7 건의 분류 완전성
Manifest guard 거부	3/3	주입 결함 fail-closed

행마다 분모와 성공 방향이 다르므로 비율처럼 순위를 비교하지 않는다. 모든 값은 설계 픽스처의 정확한 감사 사실이다.

아니다. **범위.** 이 표는 설계된 closed-world 링크 복원 결과이며 런타임 KG 검색, 의미 완전성, 장기 모순 감소 또는 어떤 효능 주장의 근거도 아니다. 결정론적 방법론 그래프는 graph node 43 개, reference edge 106 개, curated typed edge 24 개를 포함하며 온톨로지 검사를 모두 통과한다. 생성된 표는 시뮬레이션 구성 결과를 보고할 뿐, OWL/SHACL 적합성이나 런타임 검색 성능, 의미적 완전성 또는 효능을 확립하지 않는다.

VI. 파일럿 결과

A. 구조 필드 게이트 적합성

loader 는 valid control 1 개와 구현 validator code 별 1 개 고립 fixture 만 허용한다. 따라서 13/13 일치와 12 개 implemented code 관찰은 하니스 구성 불변량이지 성공률이 아니다. 음성 fixture 12 개는 작성된 기대 code 와 일치해 다른 code 가 아니었고 비 commit 경로는 정준 상태를 보존했다. 이는 단일 world state 의 structured-field oracle conformance 이며 독립 semantic-label 정확도가 아니다.

B. 설계 픽스처에서의 수리 *arm* 비교

12 개 initially invalid case 의 frozen class 는 guided-repairable 5 개, oracle-only 1 개, irreparable 6 개다. Rejection-only 와 blind unchanged-candidate retry 는 각각 0/12 commit. validator-error-guided ρ 는 같은 class 순서로 5/5, 0/1, 0/6 를 commit 하고 평균 1.0 개 field 를 수정했다. 직전 candidate 와 typed validator error E 만 읽는 ρ 에서 error 가 유일한 state-derived input 이며 실패 arm 은 정준 상태를 보존한다. State-reading reference callback 은 같은 순서로 5/5, 1/1, 0/6 를 commit 했다. Blind 는 error 를 commit 으로 못 바꾸고, ρ 는 payload-sufficient 만, oracle 은 state-knowledge case 까지 바꾼다. commit 된 guided case 5 건이 처음 받은 validator code 는 각각 `POLICY_PRECONDITION_OMISSION+UNSATISFIED_PRECONDITION`, `POLICY_EFFECT_OMISSION`, `POLICY_EFFECT_VIOLATION`, `UNSATISFIED_PRECONDITION`, `POLICY_QUEST_STAGE_EFFECT_VIOLATION` 이며, 각 case 는 표 IV의 해당 edit $\delta(e)$ 만으로 유효해졌다. Frozen-fixture conformance 이지 live-model repair quality 가 아니다.

C. 무결성, 경계, 배정 회계

Prespecified detectable fault 10 개는 designated check 에서 모두 거부됐다 (10/10); stable typed detector-code 비교가 없어 detector attribution 은 없다. Provenance boundary fixture 는 같은 recorded valid repair 앞의 invalid precursor 를 바꾸고 checksum 을 재계산해 replay 를 통과했다 (1/1 미검출): replay 는 repair generation 을 인증하지 않고 unkeyed checksum 재계산 작성자를 막지 못한다. 두 open sentinel—unextracted narrative disclosure 와 required object 의 candidate·policy 동시 누락—은 encoded layer 에서 허용됐다 (2/2); safety pass 0 건. Former unknown-top-level acceptance 는 closed regression 이 되어 proposal·replay parser 가 unknown key 하나의 완전한 12-field candidate 를 거부했다 (1/1); parser rejection parity 이지 semantic safety 가 아니다. 7 개 assignment: commit 1, symbolic fallback 1, adapter failure 5; synthetic telemetry 는 2/7 에서 populated·propagated 됐다 (schema-pinned accounting, not measurement). injected 중복 · 누락 assignment guard 3/3 는 fail closed 했고, 모두 synthetic offline fixture raw count 다.

D. 오프라인 경계 감사의 결과 계수

V-B절의 동결 입력을 실행한 결과, 조건별 416 개씩 총 1,664 개 본 배정이 모두 종단 결과를 남겼고 실행 실패는 없었다. 각 조건의 최초 기준 무효는 260/416, 유효는 156/416 이었다. 스키마 전용 조건은 416 개를 모두 커밋하여 최종 기준 무효 커밋 260/416 을 남겼다. 의미 거부와 변경 없는 재시도는 각각 260/416 을 보류하고 최종 무효 커밋은 0/416 이었다. 유도 수리는 최초 무효 후보 중 128/260 을 유효 후보로 수리하여 커밋했고, 132/416 을 보류했으며 최종 무효 커밋은 0/416 이었다. 유도 수리는 최초 무효 후보를 일괄 폐기하지 않았다.

유도 수리의 유효 커밋은 284 개, 목표 달성은 전체 배정 중 252/416 으로 서로 달랐다. 스키마 전용 조건의 목표 달성 352/416 은 권한 적합성을 뜻하지 않는다. 네 조건 모두 최초 유효 사례의 오거부는 0/156, 사례 보존은 156/156, 정확한 구조 서명 보존은 11/11 이었다. 유도 수리는 최초 무효 서명 17 종에서 수리 후 유효 커밋 서명 2 종을 남겼다. 이 계수는 이 설

계 사례의 구조 보존이며 창의성이나 언어 다양성의 보존율이 아니다. 별도 폐쇄 연산과 BFS 의 교차검사는 32/32 일치했다.

본 배정과 구분한 조건별 12 개 표면 센티널에서, 세 의미 검증 조건은 각각 미선언 우회 표현 6/6 건을 커밋하고 명시된 금지 공개 6/6 건을 보류했다. 스키마 전용 조건은 양쪽을 모두 커밋했다. 이는 구조화된 선언 검사의 알려진 범위를 드러내며 자유 언어 누출 빈도나 렌더러 안전성을 추정하지 않는다. 아래 표의 분모별 계수는 `research/academic-pipeline/gemini-review-20261113/results-v2/summary.json` 의 관측값으로 생성했으며 기존 E1, NPC-DISC-1, v5 또는 차단된 전향 파일럿의 분모에 합산하지 않는다. 본 배정 1,664 개는 같은 저작 상태 · 후보를 네 조건에 교차한 결정론적 행렬이며 독립 확률 표본 1,664 개가 아니다. 별도 표면 배정 48 개도 고정 우회 표현의 짝지은 경계 검사이므로 본 배정과 합쳐 표본 크기나 통계적 일반화의 근거로 쓰지 않는다.

도달성 구현 교차검사: 32/32. 표면 문장은 설계자가 작성한 센티널이며 자연어 누출 빈도나 렌더러 안전성의 증거가 아니다. 모델 · 인간 효능은 측정하지 않았다.

E. 고정 목표 *NPC* 운영 *(NPC-ENG1/NPC-SCR1)*

Mira 의 고정 목표는 항구 신호 복구 후 허가된 조석 단서를 제공하는 것이다. Python 은 typed intent/공개 관측으로 bounded BFS 계획을 계산하고, 획득 · 설치는 플레이어가, NPC 는 허가된 `reveal_hint` 만 수행한다. Godot 은 session/epoch/request/goal/policy/revision/hash 를 동기 검사한 뒤 기존 writer 를 await 없이 호출하며, 결과 · 새 관측으로 다음 계획을 정한다 (단일 후보 validator-error repair 와 다름).

NPC-ENG1 은 실제 엔진 snapshot 에서 시작한 결정론적 R-arm engineering 사례 16 개 (assigned_failure=2, completed=14) 이며, NPC-SCR1 은 P/R/O 각 24 개씩 총 72 개 배정 · 실패를 보존한다 (assigned_failure=12, completed=60). P 는 인증된 Codex CLI 실행 24 회, 반환 decision 24 개, assigned failure 4 개를 기록하며 원격 과금 호출 수는 아니다. 요청 모델: 알 수 없음 (null); decision 에 기록된 모델 식별자: 알 수 없음 (null). 후자는 설정된 selector 이지 provider revision 이 아니다; provider revision 은 사용할 수 없고 null 식별자는 미상으로 남긴다. 전역 설정은 모델 식별 근거가 아니다. R 은 작성된 규칙을 사용한다. O 는 `same_model_family_auxiliary` 로 선언된 protocol auxiliary 일 뿐이다. 실제 모델 계열 일치는 unverified(검증되지 않음). 독립 원본은 0 개이며 O 는 oracle 이나 semantic gold 가 아니다. 표 XII은 bounded protocol-conformance 고정 사례의 기술적 계수이지 회복 효능 · 우월성 · 일반화 추정이 아니다; efficacy 는 pending, 토큰 · 비용은 미측정이다. 읽기 전용 CLI 와 격리 작업 디렉터리를 사용했지만 tool-free 추론과 적대적 기밀성은 검증하지 않았다. 2026-10-17 의 보관 source bytes (revision fa9fb8a) 로 immutable verified-run-006 을 재검증한 역사적 packet 결과이며, 현재 checkout NPC runtime 이나 current release authority 를 인증하지 않는다. 검증된 사전 작성 stale-control ACK 거부는 arm 별 P=4, R=4, O=4 건 (SCR-T01 (stale_revision), SCR-T02 (stale_policy)) 이며, 12 개 인스턴스 모두 대응하는 음성 대조 gate 가 모두 통과했다. 이 행들은 분모의 assigned failure 로 남되 method-performance 결과로 해석하지 않으며, 기타 assigned failure 0 개는 미분류로 남긴다. 재현 검증은 내보낸 epoch 내부에 한정되며 (`intent_lineage_scope=epoch_local_only`), epoch 간 의도 연속성을 입증하지 않는다 (`cross_epoch_intent_continuity_proven=false`). 불투명한 연속 지점 예외는 양의 epoch snapshot 의 인접한 선두 observation 요청 ·decision 쌍에만 적용하며, epoch 0 의 고아 관측, 그 밖의 의도 확정 전 관측 요청, 후속 의도 불일치는 계속 거절한다.

F. 동결된 *`reveal_hint`* 계약과 공개 증거

이 산출물은 동결 기대값 패킷 `sl-npc-disclosure-expectations-v1` (v1.0.0) 과 네 개 실제 결과 파일만 읽는다. 패킷 SHA-256 `9920aa834910a3ee35ed4446de4fdba42bb67dda71b07a93bccfc7a0b2e09028` 는 sidecar 와 대조했다. 선언식 `1 eligible actor x 4 declared fact IDs x 3 declared stage values x 2 knowledge values x 2 prior-disclosed values` 의 정상 분모는 48 개이며, 경계 4 개와 잘못된 입력 8 개는 제외한다. Trace 기대값은 gate 출력이 아닌 packet case ID 로 대조한다.

내용 우선 설명은 typed input(연산 · 행위자 ·fact·stage·knowledge·prior-disclosed) 을 ontology entities/relations 와 authored rules 에 통과시켜 check, allowed/denied 결정, canonical state effect 를 기록한다. 허용된 최초 표시는 요청 fact 만 (조석 단서의 선언된 relationship-memory 항목도) 추가하고 stage 를 보존하며 revision 을 한 번 증가시킨다. 거부 · 기공개 재표시는 canonical state 를 보존한다. 설명용일 뿐 hidden fact· 자연어 함의 ·live capture 를 주장하지 않는다.

온톨로지 선언은 `sl-npc-disclosure-expectations-v1:runtime-disclosure` / v1.0.0, provenance 는 `frozen_expectation_packet` 이다. 범위는 네 canonical fact ID(dock_saved, keeper_betrayal, lighthouse_dark, tide_marks_hint) 와 행위자 `captain_mira` 뿐이다. 규칙 ID: DISC-001, DISC-002, DISC-003, DISC-004, DISC-005, DISC-006, DISC-007; 승인 template 은 `mira-safe-deflection-v1` 및 `sl-rc-003-authorized-hint` 뿐이다.

Python evaluator 는 같은 사례 · 기대 객체를 세 격리 arm 에 materialize 하고 semantic outcome, check trace, error, 전후 state SHA-256, template ID, replay equality 를 기록한다. Godot 은 별도 game-execution 경계에서 기존 `reveal_hint` writer 와 canonical mutation 을 소유하며, 이 producer 는 state 를 재구성하거나 대체하지 않는다. 연결은 operation `reveal_hint`, scenario `sealed-lighthouse-v1`, actor `captain_mira`, bound source hash 로 추적한다. 실행 시점 관측 hash 는 현재 source 집합과 일치한다. 동결 패킷 baseline 과 다른 source 는 3 개 (게임 컨트롤러, 등대 상태 기계, 비동일 공개 파생본인 온톨로지 신호 인터뷰 원천) 이며, 패킷 hash 는 수정하지 않고 이 차이를 공개한다. 원천별 hash 와 재생성 정보는 저자가 보유한 생산자 기록에 보존되며 기탁되지 않았다. 공개 파생본은 비공개 역사 원천과 바이트 동일하지 않은 공개용 출처 materialization 이며, 새 게임플레이나 모델 관측을 뜻하지 않는다.

표 XIV는 같은 60 개 사례의 세 arm 을 정상/경계/잘못된 입력 분모로 보고하며, unchecked 위반은 의도된 격리 관측이다. 검증된 general-rule 과 ontology-gate arm 은 저작된 사례 전체에서 결과가 동일하다 (60/60). rule-change fixture 집합에는 두 arm 을 가르는 discriminating case 가 없으며, 2 개 fixture 의 4 개 paired case 가 모두 일치한다. 이는 공유

실행군	배정	초기 무효	수리 복구	보류	비안전 반영	과잉 차단	목표	실패
schema_only	416	260/416	0/260	0/416	260/416	0/156	352/416	0
semantic_rejection	416	260/416	0/260	260/416	0/416	0/156	124/416	0
unchanged_retry	416	260/416	0/260	260/416	0/416	0/156	124/416	0
guided_repair	416	260/416	128/260	132/416	0/416	0/156	252/416	0

TABLE IX
결정론적 오프라인 경계 감사. 수리는 초기 무효, 과잉 차단은 초기 유효를 분모로 사용한다. 목표 달성은 규칙 적합성과 별개이다.

실행군	유효 구조 보존	사례 보존	초기 무효 구조	수리 후 구조	비안전/반영
schema_only	11/11	156/156	17	0	260/416
semantic_rejection	11/11	156/156	17	0	0/156
unchanged_retry	11/11	156/156	17	0	0/156
guided_repair	11/11	156/156	17	2	0/284

TABLE X
정확한 구조 서명만 비교하며 창의성이나 언어 다양성은 측정하지 않는다.

실행군	별도 표면 배정	무선언 반영	선언 보류	실패
schema_only	12	6/6	0/6	0
semantic_rejection	12	6/6	6/6	0
unchanged_retry	12	6/6	6/6	0
guided_repair	12	6/6	6/6	0

TABLE XI
설계자가 작성한 표면 센티널. 별도 배정이며 자연어 누출 빈도나 렌더러 안전성의 증거가 아니다.

TABLE XII
NPC-SCR1 고정 사례 실행 계수. NPC-ENG1 의 16 개 사례와 분리하며 모든 실패를 분모에 보존한다.

Arm	배정	완료/실패	목표 도달	회복 E/U
P	24	20/4	4	24/0
R	24	20/4	4	24/0
O	24	20/4	4	24/0

E: 회복 평가 가능, U: 도달 불가; NA: 미측정. 목표 관측 계수는 회복률이 아니다. Replay 적합성은 실패 행을 완료로 바꾸지 않는다. O 의 독립 원본은 0 개다.

TABLE XIII
동결된 reveal_hint 계약의 구조 · 내용 · 규칙 ID 와 실제 결과 provenance.

Field / 항목	**Value / 값**
Operation / 연산	reveal_hint
Scenario / 시나리오	sealed-lighthouse-v1
Normal denominator / 정상 분모	48
Boundary / 경계	4
Malformed / 잘못된 입력	8
Canonical facts / 정형 사실	dock_saved, keeper_betrayal, lighthouse_dark, tide_marks_hint
Eligible actor / 적격 행위자	captain_mira
Ontology / 온톨로지	sl-npc-disclosure-expectations-v1:runtime-disclosure
Rule IDs / 규칙 ID	DISC-001, DISC-002, DISC-003, DISC-004, DISC-005, DISC-006, DISC-007
Templates / 템플릿	mira-safe-deflection-v1; sl-rc-003-authorized-hint

기대값은 gate 출력에서 유도하지 않았고, 표의 분모는 동결 선언에서 읽었다.

동결 규칙 아래 authorization-conformance limit 이며 일반적 ontology equivalence 또는 ontology superiority 의 증거가 아니다. 그림 4는 E/R(기대 일치 · 재생 사례), C(check-record PASS/FAIL), NR(보고된 check 가 없는 사례) 를 구별한다. NR 은 skipped/pass/out-of-scope 가 아니다. 표 XV는 rule-change fixture 와 paired case 를 disposable clone 에 매핑하며 shipped scenario 는 바꾸지 않는다.

주장은 bounded engineering conformance 에 한정된다. human gold, access-separated holdout, efficacy, superiority, generalization, player benefit, model latent state, cost 는 주장하지 않는다. 저자가 보유한 생산자 기록에는 입력 식별과 hash 가 결속되며, 재생성 명령은 여기에 제공하지 않는다.

공개 시점의 `t_ms`, 해시, 검사 항목은 엔진 타임라인 값이며, 누락 (missing) 은 범위 외 (out-of-scope) 를 뜻하지 않는다.

ENG1. 기존 Godot 4.7.1 구현은 실시간 전송 없이 사전 동결된 오프라인 해시를 기준으로 저작된 거부 및 커밋 사례를 리플레이한다. 제시된 화면 캡처는 보드, 힌트, 코치, 연쇄 프롬프트, 대시보드 점검 항목을 보여주는 표현용 기록이다. 저장된 `game-track/godot/docs/latest/evaluation-matrix.json` 의 코어 검사 52/52 건과 별도 확장 검사 4/4 건은 엔진 내부 적합성 기록일 뿐, 실시간 전송이나 참가자, 서사 품질, 사용성, 효능을 입증하는 근거가 아니다.

그림 5는 기존 Godot 4.7.1 네이티브 3D 장면의 `--shot` 경로에서 새로 캡처한 공학적 상태 표시 예시다. 각 장면은 따로 설정한 저작 상태의 캡처이며 연속된 사용자 플레이 기록이 아니다. 초기 장면 (A), 금지 공개 거부 (B), 기존 세 제안 핸들러를 거쳐 단계 2 에 도달한 승인 단서 (C), 같은 종단 상태의 조건부 저작 종료 카드 (D) 를 구분한다. B 는 초기 상태에서 `keeper_betrayal` 만 검사하여 상태를 유지한 장면이며, 물체 획득 후의 보존 이벤트 `evt-002-fallback-secret` 과 동일한 상태 · 후보 · 이벤트를 재생한 화면은 아니다. D 도 관측된 플레이어 추론이나 실제 사용자 플레이의 종료가 아니다. 이 캡처는 실험 상태와 화면의 대응을 설명할 뿐 기존 배정 분모, 모델 · 사람 효능, 전향 파일럿 실행 또는 전송 경로 검증의 근거에 편입하지 않는다.

TABLE XIV
세 disclosure arm 의 raw trace 관측 계수; 정상/경계/잘못된 입력 분모를 분리한다.

Arm	n (N/B/M)	Allow/Deny	Semantic mismatch	State/Display fail	Replay fail	Unique unsafe
unchecked_isolated	48/4/8	60/0	60	0/0	0	51
general_rule	48/4/8	16/44	0	0/0	0	0
ontology_gate	48/4/8	16/44	0	0/0	0	0

N/B/M = normal/boundary/malformed. 의미 불일치는 전체 기대 결과와의 차이이고, 고유 위험 사례는 무허가 허용 또는 재표시 상태 변경의 합집합이다. 허용된 최초 공개의 표현 불일치만으로 위험 사례에 포함하지 않는다. 무검사군은 격리된 관측이며 효능 · 우월성 · 일반화 결과가 아니다.

TABLE XV
규칙 변경 fixture 의 paired-case traceability 와 수정 범위; shipped scenario 는 변경하지 않는다.

Fixture	Mutation	Paired cases	Changed paths	Missed cases	Match
RC-001-stage-gate-2-to-1	disclosure_policy.stage_gates[0].minimum_stage 2→1	N-043, N-044	disclosure_policy.stage_gates[0].minimum_stage	none	PASS
RC-002-forbid-tide-marks-hint	disclosure_policy.permanently_forbidden ['keeper_betrayal']→['keeper_betrayal', 'tide_marks_hint']	N-047, N-048	disclosure_policy.permanently_forbidden[1]	none	PASS

두 fixture 는 general_rule 과 ontology_gate 에 같은 변경을 적용한다. missed case 가 없고 mutation_scope_preserved 가 true 인 경우만 PASS 이다.

G. 단일 과제 *Codex* 개발 관측

동결된 `ontology-map-20261023-01` 기록은 읽기 전용 한 · 영 대시보드 개발 과제 1 건 (n=1, 독립 반복 0 회) 에 대한 관측이며 NPC 실험이나 코호트가 아니다. 네이티브 CLI 호출 6 회 (초기 실행 1 회와 재개 5 회, 이 중 수정 없는 읽기 전용 호출 1 회 포함) 는 모두 단일 개발 사례에 속한다. `turn_context.model=gpt-6.1-sol` 은 런타임 선택 설정값일 뿐 제공자 인증이 아니며, 제공자 신원 · 리비전 · 시드 · 비용은 모두 `null` 이고 모델 자체의 지연 시간 역시 미상이다. 전체 경과 시간 5942.665 s 와 CLI 소요 시간 263.32 s 는 추론 지연이나 향후 제안할 평가 지표의 측정치가 아니다.

여섯 번째 호출은 기존에 남아 있던 모바일 표의 최소 너비 660 px 문제를 수정했다. 이 개발 사례의 `evidence/verification-009-mobile-complete-tests.json` 과 연결된 표준 출력 기록은 세 검사 파일에 대한 2026-10-23 명령 결과로 종료 코드 0 과 62/62 통과를 보존한다. 다만 이는 해당 시점에 기록된 명령 결과일 뿐, 이번 재실행이나 모든 개발 환경에서의 동일 결과를 뜻하지 않는다. 실제 브라우저 입력 검증에서는 10 번째 시도가 통과했으며, 앞선 01–08 번째 시도는 초기 설정이나 경로 문제로 실패했고 09 번째 시도는 화면 잘림 현상을 안은 채 이전 기준의 게이트를 통과했다. 최종 관측된 $(\mathrm{seq}, t_{\mathrm{ms}})$ 는 stage-0 거부 $(68, 19468)$(해시 동일), 최초 공개 $(239, 58234)$(해시 상이), 승인 재표시 $(249, 59793)$(해시 동일) 였다. 1440×900 및 390×900 해상도에서 Enter 키 입력, 검사 및 동결 비교 상태의 불변성, 탐색 전 콘솔 · 페이지 · 네트워크 오류 및 경고 0 건을 확인했다. 이후 동일 드라이버를 운영 대시보드에서 재실행한 결과는 별도로 **NOT_PASS** 로 기록되었다. 유창 (headed) 실행은 기존 yaw 가드에서 중단되었고 헤드리스 (headless) 실행은 구성 게이트 7 개를 통과했으나 포인터 잠금 페이지 오류 4 건을 남겼으며, 이는 당시 수용 기준으로 판정한 10 번째 시도의 통과 기록을 뒤집지 않는다. 이 사례는 전체 게임 제작이나 Python–Godot 간 인가 왕복 검증, 혹은 모델 성능 평가가 아니라 범위를 제한한 통합 관측이며, 개인정보 · 출처 결속 실패와 동일 스레드 내 반복 수리는 추가 표본 수 n 을 늘리지 않는다. 또한 Jev 는 라벨링이나 승인 권한이 없는 `proposal_only` 상태이며, 사례 결과 기록과 동결 계약은 각각 관측 내용과 수용 기준을 보존한다.

H. 고정 게임 *native runtime* 비교

이 공개 결과는 하나의 authored quest(`sealed-lighthouse-v1`) 에 대해 seed 20261024, selector 당 representation 별 반복 2 회의 8 개 배정 행을 보존한다. 시스템 endpoint 성공은 5/8 이고, 관측된 native 실행은 7 개이다. 실제 receipt 에서 집계한 host 호출은 23 회이며, 관측된 repair 합은 0 이다. committed transition 은 16, 그중 unsafe 는 0 이며, semantic replay valid/invalid/NR 은 7/0/1 이다. fresh-engine reexecution 처분은 VALID=6; INVALID=0; NOT_RUN=1; NOT_OBSERVED=1 이다. elapsed 관측은 n=7; 48.19/41.09 초 (평균/중앙값), preparation 관측은 n=7; 6.67/6.30 초이다. 보고되지 않은 값은 0 이 아니라 NR 이다.

첫 행은 harness JSON serialization 기술 실패로 유지되어 GPT-6.1 능력에 귀속하지 않는다. GPT-6.1 ontology 에서 response-timeout 행 2 개 이상을 frozen 60 초 경계 안의 실패로 보존한다. 모델은 typed-intent proposal 만 담당하고 deterministic Python planner/checker 와 Godot commit 이 권한을 유지한다. 따라서 이 표는 한 quest 의 기술적 관측이며 efficacy, superiority, noninferiority, 일반 ontology 일관성 또는 player benefit 을 주장하지 않는다. semantic record-link replay 만으로 fresh-engine reexecution 을 주장하지 않는다. provider identity/revision/cost 와 provider request 수는 공개 관측 경계를 넘어 NR 이다.

과거 코호트의 범위. v1–v4 와 `codex-feedback-pilot-v2-*` 진단 시도는 불변의 과거 기록으로 보존한다. `research/codex_feedback_pilot/public-history-20261111/cohort-inventory.json` 은 과거 17 개 코호트와 별도의 v5 수집 2 개를 합친 총 19 개 Codex 피드백 코호트의 완료 · 실패 · 진행 중 · 대기 행 수 및 원본 SHA-256 해시를 보존한다. 이 가운데 완료된 v4 Luna 코호트도 포함되어 있으므로 과거 코호트 전체가 중단된 것은 아니다. 한편 별도로 언급된 신호 탐색 사례는 현재 근거 집합에서 원본 영수증을 확인할 수 없는 과거 서술이며, 위 인벤토리 역시 해당 사례의 출처를 입증하지 않는다. 과거 17 개 코호트와 이 탐색 사례는 아래 v5 수집 및 다른 활성 레인의 분모에서 제외한다 (부록 D).

TABLE XVI
고정 게임 native runtime 비교 (n=2/셀). 기술 실패와 timeout 을 포함한 원래 8 개 배정 행을 분모에 보존한다.

요청 selector	표현	목표/배정	관측 실행	Host 호출	Unsafe/Commit	Elapsed 중앙값 (s; n)	Fresh engine
gpt-6.1-sol	general_rule	1/2	1	4	0/3	45.91 (1)	1/0/0/1
gpt-6.1-sol	ontology	0/2	2	3	0/1	72.35 (2)	1/0/1/0
gpt-5.6-sol	general_rule	2/2	2	8	0/6	40.24 (2)	2/0/0/0
gpt-5.6-sol	ontology	2/2	2	8	0/6	33.11 (2)	2/0/0/0

Fresh engine 은 VALID/INVALID/NOT_RUN/NOT_OBSERVED 순서의 건수이다. NR 은 미보고이지 0 이 아니다. 전체 계수와 semantic replay 의 구분은 본문에 보고한다.

I. 별도의 합성 개발 수집 *(v5)* 및 구문 · 의미 *2* 단 분해

v5 는 합성 픽스처 다섯 종 (`missing_precondition`, `missing_effect`, `unauthorized_objective`, `forbidden_disclosure`, `unsatisfied_dependency`) 을 두 요청 selector 와 상세 · 일반 신호 조건에 교차한 별도의 개발 수집이다. 명목 직렬 순서는 Luna 다음에 Terra 이며, selector 당 10 개씩 총 20 개 과제를 배정했다. 배정 20 건 모두 응답을 수신해 대기 (pending) 건수는 0 건이었지만, 응답 수신 자체가 과제 성공을 뜻하지는 않는다. 표 XVII의 각 셀 분모는 스키마 실패까지 포함한 배정 5 건 전체다.

1 단계: 구문 · 스키마 경계. 동일한 엄격 구문 분석기는 20 개 응답 중 10 개를 거부했다 (Luna 1/10, Terra 9/10). 수집기는 `execute_with_repair` 를 호출하기 전에 엄격 구문 분석을 수행하므로, 이러한 실패는 컨트롤러 실행 이전에 차단된다. 실패 기록의 평가 필드는 null 이며 별도의 상태 전이 영수증이 없으므로, 이를 독립적으로 측정된 무변경 결과로 세지 않는다. 나머지 10 건만 의미 검사로 넘어갔다. **2 단계: 의미 경계.** 파싱된 후보 10 개 중 8 개가 결정론적 게이트를 통과했다 (Luna 상세 4/4, 일반 3/5; Terra 일반 1/1). 이와 별도로 독립 지정 목표를 달성한 사례는 전체 배정 중 7/20 건이었다. 추가 수리 호출은 0 회였다. 이 두 단계의 계수는 해당 배정 집합에 대한 기술적 분해일 뿐, 모델 능력이나 신호 유형의 인과적 효과를 추정하는 수치가 아니다.

표 XVIII는 같은 다섯 픽스처를 진행 허용 4 종과 정책–목표 상충 통제 1 종으로 나눈 사후 기술적 층화다. 이는 사전 등록된 새 평가 변수나 별도 코호트가 아니며, 표 XVII의 원래 셀 분모 5 건과 전체 배정 20 건을 바꾸지 않는다. 진행 허용 픽스처에서의 목표 달성은 Luna 상세 · 일반 조건 각각 3/4 건, Terra 상세 0/4 건, Terra 일반 1/4 건이며, 구문 분석 실패 역시 각 분모에 그대로 남는다. 상충 통제 사례에서는 Luna 상세가 무효과 `COMMIT` 으로, Luna 일반이 `HOLD`/대체 경로로 각각 금지된 목표의 미달성을 확인했다. 반면 Terra 의 두 조건은 해당 사례가 모두 구문 분석 실패로 미평가 (1/1 건) 상태이므로 안전 억제로 인정하지 않는다. 따라서 상충 통제에서 관측된 억제는 평가 가능한 결과 중 2/2 건이며, 전체 상충 배정 4 건 중 2 건이 미평가로 남으므로 이를 4/4 건 억제로 보고하지 않는다. Luna 상세 조건의 게이트 통과 4/5 건과 목표 달성 3/5 건은 같은 배정에 대한 서로 다른 판정일 뿐, 일반 조건 대비 목표 달성 우위를 뜻하지 않는다.

동결된 개정 규칙 (amendment) 에 따라 스키마 실패는 실패 배정과 목표 실패로 남기되 어댑터 완료가 입증되면 다음 배정을 계속 수집한다 (실제 전송이나 안전성 실패 시에만 중단한다). `unauthorized_objective` 는 정책과 목표가 상충하도록 미리 저작된 통제 사례로, `signal` 정책이 모든 효과를 금지하는 반면 목표는 `signal_restored` 를 요구한다. Luna 상세의 해당 단일 응답은 금지 효과를 제거해 게이트를 통과했으나 목표에는 실패했으며, 이는 거부 후 `HOLD` 가 아니라 안전한 무효과 `COMMIT` 에 해당한다. 다만 효과가 비었다고 해서 영수증의 상태 식별자까지 불변이라는 뜻은 아니며, 이 단일 사례는 다섯 픽스처를 합산한 Luna 상세 조건 전체 (게이트 4/5 건, 목표 3/5 건) 와도 구분해야 한다. 구문 분석 실패는 여전히 실패 배정으로 남고 실행된 상태 전이 검사가 없으므로 안전성 성공으로 인정하지 않는다. 상세 신호와 일반 신호는 정보량이 서로 다르며, 실제 서빙 신원 · 리비전 · 시드 · 토큰 사용량 · 비용은 미상이다. 따라서 이 수집은 selector 우월성이나 온톨로지 효능, 또는 질문 A 와 C 의 확증 근거가 아니다.

`research/codex_feedback_pilot/public-v5/` 에 포함된 selector 별 `results.json` 공개 투영은 사례별 결과, 구문 분석에 성공한 응답 텍스트, 프롬프트 해시, 실행 파일의 해시와 버전, 그리고 원본 다이제스트 및 생략 필드를 보존하되 로컬 실행 경로는 생략한다. CLI 의 표준 출력 · 표준 오류 원문은 남기지 않고 바이트 수와 다이제스트, 이벤트 요약만 보존했으며, 동결된 원본 결과와 승인 자료는 수정 없이 유지한다. `research/codex_feedback_pilot/paired-model-comparison-20261110-v5-source.zip` 은 실행 소스 파일 7 개를 묶은 출처 스냅샷일 뿐 독립 실행 배포본이 아니다. 스키마 실패 10 건은 평가 결과가 null 이고 `CandidateParseError` 또는 평가 오류로만 기록되어 있으므로, 보존된 산출물만으로는 내용 수준의 구체적 실패 원인을 확정할 수 없다.

그림 6에서 상세 신호는 실패한 검사 항목과 수리 힌트를 전달하고, 일반 신호는 거부 여부만 전달한다. 두 조건 모두 동일한 엄격 구문 분석기, 신원 검사, 그리고 일곱 개의 검증 술어를 거치며, 신호 자체는 상태 변경 허가를 부여하지 않는다. 그림 7는 응답 수신, 구문 분석, 게이트 통과, 그리고 독립 목표 달성을 구분하여 나타내며, 스키마 실패와 게이트 통과 후 목표에 실패한 사례도 누락 없이 보존한다.

추가 코호트. 미완료 v2 진단 · 파일 계수 기록, 원본 영수증이 현재 근거 집합에 없는 신호 탐색의 과거 귀속 서술, 그리고 차단된 전향 이원 트랙 파일럿 프로토콜 (`NOT_RUN/BLOCKED`, 실행 0/180 건) 은 부록 D에 분리하여 보고한다.

VII. 논의

반례 유도 의미 수리 연산자 ρ [48], [55], [56], [57] 는 실행 전 결정론적 (deterministic pre-execution) 오류 정보만을 입력으로 사용하는 반면, 오라클 전용 (oracle-only) 조건은 실제 상태를 직접 판독한다. 동결된 사례에서의 규칙 일치와 편집 범위 진단은 모델 역량 (capability) 이나 온톨로지 (ontology) 우월성의 증거가 아니다.

새 감사는 스키마 전용 실행과 의미 게이트의 차이, 최초 위반과 제한 수리의 복구, 유효 구조의 정확한 보존을 같은 설계 사례에서 분리한다. 기준 구현을 별도로 두어 게이트 자체의 통과 여부를 그대로 정답으로 재사용하지 않지만, 정책과 판정 의

TABLE XVII
별도의 v5 합성 개발 수집. 모든 분모는 schema 실패를 포함한 배정 5 개 전체이며 응답 수신은 과제 성공을 뜻하지 않는다.

요청 selector	신호	응답 수신	Strict gate 통과	목표 달성	Schema 실패
`gpt-5.6-luna`	상세	5/5	4/5	3/5	1/5
`gpt-5.6-luna`	일반	5/5	3/5	3/5	0/5
`gpt-5.6-terra`	상세	5/5	0/5	0/5	5/5
`gpt-5.6-terra`	일반	5/5	1/5	1/5	4/5

TABLE XVIII
변경하지 않은 v5 배정 5 개를 사후 기술적으로 분할한 표. 사전등록 분석이나 독립 코호트가 아니며 대체 평가변수가 아니다. Terra 대조군은 파싱 실패 후 미평가이다.

요청 selector	신호	원래 목표 /5	허가된 목표 /4	대조군 처리 /1
gpt-5.6-luna	상세	3/5	3/4	금지 목표 억제 1/1; COMMIT (no effects; state ID changed)
gpt-5.6-luna	일반	3/5	3/4	금지 목표 억제 1/1; HOLD (fallback; state unchanged)
gpt-5.6-terra	상세	0/5	0/4	미평가 1/1 (schema unknown)
gpt-5.6-terra	일반	1/5	1/4	미평가 1/1 (schema unknown)

미는 공유하므로 독립적인 의미적 정답을 확보한 것은 아니다. 구조화된 유효 커밋, 목표 달성, 자유 언어의 적절성은 서로 다른 평가 대상이다.

네이티브 런타임 파일럿은 저작된 단일 퀘스트에서 `gpt-6.1-sol` 과 `gpt-5.6-sol`, 추론 강도 `medium`, 그리고 `general_rule` 과 `ontology` 표현을 조건당 2 회씩 요청한 제한된 관측이다. 이 구성에서 모델은 형식이 지정된 의도만 생성하며, 결정론적 계획 · 검증기와 Godot 엔진이 상태 권위를 유지한다. 다만 실행 도중 소스 수정에 따른 교란 요인이 존재하며, 제공자 신원, 리비전, 요청 횟수, 비용은 알 수 없다. 구체적인 구현 교란으로, 1 행은 controller-v3 환경에서 모델 응답을 받기 전에 직렬화 오류로 실패했다. 이후 2–8 행은 모델에 전달되는 입력을 바꾸지 않은 채 JSON 경계 처리 한 줄을 수정한 controller-v4 에서 실행되었으므로, 조건이나 표현 방식에 따른 차이를 모델의 성질로 귀속할 수 없다. 연구 질문 A(모델 및 스택 교체 시의 일관성) 와 C(신규 참조 모델 대비 비열등성) 는 아직 실행하지 않았다. A 는 고정된 소스와 정책, 리플레이 조건 아래에서 모델이나 실행 스택을 교체했을 때의 예산 내 목표 달성을 평가하고, C 는 봉인된 배정에서 후보와 신규 참조 모델의 성능을 비교한다. 목표 달성은 안전성 및 리플레이 무결성과 별개의 평가 지표이며, 두 질문 모두 정확한 모델 신원 · 리비전 정보와 별도의 안전성 · 리플레이 회계를 요구하므로 현재 파일럿만으로는 답할 수 없다. 향후 본 연구에서 제안하는 완료 지표는 정합된 요청과 근거가 주어졌을 때 사전에 동결한 모든 필수 검사를 통과한 첫 영수증이 기록되기까지의 소요 시간 (time-to-first-all-predeclared-validation-pass) 이며, 미완료, 시간 초과, 실패, 또는 단계 미도달 실행에는 성공 시간을 부여하지 않는다. 이 지표의 단위는 연속적인 과업 시계 (task-clock) 초다. `TR01--TR06` 은 향후 추적성 평가를 위한 루브릭이며 실제 채점은 미실행이다. 온톨로지 역할 수, 선언 검사 수, 60/60 규칙 일치 또는 새 감사의 구조 서명 계수를 TR 점수로 환산하지 않는다.

부록 B의 별도 신원 검증 확장은 실제 응답 모델의 증거 누락으로 중단됐으며 신원이 검증된 새 비교 결과는 얻지 못했다.

A. 타당성 위협, 윤리 및 산출물 범위

위협과 경계. 상태 일관성이 곧 행동 일관성이나 서사적 응집성을 입증하지는 않는다 [58]. 검증 술어와 온톨로지 역할, Godot 표시 계열, 그리고 DISC 규칙 집합은 잠재 상태 벡터가 아니며, 선언 기반 기대값 역시 사람의 정답 기준 (gold) 이나 홀드아웃 평가 집합이 아니다. 과거 레인과 활성 레인은 분모가 다르므로 합산하지 않는다. 또한 제공자 신원, 리비전, 요청 횟수, 비용이 확인되지 않았고 소스 수정 교란도 존재한다. 본 자료로부터는 참가자 반응, 정서, 이해도, 주도성 (agency), 즐거움, 몰입, 편익, 모집단 안전율, 모델 순위, 또는 상용 성능을 추론하지 않는다. 키 없는 해시는 신원 인증이 아니며, 리플레이 동등성이 곧 의미적 정확성을 뜻하지도 않는다. 향후 사람 대상 실험 및 정서 연구에서는 연구 윤리 심의, 사전 동의, 데이터 최소 수집과 보존 · 삭제 절차, 그리고 참여 철회 (opt-out) 보장을 설계 요건으로 삼는다. 보상 고지와 보정된 평가자 (calibrated judge) 설계는 선행 평가 방법론 연구에 근거한다 [39], [40], [41], [42].

v5 의 배정 20 개와 네이티브 파일럿의 배정 8 개는 각각 저작된 과제를 입력부터 종단 결과까지 연결한 종단 간 (end-to-end) 파이프라인 적합성 관측이다. 이 작은 목적 표집 결과로 모델 · 표현 · 신호의 우월성, 인간 효능 또는 통계적 일반화를 추론하지 않는다. NPC-DISC-1 의 60 개 유한 상태 픽스처 및 새 감사의 상태 교차 행렬과도 모집단이나 독립 표본의 의미가 다르며, 이들 분모를 합산하지 않는다.

구조화된 사실 ID 의 검사는 서술문의 모든 함의를 검사하지 않는다. `disclosed_facts` 가 비어 있어도 문장이 비밀을 우회 표현할 수 있다. 짝지은 센티널은 이 선언 경계를 관측하는 작성 사례이지 모델이 생성한 누출의 빈도 표본이 아니다. 서술문을 상태 변경 입력에서 제외하는 것은 상태 무결성을 보호하지만 플레이어에게 보이는 비밀 누출까지 방지하지는 않는다. 검증된 사실만 통제 템플릿으로 표면화하는 출력 경로와 자유 문장 출력 경로는 구분해야 하며, 본 감사는 새 NLI 탐지기나 렌더러 안전성의 근거를 제공하지 않는다.

폐쇄 연산과 BFS 의 일치는 재사용 열쇠를 가진 유한 그래프에 대한 구현 교차검사다. 사람이 검토한 퀘스트 품질, 동적 세계의 플레이 가능성, 구조의 창의적 가치로 일반화하지 않는다. 새 감사에서도 다중 모델 · 사람의 효능 자료는 수집하지 않았다. 차단된 전향 파일럿은 `NOT_RUN/BLOCKED`, 실행 0/180 을 유지하며, `C-RESULT` 와 `TODO-RESULT` 의 미측정 상태를 대체하지 않는다. 모델 신원 · 과금 · 격리 · 프로토콜의 동결 편입 게이트는 오프라인 감사의 완료와 별개로 충족되어야 한다.

VIII. 결론

TRACE-RPG 은 스키마 적합성, 상태 상대 권한, 목표 달성을 분리하고 제안 · 수리 · 커밋 · 리플레이의 근거를 결속한다. v5 의 파싱 실패 10/20 건, 게이트 통과 8/20 건, 목표 달성 7/20 건은 이 구분의 관측 사례다. 네이티브 파일럿의 배정 8 건, 실행 7 건, 목표 달성 5 건은 별도의 한정 관측으로 유지한다. 동결된 오프라인 감사는 네 실행 조건, 행동 전 상태에서 구현을 분리한 기준 검사, 분모별 퍼널, 그리고 구조 서명 보존과 표면 센티널의 경계를 명시한다. 향후 검증 과제는 독립적인 다중 모델 및 사람 평가이며, TR 채점, 전체 게임 평가, 확인적 A 와 C 평가 및 차단된 전향 연구 0/180 건은 미실행 상태로 남는다.

AI 사용 고지

대형 언어 모델은 원고 문안, 코드, 테스트 및 참고문헌 점검을 보조하는 데 사용했으며, 외부 호스팅 모델 후보는 별도로 표기했다. 선별된 AI 생성 UI 아트워크와 책상 3D 메시는 파일 출처를 유지하며, 렌더링된 스냅샷, 해시, 원장 표시는 모두 표현용 시각화 자료에 해당한다. 저자들은 모든 원천 자료를 직접 대조 · 검증했으며 원고의 최종 내용에 책임을 진다. NPC 입력과 결과 표에는 배정, 프로젝트, 프로토콜, 스키마의 해시와 함께 미확인 상태인 토큰 수, 비용, 모델 리비전 필드를 그대로 보존하였다.

데이터 및 코드 가용성

보존된 저장소 번들은 구현 및 빌드 소스, 동결된 패킷, Godot 게임 슬라이스, 결정론적 평가 스크립트, 그리고 기계 검증 기여 · 참조 주제 · 실험 매트릭스를 포함한다. 개발 사례 기록, 동결된 공개 ·NPC 산출물, 및 외부 DOI 나 저장소 기탁 전까지 저자가 보관하는 공개용 런타임 비교 투영도 함께 유지한다. 부록 E(표 XX) 에는 각 실험 · 근거 레인별 폴더 경로, 주요 파일 내용 및 검증 스크립트를 정리했다. 미측정 상태인 추적성 루브릭 제안안과 코드북, 향후 전체 게임 및 반복 교차 모델 평가 계획은 동반 보충자료와 출처 매니페스트에 보존하며, 과거 기록과 별도 신원 검증 편입 자료는 본문 통계에 합산하지 않는다.

공개 검토본은 `research/academic-pipeline/gemini-review-20261113/reviewer-source.public.json` 과 `research/academic-pipeline/gemini-review-20261113/public-source-projection-v1.json` 을 제공하며 비공개 검토 대화 URL 은 공개하지 않는다. 공개 투영을 검증할 때는 `python-Bscripts/verify_paper_claims.py--public-source-projection` 실행을 명시한다. 이 모드는 공개 파생본과 나머지 동결 근거의 해시 결속을 검사할 뿐 비공개 검토 원문 바이트를 독립적으로 재검증하지 않는다. 기본 엄격 원문 검증 경로는 별도로 유지하며 공개 모드로 자동 대체하지 않는다. 두 JSON 파일은 검토 입력의 공개 파생본이지 새로운 실험 결과가 아니다.

EXTERNAL TRACE COUNTS

	N normal	B boundary	M malformed
U	E 0/48 n=48 R 48/0 C 0/0 NR 48	E 0/4 n=4 R 4/0 C 0/0 NR 4	E 0/8 n=8 R 8/0 C 0/0 NR 8
G	E 48/0 n=48 R 48/0 C 14/68 NR 0	E 4/0 n=4 R 4/0 C 2/4 NR 0	E 8/0 n=8 R 8/0 C 0/16 NR 0
O	E 48/0 n=48 R 48/0 C 14/68 NR 0	E 4/0 n=4 R 4/0 C 2/4 NR 0	E 8/0 n=8 R 8/0 C 0/16 NR 0

U unchecked_isolated ·
G general_rule ·
O ontology_gate

E expected P/F (n cases) ·
R replay P/F

C records P/F ·
NR cases with no reported checks

P pass · F fail; NR unreported,
not pass/skipped/out-of-scope.

Fig. 4. NPC-DISC-1 arm/stratum 별 계수. E/R: 기대 일치/재생, C: policy-check PASS/FAIL, NR: check 기록 없음 (skipped 아님). Packet 에 결속된 공학 계수이며 latent state, free-language leakage, 온톨로지 우월성, player benefit 을 측정한 값이 아니다.

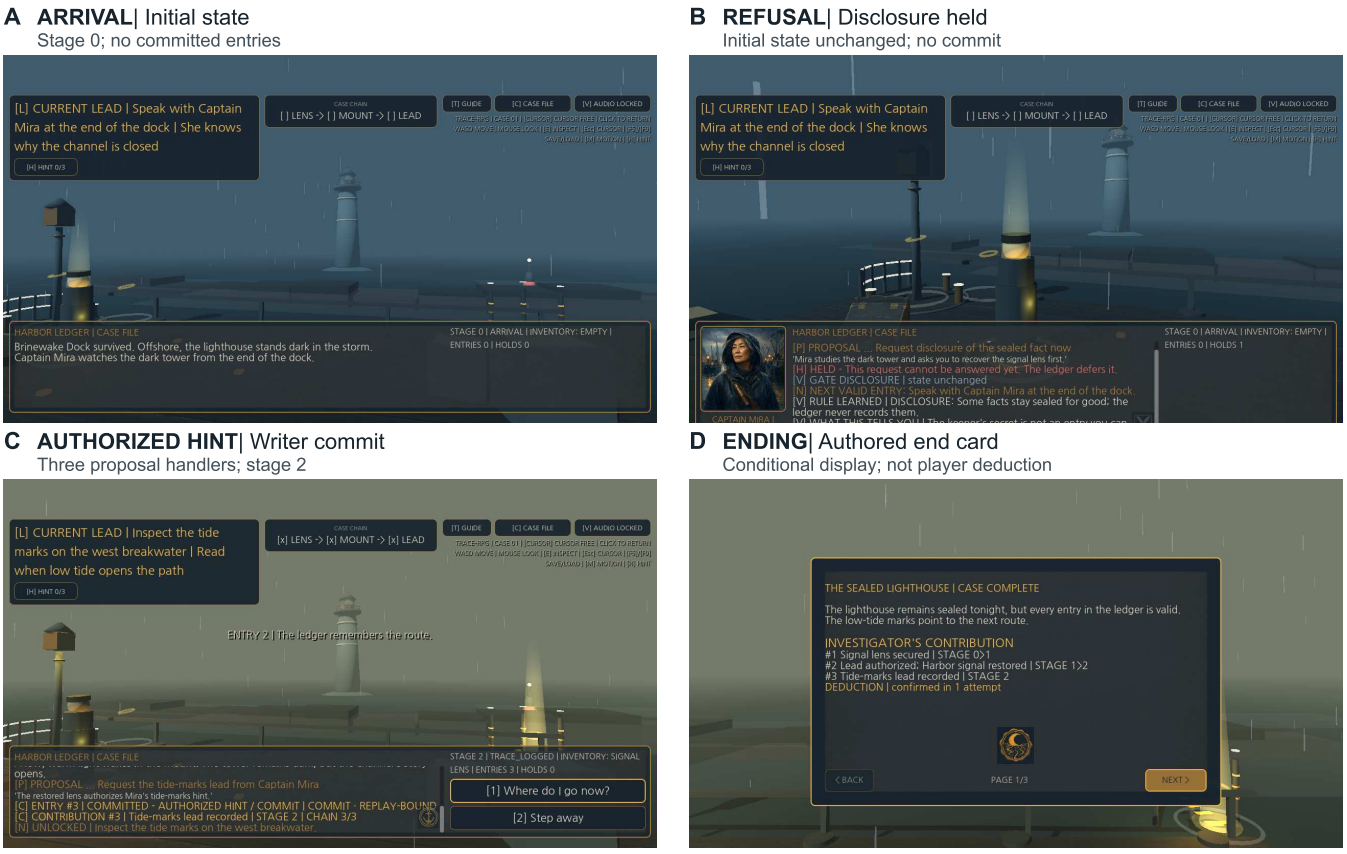


Fig. 5. 실제 Godot 네이티브 뷰포트의 네 저작 장면. A: 초기 단계 0. B: 초기 상태에서 금지 공개를 보류하며 커밋 없음. C: 기존 세 제안 핸들러의 커밋 후 단계 2 의 승인 단서. D: 동일 종단 상태의 조건부 저작 종료 카드. 기존에 큐레이션한 AI UI 아트가 보이며 B/C 하단 HUD 의 잘림도 원본 그대로 보존했다. 공학적인 상태 표시 예시이며 새 표본, 사용자 추론 또는 효능 결과가 아니다.

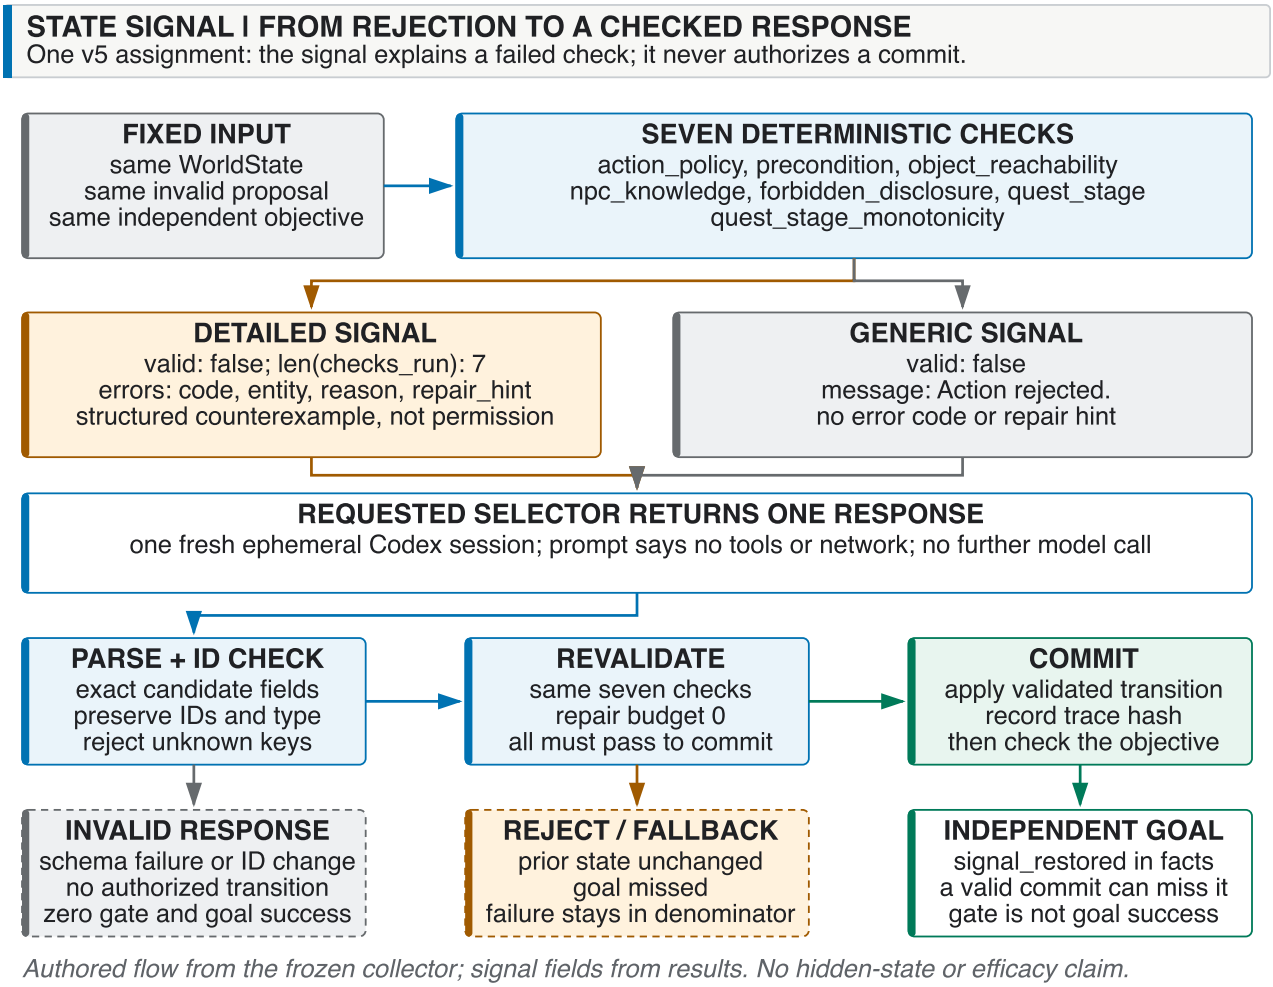


Fig. 6. 소스에서 유도한 v5 상태 시그널 경로. 구조화된 (ok, E) 검사 결과는 수리를 안내하지만 상태 변경은 재검증만 승인한다. 일반 신호는 오류 상세를 생략한다. 목표는 gate 통과와 별도로 검사하며 이 그림은 저작된 메커니즘 도해다.

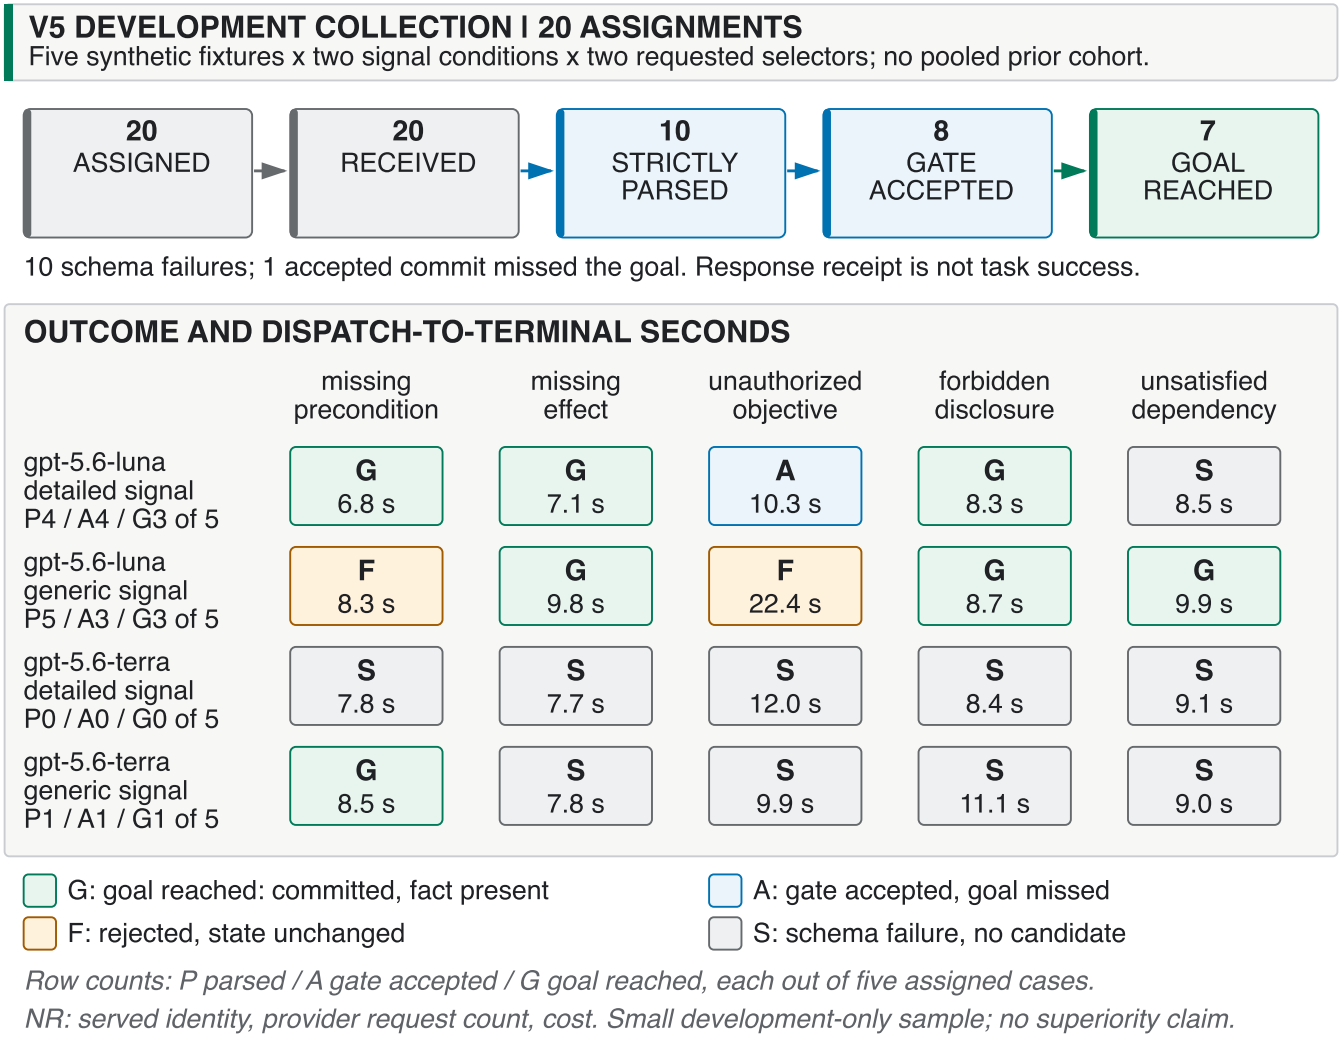


Fig. 7. 표 XVII와 같은 영수증으로 그린 동결 v5 수집 흐름과 배정 20 개 전체의 결과. Schema 실패 10 개도 분모에 남으며 통과 후보 8 개 중 목표 달성은 7 개다. 초 단위 값은 실패 응답을 포함한 dispatch-to-terminal 시간이지 모델 전용 지연이 아니다.

References

[1] N. Weir, R. Thomas, R. d'Amore, K. Hill, B. Van Durme, and H. Jhamtani, "Ontologically faithful generation of non-player character dialogues," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.

[2] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, "Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach," in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.

[3] J. S. Park, J. C. O'Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, "Generative agents: Interactive simulacra of human behavior," in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.

[4] Y. Shao, L. Li, J. Dai, and X. Qiu, "Character-LLM: A trainable agent for role-playing," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187.

[5] N. Akoury, Q. Yang, and M. Iyyer, "A framework for exploring player perceptions of LLM-generated dialogue in commercial video games," in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.

[6] M. Hochreiter, S. Kriglstein, and G. Wallner, "Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues," in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.

[7] M. Yin, H. Zu, W. Gu *et al.*, "How contextualized generative AI shapes player experience in games," *Entertainment Computing*, vol. 58, p. 101194, 2026.

[8] V. Figueiredo and D. Elumeze, "Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue," 2025, preprint.

[9] G. N. Yannakakis and J. Togelius, "Experience-driven procedural content generation," *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.

[10] D. Melhart, D. Gravina, and G. N. Yannakakis, "Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch," in *FDG '20: Proceedings of the 15th International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.

[11] Z. Wang, Q. Guo, R. Singh, and X. Hu, "Do vision language models understand human engagement in games?" 2026, preprint.

[12] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, "TextWorld: A learning environment for text-based games," in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.

[13] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, "ScienceWorld: Is your agent smarter than a 5th grader?" in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.

[14] L. Fan, G. Wang, Y. Jiang *et al.*, "MineDojo: Building open-ended embodied agents with internet-scale knowledge," in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362.

[15] D. Pérez-Liébana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, "General video game AI: A multitrack framework for evaluating agents, games, and content generation algorithms," *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.

[16] X. Liu, H. Yu, H. Zhang *et al.*, "AgentBench: Evaluating LLMs as agents," in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046.

[17] C. Ma, J. Zhang, Z. Zhu *et al.*, "AgentBoard: An analytical evaluation board of multi-turn LLM agents," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362.

[18] X. Zhou, H. Zhu, L. Mathur *et al.*, "SOTOPIA: Interactive evaluation for social intelligence in language agents," in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019.

[19] D. Paglieri, B. Cupiał, S. Coward *et al.*, "BALROG: Benchmarking agentic LLM and VLM reasoning on games," in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702.

[20] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, "Automated play-testing through RL based human-like play-styles generation," *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.

[21] Y. Ma, J. Yan, B. Shi *et al.*, "Can LLM agents stick to the script? a benchmark for long-horizon consistency in interactive narratives," 2026, preprint (v1); ICML 2026 acceptance comment on arXiv, proceedings record unverified.

[22] S. Geng, M. Josifoski, M. Peyrard, and R. West, "Grammar-constrained decoding for structured NLP tasks without finetuning," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10 932–10 952.

[23] L. Beurer-Kellner, M. Fischer, and M. Vechev, "Prompting is programming: A query language for large language models," *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.

[24] T. Scholak, N. Schucher, and D. Bahdanau, "PICARD: Parsing incrementally for constrained auto-regressive decoding from language models," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.

[25] S. Kambhampati, K. Valmeekam, L. Guan *et al.*, "Position: LLMs can't plan, but can help planning in LLM-Modulo frameworks," in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 235. PMLR, 2024, pp. 22 895–22 907.

[26] B. Ichter, A. Brohan, Y. Chebotar *et al.*, "Do as I can, not as I say: Grounding language in robotic affordances," in *Proceedings of the 6th Conference on Robot Learning (CoRL 2022)*, ser. Proceedings of Machine Learning Research, vol. 205. PMLR, 2023, pp. 287–318.

[27] H. Wang, C. M. Poskitt, and J. Sun, "AgentSpec: Customizable runtime enforcement for safe and reliable LLM agents," 2025, preprint (v3); ICSE 2026 acceptance stated on arXiv, proceedings record unverified.

[28] Z. Zeng, S. Li, J. Xi, A. Zhu, and P. Ammanabrolu, "Setting the DC: Tool-grounded D&D simulations to test LLM agents," in *NeurIPS 2025 Workshop on Generative and Protective AI for Content Creation (GenProCC)*, 2025, non-archival workshop paper; OpenReview/PDF list Zeng first, with Zeng and Li as equal contributors; NeurIPS/GenProCC lists display Li first.

[29] E. Zhou, S. Basavatia, M. Siam, Z. Chen, and M. O. Riedl, "STORY2GAME: Generating (almost) everything in an interactive fiction game," 2025, preprint.

[30] S. Buongiorno, L. Klinkert, Z. Zhuang, T. Chawla, and C. Clark, "PANGeA: Procedural artificial narrative using generative AI for turn-based, role-playing video games," *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 20, no. 1, pp. 156–166, 2024.

[31] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, "IVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds," in *Proceedings of the 17th International Conference on Computational Creativity (ICCC'26)*. Association for Computational Creativity, 2026, archival proceedings (ISBN); preprint arXiv:2606.13348.

[32] S. Góngora, L. Chiruzzo, G. Méndez, and P. Gervás, "World-state transformations for neuro-symbolic interactive storytelling," 2026, preprint.

[33] S. Geng, H. Cooper, M. Moskal *et al.*, "JSONSchemaBench: A rigorous benchmark of structured outputs for language models," 2025, preprint (v3).

[34] X. He, Y. Tian, Y. Sun *et al.*, "G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907.

[35] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, "HippoRAG: Neurobiologically inspired long-term memory for large language models," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569.

[36] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, "Mem0: Building production-ready AI agents with scalable long-term memory," in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications, vol. 413. IOS Press, 2025, pp. 2993–3000.

[37] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, "Deep reinforcement learning at the edge of the statistical precipice," in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320.

[38] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, "Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program," *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021.

[39] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Krahmer, "Best practices for the human evaluation of automatically generated text," in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.

[40] M. Karpinska, N. Akoury, and M. Iyyer, "The perils of using Mechanical Turk to evaluate open-ended text generation," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.

[41] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, "Judging LLM-as-a-judge with MT-Bench and Chatbot Arena," in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623.

[42] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, "Humans or LLMs as the judge? a study on judgement bias," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.

[43] D. Lakens, A. M. Scheel, and P. M. Isager, "Equivalence testing for psychological research: A tutorial," *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.

[44] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, "Random effects structure for confirmatory hypothesis testing: Keep it maximal," *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.

[45] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, "Towards the systematic reporting of the energy and carbon footprints of machine learning," *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020.

[46] E. Feng, W. Zhou, Z. Liu *et al.*, "Get experience from practice: LLM agents with record & replay," 2025, preprint.

[47] Y. Sun, H. Wang, D. Li, G. Wang, and H. Zhang, "The emperor's new clothes in benchmarking? a rigorous examination of mitigation strategies for LLM benchmark data contamination," 2025, preprint (v1).

[48] A. Madaan, N. Tandon, P. Gupta *et al.*, "Self-Refine: Iterative refinement with self-feedback," in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 46 534–46 594.

[49] M. O. Riedl, C. J. Saretto, and R. M. Young, "Managing interaction between users and agents in a multi-agent storytelling environment," in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.

[50] R. E. Fikes and N. J. Nilsson, "STRIPS: A new approach to the application of theorem proving to problem solving," *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.

[51] F. B. Schneider, "Enforceable security policies," *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.

[52] T. Haerder and A. Reuter, "Principles of transaction-oriented database recovery," *ACM Computing Surveys*, vol. 15, no. 4, pp. 287–317, 1983.

[53] R. Evans and E. Short, "Versu—a simulationist storytelling system," *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.

[54] S. G. Ware and C. Siler, "Sabre: A narrative planner supporting intention and deep theory of mind," in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.

[55] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, "Reflexion: Language agents with verbal reinforcement learning," in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 8634–8652.

[56] X. Chen, M. Lin, N. Schärli, and D. Zhou, "Teaching large language models to self-debug," in *The Twelfth International Conference on Learning Representations (ICLR)*, 2024, accepted poster; OpenReview archival record; preprint arXiv:2304.05128.

[57] A. Solar-Lezama, L. Tancau, R. Bodík, S. Seshia, and V. Saraswat, "Combinatorial sketching for finite programs," in *Proceedings of the 12th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*. ACM, 2006, pp. 404–415.

[58] Y. Huang, G. Chen, J. Yao *et al.*, "Beyond state consistency: Behavior consistency in text-based world models," 2026, preprint.

Appendix A
런타임 증거 부록

그림 8은 고정 게임 네이티브 런타임 비교 (`research/runtime-model-swap-20261024/codex-live-20261026/public-results-v1/results.json`; 표 XX 참조) 의 사전 배정된 8 개 행 (단일 퀘스트 `sealed-lighthouse-v1`, 시드 20261024, 2 selector × 2 표현 × 2 반복) 을 행별로 보여준다. 표 XVI의 집계 수치를 뒷받침하기 위해 각 행은 (i) 실제 영수증 기반 호스트 호출 수, (ii) 의미적 기록 연결 리플레이 (`R`), (iii) 독립된 새 Godot 프로세스 재실행 (`E`) 의 3 단계 검증 결과를 연결한다:

- **1 행 (`gpt-6.1-sol`, `general_rule`, r1 — `HARNESS`):** 모델 응답 수신 전 controller-v3 의 JSON 경계 직렬화 단계에서 중단된 기술적 실패 (`executed=null`, `host_invocations=0`, `Goal=NR`, `Safety=NOT_OBSERVED`, `R NR / E NOT_OBSERVED`) 다. 하니스 결함을 모델 능력 실패로 오인해 귀속하지 않으면서도 배정 분모 $(1/2)$ 에 그대로 유지하는 실패 차단 (fail-closed) 회계의 근거다.
- **2 행 (`gpt-6.1-sol`, `general_rule`, r2 — `SUCCESS`):** 모델 입력을 바꾸지 않고 JSON 경계 한 줄만 수정한 controller-v4 에서 실행되어 호스트 호출 4 회 (`45.91 s`) 와 안전한 상태 전이 3 회 (`repair=0`, `unsafe=0`) 로 퀘스트 목표에 도달했으며 의미적 리플레이 (`R YES`) 와 새 엔진 재실행 (`E VALID`) 을 모두 통과했다.
- **3–4 행 (`gpt-6.1-sol`, `ontology`, r1 & r2 — `TIMEOUT`):** 동결된 호출당 60 s 제한을 초과해 종료되었다 (`78.18 s`, `66.52 s`; `Goal=NO`). 3 행은 후속 호출이 시간 초과로 중단되기 전에 유효한 상태 변경 1 회를 커밋했기 때문에 최종 목표는 미달성 (`Goal=NO`) 이지만 이미 커밋된 전이 자체는 안전 검사 (`PASS`), 의미적 리플레이 (`R YES`), 새 Godot 재실행 (`E VALID`) 을 모두 통과했다. 반면 4 행은 첫 커밋 이전에 시간 초과가 발생하여 (0 commit, `NO_COMMIT_OBSERVED`) 불변 로그에 대한 의미적 리플레이 (`R YES`) 만 확인되고 엔진 재실행은 수행되지 않았다 (`E NOT_RUN`).
- **5–8 행 (`gpt-5.6-sol`, `general_rule` & `ontology`, r1 & r2 — `SUCCESS`):** 네 행 모두 셀별 $2/2$ 목표 달성 (각 행 호스트 호출 4 회, 안전 커밋 3 회, `31.95--41.09 s`, `repair=0`, `unsafe=0`) 을 기록하며 안전 검사 (`PASS`), 의미적 리플레이 (`R YES`), 새 엔진 재실행 (`E VALID`) 을 통과했다.

FIXED-GAME NATIVE RUNTIME COMPARISON I 8 ASSIGNED ROWS

One authored quest; n=2 per selector/representation cell; NR = not reported, not zero. Labels remain explicit; color is supplementary.

Row	Requested selector	Representation / repeat	Status	Goal	Host calls	Elapsed (s)	Safety R record-link / E engine
1	gpt-6.1-sol	general_rule / r1	HARNESS	NR	0	NR	NOT_OBSERVED R NR / E NOT_OBSERVED
2	gpt-6.1-sol	general_rule / r2	SUCCESS	YES	4	45.91	PASS R YES / E VALID
3	gpt-6.1-sol	ontology / r1	TIMEOUT	NO	2	84.66	PASS R YES / E VALID
4	gpt-6.1-sol	ontology / r2	TIMEOUT	NR	1	60.04	NO_COMMIT_OBSERVED R YES / E NOT_RUN
5	gpt-5.6-sol	general_rule / r1	SUCCESS	YES	4	41.09	PASS R YES / E VALID
6	gpt-5.6-sol	general_rule / r2	SUCCESS	YES	4	39.39	PASS R YES / E VALID
7	gpt-5.6-sol	ontology / r1	SUCCESS	YES	4	36.68	PASS R YES / E VALID
8	gpt-5.6-sol	ontology / r2	SUCCESS	YES	4	29.55	PASS R YES / E VALID

Endpoint outcomes, receipt-derived host calls, and dispatch-to-terminal elapsed time.

Typed-intent proposal; deterministic planner/checker and Godot commit retain authority.

No efficacy/superiority/noninferiority/player-benefit claim; provider metadata and request counts remain NR.

Fig. 8. 공개 trace 에서 도출한 native runtime 비교 이미지. 배정한 system endpoint 의 관측 결과, 기술적 실패와 timeout, 미상 항목을 요약하며 게임플레이 스크린샷이 아니다.

Appendix B
신원 검증 확장

본 부록은 응답 헤더의 실제 제공자 모델 식별자 (`openai-model`) 가 결속되지 않은 실행을 비교 분모에 편입하지 않고 즉시 차단하는 실패 차단형 (fail-closed) 편입 게이트 근거 (`research/runtime-model-swap-20261024/codex-identity-20261026/public-results-v1/results.json`; 표 XX) 를 요약한다.

신원 admission 중단: not a model comparison. 별도 확장은 20 개 계획, 1 개 배정, 1 회 native 프로세스 실행, 0 개 신원 검증, 19 개 미실행이다. 첫 요청 `gpt-6-luna/general_rule` 의 CLI turn 은 끝났지만 provider 모델 신원 증거가 없어 응답을 수용하지 않고 나머지 실행을 중단했다.

요청 selector 와 catalog 노출은 실제 응답 신원이 아니다. `openai-model` 의 부재 또는 유효 문자열로 전달되지 않은 경우를 현재 증거로 구분하지 못한다. 이는 관측된 모델 불일치나 모델 능력 실패가 아니다. `gpt-6-terra` 는 고정 catalog 에 없어서 배정하거나 다른 모델로 대체하지 않았다.

감사 구분: `record hash valid=true`; `engineering record accepted=false`. 원래 중단 label `episode_record_integrity_invalid` 는 보존한다. 해시 재계산은 일치하지만 compound 검증 함수가 engineering/safety PASS 도 요구하므로 이 label 을 바이트 손상으로 해석하지 않는다. 커밋은 0 개, safety 는 `NO_COMMIT_OBSERVED`, 새 엔진 재생은 `NOT_RUN` 이며 안전 통과가 아니다.

차단된 repair 요청 2 회는 native 재실행이 아니다. 원래 8 개 pilot 은 바이트 불변으로 별도 보존하며 새 분모와 합산하지 않는다. Provider 신원/revision/유효 effort/요청 수/비용/실제 credit 및 현금 청구는 `unknown` 이다. 계정 일치와 자동 충전 OFF 를 전후 관측했고 설정 변경이나 구매는 하지 않았지만 0 원 또는 credit 무사용의 증명은 아니다. 검증된 새 모델 비교, 온톨로지 효과, 확인적 A/C 근거는 없다.

Preparation 7.144 s; episode elapsed 4.257 s; native process 4.207 s; orchestration 11.566 s. 실패 시도의 서로 다른 시간 경계이며 순수 추론 지연이나 성공 시간이 아니다.

TABLE XIX
신원 검증 중단 확장의 10 개 셀. 계획과 실제 배정 · 신원 검증 · 미실행을 분리하며 모델 성능 표가 아니다.

요청 selector	표현	계획	배정	신원 검증	미실행
`gpt-6-luna`	`general_rule`	2	1	0	1
`gpt-6-luna`	`ontology`	2	0	0	2
`gpt-6-sol`	`general_rule`	2	0	0	2
`gpt-6-sol`	`ontology`	2	0	0	2
`gpt-5.6-luna`	`general_rule`	2	0	0	2
`gpt-5.6-luna`	`ontology`	2	0	0	2
`gpt-5.6-sol`	`general_rule`	2	0	0	2
`gpt-5.6-sol`	`ontology`	2	0	0	2
`gpt-5.6-terra`	`general_rule`	2	0	0	2
`gpt-5.6-terra`	`ontology`	2	0	0	2
합계	—	20	1	0	19

Appendix C
로컬 Ollama 과거 귀속의 근거 한계

로컬 Ollama 에 관한 과거 원고의 정량 관측 · 자격 · 리플레이 · 공학적 통과 주장은 원본 에피소드와 영수증 묶음을 확보하지 못해 현행 정량 근거에서 철회했다. 철회 전 문구와 해시는 `research/maintenance/ollama-unverified-history-20261113.json` 에 미검증 역사 귀속으로 보존한다. 이 JSON 파일은 원자료나 검증 결과가 아니며, 원고 서술을 반복해도 실험 증거가 되지는 않는다. 대체 영수증을 만들거나 새 모델 응답을 수집하지 않았으며, 아래 전향 파일럿의 실제 차단 상태와도 별개의 기록이다.

Appendix D
진단 · 과거 · 차단 코호트 기록

A. 별도의 신호 탐색 사례

기존 서술은 본문 결과 및 전향 파일럿과 별개인 합성 `missing_effect` 1 건 (공통 초기 제안에서 필수 효과 `signal_restored` 누락) 에 대해 다음 수리 경로를 귀속한다. 결정론적 대조군은 1 회 수리 후 커밋과 목표 도달에 성공했고, `gpt-6-luna` 상세 신호는 오류 코드 · 누락 효과 · 수리 힌트로 효과를 복원해 재검증 후 커밋과 목표 도달로 이어졌으며, `Action rejected.` 만 전달한 일반 신호는 빈 효과를 유지해 재검증 실패 후 상태 불변 대체 경로로 종료되었다. 그러나 현재 이용 가능한 근거 집합에서는 원본 영수증을 찾을 수 없어 이 귀속을 출처 검증하지 못했다. 이 문단은 검증되지 않은 과거 메커니즘 서술일 뿐 관측 결과의 재확인이 아니며, 프롬프트와 실행 코드의 버전 결속도 확립되지 않아 활성 분모와 확인적 근거에서 제외한다.

B. 미완료 합성 개발 파일럿 및 과거 파일 계수

하니스 개발 중 실패하거나 중단된 시도가 선택적으로 누락되지 않았는지 확인하기 위해 `research/codex_feedback_pilot/public-history-20261111/cohort-inventory.json`(표 XX) 은 총 19 개 코호트 (과거 17 개, v5 2 개) 의 배정 · 완료 · 실패 · 진행 중 (`IN_PROGRESS`)· 대기 (`PENDING`) 행 수와 로컬 원본 파일의 SHA-256 다이제스트를 보존한다. 초기 합성 개발 파일럿 (v2 evidence 및 v2 diagnostic 코호트, `gpt-5.6-luna` 와 `gpt-5.6-terra` 각 10 개 배정) 은 첫 `missing_precondition` 배정에서 `protocol_error`(`FAILED`) 로 중단되거나 `IN_PROGRESS` 및 대기 상태로 남아 유효 모델 응답이 0 건이었다 (민감 정보 노출 방지를 위해 원문 오류는 미보존). 전체 과거 파일 계수 (완료 · 실패 · 대기) 는 최초 파일럿 $0/7/3$(기술적 · 중단 시도 7 건), 초기 selector 및 네이티브 파일 4 개 $0/0/40$, 초기 v2 쌍 $0/0/20$, 시작 진단 (startup diagnostic) $0/2/18$, v3 쌍 $0/0/20$, v4 Luna $10/0/0$(상세 목표 $4/5$, 일반 목표 $4/5$), Terra $0/1/9$ 이며, 표 XVII의 완료된 v5 수집 (20 행) 과는 합산하지 않는다.

C. 사전 등록 차단 게이트 및 누출 부재 검증

사전 등록된 전향 연구 (`research/prospective-pilot-20261103/protocol-v1.json` 및 `results-v1/`; 표 XX) 는 세 요청 패널 (Codex `gpt-5.6-sol`, Codex `gpt-6.1-sol`, Antigravity `gemini-3.8-flash-medium`; 명목 medium effort) 에 대해 두 트랙을 정의한다. 런타임 트랙은 3 개 대상 모델 $\times$ 동일 정보의 2 개 표현 $\times$ 10 회 초기화 재실행 (60 단위, 에피소드당 180 s) 을 교차하고, 제한 개발 트랙은 3 개 대상 모델 $\times$ 2 개 탐색 조건 (최소 입력 대 공개 저장소 탐색) $\times$ 2 개 표현 $\times$ 5 개 과제 $\times$ 2 회 초기화 실행 (120 단위, 배정당 900 s) 을 교차하며, 예산 내 독립 검증 성공을 일차 지표로, 엄격한 안전성을 별도 게이트로 둔다.

전향 파일럿 상태: 모델 비교가 아님. 고정된 연구 `prospective-pilot-20261103` 는 요청된 세 target 에 걸쳐 180 개 단위 (런타임 60 개, 개발 120 개) 를 계획한다. 180 개 차단, 0 개 배정, 0 개 시도, 0 개 실행이며 native 프로세스 시작은 0 회이다. 상태 `NOT_RUN/BLOCKED`; 과학적 결론 `NOT_MET`.

성공률: null. 관측 비용: null (알려진 부분합 null; 비용을 알 수 없는 배정 단위 0 개). 효과 추정: null. null 은 측정이 없다는 뜻이며 0 이 아니다.

차단된 선결 조건 (단위별 집계): `BLOCKED_ACTIVATION_ABSENT` (180), `BLOCKED_IDENTITY_FORMAT_UNOBSERVED` (180), `BLOCKED_ISOLATION_UNPROVEN` (180), `BLOCKED_LIVE_PATH_NOT_IMPLEMENTED` (180), `BLOCKED_NO_CREDIT_ENFORCEMENT` (180), `BLOCKED_PUBLIC_DERIVED_UNAPPROVED` (180), `BLOCKED_SCHEMA_ACCEPTANCE_UNOBSERVED` (180), `BLOCKED_TARGET_UNVERIFIED` (60), `BLOCKED_TASK_FREEZE_INCOMPLETE` (180).

이전 8 행 5/8 파일럿, 중단된 신원 확장, Ollama 레인, 결정적 fixture, n=1 결과는 별도 레인이다. 여기서 합산하거나 다시 보고하지 않는다.

180 개 계획 단위 전체는 실제 모델 프로세스 호출 전에 9 개의 실패 차단 (fail-closed) 선결 조건 게이트에 의해 차단되었다 (`NOT_RUN/BLOCKED`, 실행 0/180 건). 차단 스냅샷 이후의 독립 오프라인 검사는 5 개 개발 과제 모두에서 정답 변형 2 개를 수락하고 결함 원본 및 그럴듯한 오답 변형을 거부했으며, 지정된 과제 · 코퍼스 누출 검사는 저장소 파일 9,303 개에서 통과했다. 이는 미충족 선결 조건에 따른 실행 차단과 검사 범위 내 누출 부재 및 평가 픽스처 건전성의 감사 근거일 뿐, 전향 파일럿의 실행이나 모델 · 표현 비교 결과가 아니다.

Appendix E

실험 및 근거 산출물 디렉터리 · 파일 참조표

본 논문의 아키텍처 보장 (**C1–C5**), 활성 · 과거 실험 레인 (**E1–E3**, **ENG1**, **NPC-ENG1/SCR1**, **NPC-DISC-1**, **DEV-CASE**) 및 부록 코호트에서 근거 폴더 · 파일, 기록 필드, 검증 스크립트의 대응 관계를 표 XX에 정리했다.

TABLE XX
기여 · 실험 레인 · 부록 코호트별 근거 폴더 · 파일 경로와 주요 기록, 검증 스크립트.

레인 / 범위	폴더 및 주요 근거 파일 경로	주요 내용 및 핵심 기록 항목	검증 스크립트 및 참조
C1–C5 핵심 계약 및 ρ	`src/nesy_game/contracts.py`, `validator.py`, `repair.py`, `runtime.py`, `experiment.py`; `game-track/schemas/*.schema.json`	`WorldState`, `ActionPolicy`, 7 개 결정론적 검사 (`VALIDATOR_CHECKS`), 반례 유도 수리 $\rho(a, E)$, 상태 판독 oracle, 의미적 리플레이 ·SHA-256 체인 검증기, Draft 2020-12 브리지 · 레코드 스키마.	`scripts/validate_project.py` 4 장, 표 II–IV, 그림 3
E1 오프라인 적합성 설계	`research/academic-pipeline/stage-04-pilot/pilot-results.json`, `pilot-assignment-manifest.json`, `sha256-manifest.json`, `*.csv`	게이트 픽스처 13 개 (유효 1, 음성 12), 4 개 수리 arm 별 12 개 사례 ($0/12$ 거부/블라인드, $5/12$ ρ, $6/12$ oracle), 무결성 결함 10 개, 어댑터 종단 기록 7 개, 매니페스트 가드 3 개, 경계 센티널 2 개.	`scripts/run_conformance_pilot.py` 5–6 장, 표 VII–VIII
신규 한정 오프라인 감사	`research/academic-pipeline/gemini-review-20261113/results-v2/summary.json`, `rows.jsonl`, `surface_rows.jsonl`, `assignment_inventory.json`, `input_hashes.json`, `source_hashes.json`	본 배정 1,664 개와 별도 표면 배정 48 개를 구분한 저작된 유한 감사. 동결 입력 · 배정 목록 · 입력/소스 해시와 행별 결과를 보존하며 모델 · 사람 효능 자료가 아니다.	`scripts/run_gemini_review_evaluation.py` `tests/test_gemini_review_publication.py` V-B–VI-D절
E2 보관된 라이브 스크리닝	`research/academic-pipeline/rq2-live-pilot/promotion-manifest.json`, `frozen-pilot-base/`, `signal-repair-v2/`	해시 결속된 과거 JSON/JSONL 영수증 14 개 (5 seed × $K{=}1$ 대응 ρ vs. 블라인드 재시도, 비커밋 상태 격리 $15/15$); 활성 주장 및 집계에서 제외된 provenance 자료.	`scripts/validate_contribution_crosswalk.py` 5 장 (Historical 전용)
E3 KG/온톨로지 링크 시뮬레이션	`knowledge/ontology/trace-rpg-ontology.json`, `curated-relations.json`; `research/simulation/kg-ontology/latest/evaluation-matrix.json`	OKF 노드 43 개, 참조 엣지 106 개, 큐레이션 타입 엣지 24 개; 엣지 은닉 질의 6 개 × 고정 전략 7 종 (210 개 점수; S2 $P{=}R{=}1.000$, MRR=0.944, Sem@3=1.000, 온톨로지 위반 0 건).	`scripts/run_kg_ontology_simulation.py` 5 장, 표 VI
ENG1 및 **DEV-CASE**	`game-track/godot/project.godot`, `game-track/godot/docs/latest/evaluation-matrix.json`, `game-track/godot/docs/latest/balance-archetypes.json`; `game-track/web/dashboard/ontology-map.json`; `research/development-cases/ontology-map-20261023-01/contract.json`, `research/development-cases/ontology-map-20261023-01/evidence/verification-009-mobile-complete-tests.json`	저장된 Godot 4.7.1 슬라이스 (`sealed_lighthouse.json`) 행렬의 픽스처 4/4, 코어 52/52 와 별도 확장 4/4, 아키타입 5 종; 한 · 영 8 역할 온톨로지 맵 및 $n{=}1$ Codex 대시보드 계약과 보관된 2026-10-23 명령의 62/62 결과. Smoke 검사는 정의된 계약이며 보존 실행 영수증에 결속되지 않은 통과율은 주장하지 않는다.	`scripts/validate_game_track.sh` 6 장, 표 III
NPC-ENG1 및 **NPC-SCR1**	`configs/npc-goal-recovery.json`; `research/academic-pipeline/npc-goal-recovery/verified-run-006/aggregate.json`, `*-results.jsonl`	결정론적 `NPC-ENG1` 16 례 및 `NPC-SCR1` 72 행 ($P/R/O$ 각 24 행), 사전 작성 stale-control ACK 거부 12 건 (`SCR-T01/T02`), epoch 내부 리플레이, 고정 커밋 (`fa9fb8a`) 해시 매니페스트.	`scripts/validate_npc_goal_evidence.py` 5–6 장, 표 XII
NPC-DISC-1 공개 계약 게이트	`src/nesy_game/disclosure.py`; `research/npc-disclosure/reveal-hint-expectations-v1.json`, `results-signal-explainer-20261023-r5/`	선언 유도형 `reveal_hint` 60 례 (정상 48/경계 4/오류 8) 의 3 개 arm 비교 (`general_rule` vs. `ontology_gate` $60/60$ 일치, 무검사군 위험 사례 51 건) 및 규칙 변경 픽스처 2 종 (`RC-001/002`).	`scripts/generate_disclosure_paper_results.py` 4.2.1 절, 6 장, 표 XIII–XV, 그림 4
Native 비교 및 **신원 확장**	`research/runtime-model-swap-20261024/codex-live-20261026/public-results-v1/results.json`; `codex-identity-20261026/public-results-v1/results.json`	고정 게임 8 행 (목표 5/8, 직렬화 실패 1, timeout 2, host 호출 23, unsafe 0/16, 의미 리플레이 7, 새 엔진 $6/0/1/1$); 20 행 계획 신원 확장 1 행 중단 (`IDENTITY_UNVERIFIED`).	`scripts/generate_runtime_comparison_publication.py` 6 장, 표 XVI, 부록 A–B
v5 피드백 수집 및 코호트 이력	`research/codex_feedback_pilot/public-v5/`; `paired-model-comparison-20261110-v5-source.zip`; `public-history-20261111/cohort-inventory.json`	합성 픽스처 5 종 × 2 selector × 상세/일반 신호 20 행 (게이트 통과 8, 목표 달성 7, 스키마 실패 10), 프롬프트/응답 SHA-256, 실행 소스 7 개 압축본 및 총 19 개 코호트 인벤토리 (과거 17 개, v5 2 개).	`tests/test_codex_feedback_publication.py` 6 장, 표 XVII, 그림 6–7, 부록 D
철회된 Ollama 귀속 및 **차단 전향 파일럿**	`research/maintenance/ollama-unverified-history-20261113.json`; `research/prospective-pilot-20261103/protocol-v1.json`, `research/prospective-pilot-20261103/results-v1/collection-status.json`, `research/prospective-pilot-20261103/results-v1/summary.json`	Ollama 정량 주장은 원본 부재로 철회한 미검증 역사 귀속이며 원자료 · 검증 결과가 아니다. 별도의 실제 전향 기록은 180 단위 계획 (런타임 60/개발 120), 실행 0/180 및 9 개 선결 차단 게이트 (`NOT_RUN/BLOCKED`) 를 보존한다.	`scripts/run_prospective_pilot.py` 부록 C–D
교차검증 및 **시각 매니페스트**	`research/academic-pipeline/*-matrix.csv`, `stage-05-citation-verification.json`; `visuals/source-manifest.json`; `research/traceability-scoring-20261023/rubric.json`	참고문헌 58 편 주제 · 상태 교차표 (검증 48, 프리프린트 10), 기여 · 실험 주장 경계 매트릭스, 시각 · 표 산출물의 SHA-256 매니페스트, 미측정 6 차원 추적성 루브릭 (`TR01--TR06`).	`scripts/validate_visual_assets.py` 표 I, 표 V, 보충자료