

TRACE-RPG: 인터랙티브게임세계의생성이벤트를위한 trace 연결기호커밋게이트

익명저자

Abstract—대규모언어모델은표현력있는퀘스트와대화를생성할수 있지만, 유창하거나스키마에맞는텍스트만으로제안이벤트의실행가능성, 권한적합성, 정식게임상대와의일관성이성립하지않는다. 본논문은생성된모든이벤트를신뢰하지않는트랜잭션제안으로취급하는기호커밋게이트 TRACE-RPG 을제안한다. 타입엄격 parser, 외부공급 행동정책, 여섯상태상대계열로묶인일곱개의결정론적검사가각하용전이를결정하며, 실패후보는최대 $K + 1$ 개의기록된시도안에서제한수리로보낼수있고통과후보는변경전전에서다시검증한다. 반례유도연산자 ρ 는직전후보와그 typed validation error 만읽고권위있는상태는결코읽지않는다. 키없는 SHA-256 콘텐츠연결, 상태의미 replay, 할당 완전계수가모든 terminal outcome 을감사가가능하게만든다. 근거는세레인으로분리한다. 단일작성 world 의결정론적오프라인적합성파일럿, 단일모델라이브스크리닝확장, 런타임권한이없는 closed-world 지식그래프링크제안시뮬레이션이다. 오프라인레인은 mechanism 적합성만확립한다. 라이브레인은 $K=1$ 에서의도적으로수리가가능하게만든 policy-blind regime 에한해 guided 5/5 대 blind 0/5 commit 을관찰했으므로 pilot-only 로남는다. 어느레인도모집단효능, 모델우월성, 플레이어경험, 상용엔진성능을확립하지않는다.

Index Terms—게임인공지능, 인터랙티브내러티브, 기호검증, 제약 생성, 런타임강제, 재현성

I. 서론

인터랙티브생성은언어과제에그치지않는다. 후보이벤트가자연스러워도존재하지않는아이템을요구하거나, 화자가모르는사실을주장하거나, 금지된퀘스트정보를공개하거나, 허가되지않은효과를도입하거나, 퀘스트단계를후퇴시킬수있다. 실행가능한텍스트환경은그렇듯한발화와유효한전이의차이를명시한다 [1], [2]. 근거기반대화개입화퀘스트시스템은퀘스트, 엔터티, 그래픽팩의가치를추가로보여주지만 [3], [4], 맥락자체가정식상태변경을승인하지않는다. TRACE-RPG 은생성된게임이벤트를신뢰하지않는트랜잭션제안으로취급하며, 정식상태변경을외부의결정론적 commit gate 를통해서만허용한다. 그림 1는그러한트랜잭션하나를왼쪽에서오른쪽으로읽는다.

구조적생성제약은인접한문제를해결한다. 문법제약디코딩, 언어모델질의언어, 점진파서는생성구조를제한할수있다 [5], [6], [7]. 그러나구문상허용되는이벤트도현재세계에대해서는거짓일수있다. 검색과메모리는유용한근거를공급할수있지만 [8], [9], [10], 검색된내용역시상태전이의권한주체가아니다.

본논문은이러한관심사를감사가가능한트랜잭션프로토콜로결합한구현인 TRACE-RPG 을제시한다. 현재기여는다음과같다.

- 1) **C1—계약**: 버전형신뢰경계 contract 와, proposal/replay 경계에서 unknown key 와모호한타입을거부하는 type-strict parser (IV절; E1);
- 2) **C2—controller**: 여섯상태상대계열에걸친검사 7 개, bounded repair, unchanged fallback, pre-commit revalidation 을갖춘 validate-repair-commit controller (IV-B절; E1, ENG1);
- 3) **C3—감사**: SHA-256 연결 record, state-semantic replay, episode-continuity check (IV-C절; E1, ENG1);

익명심사를위해제출된원고입니다.

TABLE I
기여, 선행주제, 근거레인, 추론상한 (구조화매트릭스에서생성)

ID	기여	선행주제 (참고문헌수)	레인	추론상한
C1	신뢰경계 contract	T1, T2, T3 (15)	E1, ENG1	인코딩필드계약적합성
C2	validate-repair-commit controller	T1, T8 (14)	E1, ENG1	동결사례의메커니즘 동작
C3	감사연결근거계층	T4, T7, T8 (6)	E1, ENG1	명명 fixture 의무결성 · 재생
C4	assignment-complete harness	T4, T6, T7 (18)	E1	설계사례정확집계
C5	반례유도연산자 ρ	T1, T8, T9 (8)	E1, E2	동결 class + 단일 regime screen

T1 = 근거게임세계; T2 = 검색 · 메모리에이전트; T3 = 구조생성; T4 = 환경 · 벤치마크; T5 = 플레이어경험; T6 = 인간 · LLM 평가; T7 = 통계 · 재현성; T8 = 계획 · 런타임개입; T9 = 피드백수리. 레인은표 IV에정의한다. 모든행은구현 · 작성 fixture 검증상태이며어떤 C-RESULT-* 효능 claim 도지지하지않는다.

- 4) **C4—harness**: proposal trace 가존재할수없는경우에도분류된 terminal row 를유지하는 assignment-complete 오프라인적합성 harness (V절; E1);
- 5) **C5—수리**: 동결 repairability class 에서 blind retry 및 state-reading oracle 과비교한 counterexample-guided operator $\rho(a, E)$ (IV-B절; E1, E2).

기계검증되는기여매트릭스에서생성한표 I은 C1–C5 를선행주제, 근거레인, 추론상한에결합하고, 표 IV는레인을정의한다.

레인은서로대체할수없다 (표 IV). E1 은단일작성 world 의결정론적적합성파일럿으로인코딩된메커니즘동작을측정하며모집단효능은측정하지않는다. E2 는셀당 5 회호출의라이브스크리닝으로, 고정되지않은 revision, 제어되지않는 seed label, 구성된 state 때문에 pilot-only 가상한이다. E3 는런타임검색없이 closed world 에서작성된 typed-link proposal 만채점한다. ENG1 은엔진코걸 Godot 4.7.1 적합성만추가한다. 참여자, 감정실험, live Python-Godot 왕복은없다.

II. 관련연구와연구공백

A. 인터랙티브내러티브와게임에이전트

KNUDGE 는퀘스트와엔터티명세에근거한분기형 NPC 대화를평가한다 [3]. 지식그래프보조퀘스트생성 [4], 메모리-성찰-계획에이전트 [11], 학습가능한역할연기에이전트 [12] 는근거성과개연성있는행동의상호보완적측면을다룬다. 플레이어대상연구는선택과지각된대화품질을평가한다 [13], [14]. Yin 등의 2026 년온라인레코드는서지감사당시미래시점의권호가배정되어있어제출시다시확인해야한다 [15]. 2025 년프리프린트는역할에따른안정성-측정성 trade-off 를보고하며 [16], 본논문은이를최근동기로만사용한다. 이연구들은하드허용가능성을선택적자연스러움및플레이어경험구성개념과분리할필요성을뒷받침한다.




Fig. 1. 생성이벤트하나의트랜잭션경로다. typed candidate 만신뢰검계를넘고, 외부 policy 와 c_t 를여섯상태상대계열의검사 7 개가확인한다. typed 오류 E 는 bounded ρ (점선) 또는변경없는 fallback 으로이어지고, 통과후보는재검사-commit-record-replay 된다. 태그는 claim 이아닌측정범위를표시하며, 아래 strip 은 committed snapshot 에서파생한 ledger 문법이다.

경험주도콘텐츠생성 [17] 과관찰자료식참여도 [18] 는미래적응트랙의동기가된다. 최근프린트는 vision-language model 의참여도추론한계를보고한다 [19]. 따라서감정은비권위적맥락으로유지되며현재구현근거에는포함되지않는다.

B. 환경과벤치마크

TextWorld 와 ScienceWorld 는명시적인인터랙티브상태를제공하며 [1], [2], MineDojo 는개방형지식집약 embodied 과제를추가한다 [20]. General Video Game AI 는에이전트, 게임, 콘텐츠트랙을분리한다 [21]. AgentBench 는이질적인환경의에이전트를연구하고 [22], AgentBoard 는과정수준진단을추가하며 [23], SOTOPIA 는사회적상호작용을평가하고 [24], BALROG 는장기언어및시각게임추론을평가한다 [25]. 자동화된플레이스타일에이전트는상호보완적인시험선레이지만인간평가를대체하지않는다 [26]. 이벤치마크는미래평가설계에정보를주지만트랜잭션승인경계를규정하지는않는다.

C. 제약, 신경-기호검증, 검색

제약디코더는출력구조를개선한다 [5], [6], [7]. 반면 TRACE-RPG 은구조를독립적인상태상대승인의입력조건으로취급한다. 같은 generate-and-verify 분업은게임박에서확립되어있다. LLM-Modulo 프레임워크는모델이제한한계획을외부의 sound critic 이수락또는거부하게하고 [27], SayCan 은언어로제한된 skill 을상태의존 affordance 검사뒤에만허용한다 [28]. AgentSpec 은 LLM 에이전트의런타임규칙을 trigger-predicate-enforcement 삼중항으로표현하고 [29], TRACE-RPG 은술어를게임상태에고정하며수리계약과리플레이가능한레코드를추가한다. Setting the DC 는 D&D 에이전트를 precondition 검사있는 tool call 예근거시키는반면 [30], TRACE-RPG 은자유텍스트제안을 parsing 과외부 policy 평가뒤에만허용한다. STORY2GAME 은플레이에쓰이는 action

precondition 과 effect 를 LLM 스스로생성하게하지만 [31], 여기서는 policy 가제한자와독립적으로저장된다. TRACE-RPG 은이 critic 을 typed 반례를반환하는결정론적상태상대 commit gate 로구체화한다. 게임특화비교대상은서로다른경계를보여준다. PANGeA 는 LLM 이설계자규칙에따라콘텐츠를판정하고수정하도록해검증하고 [32], 비아카이벌 ICC 2026 자료와연계된프린트 IVIE 는기호검증으로인터랙티브픽션세계를점진적으로생성하며 [33], 같은계보의 2026 년후속시스템은 LLM 을저작된 world-state transformation 선택으로제한해 [34] 트랜잭션게이트, 감사연결레코드, 수리연산자근거없이구성상일관성을얻는다. 어느비교도우월성을뜻하지않으며, 유효성은각시스템이인코딩한술어에한정된다.

G-Retriever, HippoRAG, Mem0 는관련하위그래프검색과장기메모리를다루고 [8], [9], [10], Generative Agents 와 Character-LLM 은행동메모리와 persona 를다룬다 [11], [12]. TRACE-RPG 은향후이러한맥락을사용할수있지만직접적인커밋권한은부여하지않는다. 검색과시간적메모리효익은여기에서측정하지않는다.

D. 감사가능성과재현성

과정지표는중간실패를보존할동기를제공하고 [23], 강건한평가는소수확률적실행의과도한해석을경고한다 [35]. 재현성과환경보고지침은동결된산출물과명시적측정경계를뒷받침한다 [36], [37]. 인간및 LLM 평가는구성개념, 평가자, 편향통제를요구하며 [38], [39], [40], [41], 향후비열등성과참여자분석에는정당화된 margin 과 random-effects 구조가필요하다 [42], [43]. Record-and-replay 는경험재사용을위한확립된에이전트패러다임이지만 [44], TRACE-RPG 은승인된상태전이의의미적리플레이만주장한다.

제한된 novelty 는개별구성요소의발명이아니라구현된결합이다. 선행연구는범용에이전트의런타임강제 [29], 생성된게임세계의기호적상태관리 [30], [31], 피드백기반수리 [45], 에이전트 record-and-replay [44] 를각각따로보여준다. TRACE-RPG 은이들의교집합을게임상태 commit 경계에서연구한다. 즉 parsing 된제한을독립적인 policy 와결정론적술어로검사와, bounded validator feedback 으로선택적으로수리하며, 의미적리플레이를위해기록한다. 행동개입 (interposition) 자체는오래된기법이다. 내러티브 mediation 은행동을실행전에게로채고 [46], 고전계획법은 precondition 과 effect 로적용가능성을정의하며 [47], 런타임강제는허용된제한만통과시키고 [48], 트랜잭션처리 abort 시이전상태를그대로남기며 [49], 작성형논리기반인터랙티브드라마는캐릭터가할수있는발화를규율했고 [50], 신념인지내러티브계획법은캐릭터가아는바를추론한다 [51]. 후자는본문의 knowledge/disclosure 술어가훨씬거칠게인코딩하는관심사다. C1-C2 는 strict contract 와 validate-repair-commit controller 를이게보위에배치하고, C3-C4 는 checksum-linked record, state-semantic replay, episode continuity, proposal trace 가없는사레까지보존하는 assignment-complete accounting 을더하며, C5 는실행전 typed validator error 만소비하는수리연산자를분리한다. 보고서에기능이없다고해서모든구현에그기능이없다고추론하지않는다.

III. 문제정의와보장경계

설명을위해시점 t 에서 validation 이사용하는 controller 입력을다음과같이분해한다.

$$c_t = (G_t, q_t), \quad (1)$$

여기서 G_t 는 typed snapshot field 를, q_t 는 해당 snapshot 과함께 저장되는 외부작성 action-policy, disclosure, quest-stage 제약 을 나타낸다. 중단 record history $h_{<t}$ 는 WorldState snapshot 과 별도로 유지된다. Validation predicate 는 이를 읽지 않으며 구현 은 log 에서 상태를 재구성하지 않는다. 검색, 내러티브점수, 모델 rationale, 메모리 요약, 미래의 감정 추정 은 비권위적 proposal context 이다.

신뢰하지 않는 proposer 가 후보 a_t 를 출력한다. 타입 엄격 parsing 은 알 수 없는 top-level field 의 거부 를 포함한 공유 candidate-key contract 를 먼저 강제 하고 선언 스키마를 확립한다. validator 는 다음을 반환한다.

$$V(c_t, a_t) = (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, v_{\text{disc}}, v_{\text{quest}}, E_t), \quad (2)$$

여기서 E_t 는 구조화 오류 집합이다. 상태 변경 은 다음과 같다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_i v_i = 1, \\ c_t, & \text{그외.} \end{cases} \quad (3)$$

Controller 는 인코딩된 계약 아래 다음 구현 불변량을 주장한다. 파일럿 은 이를 일반 정리로 제시하지 않고 deterministic valid, invalid, repair, fallback, replay, fault-injection fixture 로 해당 mechanism 을 시험한다. **I1 (소진 실패 불변성):** 예산 K 까지 반환되면 후보도 검증을 통과하지 못하거나 proposal/controller 실행이 commit 전에 실패하면 반환 상태는 공급된 prior state 와 같다. **I2 (제한된 기록 시도):** 모든 proposal 과 repair callback 이 반환한다는 조건에서 repair budget $K \geq 0$ 은 최대 $K + 1$ 개의 candidate attempt 를 기록한다. 성공적인 commit 은 변경 전 수락 후보에 대한 방어적 validation 을 한번 추가한다. Runtime 은 callback deadline 을 강제하지 않으므로 I2 는 wall-clock 종료 보장 이 아니다. **I3 (효과 권한):** 수락 후보는 ActionPolicy.allowed_effects 밖의 선언된 fact effect 를 CandidateAction.effects 에 포함하지 않으며, quest-stage target 도 해당 policy 에 의해 명시적으로 승인된다. **I4 (상태의 의미적 리플레이):** 동결된 스키마와 결정론적 전이 아래 수락된 trace 는 명시된 terminal state 를 재구성한다.

이 주장된 불변량은 올바른 정책 작성, 선언된 후보 필드로의 완전하고 충실한 추출, 결정론적 소프트웨어 버전, callback 반환, 단일 프로세스 파일 소유권 을 가정한다. 상태의 의미적 리플레이는 기록된 구조화 후보와 전이를 재검증하지만, 중간 수리의 provenance, reasoning, prompt, 확률적 생성 은 재현하거나 검증하지 않는다. 구조화 필드에서 누락된 자연어 함의는 보장 범위 밖이다.

IV. TRACE-RPG 아키텍처와 알고리즘

A. 신뢰 경계와 계약

그림 1 는 모델 또는 recorded adapter 를 canonical owner 밖에 둔다. Parser 는 알려진 필드의 모호한 숫자 또는 collection type 을 거부 하고 공유 key contract 에 따라 알 수 없는 top-level candidate field 도 거부 한다. action policy 는 candidate 와 별도로 공급되며 required precondition 과 allowed effect 를 정의한다. Game bridge 는 observation, proposal, validation, rejection, fallback, commit 을 전달할 수 있는 versioned event interface 이며, 정식 상태 변경 은 유효한 commit 만 승인한다. 이는 interface 를 분리하지만 상용 엔진으로의 portability 를 아직 입증하지 않는다. 표 II 는 구현 검사 7 개를 여섯 의미적 계열로 묶는다. Quest eligibility 와 quest-stage monotonicity 는 별도 검사로 유지된다. 이 인코딩 경계는 의미적 완결성 주장 이 아니다.

TABLE II
인코딩된 Validator 경계

술어	거부 대상	실패시 상태
Action policy	알 수 없는 action/type	변경 없음
Precondition	누락/거짓 requirement	변경 없음
Reachability	접근 불가 object	변경 없음
NPC knowledge	선언되지 않은 known fact	변경 없음
Disclosure	forbidden fact	변경 없음
Quest	부적격/후퇴 stage	변경 없음

```

1:  $a \leftarrow \text{Propose}(c); j \leftarrow 0$ 
2: repeat
3:    $(ok, E) \leftarrow V(c, a); \text{Record}(a, E)$ 
4:   if  $ok$  then
5:     assert  $V(c, a).ok$ ; return  $\text{Commit}(c, a)$ 
6:   if  $j = K$  then return  $\text{Fallback}(c)$ 
7:    $a \leftarrow \text{Repair}(c, a, E); j \leftarrow j + 1$ 
8: until terminal

```

Fig. 2. Validate-repair-commit 절차. 최대 $K + 1$ 개의 candidate attempt 를 기록하며, 성공 경로는 상태 변경 전 방어적 validation 을 수행한다.

B. Validate-Repair-Commit

그림 2 는 제어기의 추가 패키지가 없는 의사 코드를 제시한다. “Record” 는 in-memory trace 표현에 추가하는 것을 뜻하며, 영속시키는 중단 일관성 검사 뒤에 만 수행한다.

검증 오류는 구조화된 error code 로 repair callback 에 노출된다. repair 는 상태를 직접 변경하지 않으며, 예산 소진 시 변경 없는 결정론적 fallback 을 반환한다. 그림 1 이 중단 경로를 나타낸다. 파일럿 은 구현된 두 callback 을 비교한다. 반례 유도 연산자는 직전 후보 a 와 validator 의 구조화 오류 집합 E 만을 소비하며 권위 있는 상태는 결코 읽지 않는다.

$$\rho(a, E) = a \oplus \bigcup_{e \in E} \delta(e), \quad (4)$$

여기서 각 $\delta(e)$ 는 표 III 의 오류 class 별 결정론적 edit 이고 $\oplus$ 는 그 field edit 들을 적용한다. 각 edit 은 오류 entity 당 최대 하나의 candidate field 만 수정하므로 시도당 변경 field 수는 $|E|$ 로 유계이고, 같은 오류 집합으로 ρ 를 두 번 적용하면 고정점이며, 같은 field 에서 동시에 요구되고 거부되는 entity 는 수리 불가능 선언되어 수정되지 않는다. 상태를 읽는 참조 callback 은 반대로 오류 집합을 폐기하고 정책이 규율하는 field(precondition, effect, 두 quest-stage field) 를 권위 있는 상태에서 직접 재구성한다. 이 callback 은 선언 무결성 field(required object, used fact, disclosed fact) 를 인도적으로 수정하지 않는다. 의존성이나 disclosure 의 선언을 지우는 것은 후보를 수리하는 것이 아니라 위반을 게이트 워로 세탁하는 것이기 때문이다. 이는 상태 판독 가능 수리에 대한 oracle 상한이며, 그 결과 배포 가능한 수리 방법의 근거로 읽어서는 안 된다.

C. 무결성, 의미적 리플레이, 계수

각 result row 는 키 없는 SHA-256 무결성 체크섬 을 가지며, proposal outcome 은 추가로 trace checksum 과 연결된다. 이 hash 들은 우발적이거나 시험 대상 인 콘텐츠 변경을 탐지하지만 signature, message-authentication code, writer identity 가 아니며 콘텐츠와 checksum 을 모두 다시 쓸 수 있는 행위자에 대한 보호도 아니다. 의미적 리플레이는 prior state 와 기록된 모든 candidate/validation pair 를 엄격히 parsing 하고, final 이 아닌 모든 attempt 가 invalid 임을 요구하며, terminal transition 을 재 계산하고, 명시된 final state 와 비교함으로써 byte 무결성을 넘어

TABLE III
유도연산자 ρ 의오류 class 별 edit

Validator 오류 class	후보에대한 edit $\delta(e)$
정책 precondition 누락	명명된 predicate 삽입
정책 effect 누락	명명된 effect 삽입
정책 effect 위반	명명된 effect 제거
불충족 precondition	명명된 predicate 제거
비인가 stage 변이	quest_stage_effect 초기화
알수없는 action type	no-op (등록된대안없음)
도달불가 object; knowledge, disclosure, stage class	no-op (후보국소 edit 은세탁이거나 상태지식필요)

TABLE IV
실험레인 요약: 설계, 단위, 비교, 추론상한 (실험매트릭스에서생성)

레인	설계	단위 / 예산	비교	상한
E1	오프라인적합성: 작성 · 동결 fixture, 단일 world	gate 13; arm 당 repair 12; fault 10; adapter 7; guard 3	reject / blind / ρ / oracle	메커니즘적합 성
E2	라이브 RQ2 스크리닝: hosted proposer 1 개, matched candidate	5 cell $\times$ 5 call; $K=1$	regime 별 ρ / blind	pilot-only 전 이 screen
E3	KG/온톨로지시물레이 션: closed-world typed-link holdout	node 43; 참조 edge 106; typed 24; score 210	degree baseline / 고정전략 6 중	구성결과만
ENG1	Godot/Web 엔지니어 링: 엔진로컬 policy mirror, 참여자없음	fixture 4; check 52; smoke 8; archetype 5	작성 fixture 경 로	엔진로컬적합 성

E1-E3 와 ENG1 은서로대체할수없으며분모가다르다. 어떤레인도모집단효능, 모델순
위, 플레이여경험, 런타임검색효익, 상용엔진성능을확립하지않는다.

선다. Episode replay 는인접 JSONL record 사이의상태연속성
도요구한다. Replay 는 candidate $j+1$ 을만든 repair-generation
단계를인증하거나다시실행하지않는다.

Terminal record class 는 commit, symbolic fallback, adapter
failure, controller failure 이다. Controller-failure row 는동결
된 assignment denominator 에남고상태를변경하지않지만, can-
didate outcome 이생성되지않았다면완성된 proposal trace 가없
어도된다. 따라서 result completeness 가모든 terminal row 의
trace 존재를뜻하지않는다. 실행전 assignment key 는 (run, arm,
scenario, seed, model, revision, $h_{\text{controller}}$, h_{input} , h_{prior}) 이다. 집
계는중복, 누락, 예기치않은 key 를거부하고 symbolic, adapter,
controller failure 를각각보고한다.

V. 실험레인과근거경계

표 IV는어떤 count 를읽기전에각레인의설계, 단위, 비교, 상
한을고정한다.

A. E1 오프라인적합성설계

파일럿은다음을묻는다. (PQ1) 유효후보는 commit 되고명명
된 invalid-policy 사례는변경없이유지되는가? (PQ2) 동결된모
든 repairability class 의작성사례에서 rejection-only, 블라인드
동일후보 retry, 반례유도연산자 ρ , 상태를읽는참조 callback 이
예상결과를만드는가? (PQ3) 동결된 checksum, state-semantic,
linkage, continuity mutation 이지정된검사연산에서거부되고,
두번째파일 append 의주입된실패가예상 pair-write rollback
검사를작동시키는가? (PQ4) 엄격한 adapter 와 assignment
manifest 가할당사례마다정확히하나의분류된 terminal row
를유지하거나 fail closed 하는가? (PQ5) proposal 및 replay

parser 가그외에는완전하고유효한 candidate 에 unknown top-
level key 하나를추가한사례를모두거부하는가?

사례는의도적으로설계된적합성픽스처이며모델또는게임모집
단의표본이아니다. 네도메인은 validator/state isolation, repair-
arm 비교, record/trace fault injection, adapter/accounting con-
tract 이다. 모든 repair fixture 는실행전에동결된 repairability
class 를선언한다. *guided-repairable*(구조화오류 payload 만으
로 ρ 에충분한정보가담김), *oracle-only*(수리에권위있는상태
판독이추가로필요함), *irreparable*(구현된어떤 arm 도 commit
할수없음)이며, class 별 arm 당기대결과는설계픽스처계약
의일부다. 반복된결정론적 seed 가아니라고유사례가기술적
denominator 를구성한다. 모든기대값은실행전에명시한다.

측정치는정확한 count 이다. expected/observed validator-
class agreement, rejected 또는 controller-failure 사례의 state
mutation, repair arm 과 repairability 별 commit 및 attempt
결과, 지정된연산에서거부된/사전명세된 detectable fault,
replayed/committed trace, rejected/injected manifest violation,
사전명세한 unknown-key 음성회귀에대한 proposal/replay 거
부일치를선다. 마지막측정은결정론적 parser-contract parity 이
며실증적 safety outcome 이아니다. Exception class 만으로안
정적인 detector layer 를식별할수없으므로 detector 귀속결과
는보고하지않는다. 의도적으로설계된픽스처에 p -value 나모집
단 confidence interval 을부여하지않는다. Adapter 사례가지닌
latency 및 token 상수는입력스키마가 JSON-Schema const 로
고정한합성값이다. 이값들은계수필드전파만확인하며 provider,
runtime, device 에대한측정값이아니다.

릴리스패킷은 fixture 및 assignment manifest, schema,
outcome/trace record 를포함한 result JSON 산출물, 환경과
코드 revision, 생성 table, checksum 을동결한다. 보고는재현성
과측정경계지침을따른다 [36], [37].

B. E2 라이브 RQ2 스크리닝

라이브확장은블라인드동일후보 retry 와 ρ 를동일한 $K=1$
에서비교한다. 각셀에서 seed 로구분한 Codex CLI 호출 5 회
가 gpt-5.6-sol 후보하나씩을만들고, 두 arm 은같은최초후
보를받아호출내제안차이를제거한다. 조건은 policy 공개여부
와자명한효과 0 경로의존재를바꾼다. 승격패킷은정정된현재셀
과폐기된 v1 진단을함께보존하고모든 JSON/JSONL 영수증을
SHA-256 으로결합하며근거를 screening-pilot-only 로표
시한다. Seed label 은 hosted sampler 를제어하지않고, hosted
revision 은고정되지않았으며, token 회계는없고, 구성상태는모
집단표본이아니다. 따라서 p -value, confidence interval, 모델순
위없이정확한기술 count 와실패 class 만보고한다.

C. E3 KG/온톨로지링크제안시물레이션

세번째레인은권한을가진 typed WorldState 와분리된
engineering-only closed-world 시물레이션이다. 저장소로컬
OKF node 43 개와 reference edge 106 개를내보내고, 검
토된 typed edge 24 개를 overlay 하며, type/domain/range
무결성과 source 별 competency question 6 개를검사와,
권한이없는 SQLite mirror 를생성한다. 고정전략 7 개는
작성형질의 6 개와질의당후보 5 개를평가했다. Retained
S2-typed-lexical-loose 는 holdout 6/6 을복원했고 ($P =$
 $R = F_1 = 1.000$, realistic-tie MRR = 0.944, Brier = 0.131,
Sem@3 = 1.000), degree baseline 은하나도복원하지못했다.
Machine-generated JSON, TSV, TeX, SVG 산출물이전체수식
과 trial 을보존한다. 이는구성결과이며 OWL/SHACL 적합성,

의미완전성, runtime retrieval, 장기모순감소, 어떤효능주장의 근거도아니다.

VI. 파일럿결과

A. 구조필드게이트적합성

파일럿 loader 는 구현된 validator code 를정확히한번씩고립시키는 fixture 집합과유효 control 1 개만을허용한다. 따라서 13/13 일치와구현된오류코드 12 종의관찰은측정된성공률이라 아니라 하니스의구성불변량이다. 이실행이보여주는것은 loader 가강제하지않는부분, 즉고립된유효성 fixture 12 개가각각다른코드가아니라작성된기대코드와일치했고비 commit 경로가전체정준상태를유지했다는관찰이다. 이는단일 world state 에서저자가설계한구조필드 oracle 에대한구현적합성이며독립의미판정의정확도가아니다.

B. 설계픽스처에서의수리 arm 비교

처음부터유효하지않은설계 case 12 개는 guided-repairable 5 개, oracle-only 1 개, irreparable 6 개의동결된 repairability class 로분할된다. Rejection-only 와블라인드동일후보 retry 는각각 0/12 commit 이었다. 반례유도연산자 ρ 는 guided-repairable case 5/5 를 commit 했고, 설계상 oracle-only 0/1, irreparable 0/6 었다. 모든 ρ commit 은 candidate field 를평균 1.0 개수정했으며, 실패한모든 arm 실행은정준상태를변경없이유지했다. 상태를읽는참조 callback 은 guided-repairable 5/5 와 oracle-only 1/1 를 commit 했고 irreparable 은 0/6 었다. 이정확한 count 는세메커니즘을설계픽스처위에서분리한다. 블라인드 retry 는반례를 commit 으로전환하지못하고, ρ 는오류 payload 에충분한정보가담긴 case 만전환하며, oracle 은상태지식이필요한 case 를추가로전환한다. commit 된 guided case 5 건이처음받은 validator code 는각각 POLICY_PRECONDITION_OMISSION+UNSATISFIED_PRECONDITION, POLICY_EFFECT_OMISSION, POLICY_EFFECT_VIOLATION, UNSATISFIED_PRECONDITION, POLICY_QUEST_STAGE_EFFECT_VIOLATION 이며, 각 case 는표 III의해당 edit $\delta(e)$ 만으로유효해졌다. 이는동결픽스처에대한연산자적합성이며, 어떤 live model 의수리품질도아니다.

C. 무결성, 경계, 배경회계

현재명세가검출가능하다고지정한 10 개 fault fixture 는모두지정된검사연산에서거부됐다 (10/10). 이파일럿은안정적인 typed detector code 까지대조하지않으므로 detector layer 귀속을입증하지않는다. 별도로, 동일하게기록된유효수리앞의 무효선행후보를다른무효후보로치환하고체크섬을재계산한알려진 provenance 경계는예상대로재생을통과했다 (1/1 미검출). 따라서키없는체크섬을재계산할수있는작성자를방어하지 않으며, 재생은 repair 생성연산의출처를인증하지않는다. 열린경계 sentinel 두건—자연어 disclosure 미추출과 required object 의후보 · 정책동시누락—은 2/2 가의도대로인코딩상 허용됐고 safety pass 는 0 건이었다. 과거 unknown top-level field 허용경계는 Stage 8 이후단일음성회귀로재분류되었으며, 완전한 12-field candidate 에 unknown key 하나를추가한 fixture 를 proposal-replay parser 모두구체적으로거부했다 (1/1). 이는 parser rejection parity 이지의미안전성의증거가아니다. Adapter/accounting 7 개배정에서는 commit 1, 기호 fallback 1, adapter failure 5 었다. 합성 telemetry 필드는 2/7 배경에서채워져전파됐으며, 이는측정값이아니라회계필드전파

TABLE V
수리 arm 별 repairability class 정확집계 (설계픽스처)

Arm	정보원	Commit / 사례			평균수정 ^e
		G-rep. ^f	O-only ^f	Irrep. ^f	필드수
Rejection-only ($K=0$)	없음	0/5	0/1	0/6	—
블라인드 retry	없음	0/5	0/1	0/6	—
반례유도 ρ	오류집합 E	5/5	0/1	0/6	1.0
상태판독 oracle	권위상태 + 정책	5/5	1/1	0/6	1.0

^eCommit 된수리의변경 candidate field 평균개수 (최소성 proxy); 실패한 arm 실행은상태를변경하지않았다. ^fCommit/사례수. G-rep. = guided-repairable, O-only = oracle-only, Irrep. = irreparable(동결 repairability class).

TABLE VI
동결파일럿검사와중단결과 (행간직접비교불가)

검사또는중단군	정확결과	해석범위
게이트 fixture 일치	13/13	저자 oracle 일치
알려진경계허용	2/2	인코딩한계, safety pass 아님
달린 unknown-key 거부	1/1	proposal/replay parser parity
탐지가능무결성결함거부	10/10	지정된검사연산
알려진 provenance 경계허용	1/1	repair 생성출처미인증
Adapter 중단 class	1 commit; 1 fallback; 5 실패 / 배경 7	배정 7 건의분류완전성
Manifest guard 거부	3/3	주입결함 fail-closed

행마다분모와성공방향이다르므로비율치를순위를비교하지않는다. 모든값은설계픽스처의정확한감사사실이다.

확인이다. 배경 guard 3/3 가중복 · 누락을거부했다. 이수치는 모두합성 offline fixture 의 raw count 다.

표 V와 VI은정확한설계픽스처 count 를보고한다. 수리표는 동결된 repairability class 별로네 arm 을분리하며, 어느표도모집단도는 live-model 추정을지지하지않는다.

D. 라이브스크리닝파일럿 (pilot-only)

별도스크리닝파일럿은 Codex CLI 를통해 gpt-5.6-sol 을호출했다. 셀마다 seed 로구분한제안호출 5 회와수리예산 $K=1$ 을사용했고, 각호출의최초후보하나를블라인드동일후보 retry 와 ρ 가공유했다. Hosted revision 은고정되지않았고 token 회계는제공되지않았으며 seed 는 hosted sampler 를제어하지않으므로이호출들은독립무작위표본이아니라준반복이다. 따라서추론통계나모델순위를보고하지않는다.

표 VII에서유도우위는의도적으로 guided-repairable 오류가나오도록구성한 signal-repair-v2 의 policy-blind 셀에서만나타났다. 최초후보 5/5 가모두무효였고 ρ 는 5/5, 블라인드는 0/5 를 commit 했다. 나머지현재셀 4 개는유도우위를보이지않았다. 세셀은최초후보가이미유효했고, 동결기저의 goal-directed 셀은수리불가 quest-stage regression 이었다. 현재셀의 모든 noncommit arm 결과 15/15 가 prior-state hash 를보존했다. 이결과해당오류 regime 에서의 mechanism transfer 만지 지하며모집단효능, 모델승격, 표본효율일반화는지지하지않는다. 따라서 C-PILOT-007 과 C-PILOT-008 은 pilot-only 이고 C-RESULT-003 은 TODO-RESULT 로남는다. 폐기된 v1 진단에서는동반오류가최대 3 개에서수리불가 knowledge 오류 1 개로 줄었지만 commit 되지않아, 오류하나라도수리불가이면부분수리가합성되지않음을보여주었다.

보고경계는명시적이다. 동결 fixture 와지정검사연산이허용한 row 만오프라인생성표에들어가고, 라이브표는 SHA-256 으

TABLE VII
라이브스크리닝파일럿정확집계 (셀당제안 5 회, $K=1$)

기저 / 조건	최초유효	ρ vs blind commit	Δ	최초오류
동결 / 공개	5/5	5/5 vs 5/5	+0	—
동결 / 비공개	5/5	5/5 vs 5/5	+0	—
동결 / 목표-비공개	0/5	0/5 vs 0/5	+0	QSR
Signal-v2 / 공개	5/5	5/5 vs 5/5	+0	—
Signal-v2 / 비공개	0/5	5/5 vs 0/5	+5	PEO+PEV+PPO

QSR = quest-stage regression, PEO = policy-effect omission, PEV = policy-effect violation, PPO = policy-precondition omission. Δ 는 동일후보에서 ρ commit 수 minus blind commit 수다. 모든 수치는 screening-pilot-only 이며 추론 통계가 아니다. 폐기된 v1 진단은 표에서 제외한다.

로 결합한 screening promotion manifest 를 통과하는 별도 경로를 사용하며 그 row 는 동결 오프라인 denominator 에 들어가지 않는다. 각 lane 이 측정하지 않은 항목은 표 IV 가 나열한다.

ENG1. Godot 4.7.1 slice 에 임베드된 같은 게이트의 두 번째 구현이 작성된 정식 trace 를 리플레이했다. 보류된 금지 disclosure 는 이전 state hash 를 보존했고 승인된 commit 은 이를 전진시켰으며, 중단 hash 는 오프라인 runner 와 정확히 일치했다. 이는 scripted fixture 하나의 엔진로 컬적 합성이다. live model 이나 Python transport, participant input, narrative-quality result 는 없으며, 플레이어에게 보이는 판독은 committed snapshot 에서만 파생되어 (그림 1 아래 strip) usability 나 efficacy 근거가 아니다.

VII. 논의

A. 확립 가능한 범위

설계 파일럿은 동결된 사례에 대해서만 mechanism behavior 를 확립할 수 있다. 인코딩된 검사 가 상태를 격리하는지, bounded repair 와 fallback 이 선언 경로를 따르는지, 명명된 corruption 이 지정된 검사 연산에서 거부되는지, assigned row 가 집계 를 위해 분류된 상태로 남는지를 평가한다. 거부를 안정적 인 typed detector code 에 귀속하지는 않는다. 이는 authoring-time validation, continuous-integration regression, recorded-adapter test, engine 이전 replay inspection 에 유용하다.

오프라인 수리 비교의 적극적인 해석은 guided-대-oracle 경계다. 상태를 읽는 callback 이상한으로 남는 이유는 권위 있는 상태를 참조할 수 있어서 ρ 가 구성상 전환할 수 없는 oracle-only 사례를 전환하기 때문이다. 반례 유도 연산자는 validator 의 구조화 반례만 소비하면서 guided-repairable class 에서 oracle 과 정확히 일치한다. 이어 라이브스크리닝 확장은 이 mechanism 이 hosted proposal 로 전이되는지를 탐색했다. 구성 상태가 모든 제안을 guided-repairable class 로 유도했을 때만 ρ 와 blind retry 가 분리됐고, 최초유효 및 guided-irreparable regime 은 귀무였다. 이 regime 의 존성, 고정되지 않은 hosted revision, 준반복 호출 때문에 예외만 표본 효율이나 모델 능력을 주장할 수 없다. Feedback 을 소비하는 수리 루프에는 선례가 있다. Self-Refine 은 같은 신뢰하지 않는 모델이 생성한 언어를 feedback 으로 되먹이고 [45], Reflexion 은 시도 간 verbal self-reflection 을 저장하며 [52], Self-Debugging 은 신뢰되는 전체 프로그램 runtime 의 실행 결과를 소비한다 [53]. ρ 는 channel 과 권위에서 다르다. Feedback 은 실행 전에 결정론적 validator 가 계산한 typed 오류 집합이고, 실패한 모든 live arm 은 상태를 격리한다. 이름은 명세의 전체 상태가 아니라 verifier 의 반례가 다음 후보를 이끄는 counterexample-guided inductive synthesis 를 따르며 [54], 여기서 verifier 는 commit gate 자체다.

B. 선행 연구와의 관계

TRACE-RPG 은 constrained decoder [5], [6], [7], 검색 및 메모리 구성 요소 [8], [9], [10], 실행 가능한 환경과 benchmark [1], [2], [22], [25] 를 대체하지 않고 보완한다. Process-linked trace 는 AgentBoard 의 측정 관심사를 구현하지만 [23] 우월성의 근거는 아니다. 확증 연구, 즉 독립 semantic oracle 과 실제 blind-retry comparator 를 갖춘 사전 등 록 다중 모델 비교, 인코딩된 validity 를 갖춘 retrieval 및 memory ablation, 정당화된 검정력과 mixed-effects 분석을 갖춘 blinded matched-validity 인간 연구는 여전히 본 논문의 범위 밖이며, 스크리닝 파일럿은 어느 연구도 대체하지 않는다 [22], [38], [35], [43].

VIII. 타당성 위협, 윤리, 산출물 범위

근거에는 명시적 경계 9 개가 있다. **L1:** encoded predicate 는 structured field 에서 빠진 의미를 발견하지 못하며, 상태 일관성만으로는 행동적 · 서사적 일관성이 성립하지 않는다 [55]. **L2:** authored world 하나와 constructed live-state variant 하나로 cross-world, cross-policy, 규모 일반화를 말할 수 없다. **L3:** state-reading callback 은 oracle 이며 offline class 와 regime-dependent screening 은 일반 repair 품질이나 sample efficiency 를 확립하지 않는다. **L4:** hosted proposer 하나는 revision 고정, token 회계, sampling 을 제어하는 seed 가 없고 live Python-Godot authorization round trip 도 없다. **L5:** participant 와 affect data 가 없다. **L6:** unkeyed hash 는 integrity 만 제공하며 writer authentication 이나 adversarial tamper resistance 는 제공하지 않는다. **L7:** record consistency 는 single writer 를 가정하며 concurrent-writer safety 는 미검증이다. **L8:** engine evidence 는 startup-dominated sample 이 16.7 ms 를 넘는 Godot fixture 하나이며 portability 나 real-time 결과가 아니다. **L9:** 선택된 fixture 와 screening cell 은 population, safety-rate, model-ranking 추론을 지지하지 않는다. Internal validity 는 독립 policy expectation 및 fixture leakage 부재에, reproducibility 는 고정 software 와 artifact 에 의존한다.

파일럿은 participant 또는 personal telemetry 를 처리하지 않는다. 향후 human 및 affect 연구에는 해당 review, informed consent, compensation disclosure, minimization, retention/deletion rule, opt-out 이 필요하다. LLM judge 를 사용하더라도 automated 및 crowd judgement 모두 calibration 과 bias control 이 필요하므로 보조 수단으로 유지한다 [38], [39], [40], [41].

IX. 결론

TRACE-RPG 은 작성된 candidate-event payload 를 encoded 기호 commit gate 를 통해 canonical mutation 으로부터 격리하고, linked record 와 state-semantic replay 로 terminal outcome 을 감사 가능하게 만든다. 결정론적 오프라인 파일럿은 동결된 작성 fixture 에서 mechanism 적합성을 확립한다. 별도 라이브스크리닝 파일럿은 구성한 수리 가능 regime 에서만 guided 5/5 대 blind 0/5 분리를 관찰하고 다른 regime 에서 귀무였으므로 pilot-only 로 남는다. Cross-model superiority, player-experience benefit, retrieval 또는 memory effectiveness, affect efficacy, commercial-engine performance 는 명시적인 확증 확장으로 남는다.

AI 사용 고지

Large language model 은 prose, code 와 test drafting, command orchestration, evidence review, 결과 해석, simulated

peer review, citation-identity check 를보조했고, hosted model 은별도표기된 live-screening candidate 도생성했다. 모든보고 count 는 deterministic runner 또는 hash-bound receipt 에서오며 offline, live-screening, engine evidence 는분리된다. 저자는 claim 을 source artifact 에대조했고내용에대한책임을진다.

데이터및코드가용성

Repository 에 는 implementation, build source, 분 리 된 offline/live-screening packet 과 contribution-evidence-matrix.csv, reference-topic-crosswalk.csv, experiment-evidence-matrix.csv 가 있다. Offline manifest 는 artifact 38 개, input 22 개, provenance row 121 개 (executed 85 개, aggregate 36 개) 를, live promotion manifest 는 JSON/JSONL receipt 14 개와 superseded v1 diagnostic 을결합한다. Godot slice 는이를다루는결정론적평가와함께제공된다. Portable offline invocation 에는 absolute clone path 가없고 clean-Git input binding 은 tag trace-rpg-guided-repair-inputs-20260821-v1 에서다시성립한다. Anonymized reviewer archive 나 DOI deposit 은 주장하지않는다.

References

- [1] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, “TextWorld: A learning environment for text-based games,” in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.
- [2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, “ScienceWorld: Is your agent smarter than a 5th grader?” in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.
- [3] N. Weir, R. Thomas, R. d’Amore, K. Hill, B. Van Durme, and H. Jhamtani, “Ontologically faithful generation of non-player character dialogues,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.
- [4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, “Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach,” in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.
- [5] S. Geng, M. Josifoski, M. Peyrard, and R. West, “Grammar-constrained decoding for structured NLP tasks without finetuning,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10 932–10 952.
- [6] L. Beurer-Kellner, M. Fischer, and M. Vechev, “Prompting is programming: A query language for large language models,” *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.
- [7] T. Scholak, N. Schucher, and D. Bahdanau, “PICARD: Parsing incrementally for constrained auto-regressive decoding from language models,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.
- [8] X. He, Y. Tian, Y. Sun *et al.*, “G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907.
- [9] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, “HippoRAG: Neurobiologically inspired long-term memory for large language models,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569.
- [10] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, “Mem0: Building production-ready AI agents with scalable long-term memory,” in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, peer-reviewed ECAI 2025 record; page range was not exposed by the accessible Crossref or publisher metadata at audit time.
- [11] J. S. Park, J. C. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, “Generative agents: Interactive simulacra of human behavior,” in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.
- [12] Y. Shao, L. Li, J. Dai, and X. Qiu, “Character-LLM: A trainable agent for role-playing,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187.
- [13] N. Akoury, Q. Yang, and M. Iyyer, “A framework for exploring player perceptions of LLM-generated dialogue in commercial video games,” in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.
- [14] M. Hochreiter, S. Kriglstein, and G. Wallner, “Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues,” in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.
- [15] M. Yin, H. Zu, W. Gu *et al.*, “How contextualized generative AI shapes player experience in games,” *Entertainment Computing*, vol. 58, p. 101194, 2026, online record with a future issue assignment at the 2026-08-12 audit; issue metadata must be rechecked at submission.
- [16] V. Figueiredo and D. Elumeze, “Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [17] G. N. Yannakakis and J. Togelius, “Experience-driven procedural content generation,” *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.
- [18] D. Melhart, D. Gravina, and G. N. Yannakakis, “Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch,” in *International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.
- [19] Z. Wang, Q. Guo, R. Singh, and X. Hu, “Do vision language models understand human engagement in games?” 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [20] L. Fan, G. Wang, Y. Jiang *et al.*, “MineDojo: Building open-ended embodied agents with internet-scale knowledge,” in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362.
- [21] D. Pérez-Liébana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, “General video game AI: A multitask framework for evaluating agents, games, and content generation algorithms,” *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.
- [22] X. Liu, H. Yu, H. Zhang *et al.*, “AgentBench: Evaluating LLMs as agents,” in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046, peer-reviewed official proceedings record; no publisher DOI assigned.
- [23] C. Ma, J. Zhang, Z. Zhu *et al.*, “AgentBoard: An analytical evaluation board of multi-turn LLM agents,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362.
- [24] X. Zhou, H. Zhu, L. Mathur *et al.*, “SOTOPIA: Interactive evaluation for social intelligence in language agents,” in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019, peer-reviewed official proceedings record; no publisher DOI assigned.
- [25] D. Paglieri, B. Cupial, S. Coward *et al.*, “BALROG: Benchmarking agentic LLM and VLM reasoning on games,” in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702, peer-reviewed official proceedings record; no publisher DOI assigned.
- [26] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, “Automated play-testing through RL-based human-like play-styles generation,” *Proceedings of the AAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.
- [27] S. Kambhampati, K. Valmeekam, L. Guan *et al.*, “Position: LLMs can’t plan, but can help planning in LLM-Modulo frameworks,” in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, ser. Proceedings of Machine Learning Research, vol. 235. PMLR, 2024, pp. 22 895–22 907.
- [28] B. Ichter, A. Brohan, Y. Chebotar *et al.*, “Do as I can, not as I say: Grounding language in robotic affordances,” in *Proceedings of the 6th Conference on Robot Learning (CoRL 2022)*, ser. Proceedings of Machine Learning Research, vol. 205. PMLR, 2023, pp. 287–318.
- [29] H. Wang, C. M. Poskitt, and J. Sun, “AgentSpec: Customizable runtime enforcement for safe and reliable LLM agents,” 2025, preprint (v3); the arXiv record states acceptance at ICSE 2026, but no proceedings DOI was resolvable as of 2026-09-02.
- [30] S. Li, Z. Zeng, J. Xi, A. Zhu, and P. Ammanabrolu, “Setting the DC: Tool-grounded D&D simulations to test LLM agents,” in *NeurIPS 2025 Workshop on Generative and Protective AI for Content Creation (GenProCC)*, 2025, non-archival workshop paper; identity confirmed through the official NeurIPS 2025 program record and the GenProCC accepted-paper list on 2026-09-02.
- [31] E. Zhou, S. Basavatia, M. Siam, Z. Chen, and M. O. Riedl, “STORY2GAME: Generating (almost) everything in an interactive fiction game,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-09-02.
- [32] S. Buongiorno, L. Klinkert, Z. Zhuang, T. Chawla, and C. Clark, “PANGeA: Procedural artificial narrative using generative AI for turn-based, role-playing video games,” *Proceedings of the AAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 20, no. 1, pp. 156–166, 2024.
- [33] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, “IVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds,” 2026, preprint; accepted/forthcoming at ICCG 2026, whose available pre-proceedings were explicitly non-archival and unpublished at retrieval time.
- [34] S. Góngora, L. Chiruzzo, G. Méndez, and P. Gervás, “World-state transformations for neuro-symbolic interactive storytelling,” 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-21.
- [35] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320, peer-reviewed official proceedings record; no publisher DOI assigned.
- [36] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, “Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program,” *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021, peer-reviewed official journal article; no publisher DOI assigned.
- [37] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, “Towards the systematic reporting of the energy and carbon footprints of machine learning,” *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020, peer-reviewed official journal article; no publisher DOI assigned.
- [38] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Krahmer, “Best practices for the human evaluation of automatically generated text,” in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.

- [39] M. Karpinska, N. Akoury, and M. Iyyer, “The perils of using Mechanical Turk to evaluate open-ended text generation,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.
- [40] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623.
- [41] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, “Humans or LLMs as the judge? a study on judgement bias,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.
- [42] D. Lakens, A. M. Scheel, and P. M. Isager, “Equivalence testing for psychological research: A tutorial,” *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.
- [43] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, “Random effects structure for confirmatory hypothesis testing: Keep it maximal,” *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.
- [44] E. Feng, W. Zhou, Z. Liu *et al.*, “Get experience from practice: LLM agents with record & replay,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-09-02.
- [45] A. Madaan, N. Tandon, P. Gupta *et al.*, “Self-Refine: Iterative refinement with self-feedback,” in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 46 534–46 594.
- [46] M. O. Riedl, C. J. Saretto, and R. M. Young, “Managing interaction between users and agents in a multi-agent storytelling environment,” in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.
- [47] R. E. Fikes and N. J. Nilsson, “STRIPS: A new approach to the application of theorem proving to problem solving,” *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.
- [48] F. B. Schneider, “Enforceable security policies,” *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.
- [49] T. Haerder and A. Reuter, “Principles of transaction-oriented database recovery,” *ACM Computing Surveys*, vol. 15, no. 4, pp. 287–317, 1983.
- [50] R. Evans and E. Short, “Versu—a simulationist storytelling system,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.
- [51] S. G. Ware and C. Siler, “Sabre: A narrative planner supporting intention and deep theory of mind,” in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.
- [52] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, “Reflexion: Language agents with verbal reinforcement learning,” in *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023, pp. 8634–8652.
- [53] X. Chen, M. Lin, N. Schärli, and D. Zhou, “Teaching large language models to self-debug,” 2023, preprint; no archival venue or publisher DOI verified as of 2026-08-21.
- [54] A. Solar-Lezama, L. Tancau, R. Bodík, S. Seshia, and V. Saraswat, “Combinatorial sketching for finite programs,” in *Proceedings of the 12th International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS)*. ACM, 2006, pp. 404–415.
- [55] Y. Huang, G. Chen, J. Yao *et al.*, “Beyond state consistency: Behavior consistency in text-based world models,” 2026, preprint; no archival venue or publisher DOI verified as of 2026-09-02.