

TRACE-RPG: 인터랙티브게임세계의생성이벤트를위한 trace 연결기호커밋게이트

익명저자

Abstract—대규모언어모델은표현력있는퀘스트와 NPC 대화를 생성할수있지만, 유창하거나스키마에맞는텍스트만으로제안이벤트의실행가능성, 권한적합성, 정식게임상태와의일관성이성립하지않는다. 본논문은신뢰하지않는제안을상태변경으로부터격리하는기호커밋게이트 TRACE-RPG 을제안한다. 타입업격 parser 는공유 candidate-key contract 를강제하여알려진필드의모호한 type 과알수없는 top-level candidate field 를거부하고, 외부공급행동정책과결정론적상태상대술어가 controller 가허용하는모든전이를결정한다. 거부된후보는제한된 repair callback 에노출되고, 성공후보는변경직전에방어적으로재검증된다. 중단실행레코드는키없는 SHA-256 콘텐츠체크섬과연결되고, 상태의미재생은기록된전이를재계산하며, 에피소드연속성검사는단절된이력을거부한다. 평가는단일작성 world state 에대한의도적설계결정론적오프라인픽처에서수행하며, 보고수치중무엇이관찰값이고무엇이하니스의구성불변량인지 명시한다. 참조 repair callback 은권위있는상태에서정책필드를재구성하므로배포가능한수리방법이아니라 oracle 상한이며, adapter telemetry 값은측정값이아니라합성픽처상수다. 따라서근거는하나의 world 에서선언된구조화필드에대한구현적합성만을확립하며, 실시간모델동작, 플레이어경험, 감정, 검색, 메모리, 상용엔진성능에대해서는아무것도확립하지않는다.

Index Terms—게임인공지능, 인터랙티브내러티브, 기호검증, 제약생성, 런타임강제, 재현성

I. 서론

인터랙티브생성은언어과제에그치지않는다. 후보이벤트가자연스러워도존재하지않는아이템을요구하거나, 화자가모르는사실을주장하거나, 금지된퀘스트정보를공개하거나, 허가되지않은효과를도입하거나, 퀘스트단계를후퇴시킬수있다. 실행가능한텍스트환경은그렇듯한발화와유효한전이의차이를명시한다 [1], [2]. 근거기반대화화개인화퀘스트시스템은퀘스트, 엔터티, 그래픽맥락의가치를추가로보여주지만 [3], [4], 맥락자체가정식상태변경을승인하지는않는다.

구조적생성제약은인접한문제를해결한다. 문법제약디코딩, 언어모델질의언어, 점진파서는생성구조를제한할수있다 [5], [6], [7]. 그러나구문상허용되는이벤트도현재세계에대해서는거짓일수있다. 검색과메모리는유용한근거를공급할수있지만 [8], [9], [10], 검색된내용역시상태전이의권한주체가아니다.

본논문은이러한관심사를감사가능한트랜잭션프로토콜로결합한구현인 TRACE-RPG 을제시한다. 현재기여는다음과같다.

- 1) 정식상태, 외부공급행동정책, 후보이벤트, 실행레코드, 게임브리지에대한버전계약;
- 2) 결정론적상태상대검증, 변경없는 fallback 을갖춘제한된 repair callback, 방어적커밋검증;
- 3) 콘텐츠연결종단레코드, 상태의미적리플레이, 에피소드연속성검증; 그리고
- 4) 엄격한 adapter 경계, 동결된할당키, 구별되는종단실패 클래스, 기술적 treatment-policy 계수를갖춘오프라인 harness.

익명심사를위해제출된원고입니다.

실증의중심은단일작성 world state 에대한결정론적설계픽처적합성파일럿이며, 보존한 Godot 4.7.1 작성형 policy-mirror trace 와 render replay 가제한된엔진로컬근거를추가한다. 해당픽처의 headless 실행은엔진로컬타이밍을기록하며, 본논문은이를있는그대로보고한다. 각실행은고정 seed 의 scripted fixture 하나이며, 요청당수치는모델이나네트워크추론이아니라로컬픽처처리를측정한다. 네 fixture 실행모두에서 5개 headless frame sample 중첫 sample 이가장컷고그범위는 98.760–116.667 ms 였으므로 16.7 ms frame budget 을충족하지못했다. 이 startup-sensitive trace 는안정적인 frame benchmark 가아니다. 실시간모델호출, 참여자, 감정또는검색 실험, live Python-Godot 승인왕복, 대표성있는 end-to-end 게임플레이성능측정은없다. 해당연구는본논문의범위밖이다.

II. 관련연구와연구공백

A. 인터랙티브내러티브와게임에이전트

KNUDGE 는퀘스트와엔터티명세에근거한분기형 NPC 대화를평가한다 [3]. 지식그래프보조퀘스트생성 [4], 메모리-성찰-계획에이전트 [11], 학습가능한역할연기에이전트 [12] 는근거성과개연성있는행동의상호보완적측면을다룬다. 플레이어대상연구는선호와지각된대화품질을평가한다 [13], [14]. Yin 등의 2026 년온라인레코드는서지감사당시미래시점의권호가배정되어있어제출시다시확인해야한다 [15]. 2025 년프리프린트는역할에따른안정성-즉흥성 trade-off 를보고하며 [16], 본논문은이를최근동기로만사용한다. 이연구들은하드허용가능성을선택적자연스러움필드플레이어경험구성개념과분리할필요성을뒷받침한다.

경험주도콘텐츠생성 [17] 과관찰자표식참여도 [18] 는미래적응트랙의동기가된다. 최근프리프린트는 vision-language model 의참여도추론한계를보고한다 [19]. 따라서감정은비권위적맥락으로유지되며현재구현근거에는포함되지않는다.

B. 환경과벤치마크

TextWorld 와 ScienceWorld 는명시적인인터랙티브상태를제공하며 [1], [2], MineDojo 는개방형지식집약 embodied 과제를추가한다 [20]. General Video Game AI 는에이전트, 게임, 콘텐츠트랙을분리한다 [21]. AgentBench 는이질적인환경의에이전트를연구하고 [22], AgentBoard 는과정수준진단을추가하며 [23], SOTOPIA 는사회적상호작용을평가하고 [24], BALROG 는장기언어및시각게임추론을평가한다 [25]. 자동화된플레이스타일에이전트는상호보완적인시험선레이지만인간평가를대체하지않는다 [26]. 이벤치마크는미래평가설계에정보를주지만트랜잭션승인경계를규정하지는않는다.

C. 제약, 신경-기호검증, 검색

제약디코더는출력구조를개선한다 [5], [6], [7]. 반면 TRACE-RPG 은구조를독립적인상태상대승인의입력조건

으로 취급한다. 직접적인 게임 특화 비교 대상 두 시스템은 서로 다른 경계를 보여준다. PANGeA 는 메모리, 검증, REST 서비스, Unity 통합을 결합하지만, 공개된 검증 절차는 LLM 이 설계자 규칙에 따라 콘텐츠를 판정하고 반복 수정하도록 한다 [27]. 현재 바카이벌 ICC 2026 자료와 연계된 프리프린트 IVIE 는 기호 증을 사용해 인터랙티브 픽션 세계를 점진적으로 생성한다 [28]. 어느 비교도 우월성을 뜻하지 않으며, 각 시스템의 유효성은 해당 시스템이 인코딩한 목표와 술어에 한정된다.

G-Retriever, HippoRAG, Mem0 는 관련 하위 그래프 검색과 장기 메모리를 다루고 [8], [9], [10], Generative Agents 와 Character-LLM 은 행동 메모리와 persona 를 다룬다 [11], [12]. TRACE-RPG 은 향후 이러한 맥락을 사용할 수 있지만 직접적인 커밋 권한은 부여하지 않는다. 검색과 시간적 메모리 효력은 여기에서 측정하지 않는다.

D. 감사 가능성과 재현성

과정 지표는 중간 실패를 보존할 동기를 제공하고 [23], 강건한 평가는 소수 확률적 실행의 과도한 해석을 경고한다 [29]. 재현성과 환경 보고 지침은 동결된 산출물과 명시적 측정 경계를 뒷받침한다 [30], [31]. 인간 및 LLM 평가는 구성 개념, 평가자, 편향 통제를 요구하며 [32], [33], [34], [35], 향후 비열등성과 참여자 분석에는 정당화된 margin 과 random-effects 구조가 필요하다 [36], [37].

제한된 novelty 는 개별 구성 요소의 발명이 아니라 구현된 결함이다. 행동 개입 (interposition) 자체는 오래된 기법이다. 내러티브 mediation 은 사용자나 에이전트의 행동을 실행 전에 가로채 차단하거나 계획을 수정해 수용하고 [38], 고전 계획법은 precondition 과 effect 로 작용 가능성을 정의하며 [39], 런타임 강제는 신뢰하지 않는 행위자를 monitor 로 감싸 허용된 전이만 통과시키고 [40], 작성형 논리기반 인터랙티브 드라마는 본 저널의 전신에서 캐릭터가 할 수 있는 발화를 규율했으며 [41], 신념 인지 내러티브 계획법은 캐릭터가 아는 바를 추론한다 [42]. 이는 본 논문의 knowledge/disclosure 술어가 훨씬 더 체계적으로 인코딩하는 관심사다. TRACE-RPG 은 interposition 을 발명했다고 주장하지 않는다. 더 좁은 기여는 신뢰하지 않는 생성 proposer 아래에서 그 게이트에 결합된 근거 체계이다. 즉 콘텐츠 체크섬과 연결된 종단 레코드, 기록된 전이의 상태의 미재생, 에피소드 연속성 검증, 그리고 proposal trace 가 존재할 수 없는 사례까지 보존하는 할당 완전 실패 계수다. 보고서에 기능이 없다고 해서 모든 구현에 그 기능이 없다고 추론하지 않는다.

III. 문제 정의와 보장 경계

설명을 위해 시점 t 에서 validation 이 사용하는 controller 입력을 다음과 같이 이해한다.

$$c_t = (G_t, q_t), \quad (1)$$

여기서 G_t 는 typed snapshot field 를, q_t 는 해당 snapshot 과 함께 저장되는 외부 작성 action-policy, disclosure, quest-stage 제약을 나타낸다. 종단 record history $h_{<t}$ 는 WorldState snapshot 과 별도로 유지된다. Validation predicate 는 이를 읽지 않으며 구현은 log 에서 상태를 재구성하지 않는다. 검색, 내러티브 점수, 모델 rationale, 메모리 요약, 미래의 감정 추정은 비권위적 proposal context 이다.

신뢰하지 않는 proposer 가 후보 a_t 를 출력한다. 타입 엄격 parsing 은 알 수 없는 top-level field 의 거부 포함 공유 candidate-key contract 를 먼저 강제하고 선언 스키마를 확립한다. validator 는 다음을 반환한다.

$$V(c_t, a_t) = (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, v_{\text{disc}}, v_{\text{quest}}, E_t), \quad (2)$$

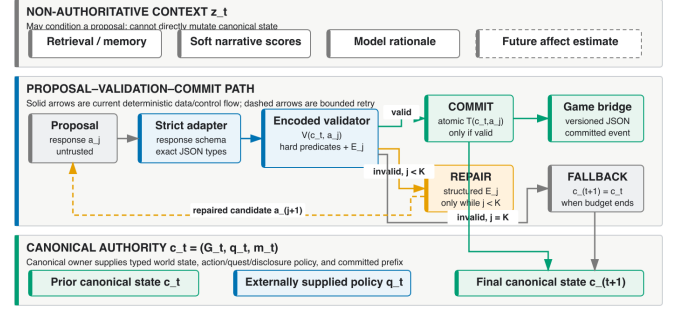


Fig. 1. 신뢰 경계. 검색 맥락과 생성 후보는 알려진 필드의 타입 검사와 상태 상대 validation 이 완료될 때까지 비권위적이다.

여기서 E_t 는 구조화 오류 집합이다. 상태 변경은 다음과 같다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_i v_i = 1, \\ c_t, & \text{그외.} \end{cases} \quad (3)$$

Controller 는 인코딩된 계약 아래 다음 구현 불변량을 주장한다. 파일럿은 이를 일방 정리로 제시하지 않고 deterministic valid, invalid, repair, fallback, replay, fault-injection fixture 로 해당 mechanism 을 시험한다. I1 (소진 실패 불변성): 예산 K 까지만 반환되면 후보도 검증을 통과하지 못하거나 proposal/controller 실행이 commit 전에 실패하면 반환 상태는 공급된 prior state 와 같다. I2 (제한된 기록 시도): 모든 proposal 과 repair callback 이 반환한다는 조건에서 repair budget $K \geq 0$ 은 최대 $K + 1$ 개의 candidate attempt 를 기록한다. 성공적인 commit 은 변경 이전 수락 후보에 대한 방어적 validation 을 한번 추가한다. Runtime 은 callback deadline 을 강제하지 않으므로 I2 는 wall-clock 종로 보장이다. I3 (효과 권한): 수락 후보는 ActionPolicy.allowed_effects 밖의 선언된 fact effect 를 CandidateAction.effects 에 포함하지 않으며, quest-stage target 도 해당 policy 에 의해 명시적으로 승인된다. I4 (상태의 미적리 플레이): 동결된 스키마와 결정론적 전이 아래 수락된 trace 는 명시된 terminal state 를 재구성한다.

이 주장된 불변량은 올바른 정책 작성, 선언된 후보 필드로의 완전하고 충실한 추출, 결정론적 소프트웨어 버전, callback 반환, 단일 프로세스 파일 소유권을 가정한다. 상태의 미적리 플레이는 기록된 구조화 후보와 전이를 재검증하지만, 중간 수리의 provenance, reasoning, prompt, 확률적 생성은 재현하거나 검증하지 않는다. 구조화 필드에서 누락된 자연어 함의는 보장 범위 밖이다.

IV. TRACE-RPG 아키텍처와 알고리즘

A. 신뢰 경계와 계약

그림 1은 모델 또는 recorded adapter 를 canonical owner 밖에 둔다. Parser 는 알려진 필드의 모호한 숫자 또는 collection type 을 거부하고 공유 key contract 에 따라 알 수 없는 top-level candidate field 도 거부한다. action policy 는 candidate 와 별도로 공급되며 required precondition 과 allowed effect 를 정의한다. Game bridge 는 observation, proposal, validation, rejection, fallback, commit 을 전달할 수 있는 versioned event interface 이며, 정식 상태 변경은 유효한 commit 만 승인한다. 이는 interface 를 분리하지만 상용 엔진으로의 portability 를 아직 입증하지 않는다. 표 1은 인코딩된 거부 경계를 요약하며 의미적 완결성 주장이 아니다.

TABLE I
인코딩된 VALIDATOR 경계

술어	거부대상	실패시상태
Action policy	알수없는 action/type	변경없음
Precondition	누락/거짓 requirement	변경없음
Reachability	접근불가 object	변경없음
NPC knowledge	선언되지않은 known fact	변경없음
Disclosure	forbidden fact	변경없음
Quest	부적격/후퇴 stage	변경없음

```

1:  $a \leftarrow \text{PROPOSE}(c); j \leftarrow 0$ 
2: repeat
3:    $(ok, E) \leftarrow V(c, a); \text{RECORD}(a, E)$ 
4:   if  $ok$  then
5:     assert  $V(c, a).ok$ ; return  $\text{COMMIT}(c, a)$ 
6:   if  $j = K$  then return  $\text{FALLBACK}(c)$ 
7:    $a \leftarrow \text{REPAIR}(c, a, E); j \leftarrow j + 1$ 
8: until terminal

```

Fig. 2. Validate-repair-commit 절차. 최대 $K + 1$ 개의 candidate attempt 를 기록하며, 성공경로는상태변경전방어적 validation 을수행한다.

B. Validate-Repair-Commit

그림 2는제어기의추가패키지없는의사코드를제시한다. “Record” 는 in-memory trace 표현에추가하는것을뜻하며, 연속쓰기는종단일관성검사뒤에만수행한다.

검증오류는구조화된 error code 로 repair callback 에노출된다. repair 는상태를직접변경하지않으며, 예산소진시변경없는결정론적 fallback 을반환한다. 그림 3는종단경로를나타낸다. 파일럿에서사용한참조 callback 은의도적으로반례유도방식이 아니다. 이 callback 은오류집합을폐기하고권위있는상태에서정책이요구하는 precondition 과 effect 를직접재구성한다. 따라서제어흐름을확인하는 oracle 상한이며, 그결과를반례를소비하는수리방법에대한근거로읽어서는안된다.

C. 무결성, 의미적리플레이, 계수

각 result row 는키없는 SHA-256 무결성체크섬을가지며, proposal outcome 은추가로 trace checksum 과연결된다. 이 hash 들은우발적이거나시험대상인콘텐츠변경을탐지하지만 signature, message-authentication code, writer identity 가 아니며콘텐츠와 checksum 을모두다시쫓수있는행위자에대한보호도아니다. 의미적리플레이는 prior state 와기록된모든 candidate/validation pair 를엄격히 parsing 하고, final 이아닌모든 attempt 가 invalid 임을요구하며, terminal transition 을재계산하고, 명시된 final state 와비교함으로써 byte 무결성을넘어선다. Episode replay 는인접 JSONL record 사이의의상태연속성도요구한다. Replay 는 candidate $j + 1$ 을만든 repair-generation 단계를인증하거나다시실행하지않는다.

Terminal record class 는 commit, symbolic fallback, adapter failure, controller failure 이다. Controller-failure row 는동결된 assignment denominator 에남고상태를변경하지않지만, candidate outcome 이생성되지않았다면완성된 proposal trace 가없어도된다. 따라서 result completeness 가모든 terminal row 의 trace 존재를뜻하지않는다. 실행 전 assignment key 는 (run, arm, scenario, seed, model, revision, $h_{\text{controller}}$, h_{input} , h_{prior}) 이다. 집계는중복, 누락, 예기치않은 key 를거부하고 symbolic, adapter, controller failure 를각각보고한다.

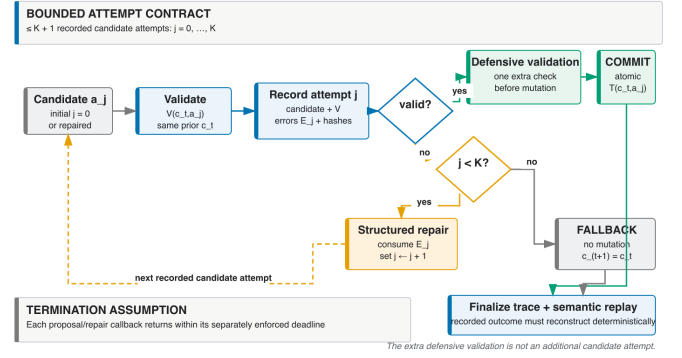


Fig. 3. Proposal, validation, 제한된 repair, fallback, commit, replay 상태. Controller failure 는종단상태이며완성된 proposal trace 가없을수있다.

V. 결정론적오프라인파일럿방법

A. 질문과설계픽스처

파일럿은다음을묻는다. (PQ1) 유효후보는 commit 되고 명명된 invalid-policy 사례는변경없이유지되는가? (PQ2) 작성된 repairable 및 irreparable 사례에서 rejection-only, unchanged retry, structured repair 가예상결과를만드는가? (PQ3) 동결된 checksum, state-semantic, linkage, continuity mutation 이지정된검사연산에서거부되고, 두번째파일 append 의주입된실패가예상 pair-write rollback 검사를작동시키는가? (PQ4) 엄격한 adapter 와 assignment manifest 가 할당사례마다정확히하나의분류된 terminal row 를유지하거나 fail closed 하는가? (PQ5) proposal 및 replay parser 가그외에는완전하고유효한 candidate 에 unknown top-level key 하나를추가한사례를모두거부하는가?

사례는의도적으로설계된적합성픽스처이며모델또는 게임모집단의표본이아니다. 네도메인은 validator/state isolation, repair control flow, record/trace fault injection, adapter/accounting contract 이다. 반복된결정론적 seed 가 아니라고유사례가기술적 denominator 를구성한다. 모든기대 값은실행전에명시한다.

B. 측정치와재현성

측정치는정확한 count 이다. expected/observed validator-class agreement, rejected 또는 controller-failure 사례의 state mutation, repair arm 과 repairability 별 commit 및 attempt 결과, 지정된연산에서거부된/사전명세된 detectable fault, replayed/committed trace, rejected/injected manifest violation, 사전명세한 unknown-key 음성회귀에대한 proposal/replay 거부일치률센다. 마지막측정은결정론적 parser-contract parity 이며실증적 safety outcome 이아니다. Exception class 만으로안정적인 detector layer 를식별할 수없으므로 detector 귀속결과보고하지않는다. 의도적으로 설계된픽스처에 p-value 나모집단 confidence interval 을부여하지않는다. Adapter 사례가지닌 latency 및 token 상수는입력스키마가 JSON-Schema const 로고정한합성값이다. 이값 들은계수필드전파만확인하며 provider, runtime, device 에대 한측정값이아니다.

릴리스패킷은 fixture 및 assignment manifest, schema, outcome/trace record 를포함한 result JSON 산출물, 환경과 코드 revision, 생성 table, checksum 을동결한다. 보고는재현 성과측정경계지침을따른다 [30], [31].

VI. 파일럿결과

A. 구조필드게이트적합성

파일럿 loader 는 구현된 validator code 를정확히한번씩고립시키는 fixture 집합과유효 control 1 개만을허용한다. 따라서 13/13 일치와구현된오류코드 12 종의관찰은측정된성공률이나 아니라 하니스의구성불변량이다. 이실행이보여주는것은 loader 가강제하지않는부분, 즉고립된음성 fixture 12 개가각각다른코드가아니라작성된기대코드와일치했고비 commit 경로가전체정준상태를유지했다는관찰이다. 이는단일 world state 에서저자가설계한구조필드 oracle 에대한구현적합성이며독립의미판정의정확도가아니다.

B. 수리메커니즘

처음부터유효하지않은두 case 에서 rejection-only 와동일후보 retry 는각각 0/2 commit 이었다. 참조 repair callback 은 수리가가능 precondition case 를 1 회수리후 commit 했고수리불가능 reachability case 는 fallback 하여 1/2 commit 이었다. 이 callback 은반례유도방식이아니다. 오류집합을폐기하고권위있는상태에서정책이요구하는 precondition 과 effect 를복사하므로, 결과는이합수가어떤 candidate field 를대입하는지에의해결정되는 oracle 상한이다. 따라서세 arm 은수리전략의비교가아니라제어흐름추적이다.

C. 무결성, 경계, 배정회계

현재메세가검출가능하다고지정한 10 개 fault fixture 는모두지정된검사연산에서거부됐다 (10/10). 이파일럿은안정적인typed detector code 까지대조하지않으므로 detector layer 귀속을입증하지않는다. 별도로, 동일하게기록된유효수리앞의무효선행후보를다른무효후보로치환하고체크섬을재계산한알려진 provenance 경계는예상대로재생을통과했다 (1/1 미검출). 따라서키없는체크섬을재계산할수있는작성자를방어하지 않으며, 재생은 repair 생성연산의출처를인증하지않는다. 열린경계 sentinel 두건—자연어 disclosure 미추출과 required object 의후보 · 정책동시누락—은 2/2 가의도대로인코딩상 허용됐고 safety pass 는 0 건이었다. 과거 unknown top-level field 허용경계는 Stage 8 이후단힌음성회귀로재분류되었으며, 완전한 12-field candidate 에 unknown key 하나를추가한 fixture 를 proposal · replay parser 모두구체적으로거부했다 (1/1). 이는 parser rejection parity 이지의미안전성의증거가아니다. Adapter/accounting 7 개배정에서는 commit 1, 기호 fallback 1, adapter failure 5 었다. 합성 telemetry 필드는 2/7 배정에서채워져전파됐으며, 이는측정값이아니라회계필드전파확인이다. 배정 guard 3/3 가중복 · 누락을거부했다. 이수치는모두합성 offline fixture 의 raw count 다.

표 II와 III은작성된 callback 경로와 raw fixture 계수를분리하여이를전략비교나모집단추정으로읽지않게한다.

그림 5는보고경계를명시한다. 동결 fixture 와지정검사연산이허용한 row 만생성결과표에들어간다.

Godot 4.7.1 은보존한 *Sealed Lighthouse* 정식 trace 를 non-headless 1280×720 SubViewport 에서리플레이했다. Manifest 는각 PNG 를 event/delivery index, validation, state hash 에결합한다. 그림 4(b) 는변경전 hash 를보존하고, (c) 는 valid commit 뒤이를변경한다. 모든원본 panel 은 생성자산이없는 primary-track render 이며, 아래 illustrative crop 은작성된 status/event callout 만확대한다.

TABLE II
수리 CALLBACK 제어흐름 (비교아님)

Callback	주입결합	대응필드대입	종단경로
없음 (K=0)	도달불가 object (수리불가)	—	fallback
없음 (K=0)	정책 precondition (수리가능)	—	fallback
동일후보재시도	도달불가 object (수리불가)	없음	fallback
동일후보재시도	정책 precondition (수리가능)	없음	fallback
정책복원 oracle	도달불가 object (수리불가)	preconditions, effects	fallback
정책복원 oracle	정책 precondition (수리가능)	preconditions, effects	commit

TABLE III
동결파일럿원시집계

검사	분자	분모
게이트 fixture 일치 ^c	13	13
알려진경계허용 ^a	2	2
닫힌 unknown-key 경계거부 ^d	1	1
탐지가능무결성결합거부	10	10
알려진무결성경계 replay 허용 ^b	1	1
Adapter 커밋	1	7
기호 fallback	1	7
Adapter 실패	5	7
Manifest guard 거부	3	3

^a 경계허용은의미추출과정적완결성한계를문서화하며 safety pass 가아니다. ^b Replay 는 repair 생성을인증하거나다시실행하지않는다. ^c Loader 가이일치를강제하므로측정값이아니라구성불변량이다. ^d Stage 8 이후의 parser 거부 parity 이지의미안전성증거가아니다.

선택 v5 packet 은하나의 scripted fixture 의 render/state 대응만확립하며 live model 또는 Python transport, participant 또는 player input, adaptation intervention, narrative-quality result 를추가하지않는다.

VII. 논의

A. 확립가능한범위

설계파일럿은동결된사례에대해서만 mechanism behavior 를확립할수있다. 인코딩된검사가상태를격리하는지, bounded repair 와 fallback 이선언경로를따르는지, 명명된 corruption 이지정된검사연산에서거부되는지, assigned row 가집계를위해분류된상태로남는지를평가한다. 거부를안정적인typed detector code 에귀속하지는않는다. 이는 authoring-time validation, continuous-integration regression, recorded-adapter test, engine 이전 replay inspection 에유용하다.

이 mechanism 은 policy 가올바르게작성되었는지, 자연어 fact 가완전하게추출되었는지, 의미적으로 unsafe 한모든 event 가 declared field 로표현되었는지를확립하지않는다. Key 없는 hash 도 writer 를인증하지않는다. Writer 는 single-process ownership 을가정하며 concurrent-writer safety 는 입증되지않았다. Versioned bridge 는 interface decoupling 이지 engine portability 또는 real-time performance 의근거가아니다.

B. 선행연구와의관계

TRACE-RPG 은 parsing 후 state-relative authorization 을적용하여 constrained decoder 를보완한다 [5], [6], [7]. 검

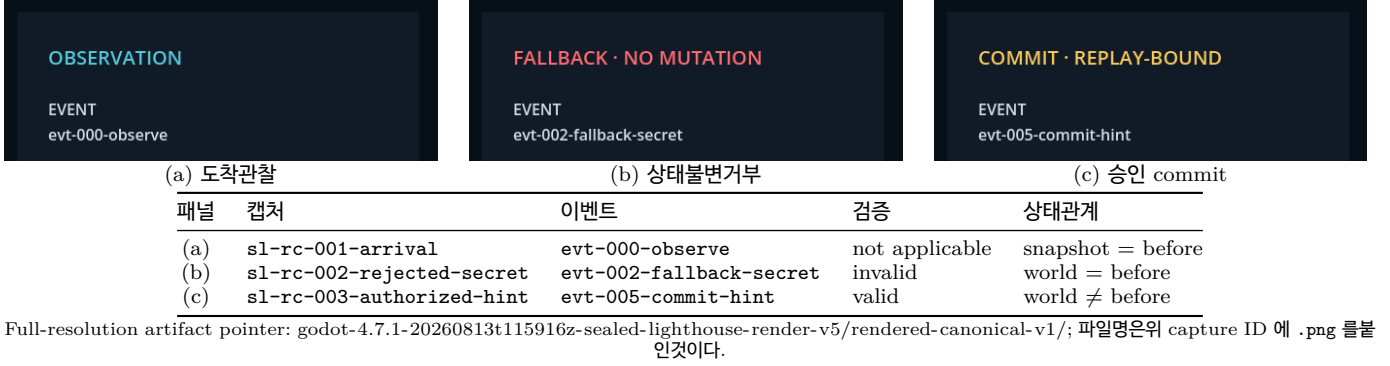


Fig. 4. 작성형 Godot render replay 에서 status/event 를확대한 illustrative crop 과 manifest metadata. 이 trace-bound 대응은 live transport, 성능, usability, immersion, efficacy 근거가아니다.




Fig. 5. 동결된 fixture 에서지정된검사연산과생성 table 로이어지는근거경계. 수치는생성산출물을통해서만반영한다.

색및메모리구성요소에는 commit authority 를부여하지않는다는점에서구별된다 [8], [9], [10]. 실행가능한환경과 benchmark 를대체하지않고보완한다 [1], [2], [22], [25]. Process-linked trace 는 AgentBoard 가강조한측정관심사를구현하지만 [23], TRACE-RPG 이해당시스템이나다른시스템보다우월하다는근거는아니다.

효능을검정할연구, 즉독립적으로 label 된 semantic oracle 과실제 blind-retry comparator 를갖춘사전등록다중모델비교, 인코딩된 validity 를맞춘 retrieval 및 memory ablation, 정당화된검정력과 mixed-effects 분석을갖춘 blinded matched-validity 인간연구는본논문의범위밖이며부분적으로도보고하지 않는다 [22], [32], [29], [37].

VIII. 타당성위협, 윤리, 산출물범위

Construct validity 는 declared field 에한정되며 encoded check 는누락된의미를발견할수없다. Internal validity 는독립적으로작성된 policy expectation 과 fixture leakage 부재에의존한다. External validity 는 offline text/mock case 에한정된다. Conclusion validity 는모집단추론없이 raw designed-case count 를보고함으로써보호한다. Reproducibility 는 고정된 software 및 artifact version 에의존한다. Security validity 는 key 없는 content-integrity check 와 deterministic semantic replay 에한정되며 adversarial authentication 은아니다.

파일럿은 participant 또는 personal telemetry 를처리하지않는다. 향후 human 및 affect 연구에는해당 review, informed consent, compensation disclosure, minimization, retention/deletion rule, opt-out 이필요하다. LLM judge 를사용하더라도 automated 및 crowd judgement 모두

calibration 과 bias control 이필요하므로보조수단으로유지한다 [32], [33], [34], [35].

IX. 결론

TRACE-RPG 은작성된 candidate-event payload 를 encoded 기호 commit gate 를통해 canonical mutation 으로부터격리하고, linked record 와 state-semantic replay 로 terminal outcome 을감사가능하게만든다. 결정론적오프라인파일럿은단일작성 world state 의동결된 fixture domain 에서구현 mechanism 에대한근거이지 cross-model superiority, player-experience benefit, retrieval 또는 memory effectiveness, affect efficacy, commercial-engine performance 의근거가아니다. 이질문들은명시적인확증확장으로남는다.

AI 사용고지

본원고준비과정에서대규모언어모델은산문, 코드, 시험초안 작성, 명령실행조율, 근거감사와결과해석, 이번개정을이끈심사패널시뮬레이션, 서지메타데이터 API 에대한인용동일성검사를보조했다. 보고수치의출처로서결정론적실행을대체하지않았다. 파일럿 count 는작성 fixture 에서프로젝트 runner 가산출하여기계생성조각을통해원고에들어가고, Godot timing 과 render 서술은보존된 engine-evidence packet 에서전사한다. 이번개정의구현및결과주장은 source 와 artifact 에대조했고, 모든인용동일성은최소하나의독립색인에서확인했다. 내용에대한책임은전적으로저자에게있다.

데이터및코드가용성

Repository 에는구현, 파일럿번들, fixture 및 assignment manifest, 생성결과조각, build source 가포함된다. 현재 SHA-256 manifest 는산출물 35 개와선언입력 20 개를포함하고 bound provenance row 64 개 (실행 fixture row 43 개와 aggregate row 21 개) 를결합한다. 산출물 35 개 hash 와 working-tree 입력 20 개 hash 는모두재계산된다. Manifest 가기록한 commit e4c2c77 에는입력경로 20 개가모두존재하지만정확한입력 digest 는 19 개만일치한다. 해당 commit 에는더이른 scripts/run_conformance_pilot.py 가있고, 동결 runner revision 은기록된 dirty-tree hash 로만표현된다. 따라서의명심사 archive 또는 DOI 기반저장소를주장하기전에 clean commit 과 tag 에서재캡쳐해야한다.

REFERENCES

- [1] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, “TextWorld: A learning environment for text-based games,” in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.
- [2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, “ScienceWorld: Is your agent smarter than a 5th grader?” in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.
- [3] N. Weir, R. Thomas, R. d’Amore, K. Hill, B. Van Durme, and H. Jhamtani, “Ontologically faithful generation of non-player character dialogues,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.
- [4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, “Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach,” in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.
- [5] S. Geng, M. Josifoski, M. Peyrard, and R. West, “Grammar-constrained decoding for structured NLP tasks without finetuning,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10932–10952.
- [6] L. Beurer-Kellner, M. Fischer, and M. Vechev, “Prompting is programming: A query language for large language models,” *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.
- [7] T. Scholak, N. Schucher, and D. Bahdanau, “PICARD: Parsing incrementally for constrained auto-regressive decoding from language models,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.
- [8] X. He, Y. Tian, Y. Sun *et al.*, “G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907.
- [9] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, “HippoRAG: Neurobiologically inspired long-term memory for large language models,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569.
- [10] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, “Mem0: Building production-ready AI agents with scalable long-term memory,” in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, peer-reviewed ECAI 2025 record; page range was not exposed by the accessible Crossref or publisher metadata at audit time.
- [11] J. S. Park, J. C. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, “Generative agents: Interactive simulacra of human behavior,” in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.
- [12] Y. Shao, L. Li, J. Dai, and X. Qiu, “Character-LLM: A trainable agent for role-playing,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187.
- [13] N. Akoury, Q. Yang, and M. Iyyer, “A framework for exploring player perceptions of LLM-generated dialogue in commercial video games,” in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.
- [14] M. Hochreiter, S. Kriglstein, and G. Wallner, “Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues,” in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.
- [15] M. Yin, H. Zu, W. Gu *et al.*, “How contextualized generative AI shapes player experience in games,” *Entertainment Computing*, vol. 58, p. 101194, 2026, online record with a future issue assignment at the 2026-08-12 audit; issue metadata must be rechecked at submission.
- [16] V. Figueiredo and D. Elumeze, “Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [17] G. N. Yannakakis and J. Togelius, “Experience-driven procedural content generation,” *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.
- [18] D. Melhart, D. Gravina, and G. N. Yannakakis, “Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch,” in *International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.
- [19] Z. Wang, Q. Guo, R. Singh, and X. Hu, “Do vision language models understand human engagement in games?” 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [20] L. Fan, G. Wang, Y. Jiang *et al.*, “MineDojo: Building open-ended embodied agents with internet-scale knowledge,” in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362.
- [21] D. Pérez-Liébana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, “General video game AI: A multitask framework for evaluating agents, games, and content generation algorithms,” *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.
- [22] X. Liu, H. Yu, H. Zhang *et al.*, “AgentBench: Evaluating LLMs as agents,” in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046, peer-reviewed official proceedings record; no publisher DOI assigned.
- [23] C. Ma, J. Zhang, Z. Zhu *et al.*, “AgentBoard: An analytical evaluation board of multi-turn LLM agents,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362.
- [24] X. Zhou, H. Zhu, L. Mathur *et al.*, “SOTOPIA: Interactive evaluation for social intelligence in language agents,” in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019, peer-reviewed official proceedings record; no publisher DOI assigned.
- [25] D. Paglieri, B. Cupial, S. Coward *et al.*, “BALROG: Benchmarking agentic LLM and VLM reasoning on games,” in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702, peer-reviewed official proceedings record; no publisher DOI assigned.
- [26] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, “Automated play-testing through RL-based human-like play-styles generation,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.
- [27] S. Buongiorno, L. Klinkert, Z. Zhuang, T. Chawla, and C. Clark, “PANGeA: Procedural artificial narrative using generative AI for turn-based, role-playing video games,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 20, no. 1, pp. 156–166, 2024.
- [28] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, “IVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds,” 2026, preprint; accepted/forthcoming at ICCV 2026, whose available pre-proceedings were explicitly non-archival and unpublished at retrieval time.
- [29] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320, peer-reviewed official proceedings record; no publisher DOI assigned.
- [30] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, “Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program,” *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021, peer-reviewed official journal article; no publisher DOI assigned.
- [31] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, “Towards the systematic reporting of the energy and carbon footprints of machine learning,” *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020, peer-reviewed official journal article; no publisher DOI assigned.
- [32] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Krahmer, “Best practices for the human evaluation of automatically generated text,” in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.
- [33] M. Karpinska, N. Akoury, and M. Iyyer, “The perils of using Mechanical Turk to evaluate open-ended text generation,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.
- [34] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623.
- [35] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, “Humans or LLMs as the judge? a study on judgement bias,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.
- [36] D. Lakens, A. M. Scheel, and P. M. Isager, “Equivalence testing for psychological research: A tutorial,” *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.
- [37] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, “Random effects structure for confirmatory hypothesis testing: Keep it maximal,” *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.
- [38] M. O. Riedl, C. J. Saretto, and R. M. Young, “Managing interaction between users and agents in a multi-agent storytelling environment,” in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.
- [39] R. E. Fikes and N. J. Nilsson, “STRIPS: A new approach to the application of theorem proving to problem solving,” *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.
- [40] F. B. Schneider, “Enforceable security policies,” *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.
- [41] R. Evans and E. Short, “Versu—a simulationist storytelling system,” *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.
- [42] S. G. Ware and C. Siler, “Sabre: A narrative planner supporting intention and deep theory of mind,” in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.