

TRACE-RPG: 인터랙티브게임세계의생성이벤트를위한 trace 연결기호커밋게이트

익명저자

Abstract—대규모언어모델은표현력있는퀘스트와 NPC 대화를 생성할수있지만, 유창하거나스키마에맞는텍스트만으로제안이벤트의실행가능성, 권한적합성, 정식게임상태와의일관성이성립하지않는다. 본논문은신뢰하지않는제안을상태변경으로부터격리하는기호커밋게이트 TRACE-RPG 을제안한다. 타입엄격 parser 는공유 candidate-key contract 를강제하여알려진필드의모호한 type 과알수없는 top-level candidate field 를거부하고, 외부공급행동정책과결정론적상태상대술어가 controller 가허용하는모든전이를결정한다. 거부된후보는제한된 repair callback 에노출되고, 성공후보는변경직전에방어적으로재검증된다. 중단실행레코드는키없는 SHA-256 콘텐츠체크섬과연결되고, 상태의미재생은기록된전이를재계산하며, 에피소드연속성검사는단절된이력을거부한다. 평가는단일작성 world state 에대한의도적설계결정론적오프라인픽처에서수행하며, 보고수치중무엇이관찰값이고무엇이하니스의구성불변량인지 명시한다. 참조 repair callback 은권위있는상태에서정책필드를재구성하므로배포가능한수리방법이아니라 oracle 상한이며, adapter telemetry 값은측정값이아니라합성픽처상수다. 따라서근거는하나의 world 에서선언된구조화필드에대한구현적합성만을확립하며, 실시간모델동작, 플레이어경험, 감정, 검색, 메모리, 상용엔진성능에대해서는아무것도확립하지않는다.

Index Terms—게임인공지능, 인터랙티브내러티브, 기호검증, 제약생성, 런타임강제, 재현성

I. 서론

인터랙티브생성은언어과제에그치지않는다. 후보이벤트가자연스러워도존재하지않는아이템을요구하거나, 화자가모르는사실을주장하거나, 금지된퀘스트정보를공개하거나, 허가되지않은효과를도입하거나, 퀘스트단계를후퇴시킬수있다. 실행가능한텍스트환경은그렇듯한발화와유효한전이의차이를명시한다 [1], [2]. 근거기반대화화개입퀘스트시스템은퀘스트, 엔터티, 그래픽맥락의가치를추가로보여주지만 [3], [4], 맥락자체가정식상태변경을승인하지는않는다.

구조적생성제약은인접한문제를해결한다. 문법제약디코딩, 언어모델질의언어, 점진파서는생성구조를제한할수있다 [5], [6], [7]. 그러나구문상허용되는이벤트도현재세계에대해서는거짓일수있다. 검색과메모리는유용한근거를공급할수있지만 [8], [9], [10], 검색된내용역시상태전이의권한주체가아니다.

본논문은이러한관심을감사가능한트랜잭션프로토콜로결합한구현인 TRACE-RPG 을제시한다. 현재기여는다음과같다.

- 1) 정식상태, 외부공급행동정책, 후보이벤트, 실행레코드, 게임브리지에대한버전계약;
- 2) 결정론적상태상대검증, 변경없는 fallback 을갖춘제한된 repair callback, 방어적커밋검증;
- 3) 콘텐츠연결종단레코드, 상태의미적리플레이, 에피소드연속성검증; 그리고
- 4) 엄격한 adapter 경계, 동결된할당키, 구별되는종단실패클래스, 기술적 treatment-policy 계수를갖춘오프라인 harness.

익명심사를위해제출된원고입니다.

실증의중심은단일작성 world state 에대한결정론적설계픽처적합성파일럿이며, 보존한 Godot 4.7.1 작성형 policy-mirror trace 와 render replay 가제한된엔진로컬근거를추가한다. 해당픽처의 headless 실행은엔진로컬타이밍을기록하며, 본 논문은이를있는그대로보고한다. 이는고정 seed 의 scripted canonical fixture 하나이고, 요청당수치는모델이나네트워크추론이아니라로컬픽처처리를측정하며, 16.7 ms frame budget 은 5-sample headless 측정에서충족되지않았으며첫 sample 이나머지보다한자릿수느렸다. 실시간모델호출, 참여자, 감정또는검색실험, live Python-Godot 승인왕복, 대표성있는 end-to-end 게임플레이성능측정은없다. 해당연구는본논문의범위밖이다.

II. 관련연구와연구공백

A. 인터랙티브내러티브와게임에이전트

KNUDGE 는퀘스트와엔터티명세에근거한분기형 NPC 대화를평가한다 [3]. 지식그래프보조퀘스트생성 [4], 메모리-성찰-계획에이전트 [11], 학습가능한역할연기에이전트 [12] 는근거성과개연성있는행동의상호보완적측면을다룬다. 플레이어대상연구는선호와지각된대화품질을평가한다 [13], [14]. Yin 등의 2026 년온라인레코드는서지감사당시미래시점의권호가배정되어있어제출시다시확인해야한다 [15]. 2025 년프리프린트는역할에따른안정성-즉흥성 trade-off 를보고하며 [16], 본논문은이를최근동기로만사용한다. 이연구들은하드허용가능성을선택적자연스러움및플레이어경험구성개념과분리할필요성을뒷받침한다.

경험주도콘텐츠생성 [17] 과관찰자표식참여도 [18] 는미래적응트랙의동기가된다. 최근프리프린트는 vision-language model 의참여도추론한계를보고한다 [19]. 따라서감정은비권위적맥락으로유지되며현재연구근거에는포함되지않는다.

B. 환경과벤치마크

TextWorld 와 ScienceWorld 는명시적인인터랙티브상태를제공하며 [1], [2], MineDojo 는개방형지식집약 embodied 과제를추가한다 [20]. General Video Game AI 는에이전트, 게임, 콘텐츠트랙을분리한다 [21]. AgentBench 는이질적인환경의에이전트를연구하고 [22], AgentBoard 는과정수준진단을추가하며 [23], SOTOPIA 는사회적상호작용을평가하고 [24], BALROG 는장기언어및시각게임추론을평가한다 [25]. 자동화된플레이스타일에이전트는상호보완적인시험선레이지만인간평가를대체하지않는다 [26]. 이벤치마크는미래평가설계에정보를주지만트랜잭션승인경계를규정하지는않는다.

C. 제약, 신경-기호검증, 검색

제약디코더는출력구조를개선한다 [5], [6], [7]. 반면 TRACE-RPG 은구조를독립적인상태상대승인의입력조건

으로 취급한다. 현재비야카이벌 ICC 2026 자료와연계된프린트인용되는 IVIE 는가장가까운최근게임특화신경-기호 비교대상이다 [27]. 이범위는필요한경계를강조한다. 즉, 기호적 유효성은인코딩된목표와술어에대해서만유효하다.

G-Retriever, HippoRAG, Mem0 는관련하위그래프검색과장기메모리를다루고 [8], [9], [10], Generative Agents 와 Character-LLM 은행동메모리와 persona 를다룬다 [11], [12]. TRACE-RPG 은향후이러한맥락을사용할수있지만직접적인커밋권한은부여하지않는다. 검색과시간적메모리효익은여기에서측정하지않는다.

D. 감사가능성과재현성

과정지표는중간실패를보존할동기를제공하고 [23], 강건한 평가는소수확률적실행의과도한해석을경고한다 [28]. 재현성과 환경보고지침은동결된산출물과명시적측정경계를뒷받침한다 [29], [30]. 인간및 LLM 평가는구성개념, 평가자, 편향통제를요구하며 [31], [32], [33], [34], 향후비열등성과참여자분석에는정당화된 margin 과 random-effects 구조가필요하다 [35], [36].

제한된 novelty 는개별구성요소의발명이아니라구현된결합이다. 행동개입 (interposition) 자체는오래된기법이다. 내러티브 mediation 은사용자나에이전트의행동을실행전예가 로채차단하거나계획을수정해수용하고 [37], 고전계획법은 precondition 과 effect 로적용가능성을정의하며 [38], 런타임강제는신뢰하지않는행위자를 monitor 로감싸허용된전지만통과시키고 [39], 작성형논리기반인터랙티브드라마는본저널의 전신에서캐릭터가할수있는발화를규율했으며 [40], 신념인지 내러티브계획법은캐릭터가아는바를추론한다 [41]. 이는본논문의 knowledge/disclosure 술어가훨씬거칠게인코딩하는관심사다. TRACE-RPG 은 interposition 을발명했다고주장하지않는다. 더좁은기여는신뢰하지않는생성 proposer 아래에서그게이트에결합된근거계층이다. 즉콘텐츠체크섬과연결된종단레코드, 기록된전이의상태의미재생, 에피소드연속성검증, 그리고 proposal trace 가존재할수없는사례까지보존하는할당완전실패계수다. 보고서에기능이없다고해서모든구현에그기능이없다고추론하지않는다.

III. 문제정의와보장경계

시점 t 에서정식상태는다음과같다.

$$c_t = (G_t, q_t, m_t), \quad (1)$$

여기서 G_t 는 typed world state 이고, q_t 는외부공급 action policy, 정식 disclosure set, quest-stage 제약을함께나타내며, m_t 는커밋된 event prefix 이다. 검색, 내러티브점수, 모델 rationale, 메모리요약, 미래의감정추정은비권위적 proposal context 이다.

신뢰하지않는 proposer 가후보 a_t 를출력한다. 타입엄격 parsing 은알수없는 top-level field 의거부를포함한공유 candidate-key contract 를먼저강제하고선언스키마를확립한다. validator 는다음을반환한다.

$$V(c_t, a_t) = (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, v_{\text{disc}}, v_{\text{quest}}, E_t), \quad (2)$$

여기서 E_t 는구조화오류집합이다. 상태변경은다음과같다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_i v_i = 1, \\ c_t, & \text{그외.} \end{cases} \quad (3)$$

인코딩된도메인의명제는다음과같다. P1 (소진실패불변성): 예산 K 까지어떤후보도검증을통과하지못하거나




Fig. 1. 신뢰경계. 검색맥락과생성후보는알려진필드의타입검사와상태상대 validation 이완료될때까지비권위적이다.

TABLE I
인코딩된 VALIDATOR 경계

술어	거부대상	실패시상태
Action policy	알수없는 action/type	변경없음
Precondition	누락/거짓 requirement	변경없음
Reachability	접근불가 object	변경없음
NPC knowledge	선언되지않은 known fact	변경없음
Disclosure	forbidden fact	변경없음
Quest	부적격/후퇴 stage	변경없음

proposal/controller 실행이 commit 전에실패하면반환상태는 공급된 prior state 와같다. P2 (제한된기록시도): 각 proposal 또는 repair callback 이별도로강제된 deadline 안에반환한다면, repair budget $K \geq 0$ 은최대 $K + 1$ 개의 candidate attempt 를기록한다. 성공적인 commit 은변경직전수락후보에대한방어적 validation 을한번추가한다. P3 (효과권한): 수락후보는 ActionPolicy.allowed_effects 밖의선언된 fact effect 를 CandidateAction.effects 에포함하지않으며, quest-stage target 도해당 policy 에의해명시적으로승인된다. P4 (상태의미적리플레이): 스키마와결정론적전이가고정되면수락된 trace 는명시된 terminal state 를재구성한다.

이명제들은올바른정책작성, 선언된후보필드로의완전하고충실한추출, 결정론적소프트웨어버전, 단일프로세스파일소유권을가정한다. 상태의미적리플레이는기록된구조화후보와전이를재검증하지만, 중간수리의 provenance, reasoning, prompt, 확률적생성은재현하거나검증하지 않는다. 구조화필드에서누락된자연어함의는보장범위밖이다.

IV. TRACE-RPG 아키텍처와알고리즘

A. 신뢰경계와계약

그림 1는모델또는 recorded adapter 를 canonical owner 밖에둔다. Parser 는알려진필드의의도호환숫자또는 collection type 을거부하고공유 key contract 에따라알수없는 top-level candidate field 도거부한다. action policy 는 candidate 와별도로공급되며 required precondition 과 allowed effect 를정의한다. bridge 는 commit 이후에만 versioned event 를 export 한다. 이는 interface 를분리하지만상용엔진으로의 portability 를아직입증하지않는다.

B. Validate-Repair-Commit

제어기는다음과같은추가패키지없는의사코드를실행한다. “Record” 는 in-memory trace 표현에추가하는것을뜻하며, 영속쓰기는종단일관성검사뒤에만수행한다.

```

1:  $a \leftarrow \text{PROPOSE}(c); j \leftarrow 0$ 
2: repeat
3:    $(ok, E) \leftarrow V(c, a); \text{RECORD}(a, E)$ 
4:   if  $ok$  then
5:     assert  $V(c, a).ok$ ; return  $\text{COMMIT}(c, a)$ 
6:   if  $j = K$  then return  $\text{FALLBACK}(c)$ 
7:    $a \leftarrow \text{REPAIR}(c, a, E); j \leftarrow j + 1$ 
8: until terminal

```

Fig. 2. Validate-repair-commit 절차. 최대 $K + 1$ 개의 candidate attempt 을 기록하며, 성공경로는 상태변경전방어적 validation 을 수행한다.




Fig. 3. Proposal, validation, 제한된 repair, fallback, commit, replay 상태. Controller failure 는 중단상태이며 완성된 proposal trace 가 없을 수 있다.

검증 오류는 구조화된 error code 로 repair callback 에 노출된다. repair 는 상태를 직접 변경하지 않으며, 예상 소진 시 변경 없는 결정론적 fallback 을 반환한다. 그림 3는 중단 경로를 나타낸다. 파일럿에서 사용한 참조 callback 은 의도적으로 반례 유도 방식이 아니다. 이 callback 은 오류 집합을 폐기하고 권위 있는 상태에서 정책이 요구하는 precondition 과 effect 를 직접 재구성한다. 따라서 제어 흐름을 확인하는 oracle 상한이며, 그 결과와 반례를 소비하는 수리 방법에 대한 근거로 읽어서는 안 된다.

C. 무결성, 의미적 리플레이, 계수

각 result row 는 키 없는 SHA-256 무결성 체크섬을 가지며, proposal outcome 은 추가로 trace checksum 과 연결된다. 이 hash 들은 우발적이거나 시험 대상 인 콘텐츠 변경을 탐지하지만 signature, message-authentication code, writer identity 가 아니며 콘텐츠와 checksum 을 모두 다시 쓸 수 있는 행위자에 대한 보호도 아니다. 의미적 리플레이는 prior state 와 기록된 모든 candidate/validation pair 를 엄격히 parsing 하고, final 이 아닌 모든 attempt 가 invalid 임을 요구하며, terminal transition 을 재계산하고, 명시된 final state 와 비교함으로써 byte 무결성을 넘어서는다. Episode replay 는 인접 JSONL record 사이의 의상 태연속성도 요구한다. Replay 는 candidate $j + 1$ 을 만든 repair-generation 단계를 인증하거나 다시 실행하지 않는다.

Terminal record class 는 commit, symbolic fallback, adapter failure, controller failure 이다. Controller-failure row 는 동결된 assignment denominator 에 남고 상태를 변경하지 않지만, candidate outcome 이 생성되지 않았다면 완성된 proposal trace 가 없어진다. 따라서 result completeness 가 모든 terminal row 의 trace 존재를 뜻하지 않는다. 실행 전 assignment key 는 (run, arm, scenario, seed, model, revision, $h_{\text{controller}}$, h_{input} , h_{prior}) 이다. 집계는 중복, 누락, 예기치 않은 key 를 거부하고 symbolic, adapter, controller failure 를 각각 보고한다.

V. 결정론적 오프라인 파일럿 방법

A. 질문과 설계 픽처

파일럿은 다음을 묻는다. (PQ1) 유효 후보는 commit 되고 명명된 invalid-policy 사례는 변경 없이 유지되는가? (PQ2) 작성된 repairable 및 irreparable 사례에서 rejection-only, unchanged retry, structured repair 가 예상 결과를 만드는가? (PQ3) 동결된 checksum, state-semantic, linkage, continuity mutation 이 지정된 검사 연산에서 거부되고, 두 번째 파일 append 의 주입된 실패가 예상 pair-write rollback 검사를 작동시키는가? (PQ4) 엄격한 adapter 와 assignment manifest 가 할당 사례마다 정확히 하나의 분류된 terminal row 를 유지하거나 fail closed 하는가?

사례는 의도적으로 설계된 적합성 픽처이며 모델 또는 게임 모집단의 표본이 아니다. 네도메인은 validator/state isolation, repair control flow, record/trace fault injection, adapter/accounting contract 이다. 반복된 결정론적 seed 가 아니라 고유 사례가 기술적 denominator 를 구성한다. 모든 기대 값은 실행 전에 명시한다.

B. 측정치와 재현성

측정치는 정확한 count 이다. expected/observed validator-class agreement, rejected 또는 controller-failure 사례의 state mutation, repair arm 과 repairability 별 commit 및 attempt 결과, 지정된 연산에서 거부된/사전 명세된 detectable fault, replayed/committed trace, rejected/injected manifest violation 을 센다. Exception class 만으로 안정적 인 detector layer 를 식별할 수 없으므로 detector 귀속 결과는 보고하지 않는다. 의도적으로 설계된 픽처에 p -value 나 모집단 confidence interval 을 부여하지 않는다. Adapter 사례가 지닌 latency 및 token 상수는 입력 스키마가 JSON-Schema const 로 고정된 적합값이다. 이 값들은 계수 필드 전파만 확인하며 provider, runtime, device 에 대한 측정값이 아니다.

릴리스 패킷은 fixture 및 assignment manifest, schema, outcome/trace record 를 포함한 result JSON 산출물, 환경과 코드 revision, 생성 table, checksum 을 동결한다. 보고는 재현성과 측정 경계 지침을 따른다 [29], [30].

VI. 파일럿 결과

A. 구조 필드 게이트 적합성

파일럿 loader 는 구현된 validator code 를 정확하게 한번씩 고립시키는 fixture 집합과 유효 control 1 개만을 허용한다. 따라서 13/13 일치와 구현된 오류 코드 12 종의 관찰은 측정된 성공률이 아니라 하니스의 구성 불변량이다. 이 실행이 보여주는 것은 loader 가 강제하지 않는 부분, 즉 고립된 음성 fixture 12 개가 각각 다른 코드 가 아니라 작성된 기대 코드와 일치했고 비 commit 경로가 전체 정준 상태를 유지했다는 관찰이다. 이는 단일 world state 에서 저자가 설계한 구조 필드 oracle 에 대한 구현 적합성이며 독립의 비판정의 정확도가 아니다.

B. 수리 메커니즘

처음부터 유효하지 않은 두 case 에서 rejection-only 와 동일하게 retry 는 각각 0/2 commit 이었다. 참조 repair callback 은 수리 가능 precondition case 를 1 회 수리 후 commit 했고 수리 불가능 reachability case 는 fallback 하여 1/2 commit 이었다. 이 callback 은 반례 유도 방식이 아니다. 오류 집합을 폐기하고 권위 있는 상태에서 정책이 요구하는 precondition 과 effect 를 복

TABLE II
수리 CALLBACK 제어흐름 (비교아님)

Callback	주입결함	대응필드대입	종단경로
없음 (K=0)	도달불가 object (수리불가)	—	fallback
없음 (K=0)	정책 precondition (수리가능)	—	fallback
동일후보재시도	도달불가 object (수리불가)	없음	fallback
동일후보재시도	정책 precondition (수리가능)	없음	fallback
정책복원 oracle	도달불가 object (수리불가)	preconditions, effects	fallback
정책복원 oracle	정책 precondition (수리가능)	preconditions, effects	commit

TABLE III
동결파일럿원시집계

검사	분자	분모
게이트 fixture 일치 ^c	13	13
알려진경계허용 ^a	2	2
달한 unknown-key 경계거부 ^d	1	1
탐지가능무결성결함거부	10	10
알려진무결성경계 replay 허용 ^b	1	1
Adapter 커밋	1	7
기호 fallback	1	7
Adapter 실패	5	7
Manifest guard 거부	3	3

^a 경계허용은의미추출과정정책완결성한계를문서화하며 safety pass 가아니다.

^b Replay 는 repair 생성을인증하거나시실행하지않는다. ^c Loader 가이밀치를강제하므로측정값이아니라구성불변량이다. ^d Stage 8 이후의 parser 거부 parity 이며의미안전성증거가아니다.

사하므로, 결과는이함수가어떤 candidate field 를대입하는지에의해결정되는 oracle 상한이다. 따라서세 arm 은수리전략의비교가아니라제어흐름추적이다.

C. 무결성, 경계, 배정회계

현재명세가검출가능하다고지정한 10 개 fault fixture 는모두지정된검사연산에서거부됐다 (10/10). 이파일럿은안정적인typed detector code 까지대조하지않으므로 detector layer 귀속을입증하지않는다. 별도로, 동일하게기록된유효수리앞의무효선행후보를다른무효후보로치환하고체크섬을재계산한알려진 provenance 경계는예상대로재생을통과했다 (1/1 미검출). 따라서키없는체크섬을재계산할수있는작성자를방어하지 않으며, 재생은 repair 생성연산의출처를인증하지않는다. 열린경계 sentinel 두건—자연어 disclosure 미추출과 required object 의후보 · 정책동시누락—은 2/2 가의도대로인코딩상 허용됐고 safety pass 는 0 건이었다. 과거 unknown top-level field 허용경계는 Stage 8 이후단한음성회귀로재분류되었으며, 완전한 12-field candidate 에 unknown key 하나를추가한 fixture 를 proposal · replay parser 모두구체적으로거부했다 (1/1). 이는 parser rejection parity 이지의미안전성의증거가아니다. Adapter/accounting 7 개배정에서는 commit 1, 기호 fallback 1, adapter failure 5 었다. 합성 telemetry 필드는 2/7 배정에서채워져전파됐으며, 이는측정값이아니라회계필드전파확인이다. 배경 guard 3/3 가중복 · 누락을거부했다. 이수치는모두합성 offline fixture 의 raw count 다.

Godot 4.7.1 은보존한 *Scaled Lighthouse* 정식 trace 를 non-headless 1280×720 SubViewport 에서리플레이했다.




Fig. 4. 동결된 fixture 에서지정된검사연산과생성 table 로이어지는근거경계. 수치는생성산출물을통해서만반영한다.

Manifest 는각 PNG 를 event/delivery index, validation, state hash 에결합한다. 그림 5(b) 는변경전 hash 를보존하고, (c) 는 valid commit 뒤이를변경한다. 모든원본 panel 은생성자산이없는 primary-track render 이며, 아래 illustrative crop 은작성된 status/event callout 만확대한다.

선택 v5 packet 은하나의 scripted fixture 의 render/state 대응만확립하며 live model 또는 Python transport, participant 또는 player input, adaptation intervention, narrative-quality result 를추가하지않는다.




Fig. 5. 작성형 Godot render replay 에서 status/event 를확대한 illustrative crop 과 manifest metadata. 이 trace-bound 대응은 live transport, 성능, usability, immersion, efficacy 근거가아니다.

VII. 논의

A. 확립가능한범위

설계파일럿은동결된사례에대해서만 mechanism behavior 를확립할수있다. 인코딩된검사가상태를격리하는지, bounded repair 와 fallback 이선언경로를따르는지, 명명된 corruption 이지정된검사연산에서거부되는지, assigned row 가집계를위해 분류된상태로남는지를평가한다. 거부를안정적인 typed detector code 에귀속하지는않는다. 이는 authoring-time validation, continuous-integration regression, recorded-adapter test, engine 이전 replay inspection 에유용하다.

이 mechanism 은 policy 가올바르게작성되었는지, 자연어 fact 가완전하게추출되었는지, 의미적으로 unsafe 한모든 event 가 declared field 로표현되었는지를확립하지않는다. Key 없는 hash 도 writer 를인증하지않는다. Writer 는 single-process ownership 을가정하며 concurrent-writer safety 는 입증되지않았다. Versioned bridge 는 interface decoupling 이지 engine portability 또는 real-time performance 의근거가아니다.

B. 선행연구와의관계

TRACE-RPG 은 parsing 후 state-relative authorization 을적용하여 constrained decoder 를보완한다 [5], [6], [7]. 검색및메모리구성요소에는 commit authority 를부여하지않는다는점에서구별된다 [8], [9], [10]. 실행가능한환경과 benchmark 를대체하지않고보완한다 [1], [2], [22], [25]. Process-linked trace 는 AgentBoard 가강조한측정관심사를구현하지만 [23], TRACE-RPG 이해당시스템이나다른시스템보다우월하다는근거는아니다.

효능을검정할연구, 즉독립적으로 label 된 semantic oracle 과실제 blind-retry comparator 를갖춘사전등록다중모델비교, 인코딩된 validity 를맞춘 retrieval 및 memory ablation, 정당화된검정력과 mixed-effects 분석을갖춘 blinded matched-validity 인간연구는본논문의범위밖이며부분적으로도보고하지 않는다 [22], [31], [28], [36].

VIII. 타당성위험, 윤리, 산출물범위

Construct validity 는 declared field 에한정되며 encoded check 는누락된의미를발견할수없다. Internal validity 는독립적으로작성된 policy expectation 과 fixture leakage 부재에의존한다. External validity 는 offline text/mock case 에한정된다. Conclusion validity 는모집단추론없이 raw designed-case

count 를보고함으로써보호한다. Reproducibility 는 고정된 software 및 artifact version 에의존한다. Security validity 는 key 없는 content-integrity check 와 deterministic semantic replay 에한정되며 adversarial authentication 은아니다.

파일럿은 participant 또는 personal telemetry 를처리하지않는다. 향후 human 및 affect 연구에는해당 review, informed consent, compensation disclosure, minimization, retention/deletion rule, opt-out 이필요하다. LLM judge 를사용하더라도 automated 및 crowd judgement 모두 calibration 과 bias control 이필요하므로보조수단으로유지한다 [31], [32], [33], [34].

IX. 결론

TRACE-RPG 은작성된 candidate-event payload 를 encoded 기호 commit gate 를통해 canonical mutation 으로부터격리하고, linked record 와 state-semantic replay 로 terminal outcome 을감사가가능하게만든다. 결정론적오프라인파일럿은단일작성 world state 의동결된 fixture domain 에서구현 mechanism 에대한근거이지 cross-model superiority, player-experience benefit, retrieval 또는 memory effectiveness, affect efficacy, commercial-engine performance 의근거가아니다. 이질문들은명시적인확증확장으로남는다.

데이터및코드가용성

구현, 동결파일럿번들, fixture 및 assignment manifest, 생성결과조각, 빌드는심사용의명아카이브로제공하며 camera-ready 시 DOI 기반저장소로대체한다. 번들은산출물 32 개와 선언입력 14 개를포함하는 SHA-256 manifest 를갖는다. 다만 manifest 에기록된 provenance commit 은파일럿 runner 보다앞서며선언된모든입력을해석하지못한다. 모든입력이기록된 revision 에서해시일치하도록패킷을깨끗한커밋트리에서재생성중이다.

REFERENCES

- [1] M.-A. Côté, Á. Kádár, X. Yuan *et al.*, “TextWorld: A learning environment for text-based games,” in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75.
- [2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, “ScienceWorld: Is your agent smarter than a 5th grader?” in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298.

- [3] N. Weir, R. Thomas, R. d'Amore, K. Hill, B. Van Durme, and H. Jhamtani, "Ontologically faithful generation of non-player character dialogues," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242.
- [4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, "Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach," in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20.
- [5] S. Geng, M. Josifoski, M. Peyrard, and R. West, "Grammar-constrained decoding for structured NLP tasks without finetuning," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10932–10952.
- [6] L. Beurer-Kellner, M. Fischer, and M. Vechev, "Prompting is programming: A query language for large language models," *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023.
- [7] T. Scholak, N. Schucher, and D. Bahdanau, "PICARD: Parsing incrementally for constrained auto-regressive decoding from language models," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901.
- [8] X. He, Y. Tian, Y. Sun *et al.*, "G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132876–132907.
- [9] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, "HippoRAG: Neurobiologically inspired long-term memory for large language models," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59532–59569.
- [10] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, "Mem0: Building production-ready AI agents with scalable long-term memory," in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, peer-reviewed ECAI 2025 record; page range was not exposed by the accessible Crossref or publisher metadata at audit time.
- [11] J. S. Park, J. C. O'Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, "Generative agents: Interactive simulacra of human behavior," in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22.
- [12] Y. Shao, L. Li, J. Dai, and X. Qiu, "Character-LLM: A trainable agent for role-playing," in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13153–13187.
- [13] N. Akoury, Q. Yang, and M. Iyyer, "A framework for exploring player perceptions of LLM-generated dialogue in commercial video games," in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311.
- [14] M. Hochreiter, S. Kriglstein, and G. Wallner, "Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues," in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018.
- [15] M. Yin, H. Zu, W. Gu *et al.*, "How contextualized generative AI shapes player experience in games," *Entertainment Computing*, vol. 58, p. 101194, 2026, online record with a future issue assignment at the 2026-08-12 audit; issue metadata must be rechecked at submission.
- [16] V. Figueiredo and D. Elumeze, "Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue," 2025, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [17] G. N. Yannakakis and J. Togelius, "Experience-driven procedural content generation," *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011.
- [18] D. Melhart, D. Gravina, and G. N. Yannakakis, "Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch," in *International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10.
- [19] Z. Wang, Q. Guo, R. Singh, and X. Hu, "Do vision language models understand human engagement in games?" 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-12.
- [20] L. Fan, G. Wang, Y. Jiang *et al.*, "MineDojo: Building open-ended embodied agents with internet-scale knowledge," in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18343–18362.
- [21] D. Pérez-Liébana, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, "General video game AI: A multitask framework for evaluating agents, games, and content generation algorithms," *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019.
- [22] X. Liu, H. Yu, H. Zhang *et al.*, "AgentBench: Evaluating LLMs as agents," in *International Conference on Learning Representations*, 2024, pp. 52989–53046, peer-reviewed official proceedings record; no publisher DOI assigned.
- [23] C. Ma, J. Zhang, Z. Zhu *et al.*, "AgentBoard: An analytical evaluation board of multi-turn LLM agents," in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74325–74362.
- [24] X. Zhou, H. Zhu, L. Mathur *et al.*, "SOTOPIA: Interactive evaluation for social intelligence in language agents," in *International Conference on Learning Representations*, 2024, pp. 40975–41019, peer-reviewed official proceedings record; no publisher DOI assigned.
- [25] D. Paglieri, B. Cupial, S. Coward *et al.*, "BALROG: Benchmarking agentic LLM and VLM reasoning on games," in *International Conference on Learning Representations*, 2025, pp. 96666–96702, peer-reviewed official proceedings record; no publisher DOI assigned.
- [26] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, "Automated play-testing through RL-based human-like play-styles generation," *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022.
- [27] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, "IVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds," 2026, preprint; accepted/forthcoming at ICCV 2026, whose available pre-proceedings were explicitly non-archival and unpublished at retrieval time.
- [28] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, "Deep reinforcement learning at the edge of the statistical precipice," in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29304–29320, peer-reviewed official proceedings record; no publisher DOI assigned.
- [29] J. Pineau, P. Vincent-Lamarre, K. Sinha *et al.*, "Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program," *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021, peer-reviewed official journal article; no publisher DOI assigned.
- [30] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, "Towards the systematic reporting of the energy and carbon footprints of machine learning," *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020, peer-reviewed official journal article; no publisher DOI assigned.
- [31] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Krahmer, "Best practices for the human evaluation of automatically generated text," in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368.
- [32] M. Karpinska, N. Akoury, and M. Iyyer, "The perils of using Mechanical Turk to evaluate open-ended text generation," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285.
- [33] L. Zheng, W.-L. Chiang, Y. Sheng *et al.*, "Judging LLM-as-a-judge with MT-Bench and Chatbot Arena," in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46595–46623.
- [34] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, "Humans or LLMs as the judge? a study on judgement bias," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327.
- [35] D. Lakens, A. M. Scheel, and P. M. Isager, "Equivalence testing for psychological research: A tutorial," *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018.
- [36] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, "Random effects structure for confirmatory hypothesis testing: Keep it maximal," *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013.
- [37] M. O. Riedl, C. J. Saretto, and R. M. Young, "Managing interaction between users and agents in a multi-agent storytelling environment," in *Proceedings of the Second International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 2003, pp. 741–748.
- [38] R. E. Fikes and N. J. Nilsson, "STRIPS: A new approach to the application of theorem proving to problem solving," *Artificial Intelligence*, vol. 2, no. 3–4, pp. 189–208, 1971.
- [39] F. B. Schneider, "Enforceable security policies," *ACM Transactions on Information and System Security*, vol. 3, no. 1, pp. 30–50, 2000.
- [40] R. Evans and E. Short, "Versu—a simulationist storytelling system," *IEEE Transactions on Computational Intelligence and AI in Games*, vol. 6, no. 2, pp. 113–130, 2014, predecessor title of IEEE Transactions on Games.
- [41] S. G. Ware and C. Siler, "Sabre: A narrative planner supporting intention and deep theory of mind," in *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE)*, vol. 17, no. 1, 2021, pp. 99–106.