

TRACE-RPG: 감사가능한인터랙티브게임세계를위한 이벤트소싱신경-기호커밋게이트

익명저자

Abstract—대규모언어모델은표현력있는퀘스트와 NPC 대화를 생성할수있지만, 유창하거나스키마에맞는텍스트만으로제한이벤트의 실행가능성, 권한적합성, 정식게임상태와의일관성이성립하지않는다. 본논문은신뢰하지않는제한을상대변경으로부터격리하는이벤트소싱신경-기호제어기 TRACE-RPG 을제안한다. 알려진후보필드에 대한타입업격 parser, 외부에서공급되는행동정책, 결정론적상태상대술어가하드커밋게이트를구성하지만, 알수없는 candidate top-level field 는현재거부되지않고무시된다. 거부된후보에는제한된수리를위한구조화반례를제공할수있으며, 성공후보는변경직전에방어적으로재검증한다. 할당완전실행레코드는종단결과를키없는 SHA-256 무결성체크섬과연결하고, 의미적리플레이는인코딩된전이를재구성하며에피소드연속성검사는단절된이력을거부한다. 모질단추론대신의도적으로설계한결정론적오프라인적합성픽스처와오류주입으로구현을평가한다. 생성된파일럿산출물은정확한사례수, 상태격리결과, 수리경로, 지정연산의 fault 거부결과, 계수검사를보고한다. 근거범위는선언된구조화필드와시험된픽스처에한정되며, 수리생성의 provenance 를검증하거나실시간모델우월성, 플레이어효익, 감정효능, 검색효익, 상용엔진성능을입증하지않는다. 따라서 TRACE-RPG 은감사가능한트랜잭션프로토콜과후속확증게임 AI 연구를위한재현가능한기반을제공한다.

Index Terms—게임인공지능, 인터랙티브내러티브, 신경-기호시스템, 제약생성, 이벤트소싱, 재현성

I. 서론

인터랙티브생성은언어과제에그치지않는다. 후보이벤트가자연스러워도존재하지않는아이템을요구하거나, 화자가모르는사실을주장하거나, 금지된퀘스트정보를공개하거나, 허가되지않은효과를도입하거나, 퀘스트단계를후퇴시킬수있다. 실행가능한텍스트환경은그렇듯한발화와유효한전이의차이를명시한다 [1], [2]. 근거기반대화화개인화퀘스트시스템은퀘스트, 엔터티, 그래프맥락의가치를추가로보여주지만 [3], [4], 맥락자체가정식상태변경을승인하지는않는다.

구조적생성제약은인접한문제를해결한다. 문법제약디코딩, 언어모델질의언어, 점진파서는생성구조를제한할수있다 [5], [6], [7]. 그러나구문상허용되는이벤트도현재세계에대해서는거짓일수있다. 검색과메모리는유용한근거를공급할수있지만 [8], [9], [10], 검색된내용역시상태전이의권한주체가아니다.

본논문은이러한관심사를감사가능한트랜잭션프로토콜로결합한구현인 TRACE-RPG 을제시한다. 현재기여는다음과같다.

- 1) 정식상태, 외부공급행동정책, 후보이벤트, 실행레코드, 게임브리지에대한버전계약;
- 2) 결정론적상태상대검증, 제한된반례유도수리, 변경없는 fallback, 방어적커밋전검증;
- 3) 콘텐츠연결종단레코드, 상태의미적리플레이, 에피소드연속성검증; 그리고
- 4) 엄격한 adapter 경계, 동결된할당키, 구별되는종단실패 클래스, 기술적 treatment-policy 계수를갖춘오프라인 harness.

익명심사를위해제출된원고입니다.

실증의중심은설계된픽스처에대한결정론적적합성과일터이다. 실시간모델호출, 인간참여자, 감정추정, 검색실험, 실제엔진루프측정은없다. 계획된 10 개모델, 인간, 메모리, 감정, 엔진연구는향후확증확장이며현재결과가아니다.

II. 관련연구와연구공백

A. 인터랙티브내러티브와게임에이전트

KNUDGE 는퀘스트와엔터티명세에근거한분기형 NPC 대화를평가한다 [3]. 지식그래프보조퀘스트생성 [4], 메모리-성찰-계획에이전트 [11], 학습가능한역할연기에이전트 [12] 는근거성과개연성있는행동의상호보완적측면을다룬다. 플레이어대상연구는선호와지각된대화품질을평가한다 [13], [14]. Yin 등의 2026 년온라인레코드는서지감사당시미래시점의권호가배정되어있어제출시다시확인해야한다 [15]. 2025 년프리프린트는역할에따른안정성-즉흥성 trade-off 를보고하며 [16], 본논문은이를최근동기로만사용한다. 이연구들은하드허용가능성을선택적자연스러움및플레이어경험구성개념과분리할필요성을뒷받침한다.

경험주도콘텐츠생성 [17] 과관찰자표식참여도 [18] 는미래적응트랙의동기가된다. 최근프리프린트는 vision-language model 의참여도추론한계를보고한다 [19]. 따라서감정은비권위적맥락으로유지되며현재구현근거에는포함되지않는다.

B. 환경과벤치마크

TextWorld 와 ScienceWorld 는명시적인인터랙티브상태를제공하며 [1], [2], MineDojo 는개방형지식집약 embodied 과제를추가한다 [20]. General Video Game AI 는에이전트, 게임, 콘텐츠트랙을분리한다 [21]. AgentBench 는이질적인환경의에이전트를연구하고 [22], AgentBoard 는과정수준진단을추가하며 [23], SOTOPIA 는사회적상호작용을평가하고 [24], BALROG 는장기언어및시각게임추론을평가한다 [25]. 자동화된플레이스타일에이전트는상호보완적인시험선레이지만인간평가를대체하지않는다 [26]. 이벤치마크는미래평가설계에정보를주지만트랜잭션승인경계를규정하지는않는다.

C. 제약, 신경-기호검증, 검색

제약디코더는출력구조를개선한다 [5], [6], [7]. 반면 TRACE-RPG 은구조를독립적인상태상대승인의입력조건으로취급한다. 현재비아카이벌 ICCG 2026 자료와연계된프리프린트로인용되는 IVIE 는가장가까운최근게임특화신경-기호 비교대상이다 [27]. 이범위는필요한경계를강조한다. 즉, 기호적 유효성은인코딩된목표와술어에대해서만유효하다.

G-Retriever, HippoRAG, Mem0 는관련하위그래프검색과장기메모리를다루고 [8], [9], [10], Generative Agents 와 Character-LLM 은행동메모리와 persona 를다룬다 [11], [12]. TRACE-RPG 은향후이러한맥락을사용할수있지만직접적인커밋권한은부여하지않는다. 검색과시간적메모리효익은여기에서측정하지않는다.

D. 감사가능성과재현성

과정지표는 중간실패를보존할동기를제공하고 [23], 강건한 평가는소수확률적실행의과도한해석을경고한다 [28]. 재현성과 환경보고지침은동결된산출물과명시적측정경계를뒷받침한다 [29], [30]. 인간및 LLM 평가는구성개념, 평가자, 편향통제를요구하며 [31], [32], [33], [34], 향후비열등성과참여자분석에는정당화된 margin 과 random-effects 구조가필요하다 [35], [36].

제한된 novelty 는개별구성요소의발명이아니라구현된결합이다. 승인된 36 개문헌집합에서보고된시스템들은실행가능한 상태, 근거화, 구조제약, 기호검사, 검색, 메모리, 과정측정, 재현성의일부들다. 보고서에기능이없다고해서모든구현에그 기능이없다고추론하지않는다. TRACE-RPG 은외부공급정책 경계, 상태상대하드검증, 제한된수리, 수리이력과연결된종단근거, 의미적리플레이, 할당완전실패계수를통해이관심사를함께 노출한다.

III. 문제정의와보장경계

시점 t 에서정식상태는다음과같다.

$$c_t = (G_t, q_t, m_t), \quad (1)$$

여기서 G_t 는 typed world state 이고, q_t 는외부공급 action policy, 정식 disclosure set, quest-stage 제약을함께나타내며, m_t 는커밋된 event prefix 이다. 검색, 내러티브점수, 모델 rationale, 메모리요약, 미래의감정추정은비권위적 proposal context 이다.

신뢰하지않는 proposer 가후보 a_t 를출력한다. 알려진필드에대한타입엄격 parsing 이먼저선언스키마를확립하지만알수없는 candidate top-level field 는무시한다. validator 는다음을 반환한다.

$$V(c_t, a_t) = (v_{\text{policy}}, v_{\text{pre}}, v_{\text{reach}}, v_{\text{know}}, v_{\text{disc}}, v_{\text{quest}}, E_t), \quad (2)$$

여기서 E_t 는구조화오류집합이다. 상태변경은다음과같다.

$$c_{t+1} = \begin{cases} T(c_t, a_t), & \bigwedge_i v_i = 1, \\ c_t, & \text{그외.} \end{cases} \quad (3)$$

인코딩된도메인의명제는다음과같다. **P1 (소진실패불변성)**: 예산 K 까지어떤후보도검증을통과하지못하거나 proposal/controller 실행이 commit 전에실패하면반환상태는공급된 prior state 와같다. **P2 (제한된기록시도)**: 각 proposal 또는 repair callback 이별로강제된 deadline 안에반환한다면, repair budget $K \geq 0$ 은최대 $K + 1$ 개의 candidate attempt 를기록한다. 성공적인 commit 은변경직전수락후보에대한방어적 validation 을한번추가한다. **P3 (효과권한)**: 수락후보는 ActionPolicy.allowed_effects 밖의선언된 fact effect 를 CandidateAction.effects 에포함하지않으며, quest-stage target 도해당 policy 에의해명시적으로승인된다. **P4 (상태의의미적리플레이)**: 스키마와결정론적전이가고정되면수락된 trace 는명시된 terminal state 를재구성한다.

이명제들은올바른정책작성, 선언된후보필드로의완전하고충실한추출, 결정론적소프트웨어버전, 단일프로세스파일소유권을가정한다. 상태의의미적리플레이는기록된구조화후보와전이를재검증하지만, 중간수리의 provenance, reasoning, prompt, 확률적생성은재현하거나검증하지 않는다. 구조화필드에서누락된자연어함의는보장범위밖이다.




Fig. 1. 신뢰경계. 검색맥락과생성후보는알려진필드의타입검사와상태상대 validation 이완료될때까지비권위적이다.

TABLE I
인코딩된 VALIDATOR 경계

술어	거부대상	실패시상태
Action policy	알수없는 action/type	변경없음
Precondition	누락/거짓 requirement	변경없음
Reachability	접근불가 object	변경없음
NPC knowledge	선언되지않은 known fact	변경없음
Disclosure	forbidden fact	변경없음
Quest	부적격/후퇴 stage	변경없음

IV. TRACE-RPG 아키텍처와알고리즘

A. 신뢰경계와계약

그림 1는모델또는 recorded adapter 를 canonical owner 밖에둔다. Parser 는알려진필드의의도호환숫자또는 collection type 을거부하지만알수없는 candidate top-level field 는무시한다. action policy 는 candidate 와별도로공급되며 required precondition 과 allowed effect 를정의한다. bridge 는 commit 이후에만 versioned event 를 export 한다. 이는 interface 를 분리하지만상용엔진으로의 portability 를아직입증하지않는다.

B. Validate-Repair-Commit

제어기는다음과같은추가패키지없는의사코드를실행한다. “Record” 는 in-memory trace 표현에추가하는것을뜻하며, 영속쓰기는중단일관성검사뒤에만수행한다.

구조화반례는 repair callback 에 error code 를노출한다. repair 는상태를직접변경하지않으며, 예산소진시변경없는결정론적 fallback 을반환한다. 그림 3는중단경로를나타낸다.

C. 무결성, 의미적리플레이, 계수

각 result row 는키없는 SHA-256 무결성체크섬을가지며, proposal outcome 은추가로 trace checksum 과연결된다. 이 hash 들은우발적이거나시험대상인콘텐츠변경을탐지하지만 signature, message-authentication code, writer identity 가 아니며콘텐츠와 checksum 을모두다시쫓수있는행위자에대한 보호도아니다. 의미적리플레이는 prior state 와기록된모든 candidate/validation pair 를엄격히 parsing 하고, final 이아닌모든 attempt 가 invalid 임을요구하며, terminal transition 을제재산하고, 명시된 final state 와비교함으로써 byte 무결성을넘어선다. Episode replay 는인접 JSONL record 사이의의상태연속성도요구한다. Replay 는 candidate $j + 1$ 을만든 repair-generation 단계를인증하거나시행하지않는다.

Terminal record class 는 commit, symbolic fallback, adapter failure, controller failure 이다. Controller-failure

```

1:  $a \leftarrow \text{PROPOSE}(c); j \leftarrow 0$ 
2: repeat
3:    $(ok, E) \leftarrow V(c, a); \text{RECORD}(a, E)$ 
4:   if  $ok$  then
5:     assert  $V(c, a).ok$ ; return  $\text{COMMIT}(c, a)$ 
6:     if  $j = K$  then return  $\text{FALLBACK}(c)$ 
7:      $a \leftarrow \text{REPAIR}(c, a, E); j \leftarrow j + 1$ 
8: until terminal

```

Fig. 2. Validate-repair-commit 절차. 최대 $K + 1$ 개의 candidate attempt 를 기록하며, 성공경로는 상태변경전방어적 validation 을 수행한다.




Fig. 3. Proposal, validation, 제한된 repair, fallback, commit, replay 상태. Controller failure 는 중단상태이며 완성된 proposal trace 가 없을 수 있다.

row 는 동결된 assignment denominator 에 남고 상태를 변경하지 않지만, candidate outcome 이 생성되지 않았다면 완성된 proposal trace 가 없어진다. 따라서 result completeness 가 모든 terminal row 의 trace 존재를 뜻하지 않는다. 실행 전 assignment key 는 (run, arm, scenario, seed, model, revision, $h_{\text{controller}}$, h_{input} , h_{prior}) 이다. 집계는 중복, 누락, 예기치 않은 key 를 거부하고 symbolic, adapter, controller failure 를 각각 보고한다.

V. 결정론적 오프라인 파일럿 방법

A. 질문과 설계 픽처

파일럿은 다음을 묻는다. (PQ1) 유효 후보는 commit 되고 명명된 invalid-policy 사례는 변경 없이 유지되는가? (PQ2) 작성된 repairable 및 irreparable 사례에서 rejection-only, unchanged retry, structured repair 가 예상 결과를 만드는가? (PQ3) 동결된 checksum, state-semantic, linkage, continuity mutation 이 지정된 검사 연산에서 거부되고, 두 번째 파일 append 의 주입된 실패가 예상 pair-write rollback 검사를 작동시키는가? (PQ4) 엄격한 adapter 와 assignment manifest 가 할당 사례마다 정확히 하나의 분류된 terminal row 를 유지하거나 fail closed 하는가?

사례는 의도적으로 설계된 적합성 픽처이며 모델 또는 게임 모 집단의 표본이 아니다. 네도메인은 validator/state isolation, repair control flow, record/trace fault injection, adapter/accounting contract 이다. 반복된 결정론적 seed 가 아니라고 유사 사례가 기술적 denominator 를 구성한다. 모든 기대 값은 실행 전에 명시한다.

B. 측정치와 재현성

측정치는 정확한 count 이다. expected/observed validator-class agreement, rejected 또는 controller-failure 사례의

TABLE II
결정론적 수리 ARM 결과

Arm	사례	커밋	수리 호출
거부 전용	2	0	0
동일 후보 재 시도	2	0	2
구조화 수리	2	1	2

state mutation, repair arm 과 repairability 별 commit 및 attempt 결과, 지정된 연산에서 거부된/사전 명세된 detectable fault, replayed/committed trace, rejected/injected manifest violation 을 센다. Exception class 만으로 안정적 인 detector layer 를 식별할 수 없으므로 detector 귀속 결과는 보고하지 않는다. 의도적으로 설계된 픽처에 p -value 나 모 집단 confidence interval 을 부여하지 않는다. Recorded response 의 provider-response latency 는 response 수신 조건으로 하는 과거 fixture metadata 이며, local adapter timing 은 end-to-end game latency 가 아니다.

릴리스 패키트는 fixture 및 assignment manifest, schema, outcome/trace record 를 포함한 result JSON 산출물, 환경과 코드 revision, 생성 table, checksum 을 동결한다. 보고는 재현성과 측정 경계 지침을 따른다 [29], [30].

VI. 파일럿 결과

A. 구조 필드 게이트 적합성

동결된 13 개 게이트 fixture (유효 control 1 개와 고립된 음성 fixture 12 개) 는 모두 사전 명세 결과와 일치했다 (13/13). 구현된 유류 코드 12 종이 각각 관찰됐고, 비 commit 경로는 전체 정준 상태를 유지했다. 이 일치는 저자가 설계한 구조 필드 oracle 에 대한 구현 적합성이며 독립의 미판정의 정확도가 아니다.

B. 수리 메커니즘

처음부터 유효하지 않은 두 case 에서 rejection-only 와 동일 후보 retry 는 각각 0/2 commit 이었다. 구조화 수리는 수리가 능 precondition case 를 1 회 수리 후 commit 했고 수리 불가능 reachability case 는 fallback 하여 1/2 commit 이었다. 이는 결정론적 callback 의 제어 흐름 sanity check 이며 LLM 수리 품질이나 sample efficiency 비교가 아니다.

C. 무결성, 경계, 배정 회계

현재 명세가 검출 가능하다고 지정한 10 개 fault fixture 는 모두 지정된 검사 연산에서 거부됐다 (10/10). 이 파일럿은 안정적 인 typed detector code 까지 대조하지 않으므로 detector layer 귀속을 입증하지 않는다. 별도로, 동일하게 기록된 유효 수리 앞의 무효 선행 후보를 다른 무효 후보로 치환하고 체크섬을 재계산한 알려진 provenance 경계는 예상대로 재생을 통과했다 (1/1 미검출). 따라서 키 없는 체크섬을 재계산할 수 있는 작성자를 방어하지 않으며, 재생은 repair 생성 연산의 출처를 인증하지 않는다. 세 경계 sentinel—자연어 disclosure 미추출, required object 의 후보 · 정책 동시 누락, 알 수 없는 candidate top-level field 무시—은 3/3 가 의도대로 인코딩 상용됐고 safety pass 는 0 건 이었다. Adapter/accounting 7 개 배정에서는 commit 1, 기호 fallback 1, adapter failure 5 였으며, provider 응답 관측은 2/7 이었다. 배정 guard 3/3 가 중복 · 누락을 거부했다. 이 수치는 모두 합성 offline fixture 의 raw count 다.

TABLE III
동결파일럿원시집계

검사	분자	분모
게이트 fixture 일치	13	13
알려진경계허용 ^a	3	3
탐지가능무결성결함거부	10	10
알려진무결성경계 replay 허용 ^b	1	1
Adapter 커밋	1	7
기호 fallback	1	7
Adapter 실패	5	7
Manifest guard 거부	3	3

^a 경계허용은의미추출, 정책완결성, 알수없는필드처리의한계를문서화하며 safety pass 가아니다. ^b Replay 는 repair 생성을인증하거나다시실행하지않는다.




Fig. 4. 동결된 fixture 에서지정된검사연산과생성 table 로이어지는근거경계. 수치는생성산출물을통해서만명한다.

생성수치와무관하게이파일럿에는 live model call, participant, affect prediction, retrieval 또는 memory intervention, narrative-quality comparison, 실제 game-engine loop 가없다. 범위는구현된 structured transition 과 evidence path 의 적합성이다.

VII. 논의

A. 확립가능한범위

설계파일럿은동결된사례에대해서만 mechanism behavior 를확립할수있다. 인코딩된검사가상태를격리하는지, bounded repair 와 fallback 이선언경로를따르는지, 명명된 corruption 이지정된검사연산에서거부되는지, assigned row 가집계를위해 분류된상태로남는지를평가한다. 거부불안정적인 typed detector code 에귀속하지않는다. 이는 authoring-time validation, continuous-integration regression, recorded-adapter test, engine 이전 replay inspection 에유용하다.

이 mechanism 은 policy 가올바르게작성되었는지, 자연어 fact 가완전하게추출되었는지, 의미적으로 unsafe 한모든 event 가 declared field 로표현되었는지를확립하지않는다. Key 없는 hash 도 writer 를인증하지않는다. Writer 는 single-process ownership 을가정하며 concurrent-writer safety 는 입증되지않았다. Versioned bridge 는 interface decoupling 이지 engine portability 또는 real-time performance 의근거가아니다.

B. 선행연구와의관계

TRACE-RPG 은 parsing 후 state-relative authorization 을적용하여 constrained decoder 를보완한다 [5], [6], [7]. 검색및메모리구성요소에는 commit authority 를부여하지않는다는점에서구별된다 [8], [9], [10]. 실행가능한환경과 benchmark

를대체하지않고보완한다 [1], [2], [22], [25]. Process-linked trace 는 AgentBoard 가강조한측정관심사를구현하지만 [23], TRACE-RPG 이해당시스템이나다른시스템보다우월하다는근거는아니다.

VIII. 확증확장

향후사전등록연구는동결된모델 instance 10 개를선별하고소규모 panel 을승격해 controller 를비교한다. 독립적으로 label 된 semantic oracle 을사용하고, 실제 blind-retry comparator 를구현하고, attempt 별 token 과 latency 를기록하고, timeout 및 parse failure 를 treatment-policy estimand 에유지해야한다. Hardware/access profile 마다한 instance 만 승격하면결과는 instance 수준에머물며 scale 또는 access effect 를식별하지못한다 [21], [22], [25], [28].

Retrieval 및 memory ablation 은인코딩된 validity 를맞춘 상태에서 graph 및 conversational-memory context 를비교한다 [8], [9], [10]. 별도의 matched-validity human study 에는 ethics review, player-qualified rater, blinding, randomized order, attention check, reliability, prospective power, 정당화된 mixed-effects analysis 가필요하다 [13], [31], [32], [36]. Affect estimate 는선택적이고비권위적으로유지하며 validity non-inferiority margin 에는독립적인근거가필요하다 [17], [18], [19], [35].

IX. 타당성위험, 윤리, 산출물범위

Construct validity 는 declared field 에한정되며 encoded check 는누락된의미를발견할수없다. Internal validity 는독립적으로작성된 policy expectation 과 fixture leakage 부재에의존한다. External validity 는 offline text/mock case 에한정된다. Conclusion validity 는모집단추론없이 raw designed-case count 를보고함으로써보호한다. Reproducibility 는고정된 software 및 artifact version 에의존한다. Security validity 는 key 없는 content-integrity check 와 deterministic semantic replay 에한정되며 adversarial authentication 은아니다.

파일럿은 participant 또는 personal telemetry 를처리하지않는다. 향후 human 및 affect 연구에는해당 review, informed consent, compensation disclosure, minimization, retention/deletion rule, opt-out 이필요하다. LLM judge 를사용하더라도 automated 및 crowd judgement 모두 calibration 과 bias control 이필요하므로보조수단으로유지한다 [31], [32], [33], [34].

X. 결론

TRACE-RPG 은작성된 candidate-event payload 를 encoded neuro-symbolic commit gate 를통해 canonical mutation 으로부터격리하고, linked record 와 state-semantic replay 로 terminal outcome 을감사가가능하게만든다. 결론론적 오프라인파일럿은동결된 fixture domain 의구현 mechanism 에대한근거이지 cross-model superiority, player-experience benefit, retrieval 또는 memory effectiveness, affect efficacy, commercial-engine performance 의근거가아니다. 이질문들은명시적인확증확장으로남는다.

REFERENCES

- [1] M.-A. Côté, Á. Kádár, X. Yuan, B. Kybartas, T. Barnes, E. Fine, J. Moore, M. Hausknecht, L. El Asri, M. Adada, W. Tay, and A. Trischler, “TextWorld: A learning environment for text-based games,” in *Computer Games*, ser. Communications in Computer and Information Science. Springer International Publishing, 2019, vol. 1017, pp. 41–75. [Online]. Available: https://doi.org/10.1007/978-3-030-24337-1_3
- [2] R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu, “ScienceWorld: Is your agent smarter than a 5th grader?” in *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2022, pp. 11 279–11 298. [Online]. Available: <https://doi.org/10.18653/v1/2022.emnlp-main.775>
- [3] N. Weir, R. Thomas, R. d’Amore, K. Hill, B. Van Durme, and H. Jhamtani, “Ontologically faithful generation of non-player character dialogues,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 9212–9242. [Online]. Available: <https://doi.org/10.18653/v1/2024.emnlp-main.520>
- [4] T. Ashby, B. K. Webb, G. Knapp, J. Searle, and N. Fulda, “Personalized quest and dialogue generation in role-playing games: A knowledge graph- and language model-based approach,” in *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. ACM, 2023, pp. 1–20. [Online]. Available: <https://doi.org/10.1145/3544548.3581441>
- [5] S. Geng, M. Josifoski, M. Peyrard, and R. West, “Grammar-constrained decoding for structured NLP tasks without finetuning,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 10 932–10 952. [Online]. Available: <https://doi.org/10.18653/v1/2023.emnlp-main.674>
- [6] L. Beurer-Kellner, M. Fischer, and M. Vechev, “Prompting is programming: A query language for large language models,” *Proceedings of the ACM on Programming Languages*, vol. 7, no. PLDI, pp. 1946–1969, 2023. [Online]. Available: <https://doi.org/10.1145/3591300>
- [7] T. Scholak, N. Schucher, and D. Bahdanau, “PICARD: Parsing incrementally for constrained auto-regressive decoding from language models,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 9895–9901. [Online]. Available: <https://doi.org/10.18653/v1/2021.emnlp-main.779>
- [8] X. He, Y. Tian, Y. Sun, N. V. Chawla, T. Laurent, Y. LeCun, X. Bresson, and B. Hooi, “G-Retriever: Retrieval-augmented generation for textual graph understanding and question answering,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 132 876–132 907. [Online]. Available: <https://doi.org/10.52202/079017-4224>
- [9] B. Jiménez Gutiérrez, Y. Shu, Y. Gu, M. Yasunaga, and Y. Su, “HippoRAG: Neurobiologically inspired long-term memory for large language models,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 59 532–59 569. [Online]. Available: <https://doi.org/10.52202/079017-1902>
- [10] P. Chhikara, D. Khant, S. Aryan, T. Singh, and D. Yadav, “Mem0: Building production-ready AI agents with scalable long-term memory,” in *ECAI 2025*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, peer-reviewed ECAI 2025 record; page range was not exposed by the accessible Crossref or publisher metadata at audit time. [Online]. Available: <https://doi.org/10.3233/FAIA251160>
- [11] J. S. Park, J. C. O’Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein, “Generative agents: Interactive simulacra of human behavior,” in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*. ACM, 2023, pp. 1–22. [Online]. Available: <https://doi.org/10.1145/3586183.3606763>
- [12] Y. Shao, L. Li, J. Dai, and X. Qiu, “Character-LLM: A trainable agent for role-playing,” in *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2023, pp. 13 153–13 187. [Online]. Available: <https://doi.org/10.18653/v1/2023.emnlp-main.814>
- [13] N. Akoury, Q. Yang, and M. Iyyer, “A framework for exploring player perceptions of LLM-generated dialogue in commercial video games,” in *Findings of the Association for Computational Linguistics: EMNLP 2023*. Association for Computational Linguistics, 2023, pp. 2295–2311. [Online]. Available: <https://doi.org/10.18653/v1/2023.findings-emnlp.151>
- [14] M. Hochreiter, S. Kriglstein, and G. Wallner, “Beyond pre-defined scripts: Player perceptions on generative non-player character dialogues,” in *Proceedings of the 31st International Conference on Intelligent User Interfaces*. ACM, 2026, pp. 2004–2018. [Online]. Available: <https://doi.org/10.1145/3742413.3789221>
- [15] M. Yin, H. Zu, W. Gu, Z. Wang, W. She, Y. Cai, P. Hui, and T. Zuo, “How contextualized generative AI shapes player experience in games,” *Entertainment Computing*, vol. 58, p. 101194, 2026, online record with a future issue assignment at the 2026-08-12 audit; issue metadata must be rechecked at submission. [Online]. Available: <https://doi.org/10.1016/j.entcom.2026.101194>
- [16] V. Figueiredo and D. Elumzeze, “Symbolically scaffolded play: Designing role-sensitive prompts for generative NPC dialogue,” 2025, preprint; no archival venue or publisher DOI verified as of 2026-08-12. [Online]. Available: <https://arxiv.org/abs/2510.25820>
- [17] G. N. Yannakakis and J. Togelius, “Experience-driven procedural content generation,” *IEEE Transactions on Affective Computing*, vol. 2, no. 3, pp. 147–161, 2011. [Online]. Available: <https://doi.org/10.1109/T-AFFC.2011.6>
- [18] D. Melhart, D. Gravina, and G. N. Yannakakis, “Moment-to-moment engagement prediction through the eyes of the observer: PUBG streaming on Twitch,” in *International Conference on the Foundations of Digital Games*. ACM, 2020, pp. 1–10. [Online]. Available: <https://doi.org/10.1145/3402942.3402958>
- [19] Z. Wang, Q. Guo, R. Singh, and X. Hu, “Do vision language models understand human engagement in games?” 2026, preprint; no archival venue or publisher DOI verified as of 2026-08-12. [Online]. Available: <https://arxiv.org/abs/2603.18480>
- [20] L. Fan, G. Wang, Y. Jiang, A. Mandelkar, Y. Yang, H. Zhu, A. Tang, D.-A. Huang, Y. Zhu, and A. Anandkumar, “MineDojo: Building open-ended embodied agents with internet-scale knowledge,” in *Advances in Neural Information Processing Systems*, vol. 35. Neural Information Processing Systems Foundation, 2022, pp. 18 343–18 362. [Online]. Available: <https://doi.org/10.52202/068431-1333>
- [21] D. Pérez-Liébaná, J. Liu, A. Khalifa, R. D. Gaina, J. Togelius, and S. M. Lucas, “General video game AI: A multitask framework for evaluating agents, games, and content generation algorithms,” *IEEE Transactions on Games*, vol. 11, no. 3, pp. 195–214, 2019. [Online]. Available: <https://doi.org/10.1109/TG.2019.2901021>
- [22] X. Liu, H. Yu, H. Zhang, Y. Xu, X. Lei, H. Lai, Y. Gu, H. Ding, K. Men, K. Yang, S. Zhang, X. Deng, A. Zeng, Z. Du, C. Zhang, S. Shen, T. Zhang, Y. Su, H. Sun, M. Huang, Y. Dong, and J. Tang, “AgentBench: Evaluating LLMs as agents,” in *International Conference on Learning Representations*, 2024, pp. 52 989–53 046, peer-reviewed official proceedings record; no publisher DOI assigned. [Online]. Available: https://proceedings.iclr.cc/paper_files/paper/2024/hash/e9df36b21ff4ee211a8b71ee8b7e9f57-Abstract-Conference.html
- [23] C. Ma, J. Zhang, Z. Zhu, C. Yang, Y. Yang, Y. Jin, Z. Lan, L. Kong, and J. He, “AgentBoard: An analytical evaluation board of multi-turn LLM agents,” in *Advances in Neural Information Processing Systems*, vol. 37. Neural Information Processing Systems Foundation, 2024, pp. 74 325–74 362. [Online]. Available: <https://doi.org/10.52202/079017-2365>
- [24] X. Zhou, H. Zhu, L. Mathur, R. Zhang, H. Yu, Z. Qi, L.-P. Morency, Y. Bisk, D. Fried, G. Neubig, and M. Sap, “SOTOPIA: Interactive evaluation for social intelligence in language agents,” in *International Conference on Learning Representations*, 2024, pp. 40 975–41 019, peer-reviewed official proceedings record; no publisher DOI assigned. [Online]. Available: https://proceedings.iclr.cc/paper_files/paper/2024/hash/b3075b88e583a0e98d8b24338a613060-Abstract-Conference.html

- [25] D. Paglieri, B. Cupiał, S. Coward, U. Piterbarg, M. Wołczyk, A. Khan, E. Pignatelli, Ł. Kuciński, L. Pinto, R. Fergus, J. Foerster, J. Parker-Holder, and T. Rocktäschel, “BALROG: Benchmarking agentic LLM and VLM reasoning on games,” in *International Conference on Learning Representations*, 2025, pp. 96 666–96 702, peer-reviewed official proceedings record; no publisher DOI assigned. [Online]. Available: https://proceedings.iclr.cc/paper_files/paper/2025/hash/f0b1515be276f6ba82b4f2b25e50bef0-Abstract-Conference.html
- [26] P. Le Pelletier de Woillemont, R. Labory, and V. Corruble, “Automated play-testing through RL-based human-like play-styles generation,” *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, vol. 18, no. 1, pp. 146–154, 2022. [Online]. Available: <https://doi.org/10.1609/aiide.v18i1.21958>
- [27] M. Vaucher, S. Silveira, S. Góngora, and L. Chiruzzo, “IVIE: A neuro-symbolic approach to incremental and validated generation of interactive fiction worlds,” 2026, preprint; accepted/forthcoming at ICCV 2026, whose available pre-proceedings were explicitly non-archival and unpublished at retrieval time. [Online]. Available: <https://arxiv.org/abs/2606.13348>
- [28] R. Agarwal, M. Schwarzer, P. S. Castro, A. Courville, and M. G. Bellemare, “Deep reinforcement learning at the edge of the statistical precipice,” in *Advances in Neural Information Processing Systems*, vol. 34. Curran Associates, Inc., 2021, pp. 29 304–29 320, peer-reviewed official proceedings record; no publisher DOI assigned. [Online]. Available: <https://proceedings.neurips.cc/paper/2021/hash/f514cec81cb148559cf475e7426eed5e-Abstract.html>
- [29] J. Pineau, P. Vincent-Lamarre, K. Sinha, V. Larivière, A. Beygelzimer, F. d’Alché Buc, E. Fox, and H. Larochelle, “Improving reproducibility in machine learning research: A report from the NeurIPS 2019 reproducibility program,” *Journal of Machine Learning Research*, vol. 22, no. 164, pp. 1–20, 2021, peer-reviewed official journal article; no publisher DOI assigned. [Online]. Available: <https://jmlr.org/papers/v22/20-303.html>
- [30] P. Henderson, J. Hu, J. Romoff, E. Brunskill, D. Jurafsky, and J. Pineau, “Towards the systematic reporting of the energy and carbon footprints of machine learning,” *Journal of Machine Learning Research*, vol. 21, no. 248, pp. 1–43, 2020, peer-reviewed official journal article; no publisher DOI assigned. [Online]. Available: <https://jmlr.org/papers/v21/20-312.html>
- [31] C. van der Lee, A. Gatt, E. van Miltenburg, S. Wubben, and E. Krahmer, “Best practices for the human evaluation of automatically generated text,” in *Proceedings of the 12th International Conference on Natural Language Generation*. Association for Computational Linguistics, 2019, pp. 355–368. [Online]. Available: <https://doi.org/10.18653/v1/W19-8643>
- [32] M. Karpinska, N. Akoury, and M. Iyyer, “The perils of using Mechanical Turk to evaluate open-ended text generation,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 1265–1285. [Online]. Available: <https://doi.org/10.18653/v1/2021.emnlp-main.97>
- [33] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica, “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” in *Advances in Neural Information Processing Systems*, vol. 36. Neural Information Processing Systems Foundation, 2023, pp. 46 595–46 623. [Online]. Available: <https://doi.org/10.52202/075280-2020>
- [34] G. H. Chen, S. Chen, Z. Liu, F. Jiang, and B. Wang, “Humans or LLMs as the judge? a study on judgement bias,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2024, pp. 8301–8327. [Online]. Available: <https://doi.org/10.18653/v1/2024.emnlp-main.474>
- [35] D. Lakens, A. M. Scheel, and P. M. Isager, “Equivalence testing for psychological research: A tutorial,” *Advances in Methods and Practices in Psychological Science*, vol. 1, no. 2, pp. 259–269, 2018. [Online]. Available: <https://doi.org/10.1177/2515245918770963>
- [36] D. J. Barr, R. Levy, C. Scheepers, and H. J. Tily, “Random effects structure for confirmatory hypothesis testing: Keep it maximal,” *Journal of Memory and Language*, vol. 68, no. 3, pp. 255–278, 2013. [Online]. Available: <https://doi.org/10.1016/j.jml.2012.11.001>